

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 03 - 2S2025 - 08/10/2025

Introdução

Nesta atividade vocês irão trabalhar com modelos de regressão linear múltipla.

Atividade

A Organização Mundial de Saúde quer verificar quais fatores influenciam a expectativa de vida. Observou-se que nos últimos 15 anos houve um enorme desenvolvimento no sector da saúde, resultando na melhoria das taxas de mortalidade humana, especialmente nas nações em desenvolvimento, em comparação com os últimos 30 anos. Portanto, neste projeto estão sendo considerados dados dos anos de 2000 a 2015 para 193 países para uma análise mais aprofundada. As variáveis preditoras representam diversos grupos de fatores, ou seja, fatores econômicos e sociais além de fatores relacionados à imunização e mortalidade.

O conjunto de dados completo está no site Kaggle > DataSets > Life Expectancy (WHO), mas nós iremos trabalhar com um subconjunto desses dados (arquivo `LifeExpectancyModificado.csv`) que compreende 2095 observações e 11 variáveis preditoras (renomeadas), descritas a seguir:

- **LifeExp**: expectativa de vida (em anos)
- **Developed**: Status do país (Yes = Desenvolvido ou No = em desenvolvimento)
- **Mortality**: taxa de mortalidade para adultos entre 15 e 60 anos
- **BMI**: Índice de Massa Corporal da população
- **Alcohol**: consumo de álcool per capita (em litros)
- **Polio**: cobertura de imunização para Polio entre crianças
- **HIV**: Mortes por HIV/AIDS por 1000 nascidos vivos
- **GDP**: Produto Interno Bruto per capita (em Dólares USD)
- **IDHComp**: IDH em termos de composição do rendimento dos recursos
- **School**: Anos de escolaridade
- **InfantDeaths**: número de mortes infantis por 1000 habitantes
- **Population**: População do país (em milhões de habitantes)

O interesse está em determinar quais fatores estão relacionados à expectativa de vida e você é o Estatístico que irá analisar estes dados.

Leia o conjunto de dados no R, como a seguir, e visualize as primeiras observações. Verifique se as colunas estão no formato correto.

```
# Lendo o conjunto de dados
dados = read_csv("LifeExpectancyModificado.csv", show_col_types = FALSE)
# Encontramos algumas observacoes com IDHComp = 0
# o que nao e muito aderente com a relidade
# por isso optamos por filtrar e trazer somente dados com IDHComp > 0
```

```
dados %<>%
  filter(IDHComp > 0)

dados_contínuos <- dados[,sapply(dados, is.numeric)]
```

- 1) Faça o gráfico de dispersão entre todas as variáveis contínuas do conjunto de dados e calcule a correlação entre elas. Comente.




Figure 1: Matriz de dispersão - Questão 1

```
ggsave("matriz_dispersao.png", width = 12, height = 10, dpi = 300)

# Criando o gráfico de dispersão entre todas as variáveis contínuas do conjunto de dados
ggpairs(
  dados_contínuos,
  #title = "Matriz de dispersão entre variáveis contínuas",
  upper = list(continuous = wrap("cor", size = 4, color = "black")),
  lower = list(continuous = wrap("points", alpha = 0.5, size = 2, color = "#2C7BB6")),
  diag = list(continuous = wrap("densityDiag", fill = "#ABD9E9"))
) +
  theme_bw(base_size = 12) + # aumentei base_size (antes era 10)
```

```

theme(
  plot.title = element_text(size = 18, face = "bold", hjust = 0.5),
  strip.text = element_text(size = 11, face = "bold"),
  axis.text.x = element_text(size = 8, angle = 45, hjust = 1),
  axis.text.y = element_text(size = 8),
  panel.grid.major = element_blank(),
  panel.grid.minor = element_blank(),
  panel.background = element_rect(fill = "white", color = "gray90"),
  plot.background = element_rect(fill = "white", color = NA)
)

```

Uma matriz de correlação é uma tabela que mostra os coeficientes de correlação entre várias variáveis
Cada elemento da matriz representa a correlação entre duas variáveis. O coeficiente de correlação é u

Propriedades da Matriz de Correlação

Simétrica: A matriz é simétrica em relação à diagonal principal. Isso porque a correlação entre a var
X e Y é a mesma entre Y e X

$Cor(X, Y) = Cor(Y, X)$


Diagonal Principal: Os elementos da diagonal principal são sempre 1, pois uma variável é perfeitament

```

matriz_cor <- round(cor(dados_continuos), 2)
ggcorrplot(
  method = "square",
  show.diag = TRUE,
  matriz_cor,
  type = "upper",
  lab = TRUE,
  lab_size = 2.5,
  tl.cex = 12,
  tl.srt = 45,
  digits = 2,
  colors = cores_base,
  outline.color = "black",
  title = "Matriz de Correlação"
) +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", color = "#1A4A7A"),
  axis.text.x = element_text(angle = 45, hjust = 1)
)

```

Matriz de Correlação



```
corX1_X2 = round(cor(dados$IDHComp,dados$School),2)
```

Seleção de Preditores para a Variável Resposta LifeExp

Com base na análise da matriz de dispersão e da matriz de correlação, identificamos os preditores que apresentam as maiores correlações com a variável resposta LifeExp.

IDHComp: Correlação de 0,89 com LifeExp, indicando uma relação linear positiva muito forte. Isso era esperado, uma vez que o IDHComp é uma medida que sintetiza dimensões como saúde, educação e renda, diretamente relacionadas à expectativa de vida.

School: Correlação de 0,78 com LifeExp, também uma relação positiva forte. A educação é um determinante social da saúde, e maior escolaridade está associada a melhores condições de vida e, consequentemente, maior longevidade.

Mortality: Correlação de -0,69 com LifeExp. Essa forte relação negativa é coerente com a realidade, pois quanto menor a mortalidade, maior a expectativa de vida. A mortalidade é um indicador inverso à sobrevivência e, portanto, deve se relacionar negativamente com a expectativa de vida.

Relação entre os Preditores e Multicolinearidade Além das correlações com a variável resposta, observamos uma correlação muito alta entre os dois principais preditores positivos, **School e IDHComp**, com valor de **0.93**. Essa alta correlação indica que esses dois preditores compartilham muita informação em comum.

- 2) Defina algum critério e escolha dois preditores contínuos, denominados X_1 e X_2 . Ajuste um modelo de regressão linear simples de Y com cada um dos preditores X_1 e X_2 , separadamente. Interprete os coeficientes.

- 3) Ajuste um modelo de regressão linear múltipla usando X_1 e X_2 como preditores, ou seja,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i.$$

Reporte as estimativas dos coeficientes e interprete-os. Qual é função de regressão estimada?

- 4) Para entender melhor o significado de β_1 no modelo de regressão linear múltipla, execute os passos a seguir:
- Calcule a correlação entre X_1 e X_2 .
 - Faça um gráfico de dispersão de Y versus X_1 , com as cores de acordo com os níveis de X_2 .
 - Remova o efeito de X_2 da variável resposta Y . Para isso, faça a regressão de Y em X_2 e guarde os resíduos $e_{y|x_2}$.
 - Remova o efeito de X_2 da variável preditora X_1 . Para isso, faça a regressão de X_1 em X_2 e guarde os resíduos $e_{x_1|x_2}$.
 - Faça a regressão dos resíduos $e_{y|x_2}$ em $e_{x_1|x_2}$. Compare a estimativa do coeficiente angular desta regressão com a estimativa de β_1 obtida em 3).
 - Faça um gráfico de dispersão de $e_{y|x_2}$ versus $e_{x_1|x_2}$, com as cores de acordo com os níveis de X_2 . Compare com o gráfico em (a).
- 5) Obtenha a tabela ANOVA para o modelo de RLM obtido em 3. Use a função `anova()` do R.
- 6) A partir da tabela ANOVA acima, apresente um teste de hipótese para verificar se os coeficientes β_1 e β_2 são nulos. Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p-valor e conclusão.
- 7) Faça um teste t para cada um dos coeficientes β_1 e β_2 . Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p-valor e conclusão.
- 8) Calcule os intervalos de 95% de confiança para cada um dos β_1 e β_2 . Como esses intervalos se relacionam com a conclusão dos testes t feitos no item anterior?