

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 03 - 2S2025 - 08/10/2025

Introdução

Nesta atividade vocês irão trabalhar com modelos de regressão linear múltipla.

Atividade

A Organização Mundial de Saúde quer verificar quais fatores influenciam a expectativa de vida. Observou-se que nos últimos 15 anos houve um enorme desenvolvimento no sector da saúde, resultando na melhoria das taxas de mortalidade humana, especialmente nas nações em desenvolvimento, em comparação com os últimos 30 anos. Portanto, neste projeto estão sendo considerados dados dos anos de 2000 a 2015 para 193 países para uma análise mais aprofundada. As variáveis preditoras representam diversos grupos de fatores, ou seja, fatores econômicos e sociais além de fatores relacionados à imunização e mortalidade.

O conjunto de dados completo está no site Kaggle > DataSets > Life Expectancy (WHO), mas nós iremos trabalhar com um subconjunto desses dados (arquivo `LifeExpectancyModificado.csv`) que compreende 2095 observações e 11 variáveis preditoras (renomeadas), descritas a seguir:

- **LifeExp**: expectativa de vida (em anos)
- **Developed**: Status do país (Yes = Desenvolvido ou No = em desenvolvimento)
- **Mortality**: taxa de mortalidade para adultos entre 15 e 60 anos
- **BMI**: Índice de Massa Corporal da população
- **Alcohol**: consumo de álcool per capita (em litros)
- **Polio**: cobertura de imunização para Polio entre crianças
- **HIV**: Mortes por HIV/AIDS por 1000 nascidos vivos
- **GDP**: Produto Interno Bruto per capita (em Dólares USD)
- **IDHComp**: IDH em termos de composição do rendimento dos recursos
- **School**: Anos de escolaridade
- **InfantDeaths**: número de mortes infantis por 1000 habitantes
- **Population**: População do país (em milhões de habitantes)

O interesse está em determinar quais fatores estão relacionados à expectativa de vida e você é o Estatístico que irá analisar estes dados.

Leia o conjunto de dados no R, como a seguir, e visualize as primeiras observações. Verifique se as colunas estão no formato correto.

```
# Lendo o conjunto de dados
dados = read_csv("LifeExpectancyModificado.csv", show_col_types = FALSE)
# Encontramos algumas observacoes com IDHComp = 0
# o que nao e muito aderente com a relidade
# por isso optamos por filtrar e trazer somente dados com IDHComp > 0
```

```
dados %<>%
  select(-Developed)%>%
  filter(IDHComp > 0)

dados_contínuos <- dados[,sapply(dados, is.numeric)]
```

- 1) Faça o gráfico de dispersão entre todas as variáveis contínuas do conjunto de dados e calcule a correlação entre elas. Comente.




Figure 1: Matriz de dispersão - Questão 1

Uma matriz de correlação é uma tabela que mostra os coeficientes
 # de correlação entre várias variáveis.
 # Cada elemento da matriz representa a correlação entre duas variáveis.

Propriedades da Matriz de Correlação

Simétrica: A matriz é simétrica em relação à diagonal principal.
 # Isso porque a correlação entre a variável
 # X e Y é a mesma entre Y e X

```


# Cor(X,Y) = Cor(Y,X)

# Diagonal Principal: Os elementos da diagonal principal são sempre 1,
# pois uma variável é perfeitamente correlacionada consigo mesma.
# COR(X,X) = 1

matriz_cor <- round(cor(dados_continuos),2)


ggcorrplot(
  method = "square",
  show.diag = TRUE,
  matriz_cor,
  type = "upper",
  lab = TRUE,
  lab_size = 2.5,
  tl.cex = 12,
  tl.srt = 45,
  digits = 2 ,
  colors = cores_base,
  outline.color = "black",
  title = "Matriz de Correlação"
) + theme(plot.title = element_text(hjust = 0.5, face = "bold", color = "#1A4A7A"),
  axis.text.x = element_text(angle = 45, hjust = 1))

```




```
# Correlacao entre IDHComp e School
corX1_X2 = round(cor(dados_contínuos$IDHComp,dados_contínuos$School),2)
```

A correlacao entre School e IDHComp e **0.93**



A análise do gráfico **LifeExp X School** revelou registros com **School = 0**, os quais também apresentavam **IDHComp = 0**. Para assegurar a consistência dos dados, será aplicado um filtro mantendo apenas observações com **IDHComp > 0**.

```
dados %<>%
  select(-Developed)%>%
  filter(IDHComp > 0)
```



Seleção de Preditores para a Variável Resposta LifeExp

Com base na análise da matriz de dispersão e da matriz de correlação, identificamos os preditores que apresentam as maiores correlações com a variável resposta LifeExp.

IDHComp: Correlação de 0,89 com LifeExp, indicando uma relação linear positiva muito forte. Isso era esperado, uma vez que o IDHComp é uma medida que sintetiza dimensões como saúde, educação e renda, diretamente relacionadas à expectativa de vida.

School: Correlação de 0,78 com LifeExp, também uma relação positiva forte. A educação é um determinante social da saúde, e maior escolaridade está associada a melhores condições de vida e, conseqüentemente, maior longevidade.

Mortality: Correlação de -0,69 com LifeExp. Essa forte relação negativa é coerente com a realidade, pois quanto menor a mortalidade, maior a expectativa de vida. A mortalidade é um indicador inverso à sobrevivência e, portanto, deve se relacionar negativamente com a expectativa de vida.

Relação entre os Preditores e Multicolinearidade Além das correlações com a variável resposta, observamos uma correlação muito alta entre os dois principais preditores positivos, **School e IDHComp**, com valor de **0.93**. Essa alta correlação indica que esses dois preditores compartilham muita informação em comum.

- 2) Defina algum critério e escolha dois preditores contínuos, denominados X_1 e X_2 . Ajuste um modelo de regressão linear simples de Y com cada um dos preditores X_1 e X_2 , separadamente. Interprete os coeficientes.

Critério de escolha dos preditores

O critério adotado para a escolha dos preditores foi baseado na correlação com a variável resposta (LifeExp). Assim, foram selecionadas as variáveis contínuas que apresentaram maior correlação linear com a minha variável resposta pois essas tendem a ter maior poder explicativo no modelo.

- X1: School
- X2: IDHComp

Esses preditores foram, então, utilizados para ajustar modelos de regressão linear simples separadamente, a fim de avaliar a relação individual de cada um com a minha variável resposta LifeExp.

```
# X1 = School
modeloX1 = lm(LifeExp ~ School ,data = dados)
summary(modeloX1)

##
## Call:
## lm(formula = LifeExp ~ School, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -24.2783  -3.2877   0.8096   4.1224  16.3372
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   39.9500     0.5363   74.49  <2e-16 ***
## School         2.3986     0.0429   55.92  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.19 on 2007 degrees of freedom
## Multiple R-squared:  0.6091, Adjusted R-squared:  0.6089
## F-statistic: 3127 on 1 and 2007 DF, p-value: < 2.2e-16
```

```
# X2 = IDHComp
modeloX2 = lm(LifeExp ~ IDHComp ,data = dados)
summary(modeloX2)

##
## Call:
## lm(formula = LifeExp ~ IDHComp, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.3605  -2.1521   0.5098   2.7585  16.0796
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   35.1036     0.4075   86.14  <2e-16 ***
## IDHComp       52.2488     0.6093   85.75  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.585 on 2007 degrees of freedom
## Multiple R-squared:  0.7856, Adjusted R-squared:  0.7855
## F-statistic: 7353 on 1 and 2007 DF,  p-value: < 2.2e-16
```

Modelo 1: LifeExp ~ School

O intercepto ($\beta_0 = 39,95$) representa a expectativa de vida estimada quando a variável School é igual a zero. No entanto, essa situação não ocorre no conjunto de dados analisado, uma vez que os casos com School = 0 foram removidos durante o processo de limpeza, por não representarem valores plausíveis para a análise. Assim, o intercepto não possui interpretação prática direta, servindo apenas como referência para a reta de regressão.

O coeficiente associado a School ($\beta_1 = 2,39$) indica que, para cada aumento de uma unidade na variável escolaridade, espera-se um acréscimo médio de aproximadamente 2,39 anos na expectativa de vida. Esse resultado confirma a existência de uma relação positiva e estatisticamente significativa entre escolaridade e expectativa de vida.

O modelo apresentou um $R^2 = 0,60$, o que significa que cerca de 60% da variação observada na expectativa de vida (LifeExp) é explicada apenas pela variável School. Esse valor de R^2 indica um bom poder explicativo para um modelo univariado.

Modelo 2: LifeExp ~ IDHComp

O intercepto ($\beta_0 = 35,10$) representa a expectativa de vida estimada para um valor hipotético de IDHComp igual a zero, servindo apenas como referência para a reta de regressão, uma vez que essa situação não ocorre na prática — nenhum país ou região apresenta IDH igual a zero.

O coeficiente associado a IDHComp ($\beta_1 = 52,25$) indica que, para cada aumento unitário na variável, a expectativa de vida média tende a aumentar em aproximadamente 52,25 anos. Entretanto, como o IDHComp varia em uma escala de 0 a 1, um aumento de apenas 0,01 nessa variável (por exemplo, de 0,70 para 0,71) corresponde, na prática, a um acréscimo médio de 0,52 anos na expectativa de vida.

Para tornar essa interpretação mais intuitiva, poderíamos reescalar o IDHComp multiplicando-o por 100, representando-o em pontos percentuais. Nesse caso, o coeficiente seria ajustado para aproximadamente 0,52, indicando que a cada aumento de 1 ponto percentual no IDHComp, espera-se um crescimento médio de 0,52 anos na expectativa de vida.

```
modeloX22 = lm(LifeExp ~ I(IDHComp*100) ,data = dados)
coef(modeloX22)
```

```
##      (Intercept) I(IDHComp * 100)
##      35.1035967      0.5224876
```

O modelo apresentou um $R^2 = 0,785$, o que significa que cerca de 78,5% da variação observada na expectativa de vida (LifeExp) é explicada apenas pela variável IDHComp. Esse valor indica um elevado poder explicativo, superior ao do modelo com School, evidenciando que o IDHComp é um preditor mais abrangente, por incorporar dimensões relacionadas à educação, renda e saúde.

```
cor_school <- round(cor(dados$LifeExp, dados$School),2)
cor_idh <- round(cor(dados$LifeExp, dados$IDHComp),2)
correlacoes = c(cor_school,cor_idh)
```

```
# Extrair os R² de cada modelo
r2_school <- round(summary(modeloX1)$r.squared,2)
r2_idh <- round(summary(modeloX2)$r.squared,2)
r2_School_IDHComp = c(r2_school,r2_idh)
```

```
tabela_resultados <- data.frame(
  Preditor = c("School", "IDHComp"),
  Correlacao = correlacoes,
  R2 = r2_School_IDHComp,
  Coeficiente = c(2.399, 52.249),
  SE = c(0.043, 0.609),
  Valor_p = c("< 0.001", "< 0.001"),
  IC_95 = c("[2.315, 2.483]", "[51.054, 53.446]")
)
```

```
tabela_latex <-
  kable(tabela_resultados,
    format = "latex",
    col.names = c("Preditor", "Correlação", "R²", "Coeficiente Beta", "Erro Padrão (Beta)", "Valor-p", "IC 95%"),
    digits = 3,
    caption = "Preditores de LifeExp",
    align = c("l", "c", "c", "c", "c", "c", "c"),
    booktabs = TRUE) %>%
  kable_styling(latex_options = c("striped", "hold_position"))
```

```
# Mostrar a tabela
tabela_latex
```

Table 1: Preditores de LifeExp

Preditor	Correlação	R²	Coeficiente Beta	Erro Padrão (Beta)	Valor-p	IC 95%
School	0.78	0.61	2.399	0.043	< 0.001	[2.315, 2.483]
IDHComp	0.89	0.79	52.249	0.609	< 0.001	[51.054, 53.446]

A Tabela 1 apresenta a correlação de cada preditor contínuo selecionado com a variável resposta, (LifeExp), bem como o coeficiente de determinação (R^2) obtido ao ajustar modelos de regressão linear simples. Observa-se que ambos os preditores, School e IDHComp, apresentam correlações positivas elevadas com LifeExp, indicando que valores maiores para **School** e **IDHComp** estão associados a maior expectativa de vida.

Além disso, os valores de (R^2) mostram a proporção da variabilidade de LifeExp explicada por cada preditor individualmente. School apresenta um (R^2) ligeiramente menor que IDHComp, sugerindo que o índice de desenvolvimento humano é um preditor mais forte isoladamente. Esses resultados fornecem uma base inicial para avaliar o potencial de cada variável na modelagem preditiva, bem como para investigar possíveis efeitos de multicolinearidade em modelos múltiplos.

3) Ajuste um modelo de regressão linear múltipla usando X_1 e X_2 como preditores, ou seja,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i.$$

Reporte as estimativas dos coeficientes e interprete-os. Qual é função de regressão estimada?

```
# Modelo ajustado com X1 e X2
fitX1_X2 = lm(LifeExp ~ School+IDHComp , data=dados_contínuos)
r2_mult <- round(summary(fitX1_X2)$r.squared,2)
summary(fitX1_X2)

##
## Call:
## lm(formula = LifeExp ~ School + IDHComp, data = dados_contínuos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.6827  -2.2331   0.4342   2.6272  14.7357
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  35.64029    0.39568   90.07  <2e-16 ***
## School       -1.02476    0.08386  -12.22  <2e-16 ***
## IDHComp       70.54323    1.60848   43.86  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.424 on 2006 degrees of freedom
## Multiple R-squared:  0.8004, Adjusted R-squared:  0.8002
## F-statistic: 4023 on 2 and 2006 DF, p-value: < 2.2e-16
```

```
summary(modeloX1)

##
## Call:
## lm(formula = LifeExp ~ School, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -24.2783  -3.2877   0.8096   4.1224  16.3372
##
## Coefficients:
```



```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  39.9500      0.5363   74.49  <2e-16 ***
## School       2.3986      0.0429   55.92  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.19 on 2007 degrees of freedom
## Multiple R-squared:  0.6091, Adjusted R-squared:  0.6089
## F-statistic: 3127 on 1 and 2007 DF, p-value: < 2.2e-16
```

```
summary(modeloX2)
```

```
##
## Call:
## lm(formula = LifeExp ~ IDHComp, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.3605  -2.1521   0.5098   2.7585  16.0796
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  35.1036      0.4075   86.14  <2e-16 ***
## IDHComp      52.2488      0.6093   85.75  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.585 on 2007 degrees of freedom
## Multiple R-squared:  0.7856, Adjusted R-squared:  0.7855
## F-statistic: 7353 on 1 and 2007 DF, p-value: < 2.2e-16
```

Comentários sobre o modelo

O seguinte modelo foi ajustado :

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i}$$

- X_1 **School** = **-1.02** : Mantendo IDHComp constante, cada aumento de 1 unidade em School está associado a uma redução de aproximadamente 1.02 anos na expectativa de vida. O sinal negativo aqui é resultado da alta correlação entre School e IDHComp, ou seja, este coeficiente reflete o efeito de School ajustado pelo IDHComp.
- X_2 **IDHComp** = **70.54** : Mantendo School constante, cada aumento de 1 unidade em IDHComp está associado a um aumento de 70.54 anos na expectativa de vida. Este coeficiente é dominante, refletindo a forte relação de IDHComp com a variável resposta.

R^2 e Multicolinearidade

Observa-se que o modelo de regressão ajustado apenas com o preditor X_2 apresenta um $R^2 = 0.79$ muito próximo ao modelo que inclui ambos os preditores, X_1 e X_2 e possui um $R^2 = 0.80$. Isso indica que a inclusão do X_1 não acrescenta ganho significativo de explicação da variabilidade da variável resposta. Esse comportamento é esperado, considerando a alta correlação entre X_1 e X_2 , o que sugere que ambos medem quase a mesma coisa e compartilham grande parte da informação explicativa.

```
## # A tibble: 1 x 12
##   r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
##   <dbl>      <dbl> <dbl>    <dbl>  <dbl> <dbl> <dbl> <dbl> <dbl>
## 1    0.800        0.800  4.42    4023.    0     2 -5837. 11681. 11704.
## # i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

```
## # A tibble: 3 x 7
##   term          estimate std.error statistic  p.value conf.low conf.high
##   <chr>          <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
## 1 (Intercept)    35.6      0.396     90.1 0        34.9      36.4
## 2 School         -1.02     0.0839    -12.2 3.58e- 33    -1.19     -0.860
## 3 IDHComp         70.5      1.61     43.9 3.38e-295    67.4      73.7
```

```
##   School IDHComp
## 7.483111 7.483111
```




Table 2: Comparação do R^2 entre Modelos de Regressão

Preditores	R^2
X1: School	0.61
X2: IDHComp	0.79
X1 + X2 : School + IDHComp	0.80

Portando a função de regressão estimada para o modelo múltiplo é dada por:

$$\widehat{LifeExp} = 35.64 - 1.02 \cdot School + 70.54 \cdot IDHComp$$

onde:

- $\widehat{LifeExp}$: expectativa de vida estimada (anos)
- $School$: média de anos de escolaridade
- $IDHComp$: índice de desenvolvimento humano composto

Essa equação representa a relação ajustada entre a expectativa de vida e os dois preditores selecionados, considerando simultaneamente o efeito de ambos no modelo.

4) Para entender melhor o significado de β_1 no modelo de regressão linear múltipla, execute os passos a seguir:

a) Calcule a correlação entre X_1 e X_2 .

```
X1 <- dados$School
X2 <- dados$IDHComp

cor_x1x2 <- cor(X1, X2, use = "pairwise.complete.obs")
cor_x1x2
```

```
## [1] 0.9307877
```

A correlação calculada foi de 0,93, o que indica uma relação linear positiva muito forte entre $School$ e $IDHComp$, ou seja, praticamente todas as informações de $School$ já estão incorporadas em $IDHComp$.


Essa dependência linear explica os resultados do item anterior (o VIF é igual a 7.48), mostrando que existe redundância de informação entre as variáveis.

Como consequência, incluir ambas em um modelo de regressão múltipla gera **multicolinearidade**, o que afeta a estabilidade e o sinal dos coeficientes, embora o poder explicativo global continue sendo elevado.

b) Faça um gráfico de dispersão de Y versus X_1 , com as cores de acordo com os níveis de X_2 .

```
dados_plot <- dados %>%
  drop_na(LifeExp, School, IDHComp) %>%
  mutate(
    IDH_nivel = ggplot2::cut_number(IDHComp, 4,
                                     labels = c("Q1 (baixo)", "Q2", "Q3", "Q4 (alto)"))
  )

ggplot(dados_plot, aes(x = School, y = LifeExp, color = IDH_nivel)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 0.9) +
  labs(
    title = "LifeExp vs School por níveis de IDH (quartis)",
    x = "School (anos)",
    y = "LifeExp (anos)",
    color = "IDHComp"
  ) +
  theme_bw()
```



O gráfico mostra uma associação positiva entre *LifeExp* e *School*; no entanto, ao estratificar por níveis de *IDHComp*, observa-se que os países com maior IDH também apresentam maior longevidade. Isso gera um deslocamento vertical da relação de acordo com o nível de desenvolvimento humano: para um mesmo grau de escolaridade, os países com IDH mais alto alcançam expectativas de vida mais elevadas.

A forte colinearidade entre *School* e *IDHComp* ($r \approx 0.93$) implica que o que é observado marginalmente para *School* mistura seu efeito com o do *IDHComp*. Por isso, quando o *IDHComp* é controlado no modelo múltiplo, o efeito parcial de *School* se reduz e até inverte seu sinal, enquanto o *IDHComp* mantém um efeito positivo e dominante sobre *LifeExp*. Isso evidencia que grande parte da relação entre educação e longevidade é mediada pelo desenvolvimento humano global, e não apenas pelos anos de escolaridade.

c) Remova o efeito de X_2 da variável resposta Y . Para isso, faça a regressão de Y em X_2 e guarde.

```
# Regressão simples de Y (LifeExp) em X2 (IDHComp)
modelo_y_x2 <- lm(LifeExp ~ IDHComp, data = dados)

# Resumo do modelo
summary(modelo_y_x2)
```

```
##
## Call:
## lm(formula = LifeExp ~ IDHComp, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.3605  -2.1521   0.5098   2.7585  16.0796
```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  35.1036     0.4075   86.14 <2e-16 ***
## IDHComp      52.2488     0.6093   85.75 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.585 on 2007 degrees of freedom
## Multiple R-squared:  0.7856, Adjusted R-squared:  0.7855
## F-statistic: 7353 on 1 and 2007 DF, p-value: < 2.2e-16
```

```
# Guardar os resíduos e_y/x2
e_yx2 <- resid(modelo_y_x2)

# Opcional: adicionar os resíduos ao dataframe
dados$e_yx2 <- e_yx2

# Verificar primeiras observações
head(dados$e_yx2)
```

```
##           1           2           3           4           5           6
## 4.86924830 -0.07400543  0.23948712  0.20522842  0.37546724  0.28895979
```

Fazendo uma análise, observa-se que o intercepto $\beta_0 = 35.10$ e o coeficiente angular $\beta_1 = 52.25$, o que significa que, para cada aumento de uma unidade em *IDHComp*, a expectativa de vida média aumenta aproximadamente 52,25 anos.

Em ambos os coeficientes, o valor-*p* é menor que 2×10^{-16} , indicando uma relação linear positiva e altamente significativa entre *IDHComp* e *LifeExp*.

Além disso, o $R^2 = 0.786$ revela que cerca de 78,6% da variabilidade da expectativa de vida entre os países é explicada unicamente pelo *IDHComp*, o que demonstra que ele é um excelente preditor individual, pois engloba diversas dimensões relacionadas ao tempo de vida.

Os 21,4% restantes da variabilidade podem ser atribuídos a fatores não incluídos no modelo, como aspectos culturais, políticas públicas, desigualdade social ou variações amostrais.

d) Remove o efeito de *School* da variável preditora *School*. Para isso, faça a regressão de *School* em *IDHComp*.

```
# Regressão de X1 (School) em X2 (IDHComp)
modelo_x1_x2 <- lm(School ~ IDHComp, data = dados)

# Resumo do modelo
summary(modelo_x1_x2)
```

```
##
## Call:
## lm(formula = School ~ IDHComp, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.1042 -0.7315 -0.0628  0.7999  3.9662
```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)   0.5237     0.1047   5.004 6.11e-07 ***
## IDHComp       17.8525     0.1565 114.068 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.178 on 2007 degrees of freedom
## Multiple R-squared:  0.8664, Adjusted R-squared:  0.8663
## F-statistic: 1.301e+04 on 1 and 2007 DF,  p-value: < 2.2e-16
```

```
# Guardar os resíduos e_{x1|x2}
e_x1x2 <- resid(modelo_x1_x2)

# Adicionar ao dataframe
dados$e_x1x2 <- e_x1x2

# Verificar primeiras observações
head(dados$e_x1x2)
```

```
##           1           2           3           4           5           6
## 1.0249080 0.9784656 0.9855808 1.0105485 0.8712213 0.6783365
```

Fazendo uma análise, observa-se que o intercepto $\beta_0 = 0.5237$ e o coeficiente angular $\beta_1 = 17.85$, o que significa que, para cada aumento de uma unidade em *IDHComp*, espera-se um incremento médio de 17,85 anos de escolaridade.

O coeficiente de determinação $R^2 = 0.866$ mostra que o modelo explica 86,6% da variabilidade total nos anos médios de escolaridade entre os países. Isso sugere que o *IDHComp*, por si só, é capaz de capturar quase todo o comportamento da variável *School*, o que faz sentido, pois o IDH inclui componentes educacionais em seu cálculo.

Os resíduos representam a parcela da escolaridade que não pode ser explicada pelo *IDHComp*.

e) Faça a regressão dos resíduos $e_{y|x2}$ em $e_{x1|x2}$. Compare a estimativa do coeficiente angular

```
# Regressão dos resíduos de Y~X2 em X1~X2
modelo_residuos <- lm(e_yx2 ~ e_x1x2, data = dados)

# Resumo do modelo
summary(modelo_residuos)
```

```
##
## Call:
## lm(formula = e_yx2 ~ e_x1x2, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.6827  -2.2331   0.4342   2.6272  14.7357
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
```

```
## (Intercept)  1.972e-16  9.868e-02    0.00      1
## e_x1x2      -1.025e+00  8.384e-02  -12.22   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.423 on 2007 degrees of freedom
## Multiple R-squared:  0.06928,    Adjusted R-squared:  0.06881
## F-statistic: 149.4 on 1 and 2007 DF,  p-value: < 2.2e-16
```


Ao regredir $e_{y|x2}$ sobre $e_{x1|x2}$, obteve-se uma inclinação de -1.025 ($EP = 0.084$, $IC95\% \approx [-1.189, -0.861]$, $p < 0.001$) e um intercepto nulo (aproximadamente 0).

Esse valor coincide com o β_1 do modelo múltiplo ($LifeExp \sim School + IDHComp$, $\beta_1 \approx -1.02$), demonstrando que a regressão dos resíduos recupera o efeito parcial de *School* sobre *LifeExp*, controlando o *IDHComp*.

O $R^2 = 0.069$ indica que, após remover o efeito do *IDH*, a parte residual da escolaridade explica pouca variação adicional na expectativa de vida, o que é coerente com a forte colinearidade entre *School* e *IDHComp*.

f) Faça um gráfico de dispersão de $e_{y|x2}$ versus $e_{x1|x2}$, com as cores de acordo com os níveis de *IDHComp*.

```
ggplot(dados, aes(x = e_x1x2, y = e_yx2, color = IDHComp)) +
  geom_point(alpha = 0.7, size = 2) +
  geom_smooth(method = "lm", se = FALSE, color = "black", linetype = "dashed") +
  scale_color_viridis_c(option = "plasma", direction = 1) +
  labs(
    title = expression("e"[y~"|"~x2]~"vs"~"e"[x1~"|"~x2]~"por níveis de IDHComp"),
    subtitle = "Gráfico de resíduos (LifeExp ~ School, controlando IDHComp)",
    x = expression(e[x1~"|"~x2]~"(School - efeito de IDHComp)"),
    y = expression(e[y~"|"~x2]~"(LifeExp - efeito de IDHComp)"),
    color = "IDHComp"
  ) +
  theme_bw(base_size = 12) +
  theme(
    plot.title = element_text(size = 14, face = "bold", hjust = 0.5),
    plot.subtitle = element_text(size = 11, hjust = 0.5),
    legend.position = "right"
  )
```



O gráfico de dispersão entre os resíduos $e_{y|x2}$ e $e_{x1|x2}$ mostra uma nuvem de pontos centrada em torno do eixo horizontal, com uma inclinação ligeiramente negativa.

Esse padrão coincide com o coeficiente de -1.025 obtido na regressão dos resíduos, que representa o efeito parcial de *School* sobre *LifeExp*, controlando o *IDHComp*.

Diferentemente do gráfico do item (a) (*LifeExp* vs *School*), onde havia uma clara tendência positiva influenciada pelo nível de desenvolvimento humano, neste caso as cores se misturam, indicando que o efeito do *IDHComp* foi corretamente removido.

Assim, a relação que antes parecia positiva torna-se fraca e negativa ao isolar o componente educacional independente do desenvolvimento humano, confirmando que a associação inicial entre educação e expectativa de vida estava fortemente mediada pelo *IDHComp*.

5) Obtenha a tabela ANOVA para o modelo de RLM obtido em 3. Use a função `anova()` do R.

```
anova(m12)
```

```
## Analysis of Variance Table
##
## Response: LifeExp
##          Df Sum Sq Mean Sq F value    Pr(>F)
## School      1 119813   119813   6121.8 < 2.2e-16 ***
## IDHComp      1  37645    37645   1923.5 < 2.2e-16 ***
## Residuals 2006  39260         20
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


De acordo com a tabela ANOVA, observa-se que *School* e *IDHComp* apresentam valores- p menores que 2.2×10^{-16} , o que indica que sua contribuição estatística é altamente significativa para explicar a expectativa de vida.

O valor de F associado a *School* é muito maior do que o de *IDHComp*, o que implica que *School* explica uma porção maior da variação total de *LifeExp*, considerando a ordem de entrada das variáveis na tabela ANOVA.

Isso não contradiz o resultado anterior, no qual o efeito parcial de *School* foi negativo, pois essa diferença decorre do **ordem sequencial** em que as variáveis são introduzidas no modelo.

- 6) A partir da tabela ANOVA acima, apresente um teste de hipótese para verificar se os coeficientes β_1 e β_2 são nulos. Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p -valor e conclusão.

6) Teste de hipótese global para os coeficientes β_1 e β_2

Para verificar se os preditores $X_1 = \text{School}$ e $X_2 = \text{IDHComp}$ têm efeito significativo sobre a variável resposta $Y = \text{LifeExp}$, consideramos o seguinte teste de hipótese global:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = 0 & (\text{nenhum preditor explica LifeExp}) \\ H_1 : \text{pelo menos um } \beta_j \neq 0 & (\text{pelo menos um preditor tem efeito significativo sobre LifeExp}) \end{cases}$$

A estatística de teste utilizada é baseada na decomposição da variância (ANOVA):

$$F = \frac{(SQ_{\text{Regressão}}/p)}{(SQ_{\text{Resíduos}}/(n-p-1))},$$

onde: - $SQ_{\text{Regressão}} = 157,458$ representa a soma dos quadrados explicados pelos preditores; - $SQ_{\text{Resíduos}} = 39,260$ é a soma dos quadrados dos resíduos; - $p = 2$ é o número de preditores; - $n = 2009$ é o número total de observações.

Substituindo os valores, obtemos:

$$F_{obs} = \frac{(157,458/2)}{(39,260/2006)} \approx 4023.$$

Sob a hipótese nula H_0 , a estatística segue uma distribuição $F_{(2,2006)}$.

O valor- p associado ao teste é extremamente pequeno ($p\text{-valor} < 2 \times 10^{-16}$), indicando forte evidência contra H_0 .

$\Rightarrow$ Como $p\text{-valor} < 0,001$, rejeitamos H_0 .

Portanto, concluímos que **pelo menos um dos coeficientes β_1 ou β_2 é diferente de zero**, ou seja, o modelo de regressão múltipla com *School* e *IDHComp* é estatisticamente significativo e explica uma proporção substancial da variação da expectativa de vida.

Conclusão: o modelo é globalmente significativo ($F_{obs} = 4023$, $p < 0.001$).

- 7) Faça um teste t para cada um dos coeficientes β_1 e β_2 . Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p -valor e conclusão.

7) Testes t individuais para β_1 (School) e β_2 (IDHComp)

Considere o modelo múltiplo ajustado no item 3:

$$\widehat{\text{LifeExp}} = \beta_0 + \beta_1 \text{School} + \beta_2 \text{IDHComp}.$$

Com $n = 2009$ observações e $p = 2$ preditores, os testes t usam $df = n - p - 1 = 2006$.

A estatística de teste para cada coeficiente é

$$t_j = \frac{\hat{\beta}_j - 0}{\text{EP}(\hat{\beta}_j)}, \quad \text{sob } H_0 \text{ temos } t_j \sim t_{(2006)}.$$

(a) Teste para β_1 (School)

$$\begin{cases} H_0 : \beta_1 = 0, \\ H_1 : \beta_1 \neq 0. \end{cases}$$

Estimativa e erro-padrão: $\hat{\beta}_1 = -1.024755$, $\text{EP}(\hat{\beta}_1) = 0.083862$.

$$t_{\text{obs}} = \frac{-1.024755}{0.083862} = -12.21953.$$

Distribuição sob H_0 : $t_{(2006)}$. Valor- p : $p = 3.579311 \times 10^{-33} (< 0.001)$.

$\Rightarrow$ **Conclusão:** rejeitamos H_0 .

Há evidência estatística de que $\beta_1 \neq 0$; o efeito parcial estimado de School (controlando IDHComp) é negativo e significativo.

(b) Teste para β_2 (IDHComp)

$$\begin{cases} H_0 : \beta_2 = 0, \\ H_1 : \beta_2 \neq 0. \end{cases}$$

Estimativa e erro-padrão: $\hat{\beta}_2 = 70.543231$, $\text{EP}(\hat{\beta}_2) = 1.608476$.

$$t_{\text{obs}} = \frac{70.543231}{1.608476} = 43.85718.$$

Distribuição sob H_0 : $t_{(2006)}$. Valor- p : $p = 3.377178 \times 10^{-295} (< 0.001)$.

$\Rightarrow$ **Conclusão:** rejeitamos H_0 .

Há evidência estatística de que $\beta_2 \neq 0$; o efeito de IDHComp sobre LifeExp é positivo e altamente significativo.

Ambos os coeficientes são diferentes de zero ao nível usual ($\alpha = 0.05$).

Conclusão geral:

Os resultados dos testes t indicam que tanto β_1 quanto β_2 são estatisticamente diferentes de zero ao nível de significância de 5%.

O coeficiente associado à variável School ($\hat{\beta}_1 = -1.02$) apresenta um efeito parcial **negativo e significativo**, o que significa que, mantido o nível de desenvolvimento humano constante, variações residuais na escolaridade estão associadas a pequenas reduções na expectativa de vida.

Esse comportamento, embora contraintuitivo, decorre da **alta colinearidade** entre *School* e *IDHComp*, de modo que grande parte do efeito positivo da educação já está incorporado na variável de desenvolvimento humano.

Por outro lado, o coeficiente $\hat{\beta}_2 = 70.54$ revela um **efeito positivo, forte e altamente significativo** do *IDHComp* sobre a expectativa de vida, confirmando que o desenvolvimento humano é o principal determinante do aumento da longevidade entre os países analisados.

Em conjunto, os resultados dos testes *t* reforçam que o modelo múltiplo é estatisticamente sólido, com ambos os preditores contribuindo de forma significativa, mas com magnitudes e direções distintas — o *IDHComp* exercendo o papel dominante e a *School* apresentando um efeito parcial residual após o controle do IDH.

- 8) Calcule os intervalos de 95% de confiança para cada um dos β_1 e β_2 . Como esses intervalos se relacionam com a conclusão dos testes *t* feitos no item anterior?

```
confint(m12, level = 0.95)
```

```
##                2.5 %      97.5 %
## (Intercept) 34.864306 36.4162767
## School      -1.189221 -0.8602893
## IDHComp      67.388772 73.6976898
```

Os intervalos de confiança de 95% para os coeficientes β_1 (*School*) e β_2 (*IDHComp*) não incluem o valor nulo, o que nos leva à mesma conclusão que os testes *t* realizados no item anterior: ambos os coeficientes são significativamente diferentes de zero ao nível de significância de 5%.

Neste caso, o IC de *School* está completamente abaixo de 0 $[-1.189, -0.861]$, o que confirma um efeito parcial negativo ao controlar por *IDHComp*. Por outro lado, o IC de *IDHComp* está completamente acima de 0 $[67.389, 73.697]$, o que indica um efeito positivo e forte sobre *LifeExp*.