

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 03 - 2S2025 - 08/10/2025

Introdução

Nesta atividade vocês irão trabalhar com modelos de regressão linear múltipla.

Atividade

A Organização Mundial de Saúde quer verificar quais fatores influenciam a expectativa de vida. Observou-se que nos últimos 15 anos houve um enorme desenvolvimento no sector da saúde, resultando na melhoria das taxas de mortalidade humana, especialmente nas nações em desenvolvimento, em comparação com os últimos 30 anos. Portanto, neste projeto estão sendo considerados dados dos anos de 2000 a 2015 para 193 países para uma análise mais aprofundada. As variáveis preditoras representam diversos grupos de fatores, ou seja, fatores econômicos e sociais além de fatores relacionados à imunização e mortalidade.

O conjunto de dados completo está no site Kaggle > DataSets > Life Expectancy (WHO), mas nós iremos trabalhar com um subconjunto desses dados (arquivo `LifeExpectancyModificado.csv`) que compreende 2095 observações e 11 variáveis preditoras (renomeadas), descritas a seguir:

- **LifeExp**: expectativa de vida (em anos)
- **Developed**: Status do país (Yes = Desenvolvido ou No = em desenvolvimento)
- **Mortality**: taxa de mortalidade para adultos entre 15 e 60 anos
- **BMI**: Índice de Massa Corporal da população
- **Alcohol**: consumo de álcool per capita (em litros)
- **Polio**: cobertura de imunização para Polio entre crianças
- **HIV**: Mortes por HIV/AIDS por 1000 nascidos vivos
- **GDP**: Produto Interno Bruto per capita (em Dólares USD)
- **IDHComp**: IDH em termos de composição do rendimento dos recursos
- **School**: Anos de escolaridade
- **InfantDeaths**: número de mortes infantis por 1000 habitantes
- **Population**: População do país (em milhões de habitantes)

O interesse está em determinar quais fatores estão relacionados à expectativa de vida e você é o Estatístico que irá analisar estes dados.

Leia o conjunto de dados no R, como a seguir, e visualize as primeiras observações. Verifique se as colunas estão no formato correto.

- 1) Faça o gráfico de dispersão entre todas as variáveis contínuas do conjunto de dados e calcule a correlação entre elas. Comente.
- 2) Defina algum critério e escolha dois preditores contínuos, denominados X_1 e X_2 . Ajuste um modelo de regressão linear simples de Y com cada um dos preditores X_1 e X_2 , separadamente. Interprete os coeficientes.
- 3) Ajuste um modelo de regressão linear múltipla usando X_1 e X_2 como preditores, ou seja,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i.$$

Reporte as estimativas dos coeficientes e interprete-os. Qual é função de regressão estimada?

- 4) Para entender melhor o significado de β_1 no modelo de regressão linear múltipla, execute os passos a seguir:
 - a) Calcule a correlação entre X_1 e X_2 .
 - b) Faça um gráfico de dispersão de Y versus X_1 , com as cores de acordo com os níveis de X_2 .
 - c) Remova o efeito de X_2 da variável resposta Y . Para isso, faça a regressão de Y em X_2 e guarde os resíduos $e_{y|x_2}$.
 - d) Remova o efeito de X_2 da variável preditora X_1 . Para isso, faça a regressão de X_1 em X_2 e guarde os resíduos $e_{x_1|x_2}$.
 - e) Faça a regressão dos resíduos $e_{y|x_2}$ em $e_{x_1|x_2}$. Compare a estimativa do coeficiente angular desta regressão com a estimativa de β_1 obtida em 3).
 - f) Faça um gráfico de dispersão de $e_{y|x_2}$ versus $e_{x_1|x_2}$, com as cores de acordo com os níveis de X_2 . Compare com o gráfico em (a).
- 5) Obtenha a tabela ANOVA para o modelo de RLM obtido em 3. Use a função `anova()` do R.
- 6) A partir da tabela ANOVA acima, apresente um teste de hipótese para verificar se os coeficientes β_1 e β_2 são nulos. Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p-valor e conclusão.
- 7) Faça um teste t para cada um dos coeficientes β_1 e β_2 . Escreva as hipóteses, estatística do teste (fórmula, valor observado e distribuição sob H_0), p-valor e conclusão.
- 8) Calcule os intervalos de 95% de confiança para cada um dos β_1 e β_2 . Como esses intervalos se relacionam com a conclusão dos testes t feitos no item anterior?