

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 04 - 2S2025 - 22/10/2025

Introdução

Nesta atividade vocês irão trabalhar os seguintes conceitos:

- regressão linear múltipla;
- tabela ANOVA;
- soma extra de quadrados para testar hipóteses sobre os coeficientes;
- coeficientes de determinação múltiplo e parcial.


Atividade 1: Gordura Corporal

Considere os dados sobre gordura corporal em anexo. Esses são os mesmos dados que foram utilizados nos slides apresentados em aula. O interesse está em explicar a relação entre a taxa de gordura corporal (Y) e três medidas corporais:

- $X1$: espessura da dobra cutânea do tríceps;
- $X2$: circunferência da coxa; e
- $X3$: circunferência do meio do braço.


- 1) Faça uma matriz com os gráficos de dispersão entre os pares de variáveis e também as correlações. Qual a correlação das preditoras com a variável resposta? As variáveis preditoras são correlacionadas entre si?

```
dados <- read.table("fat.txt",  
                    col.names = c("X1", "X2", "X3", "Y"))
```



```
matriz_cor <- round(cor(dados),2)

ggcorrplot(
  method = "square",show.diag = TRUE,matriz_cor,type = "upper",lab = TRUE,lab_size = 2.5,
  tl.cex = 12,tl.srt = 45,digits = 2 ,colors = cores_base,outline.color = "black",
  title = "Matriz de Correlação" + theme(plot.title = element_text(hjust = 0.5,
  face = "bold", color = "#1A4A7A"),axis.text.x = element_text(angle = 45, hjust = 1))
```



```
corX1_Y = cor(dados$X1,dados$Y)
corX2_Y = cor(dados$X2,dados$Y)
corX1_X2 = cor(dados$X1,dados$X2)
```

Análise da Matriz de Correlação

Observa-se que as variáveis preditoras **X1** e **X2** apresentam forte correlação com a variável resposta **Y** (0.84 e 0.88, respectivamente), indicando que ambas possuem grande poder explicativo em relação a **Y**.

No entanto, nota-se também que **X1** e **X2** são altamente correlacionadas entre si (0.92), o que sugere a presença de **multicolinearidade**. Essa forte relação entre os dois preditores pode causar redundância de informação no modelo e dificultar a interpretação dos coeficientes.

Por outro lado, a variável **X3** apresenta correlação baixa com **Y** (0.14) e fraca correlação com as demais preditoras, indicando que ela pode trazer informação complementar ao modelo sem contribuir para o problema de multicolinearidade.

2) Ajuste um modelo de regressão linear múltipla usando X_1 , X_2 e X_3 como preditores, ou seja,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i.$$

Reporte as estimativas dos coeficientes e interprete-os. Qual é função de regressão estimada?

```
# Ajustando o modelo com os preditores X1,X2,X3
modelo = lm(Y ~ X1+X2+X3,data = dados)
summary(modelo)

##
## Call:
## lm(formula = Y ~ X1 + X2 + X3, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7263 -1.6111  0.3923  1.4656  4.1277
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   117.085      99.782   1.173   0.258
## X1              4.334       3.016   1.437   0.170
## X2             -2.857       2.582  -1.106   0.285
## X3             -2.186       1.595  -1.370   0.190
##
## Residual standard error: 2.48 on 16 degrees of freedom
## Multiple R-squared:  0.8014, Adjusted R-squared:  0.7641
## F-statistic: 21.52 on 3 and 16 DF,  p-value: 7.343e-06

# Escrevendo a funcao de regressao linear com 4 casas decimais
b <- coef(modelo)
cat(sprintf("\nŶ = %.4f + %.4f·X1 + %.4f·X2 + %.4f·X3\n",
           b[1], b[2], b[3], b[4]))

## Ŷ = 117.0847 + 4.3341·X1 + -2.8568·X2 + -2.1861·X3
```

Análise do Modelo de Regressão com Preditores X_1 , X_2 e X_3

O modelo de regressão linear múltipla ajustado é representado por:

$$\hat{Y} = 117.08 - 4.33 \cdot X_1 - 2.85 \cdot X_2 - 2.18 \cdot X_3$$

Interpretação Detalhada dos Coeficientes

Este modelo de regressão linear múltipla busca explicar o percentual de gordura corporal (Y) a partir de três medidas corporais :

- X_1 : Espessura da dobra cutânea do tríceps
- X_2 : Circunferência da coxa
- X_3 : Circunferência do meio do braço.

Cada coeficiente β_j representa o efeito parcial do seu preditor sobre Y , mantendo os outros preditores constantes. Da análise, o intercepto β_0 , quando $X_1 = X_2 = X_3 = 0$, é de 117,0847. O coeficiente de X_1 é $\beta_1 = 4,3341$; isto é, quando X_2 e X_3 são fixos, um aumento de 1 unidade em X_1 produz, em média, um aumento de 4,33 unidades no percentual de gordura corporal. O coeficiente de X_2 é $\beta_2 = -2,8568$; isto é, quando X_1 e X_3 são fixos, um aumento de 1 unidade em X_2 se associa a uma diminuição de 2,86 unidades na gordura corporal. Ao manter fixo X_1 , uma coxa maior pode indicar uma maior massa corporal não gorda. Além disso, a forte correlação entre X_1 e X_2 , que se pode ver do inciso anterior e que é de 0,92, gera colinearidade, o que pode inverter sinais. O coeficiente de X_3 é $\beta_3 = -2,1861$; isto é, quando X_1 e X_2 são fixos, um aumento de 1 unidade em X_3 se associa a uma diminuição de 2,19 unidades na gordura corporal.

Nenhum dos coeficientes tem p-valor < 0.05, então nenhum preditor é estatisticamente significativo individualmente nesse modelo (ao nível de 5%).

3) Obtenha a tabela ANOVA para o modelo ajustado usando os 3 preditores. Explique as somas de quadrados apresentados nesta tabela ANOVA.

```
## Analysis of Variance Table
##
## Response: Y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## X1          1 352.27  352.27 57.2768 1.131e-06 ***
## X2          1  33.17   33.17  5.3931 0.03373 *
## X3          1  11.55   11.55  1.8773 0.18956
## Residuals 16  98.40    6.15
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ 1
## Model 2: Y ~ X1 + X2 + X3
##   Res.Df    RSS Df Sum of Sq      F    Pr(>F)
## 1       19 495.39
## 2       16  98.40  3    396.98 21.516 7.343e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A ANOVA (Análise de Variância) na regressão serve para decompor a variabilidade total de Y (a variável resposta) em duas partes:

$$SQ_{Total} = SQ_{Regressao} + SQ_{Erro}$$

Ou seja as **somas de quadrados** quantificam a variação da variável resposta Y :

- **SQTotal (SST)** representa a variação total de Y em torno da média.

$$SQ_{Total} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

$$SQ_{Total} = 495.38950$$

- **SQRegressão (SSR)** mede a parte da variação explicada pelo modelo (pelos preditores).

$$SQ_{Reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 =$$

$$SQ_{Reg} = 396.98461$$

- **SQErro (SSE)** representa a variação não explicada pelo modelo, ou seja, o ruído ou erro aleatório.

$$SQ_{Erro} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 =$$

$$SQ_{Erro} = 98.40489$$

4) Preencha a tabela ANOVA a seguir:

Fonte	gl	SQ	QM	F	Pr..F.
Regressão	3	396.98461	132.32820	21.51571	1e-05
Erro	16	98.40489	6.15031	NA	NA
Total	19	495.38950	NA	NA	NA

A partir desta tabela ANOVA, faça um teste F para verificar se os coeficientes β_1 , β_2 e β_3 são todos não nulos. Quais são as hipóteses sendo testadas, a estatística do teste e conclusão.

Teste F Global da Regressão

A partir da tabela ANOVA, realiza-se o teste F para verificar se os coeficientes β_1 , β_2 e β_3 são todos nulos.

As hipóteses do teste são:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \\ H_1 : \text{ao menos um } \beta_j \neq 0 \end{cases}$$

Comparando o modelo nulo $Y \sim 1$ com o modelo completo $Y \sim X_1 + X_2 + X_3$, obtém-se:

- $gl_{\text{Regressão}} = 3$, $SQ_{\text{Regressão}} = 396,98$, $QM_{\text{Regressão}} = 132,33$
- $gl_{\text{Erro}} = 16$, $SQ_{\text{Erro}} = 98,40$, $QM_{\text{Erro}} = 6,15$
- $gl_{\text{Total}} = 19$, $SQ_{\text{Total}} = 495,39$

A estatística do teste é:

$$F = \frac{QM_{\text{Regressão}}}{QM_{\text{Erro}}} = 21,516$$

com p-valor = $7,343 \times 10^{-6}$.

Como o p-valor é muito pequeno ($p < 0,05$), **rejeita-se** H_0 e conclui-se que o modelo com os três preditores é **globalmente significativo**, ou seja, pelo menos um dos coeficientes β_j é diferente de zero.

- 5) Usando a função `summary()`, obtenha a tabela dos coeficientes, juntamente com os testes t para cada coeficiente. Se você tivesse que escolher um preditor para excluir do modelo, qual seria? Justifique.

```
summary(modelo)$coefficients
```

```
##              Estimate Std. Error  t value Pr(>|t|)
## (Intercept) 117.084695  99.782403  1.173400 0.2578078
## X1           4.334092   3.015511  1.437266 0.1699111
## X2          -2.856848   2.582015 -1.106441 0.2848944
## X3          -2.186060   1.595499 -1.370142 0.1895628
```

Cada teste t avalia a hipótese:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0,$$

condicionalmente aos demais preditores do modelo.

Esses testes avaliam o **efeito parcial** de cada variável sobre Y .

Pela tabela de coeficientes, observa-se que todos os preditores (X_1, X_2, X_3) apresentam p-valores acima de 0,05, indicando que **nenhum deles é individualmente significativo** quando os outros estão no modelo. No entanto, o teste F global mostrou que o modelo como um todo é significativo, o que sugere **presença de multicolinearidade**.

Sabemos que X_1 e X_2 possuem **alta correlação** ($r = 0,92$), o que infla os erros-padrão e reduz a significância dos coeficientes individuais.

Se fosse necessário excluir um preditor, o mais apropriado seria **remover** X_2 , pois :

- Apresenta o **maior p-valor** ($p = 0,2848944$), sendo o menos significativo
- Possui uma **alta correlação com** X_1 , fornecendo informação redundante
- Essa exclusão tende a **reduzir a multicolinearidade** e tornar o modelo mais estável.

Portanto, considerando tanto os testes t quanto a correlação entre preditores, o preditor X_2 seria o mais adequado para ser removido do modelo.

- 6) Construa um teste para verificar se $\beta_2 = 0$ usando as somas extras de quadrados, ou seja, verifique se o efeito da variável X_2 é significativo para explicar Y , considerando que X_1 e X_3 estão no modelo.

```
# Modelos reduzido e completo
mod_red  <- lm(Y ~ X1 + X3, data = dados)      # sem X2
mod_full <- lm(Y ~ X1 + X2 + X3, data = dados) # com X2

# Teste por soma extra de quadrados para X2 | X1, X3
anova(mod_red, mod_full)
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ X1 + X3
## Model 2: Y ~ X1 + X2 + X3
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      17 105.934
## 2      16  98.405   1    7.5293 1.2242 0.2849
```

```
# Entrega: Df, RSS (SSE), Sum of Sq (SSE_red - SSE_full), F y p-value
```

```
# (Equivalente al t de X2 en summary(mod_full): t^2 = F con df1=1)
```

```
summary(mod_full)$coefficients["X2", ]
```

```
## Estimate Std. Error t value Pr(>|t|)
## -2.8568479 2.5820153 -1.1064411 0.2848944
```

O modelo 2, que é o modelo completo, vs o modelo reduzido, que é o modelo 1. A hipótese do teste parcial, que é o efeito de X_2 dado X_1 e X_3 , é $H_0 : \beta_2 = 0$ vs $H_1 : \beta_2 \neq 0$. O estatístico de prova F por somas extras de quadrados é:

$$F = \frac{(SSE_r - SSE_f)/(p_f - p_r)}{MSE_f} = \frac{SSE_r - SSE_f}{MSE_f}$$

$$F \sim F(1, n - p_f)$$

Onde $p_f = 4$ (o intercepto + 3 betas) e $p_r = 3$. Dos cálculos da tabela pode-se ver que o modelo completo tem $SSE_f = 98,4049$ e $MSE_f = 6,1503$. No modelo reduzido, a soma extra de X_2 dado X_1 e X_3 é a diferença $SSE_r - SSE_f = 7,5301$. Então o $F_{\text{parcial}}(X_2 | X_1, X_3) = 7,5301/6,1502 = 1,224$. Com um p-valor de 0,285, como $\alpha = 0,05$, a decisão é que não se rejeita H_0 . Por conseguinte, a conclusão é que o efeito de X_2 não é significativo para explicar Y , considerando que X_1 e X_3 já estão no modelo.

7) O teste F do item anterior é equivalente a qual teste t do item 5)? Qual a relação entre as estatísticas do teste? Interprete esse resultado.

O teste F parcial realizado no item anterior para testar

$$H_0 : \beta_2 = 0 \quad \text{versus} \quad H_1 : \beta_2 \neq 0$$

é **equivalente ao teste t para o coeficiente de X_2** apresentado na tabela do `summary(modelo)` do item 5.

```
summary(modelo)
```

```
##
## Call:
## lm(formula = Y ~ X1 + X2 + X3, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7263 -1.6111  0.3923  1.4656  4.1277
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   117.085      99.782    1.173   0.258
## X1              4.334       3.016    1.437   0.170
## X2             -2.857       2.582   -1.106   0.285
## X3             -2.186       1.595   -1.370   0.190
##
## Residual standard error: 2.48 on 16 degrees of freedom
## Multiple R-squared:  0.8014, Adjusted R-squared:  0.7641
## F-statistic: 21.52 on 3 and 16 DF,  p-value: 7.343e-06
```

Relação entre as Estatísticas do Teste

- No teste t do item 5, para X_2 , obtivemos:
- **t value = -1.1064411**
- **$\Pr(> |t|) = 0.2848944$**

No teste F parcial do item anterior, obtivemos:

-F = 1.224

-p-value = 0.285

A relação matemática entre as estatísticas é :

$$F = t^2$$

Calculando

$$(1.1064411)^2 = 1.224 = F$$

Além disso, os p-valores são essencialmente idênticos (0.2849 vs. 0.285), considerando arredondamentos.

- 8) Obtenha a tabela ANOVA que decompõe a SQ_{Reg} em $SQ(X_2)$, $SQ(X_1|X_2)$ e $SQ(X_3|X_1, X_2)$. Como executar isso no R?

```
# Modelo com outra ordem: X2,X1,X3
mod_ord <- lm(Y ~ X2 + X1 + X3, data = dados)

# ANOVA Tipo I (secuencial) em ese orden
anova(mod_ord)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## X2         1 381.97   381.97  62.1052 6.735e-07 ***
## X1         1   3.47    3.47   0.5647   0.4633
## X3         1  11.55   11.55   1.8773   0.1896
## Residuals 16  98.40    6.15
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Neste item fizemos a ANOVA sequencial (Tipo I) com a ordem $X_2 \rightarrow X_1 \rightarrow X_3$, decompondo SQ_{Reg} em $SQ(X_2) = 381,966$, $SQ(X_1 | X_2) = 3,473$ e $SQ(X_3 | X_1, X_2) = 11,546$ (somam 396,985, que coincide com SQ_{Reg}); o resíduo é $SQ_E = 98,405$ e $QM_E = 6,150$ ($n = 20$). Ao contrastar cada passo, X_2 é altamente significativo ($F \approx 62,11$, $p \ll 0,001$), enquanto $X_1 | X_2$ ($F \approx 0,56$, $p \approx 0,463$) e $X_3 | X_1, X_2$ ($F \approx 1,88$, $p \approx 0,190$) não resultam significativos. A leitura chave é que, pela colinearidade alta entre X_1 e X_2 , o preditor que entra primeiro (aqui X_2) “leva” quase toda a variação explicada; por isso esta ANOVA depende da ordem e, se quisermos avaliar aportes parciais independentes da ordem, devemos olhar também os t-tests (Tipo II/III) além desta partição.

- 9) Teste se ambos os preditores X_1 e X_3 podem ser excluídos do modelo, dado que X_2 é mantido no modelo. Escreva as hipóteses, estatística do teste e conclusão para um nível de significância $\alpha = 0.05$.


```

# Modelo reduzido (apenas X2)
modelo_reduzido <- lm(Y ~ X2, data = dados)

# Modelo completo (X2, X1 e X3)
modelo_completo <- lm(Y ~ X2 + X1 + X3, data = dados)

# Teste F parcial
teste_F <- anova(modelo_reduzido, modelo_completo)
print(teste_F)

```

```

## Analysis of Variance Table
##
## Model 1: Y ~ X2
## Model 2: Y ~ X2 + X1 + X3
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      18 113.424
## 2      16  98.405  2    15.019 1.221  0.321

```

Teste de Exclusão Conjunta de X_1 e X_3 dado X_2

$$H_0 : \beta_1 = \beta_3 = 0 \quad \text{versus} \quad H_1 : \beta_1 \neq 0 \quad \text{ou} \quad \beta_3 \neq 0$$

Execução do Teste no R

```

# Modelo reduzido (apenas X2)
modelo_X2 <- lm(Y ~ X2, data = dados)

# Modelo completo (X2 + X1 + X3)
modelo_completo <- lm(Y ~ X2 + X1 + X3, data = dados)

# Teste F parcial
teste_F <- anova(modelo_reduzido, modelo_completo)
print(teste_F)

```

```

## Analysis of Variance Table
##
## Model 1: Y ~ X2
## Model 2: Y ~ X2 + X1 + X3
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      18 113.424
## 2      16  98.405  2    15.019 1.221  0.321

```

Conclusão para $\alpha = 0.05$

Com base no resultado do teste F :

- Se **p-valor** < **0.05** : Rejeitamos H_0 e concluímos que pelo menos uma entre X_1 e X_3 contribui significativamente para o modelo, mesmo quando X_2 está presente.
- Se **p-valor** > **0.05** : Não rejeitamos H_0 e concluímos que ambas as variáveis X_1 e X_3 melhora significativamente a capacidade do modelo de explicar Y além do que já é explicado por X_2 sozinho

- 10) Encontre o coeficiente de determinação R^2 da regressão linear simples quando apenas X_2 está no modelo. Interprete.

```
r2 = summary(modelo_X2)$r.squared
```

Encontramos um $R^2 = 0.77$ ou seja X_2 sozinho explica aproximadamente 77% da variação em Y . A circunferência da coxa (X_2) é um bom preditor individual do percentual de gordura corporal

- 11) Encontre o coeficiente de determinação múltiplo e ajustado, R^2 e R^2_{adj} , respectivamente, quando os três preditores estão no modelo. Interprete-os.

```
R2_multiplo <- summary(modelo)$r.squared  
R2_ajustado <- summary(modelo)$adj.r.squared
```

Poder Explicativo do Modelo Múltiplo:

- O modelo com três preditores explica 80% da variação em Y
- O modelo captura a maior parte da variabilidade no percentual de gordura corporal

Comparação com Modelos Simples:

- O modelo múltiplo oferece ganho modesto em relação ao melhor modelo simples (X_2 sozinho: $R^2 = 0.7744$)
- Isso sugere sobreposição de informação entre os preditores (*multicolinearidade*)

- 12) Calcule o coeficiente de determinação de Y com X_1 e X_3 , dado que X_2 está no modelo. Interprete.

```
# Modelo com apenas X2 (modelo reduzido)  
modelo_X2 <- lm(Y ~ X2, data = dados)  
  
# Modelo com X2, X1 e X3 (modelo completo)  
modelo_completo <- lm(Y ~ X2 + X1 + X3, data = dados)  
  
# Somas de quadrados dos resíduos  
SSE_reduzido <- sum(residuals(modelo_X2)^2)  
SSE_completo <- sum(residuals(modelo_completo)^2)  
  
# Coeficiente de determinação parcial  
R2_parcial <- (SSE_reduzido - SSE_completo) / SSE_reduzido  
  
cat("SSE (modelo com X2):", round(SSE_reduzido, 4), "\n")
```

```
## SSE (modelo com X2): 113.4237
```

```
cat("SSE (modelo com X1, X2, X3):", round(SSE_completo, 4), "\n")
```

```
## SSE (modelo com X1, X2, X3): 98.4049
```

```
cat("Coeficiente de determinação parcial  $R^2(Y \sim X1, X3 \mid X2)$ :", round(R2_parcial, 4), "\n")
```

```
## Coeficiente de determinação parcial  $R^2(Y \sim X1, X3 \mid X2)$ : 0.1324
```

```
# Método alternativo usando  $R^2$ 
R2_X2 <- summary(modelo_X2)$r.squared
R2_completo <- summary(modelo_completo)$r.squared
R2_parcial_alt <- (R2_completo - R2_X2) / (1 - R2_X2)

cat("Verificação alternativa:", round(R2_parcial_alt, 4), "\n")
```

```
## Verificação alternativa: 0.1324
```

- 13) Depois de toda essa análise, ajuste o modelo que você considera mais apropriado para explicar a taxa de gordura corporal.

Comparação de Modelos

```
# Modelos alternativos considerados
modelo_X2 <- lm(Y ~ X2, data = dados) # Melhor preditor individual
modelo_X1_X2 <- lm(Y ~ X1 + X2, data = dados) # Duas melhores variáveis
modelo_X1_X3 <- lm(Y ~ X1 + X3, data = dados) # Alternativa sem X2
modelo_completo <- lm(Y ~ X1 + X2 + X3, data = dados) # Modelo completo

# Tabela comparativa
comparacao_modelos <- data.frame(
  Modelo = c("Y ~ X2", "Y ~ X1 + X2", "Y ~ X1 + X3", "Y ~ X1 + X2 + X3"),
  R2 = c(summary(modelo_X2)$r.squared,
          summary(modelo_X1_X2)$r.squared,
          summary(modelo_X1_X3)$r.squared,
          summary(modelo_completo)$r.squared),
  R2_ajustado = c(summary(modelo_X2)$adj.r.squared,
                  summary(modelo_X1_X2)$adj.r.squared,
                  summary(modelo_X1_X3)$adj.r.squared,
                  summary(modelo_completo)$adj.r.squared),
  AIC = c(AIC(modelo_X2),
           AIC(modelo_X1_X2),
           AIC(modelo_X1_X3),
           AIC(modelo_completo))
)

print(comparacao_modelos)
```

```
##           Modelo           R2 R2_ajustado      AIC
## 1           Y ~ X2 0.7710414  0.7583215 97.46550
## 2      Y ~ X1 + X2 0.7780518  0.7519403 98.84355
## 3      Y ~ X1 + X3 0.7861598  0.7610022 98.09925
## 4 Y ~ X1 + X2 + X3 0.8013586  0.7641133 98.62471
```

```

# Modelos alternativos considerados
modelo_X2 <- lm(Y ~ X2, data = dados) # Melhor preditor individual
modelo_X1_X2 <- lm(Y ~ X1 + X2, data = dados) # Duas melhores variáveis
modelo_X1_X3 <- lm(Y ~ X1 + X3, data = dados) # Alternativa sem X2
modelo_completo <- lm(Y ~ X1 + X2 + X3, data = dados) # Modelo completo

# Tabela comparativa
comparacao_modelos <- data.frame(
  Modelo = c("Y ~ X2", "Y ~ X1 + X2", "Y ~ X1 + X3", "Y ~ X1 + X2 + X3"),
  R2 = c(
    summary(modelo_X2)$r.squared,
    summary(modelo_X1_X2)$r.squared,
    summary(modelo_X1_X3)$r.squared,
    summary(modelo_completo)$r.squared
  ),
  R2_ajustado = c(
    summary(modelo_X2)$adj.r.squared,
    summary(modelo_X1_X2)$adj.r.squared,
    summary(modelo_X1_X3)$adj.r.squared,
    summary(modelo_completo)$adj.r.squared
  ),
  AIC = c(
    AIC(modelo_X2),
    AIC(modelo_X1_X2),
    AIC(modelo_X1_X3),
    AIC(modelo_completo)
  )
)

# Arredondar valores para melhor apresentação
comparacao_modelos$R2 <- round(comparacao_modelos$R2, 4)
comparacao_modelos$R2_ajustado <- round(comparacao_modelos$R2_ajustado, 4)
comparacao_modelos$AIC <- round(comparacao_modelos$AIC, 2)

# Adicionar coluna de recomendação
comparacao_modelos$Recomendacao <- ifelse(comparacao_modelos$Modelo == "Y ~ X2",
                                           "RECOMENDADO", "")

# Ordenar por R² ajustado (decrecente)
comparacao_modelos <- comparacao_modelos[order(-comparacao_modelos$R2_ajustado), ]

# Exibir tabela
print(comparacao_modelos, row.names = FALSE)

```

```

##           Modelo      R2 R2_ajustado  AIC Recomendacao
## Y ~ X1 + X2 + X3 0.8014      0.7641 98.62
##           Y ~ X1 + X3 0.7862      0.7610 98.10
##           Y ~ X2 0.7710      0.7583 97.47 RECOMENDADO
##           Y ~ X1 + X2 0.7781      0.7519 98.84

```

```
library(knitr)
```

```
# Criar tabela formatada para o relatório
```

```
kable(comparacao_modelos,
      align = c('l', 'r', 'r', 'r', 'l'),
      col.names = c('Modelo', 'R²', 'R² Ajustado', 'AIC', 'Recomendação'),
      caption = "Tabela Comparativa dos Modelos de Regressão para Predição do Percentual de Gordura Corp")
```

Table 2: Tabela Comparativa dos Modelos de Regressão para Predição do Percentual de Gordura Corporal

	Modelo	R²	R² Ajustado	AIC	Recomendação
4	Y ~ X1 + X2 + X3	0.8014	0.7641	98.62	
3	Y ~ X1 + X3	0.7862	0.7610	98.10	
1	Y ~ X2	0.7710	0.7583	97.47	RECOMENDADO
2	Y ~ X1 + X2	0.7781	0.7519	98.84	

14) Faça a análise de resíduos com para este modelo que você ajustou no item 13.

```
# Modelo final selecionado
modelo_final <- lm(Y ~ X2, data = dados)

# Obter os resíduos e valores ajustados
residuos <- residuals(modelo_final)
valores_ajustados <- fitted(modelo_final)

par(mfrow = c(2, 3), mar = c(4, 4, 2, 2))

# 1. Resíduos vs Valores Ajustados
plot(valores_ajustados, residuos,
     xlab = "Valores Ajustados", ylab = "Resíduos",
     main = "Resíduos vs Valores Ajustados",
     pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2)
lines(lowess(valores_ajustados, residuos), col = "darkgreen", lwd = 2)

# 2. Q-Q Plot para Normalidade
qqnorm(residuos, main = "Q-Q Plot dos Resíduos", pch = 19, col = "blue")
qqline(residuos, col = "red", lwd = 2)

# 3. Scale-Location Plot
residuos_padronizados <- rstandard(modelo_final)
plot(valores_ajustados, sqrt(abs(residuos_padronizados)),
     xlab = "Valores Ajustados",
     main = "Scale-Location Plot", pch = 19, col = "blue")
lines(lowess(valores_ajustados, sqrt(abs(residuos_padronizados))),
     col = "darkgreen", lwd = 2)


# 4. Resíduos vs Variável Preditora (X2)
plot(dados$X2, residuos,
     xlab = "Circunferência da Coxa (X2)", ylab = "Resíduos",
     main = "Resíduos vs X2", pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2)
lines(lowess(dados$X2, residuos), col = "darkgreen", lwd = 2)
```

```

# 5. Histograma dos Resíduos
hist(resíduos, breaks = 10, freq = FALSE,
     xlab = "Resíduos", main = "Distribuição dos Resíduos",
     col = "lightblue", border = "black")
curve(dnorm(x, mean = mean(resíduos), sd = sd(resíduos)),
     add = TRUE, col = "red", lwd = 2)

# 6. Resíduos vs Ordem de Coleta
plot(1:length(resíduos), resíduos, type = "b",
     xlab = "Ordem de Coleta", ylab = "Resíduos",
     main = "Resíduos vs Ordem", pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2)

```



```

par(mfrow = c(1, 1))

# Teste de normalidade (Shapiro-Wilk)
teste_normalidade <- shapiro.test(resíduos)
cat("Teste de Normalidade de Shapiro-Wilk:\n")

## Teste de Normalidade de Shapiro-Wilk:

cat("W =", round(teste_normalidade$statistic, 4), "\n")

```

```
## W = 0.974
```

```
cat("p-valor =", round(teste_normalidade$p.value, 4), "\n")
```

```
## p-valor = 0.8363
```

```
# Teste de homocedasticidade (Breusch-Pagan)
library(lmtest)
teste_homocedasticidade <- bptest(modelo_final)
cat("\nTeste de Homocedasticidade de Breusch-Pagan:\n")
```

```
##
## Teste de Homocedasticidade de Breusch-Pagan:
```

```
cat("BP =", round(teste_homocedasticidade$statistic, 4), "\n")
```

```
## BP = 0.8583
```

```
cat("p-valor =", round(teste_homocedasticidade$p.value, 4), "\n")
```

```
## p-valor = 0.3542
```

```
# Teste de independência dos resíduos (Durbin-Watson)
teste_independencia <- dwtest(modelo_final)
cat("\nTeste de Independência de Durbin-Watson:\n")
```

```
##
## Teste de Independência de Durbin-Watson:
```

```
cat("DW =", round(teste_independencia$statistic, 4), "\n")
```

```
## DW = 2.5001
```

```
cat("p-valor =", round(teste_independencia$p.value, 4), "\n")
```

```
## p-valor = 0.8604
```

```
# Calcular medidas de influência
leverage <- hatvalues(modelo_final)
residuos_student <- rstudent(modelo_final)
cook_distance <- cooks.distance(modelo_final)

# Definir pontos de corte
n <- nrow(dados)
p <- length(coef(modelo_final))
limite_leverage <- 2 * p / n
limite_cook <- 4 / (n - p)

# Identificar observações influentes
obs_influentes <- which(leverage > limite_leverage |
                        abs(residuos_student) > 2 |
                        cook_distance > limite_cook)

cat("Pontos de corte:\n")
```

```
## Pontos de corte:
```

```
cat("Leverage >", round(limite_leverage, 3), "\n")
```

```
## Leverage > 0.2
```

```
cat("Cook's Distance >", round(limite_cook, 3), "\n")
```

```
## Cook's Distance > 0.222
```

```
cat("|Resíduos Studentizados| > 2\n\n")
```

```
## |Resíduos Studentizados| > 2
```

```
cat("Observações potencialmente influentes:\n")
```


```
## Observações potencialmente influentes:
```

```
if(length(obs_influentes) > 0) {  
  dados_influentes <- data.frame(  
    Observacao = obs_influentes,  
    Leverage = round(leverage[obs_influentes], 3),  
    Residuos_Student = round(residuos_student[obs_influentes], 3),  
    Cook_Distance = round(cook_distance[obs_influentes], 3)  
  )  
  print(dados_influentes)  
} else {  
  cat("Nenhuma observação influente identificada\n")  
}
```

```
##      Observacao Leverage Residuos_Student Cook_Distance  
## 5              5      0.205             0.169          0.004  
## 13             13      0.092            -2.037          0.179
```

```
plot(cook_distance, type = "h",  
     xlab = "Índice da Observação", ylab = "Distância de Cook",  
     main = "Distância de Cook para Identificação de Pontos Influentes",  
     ylim = c(0, max(cook_distance) * 1.1))
```


Distância de Cook para Identificação de Pontos Influentes



```
# abline(h = limite_cook, col = "red", lwd = 2, lty = 2)
# text(which(cook_distance > limite_cook),
#       cook_distance[which(cook_distance > limite_cook)],
#       labels = which(cook_distance > limite_cook),
#       pos = 3, col = "red")

#' ### Estatísticas Descritivas dos Resíduos

estatisticas_residuos <- data.frame(
  Estatistica = c("Média", "Desvio Padrão", "Mínimo", "Q1", "Mediana", "Q3", "Máximo"),
  Valor = c(round(mean(residuos), 4),
            round(sd(residuos), 4),
            round(min(residuos), 4),
            round(quantile(residuos, 0.25), 4),
            round(median(residuos), 4),
            round(quantile(residuos, 0.75), 4),
            round(max(residuos), 4))
)

print(estatisticas_residuos, row.names = FALSE)
```

```
##   Estatistica  Valor
##      Média  0.0000
## Desvio Padrão  2.4433
```

##	Mínimo	-4.4949
##	Q1	-1.5671
##	Mediana	0.1241
##	Q3	1.3362
##	Máximo	4.4084