

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 04 - 2S2025 - 22/10/2025

Introdução

Nesta atividade vocês irão trabalhar os seguintes conceitos:

- regressão linear múltipla;
- tabela ANOVA;
- soma extra de quadrados para testar hipóteses sobre os coeficientes;
- coeficientes de determinação múltiplo e parcial.


Atividade 1: Gordura Corporal

Considere os dados sobre gordura corporal em anexo. Esses são os mesmos dados que foram utilizados nos slides apresentados em aula. O interesse está em explicar a relação entre a taxa de gordura corporal (Y) e três medidas corporais:

- $X1$: espessura da dobra cutânea do tríceps;
- $X2$: circunferência da coxa; e
- $X3$: circunferência do meio do braço.


- 1) Faça uma matriz com os gráficos de dispersão entre os pares de variáveis e também as correlações. Qual a correlação das preditoras com a variável resposta? As variáveis preditoras são correlacionadas entre si?

```
dados <- read.table("fat.txt",  
                    col.names = c("X1", "X2", "X3", "Y"))
```



```
matriz_cor <- round(cor(dados),2)

ggcorrplot(
  method = "square",show.diag = TRUE,matriz_cor,type = "upper",lab = TRUE,lab_size = 2.5,
  tl.cex = 12,tl.srt = 45,digits = 2 ,colors = cores_base,outline.color = "black",
  title = "Matriz de Correlação" + theme(plot.title = element_text(hjust = 0.5,
  face = "bold", color = "#1A4A7A"),axis.text.x = element_text(angle = 45, hjust = 1))
```



```
corX1_Y = cor(dados$X1,dados$Y)
corX2_Y = cor(dados$X2,dados$Y)
corX1_X2 = cor(dados$X1,dados$X2)
```

Análise da Matriz de Correlação

Observa-se que as variáveis preditoras **X1** e **X2** apresentam forte correlação com a variável resposta **Y** (0.84 e 0.88, respectivamente), indicando que ambas possuem grande poder explicativo em relação a **Y**.

No entanto, nota-se também que **X1** e **X2** são altamente correlacionadas entre si (0.92), o que sugere a presença de **multicolinearidade**. Essa forte relação entre os dois preditores pode causar redundância de informação no modelo e dificultar a interpretação dos coeficientes.

Por outro lado, a variável **X3** apresenta correlação baixa com **Y** (0.14) e fraca correlação com as demais preditoras, indicando que ela pode trazer informação complementar ao modelo sem contribuir para o problema de multicolinearidade.

2) Ajuste um modelo de regressão linear múltipla usando X_1 , X_2 e X_3 como preditores, ou seja,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i.$$

Reporte as estimativas dos coeficientes e interprete-os. Qual é função de regressão estimada?

```
# Ajustando o modelo com os preditores X1,X2,X3
modelo = lm(Y ~ X1+X2+X3,data = dados)
summary(modelo)

##
## Call:
## lm(formula = Y ~ X1 + X2 + X3, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7263 -1.6111  0.3923  1.4656  4.1277
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   117.085      99.782   1.173   0.258
## X1              4.334       3.016   1.437   0.170
## X2             -2.857       2.582  -1.106   0.285
## X3             -2.186       1.595  -1.370   0.190
##
## Residual standard error: 2.48 on 16 degrees of freedom
## Multiple R-squared:  0.8014, Adjusted R-squared:  0.7641
## F-statistic: 21.52 on 3 and 16 DF,  p-value: 7.343e-06

# Escrevendo a funcao de regressao linear com 4 casas decimais
b <- coef(modelo)
cat(sprintf("\nY-hat = %.4f + %.4f*X1 + %.4f*X2 + %.4f*X3\n",
           b[1], b[2], b[3], b[4]))

## Y-hat = 117.0847 + 4.3341*X1 + -2.8568*X2 + -2.1861*X3
```

Análise do Modelo de Regressão com Preditores X_1 , X_2 e X_3

O modelo de regressão linear múltipla ajustado é representado por:

$$\hat{Y} = 117.08 - 4.33 \cdot X_1 - 2.85 \cdot X_2 - 2.18 \cdot X_3$$

Interpretação Detalhada dos Coeficientes

Este modelo de regressão linear múltipla busca explicar o percentual de gordura corporal (Y) a partir de três medidas corporais :

- X_1 : Espessura da dobra cutânea do tríceps
- X_2 : Circunferência da coxa
- X_3 : Circunferência do meio do braço.

Cada coeficiente β_j representa o efeito parcial do seu preditor sobre Y , mantendo os outros preditores constantes. Da análise, o intercepto β_0 , quando $X_1 = X_2 = X_3 = 0$, é de 117,0847. O coeficiente de X_1 é $\beta_1 = 4,3341$; isto é, quando X_2 e X_3 são fixos, um aumento de 1 unidade em X_1 produz, em média, um aumento de 4,33 unidades no percentual de gordura corporal. O coeficiente de X_2 é $\beta_2 = -2,8568$; isto é, quando X_1 e X_3 são fixos, um aumento de 1 unidade em X_2 se associa a uma diminuição de 2,86 unidades na gordura corporal. Ao manter fixo X_1 , uma coxa maior pode indicar uma maior massa corporal não gorda. Além disso, a forte correlação entre X_1 e X_2 , que se pode ver do inciso anterior e que é de 0,92, gera colinearidade, o que pode inverter sinais. O coeficiente de X_3 é $\beta_3 = -2,1861$; isto é, quando X_1 e X_2 são fixos, um aumento de 1 unidade em X_3 se associa a uma diminuição de 2,19 unidades na gordura corporal.

Nenhum dos coeficientes tem p-valor < 0.05, então nenhum preditor é estatisticamente significativo individualmente nesse modelo (ao nível de 5%).

3) Obtenha a tabela ANOVA para o modelo ajustado usando os 3 preditores. Explique as somas de quadrados apresentados nesta tabela ANOVA.

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## X1         1 352.27  352.27 57.2768 1.131e-06 ***
## X2         1  33.17   33.17  5.3931 0.03373 *
## X3         1  11.55   11.55  1.8773 0.18956
## Residuals 16  98.40    6.15
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ 1
## Model 2: Y ~ X1 + X2 + X3
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1       19 495.39
## 2       16  98.40  3   396.98 21.516 7.343e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A ANOVA (Análise de Variância) na regressão serve para decompor a variabilidade total de Y (a variável resposta) em duas partes:

$$SQ_{Total} = SQ_{Regressao} + SQ_{Erro}$$

Ou seja as **somas de quadrados** quantificam a variação da variável resposta Y :

- **SQTotal (SST)** representa a variação total de Y em torno da média.

$$SQ_{Total} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

$$SQ_{Total} = 495.38950$$

- **SQRegressão (SSR)** mede a parte da variação explicada pelo modelo (pelos preditores).

$$SQ_{Reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 =$$

$$SQ_{Reg} = 396.98461$$

- **SQErro (SSE)** representa a variação não explicada pelo modelo, ou seja, o ruído ou erro aleatório.

$$SQ_{Erro} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 =$$

$$SQ_{Erro} = 98.40489$$

4) Preencha a tabela ANOVA a seguir:

Fonte	gl	SQ	QM	F	Pr..F.
Regressão	3	396.98461	132.32820	21.51571	1e-05
Erro	16	98.40489	6.15031	NA	NA
Total	19	495.38950	NA	NA	NA

A partir desta tabela ANOVA, faça um teste F para verificar se os coeficientes β_1 , β_2 e β_3 são todos não nulos. Quais são as hipóteses sendo testadas, a estatística do teste e conclusão.

Teste F Global da Regressão

A partir da tabela ANOVA, realiza-se o teste F para verificar se os coeficientes β_1 , β_2 e β_3 são todos nulos.

As hipóteses do teste são:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \\ H_1 : \text{ao menos um } \beta_j \neq 0 \end{cases}$$

Comparando o modelo nulo $Y \sim 1$ com o modelo completo $Y \sim X_1 + X_2 + X_3$, obtém-se:

- $gl_{\text{Regressão}} = 3$, $SQ_{\text{Regressão}} = 396,98$, $QM_{\text{Regressão}} = 132,33$
- $gl_{\text{Erro}} = 16$, $SQ_{\text{Erro}} = 98,40$, $QM_{\text{Erro}} = 6,15$
- $gl_{\text{Total}} = 19$, $SQ_{\text{Total}} = 495,39$

A estatística do teste é:

$$F = \frac{QM_{\text{Regressão}}}{QM_{\text{Erro}}} = 21,516$$

com p-valor = $7,343 \times 10^{-6}$.

Como o p-valor é muito pequeno ($p < 0,05$), **rejeita-se** H_0 e conclui-se que o modelo com os três preditores é **globalmente significativo**, ou seja, pelo menos um dos coeficientes β_j é diferente de zero.

- 5) Usando a função `summary()`, obtenha a tabela dos coeficientes, juntamente com os testes t para cada coeficiente. Se você tivesse que escolher um preditor para excluir do modelo, qual seria? Justifique.

```
summary(modelo)$coefficients
```

```
##              Estimate Std. Error  t value Pr(>|t|)
## (Intercept) 117.084695  99.782403  1.173400 0.2578078
## X1           4.334092   3.015511  1.437266 0.1699111
## X2          -2.856848   2.582015 -1.106441 0.2848944
## X3          -2.186060   1.595499 -1.370142 0.1895628
```

Cada teste t avalia a hipótese:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0,$$

condicionalmente aos demais preditores do modelo.

Esses testes avaliam o **efeito parcial** de cada variável sobre Y .

Pela tabela de coeficientes, observa-se que todos os preditores (X_1, X_2, X_3) apresentam p-valores acima de 0,05, indicando que **nenhum deles é individualmente significativo** quando os outros estão no modelo. No entanto, o teste F global mostrou que o modelo como um todo é significativo, o que sugere **presença de multicolinearidade**.

Sabemos que X_1 e X_2 possuem **alta correlação** ($r = 0,92$), o que infla os erros-padrão e reduz a significância dos coeficientes individuais.

Se fosse necessário excluir um preditor, o mais apropriado seria **remover** X_2 , pois :

- Apresenta o **maior p-valor** ($p = 0,2848944$), sendo o menos significativo
- Possui uma **alta correlação com** X_1 , fornecendo informação redundante
- Essa exclusão tende a **reduzir a multicolinearidade** e tornar o modelo mais estável.

Portanto, considerando tanto os testes t quanto a correlação entre preditores, o preditor X_2 seria o mais adequado para ser removido do modelo.

- 6) Construa um teste para verificar se $\beta_2 = 0$ usando as somas extras de quadrados, ou seja, verifique se o efeito da variável X_2 é significativo para explicar Y , considerando que X_1 e X_3 estão no modelo.

```
# Modelos reduzido e completo
mod_red  <- lm(Y ~ X1 + X3, data = dados)      # sem X2
mod_full <- lm(Y ~ X1 + X2 + X3, data = dados) # com X2

# Teste por soma extra de quadrados para X2 | X1, X3
anova(mod_red, mod_full)
```

```
## Analysis of Variance Table
##
## Model 1: Y ~ X1 + X3
## Model 2: Y ~ X1 + X2 + X3
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      17 105.934
## 2      16  98.405   1    7.5293 1.2242 0.2849
```

```
# Entrega: Df, RSS (SSE), Sum of Sq (SSE_red - SSE_full), F y p-value
```

```
# (Equivalente al t de X2 en summary(mod_full): t^2 = F con df1=1)
```

```
summary(mod_full)$coefficients["X2", ]
```

```
## Estimate Std. Error t value Pr(>|t|)
## -2.8568479 2.5820153 -1.1064411 0.2848944
```

O modelo 2, que é o modelo completo, vs o modelo reduzido, que é o modelo 1. A hipótese do teste parcial, que é o efeito de X_2 dado X_1 e X_3 , é $H_0 : \beta_2 = 0$ vs $H_1 : \beta_2 \neq 0$. O estatístico de prova F por somas extras de quadrados é:

$$F = \frac{(SSE_r - SSE_f)/(p_f - p_r)}{MSE_f} = \frac{SSE_r - SSE_f}{MSE_f}$$

$$F \sim F(1, n - p_f)$$

Onde $p_f = 4$ (o intercepto + 3 betas) e $p_r = 3$. Dos cálculos da tabela pode-se ver que o modelo completo tem $SSE_f = 98,4049$ e $MSE_f = 6,1503$. No modelo reduzido, a soma extra de X_2 dado X_1 e X_3 é a diferença $SSE_r - SSE_f = 7,5301$. Então o $F_{\text{parcial}}(X_2 | X_1, X_3) = 7,5301/6,1502 = 1,224$. Com um p-valor de 0,285, como $\alpha = 0,05$, a decisão é que não se rejeita H_0 . Por conseguinte, a conclusão é que o efeito de X_2 não é significativo para explicar Y , considerando que X_1 e X_3 já estão no modelo.

- 7) O teste F do item anterior é equivalente a qual teste t do item 5)? Qual a relação entre as estatísticas do teste? Interprete esse resultado.

O teste F parcial realizado no item anterior para testar

$$H_0 : \beta_2 = 0 \quad \text{versus} \quad H_1 : \beta_2 \neq 0$$

é **equivalente ao teste t para o coeficiente de X_2** apresentado na tabela do `summary(modelo)` do item 5.

```
summary(modelo)
```

```
##
## Call:
## lm(formula = Y ~ X1 + X2 + X3, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.7263 -1.6111  0.3923  1.4656  4.1277
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   117.085      99.782   1.173   0.258
## X1              4.334       3.016   1.437   0.170
## X2             -2.857       2.582  -1.106   0.285
## X3             -2.186       1.595  -1.370   0.190
##
## Residual standard error: 2.48 on 16 degrees of freedom
## Multiple R-squared:  0.8014, Adjusted R-squared:  0.7641
## F-statistic: 21.52 on 3 and 16 DF,  p-value: 7.343e-06
```

Relação entre as Estatísticas do Teste

- No teste t do item 5, para X_2 , obtivemos:
- **t value = -1.1064411**
- **$\Pr(> |t|) = 0.2848944$**

No teste F parcial do item anterior, obtivemos:

-F = 1.224

-p-value = 0.285

A relação matemática entre as estatísticas é :

$$F = t^2$$

Calculando

$$(1.1064411)^2 = 1.224 = F$$

Além disso, os p -valores são essencialmente idênticos (0.2849 vs. 0.285), considerando arredondamentos.

- 8) Obtenha a tabela ANOVA que decompõe a SQ_{Reg} em $SQ(X_2)$, $SQ(X_1|X_2)$ e $SQ(X_3|X_1, X_2)$. Como executar isso no R?

```
# Modelo com outra ordem: X2,X1,X3
mod_ord <- lm(Y ~ X2 + X1 + X3, data = dados)

# ANOVA Tipo I (secuencial) em ese orden
anova(mod_ord)
```

```
## Analysis of Variance Table
##
## Response: Y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## X2         1 381.97   381.97  62.1052 6.735e-07 ***
## X1         1   3.47    3.47   0.5647  0.4633
## X3         1  11.55   11.55   1.8773  0.1896
## Residuals 16  98.40    6.15
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Neste item fizemos a ANOVA sequencial (Tipo I) com a ordem $X_2 \rightarrow X_1 \rightarrow X_3$, decompondo SQ_{Reg} em $SQ(X_2) = 381,966$, $SQ(X_1 | X_2) = 3,473$ e $SQ(X_3 | X_1, X_2) = 11,546$ (somam 396,985, que coincide com SQ_{Reg}); o resíduo é $SQ_E = 98,405$ e $QM_E = 6,150$ ($n = 20$). Ao contrastar cada passo, X_2 é altamente significativo ($F \approx 62,11$, $p \ll 0,001$), enquanto $X_1 | X_2$ ($F \approx 0,56$, $p \approx 0,463$) e $X_3 | X_1, X_2$ ($F \approx 1,88$, $p \approx 0,190$) não resultam significativos. A leitura chave é que, pela colinearidade alta entre X_1 e X_2 , o preditor que entra primeiro (aqui X_2) “leva” quase toda a variação explicada; por isso esta ANOVA depende da ordem e, se quisermos avaliar aportes parciais independentes da ordem, devemos olhar também os t -tests (Tipo II/III) além desta partição.

- 9) Teste se ambos os preditores X_1 e X_3 podem ser excluídos do modelo, dado que X_2 é mantido no modelo. Escreva as hipóteses, estatística do teste e conclusão para um nível de significância $\alpha = 0.05$.


```

# Modelo reduzido (apenas X2)
modelo_reduzido <- lm(Y ~ X2, data = dados)

# Modelo completo (X2, X1 e X3)
modelo_completo <- lm(Y ~ X2 + X1 + X3, data = dados)

# Teste F parcial
teste_F <- anova(modelo_reduzido, modelo_completo)
print(teste_F)

```

```

## Analysis of Variance Table
##
## Model 1: Y ~ X2
## Model 2: Y ~ X2 + X1 + X3
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      18 113.424
## 2      16  98.405  2    15.019 1.221  0.321

```

Teste de Exclusão Conjunta de X_1 e X_3 dado X_2

$$H_0 : \beta_1 = \beta_3 = 0 \quad \text{versus} \quad H_1 : \beta_1 \neq 0 \quad \text{ou} \quad \beta_3 \neq 0$$

Execução do Teste no R

```

# Modelo reduzido (apenas X2)
modelo_reduzido <- lm(Y ~ X2, data = dados)

# Modelo completo (X2 + X1 + X3)
modelo_completo <- lm(Y ~ X2 + X1 + X3, data = dados)

```

- 10) Encontre o coeficiente de determinação R^2 da regressão linear simples quando apenas X_2 está no modelo. Interprete.
- 11) Encontre o coeficiente de determinação múltiplo e ajustado, R^2 e R_{adj}^2 , respectivamente, quando os três preditores estão no modelo. Interprete-os.
- 12) Calcule o coeficiente de determinação de Y com X_1 e X_3 , dado que X_2 está no modelo. Interprete.
- 13) Depois de toda essa análise, ajuste o modelo que você considera mais apropriado para explicar a taxa de gordura corporal.
- 14) Faça a análise de resíduos com para este modelo que você ajustou no item 13.