

## Exercícios Teóricos

I- Considerando o modelo de regressão linear simples dado por:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad (*)$$

para  $i = 1, 2, \dots, n$ . Encontre os estimadores pelos seguintes métodos:

a) Mínimos quadrados

Queremos encontrar estimadores  $\hat{\beta}_0$  e  $\hat{\beta}_1$  tais que minimizem o nosso erro aleatório

Manipulando (\*) temos

$$y_i - (\beta_0 + \beta_1 x_i) = \varepsilon_i \quad (**)$$

Vamos elevar (\*\*) ao quadrado pois vamos precisar derivar

$$\textcircled{**} \quad [y_i - (\beta_0 + \beta_1 x_i)]^2 = \varepsilon_i^2$$

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 + \beta_1 x_i)^2$$

para encontrar o mínimo vamos derivar com respeito ao parâmetro que queremos encontrar e igualar a zero

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n \frac{\partial (y_i - \beta_0 + \beta_1 x_i)^2}{\partial \beta_0}$$

Sabemos que a derivada é um operador linear portanto a derivada da soma é a soma das derivadas

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^n 2 \cdot (y_i - \beta_0 - \beta_1 x_i) (-1)$$

Analogamente temos

$$\frac{\partial S}{\partial \beta_1} = \sum_{i=1}^n 2 \cdot (y_i - \beta_0 - \beta_1 x_i) (-x_i)$$

$$\left\{ \begin{array}{l} \frac{\partial S}{\partial \beta_0} = -2 \cdot \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \\ \frac{\partial S}{\partial \beta_1} = -2 \cdot \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0 \end{array} \right.$$

Encontrando  $\hat{\beta}_0$

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\Leftrightarrow \sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0$$

$$\Leftrightarrow n\beta_0 = \sum_{i=1}^n y_i - \beta_1 \cdot \sum_{i=1}^n x_i$$

Vamos dividir por  $n$

$$\hat{\beta}_0 = \frac{1}{n} \cdot \sum_{i=1}^n y_i - \beta_1 \cdot \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

$$\hat{\beta}_0 = \bar{y} - \beta_1 \bar{x}$$

Agora vamos encontrar  $\hat{\beta}_1$

$$\sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i - \hat{\beta}_0 \cdot \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) n \bar{x} - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} - n \hat{\beta}_1 \bar{x}^2 - \hat{\beta}_1 \sum_{i=1}^n x_i^2 = 0$$

$$\Leftrightarrow \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} - \hat{\beta}_1 \cdot \sum_{i=1}^n (x_i^2 - n \bar{x}^2) = 0$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 ; \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Identificando  $S_{xx}$  e  $S_{xy}$  e  
com muita álgebra chegamos em

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Portanto ficamos com

$$\hat{\beta}_0 = \bar{y} - \beta_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

————— ⊕ ————— ⊕ —————

b) Máxima Verossimilhança

$\epsilon_i \sim N(0, \sigma^2)$  com  $\sigma^2$  conhecido

Como  $\epsilon_i \sim N(0, \sigma^2)$  entao

$y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$  logo a função densidade de  $y_i$  é dada por

$$f(y_i | \beta_0, \beta_1, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left\{ -\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2} \right\}$$

$$L(\beta_0, \beta_1) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp \left\{ -\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2} \right\}$$

Vamos aplicar a função log para facilitar a maximização

$$\ell(\beta_0, \beta_1) = \log L(\beta_0, \beta_1)$$

não depende de  $\beta_0, \beta_1$

$$= -\frac{1}{2} \cdot n \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

$A$

$$\ell(\beta_0, \beta_1) = A - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Como conhecemos  $\sigma^2$  e  $A$  não depende de  $\beta_0$  e  $\beta_1$  temos que maximizar a log-verossimilhança é o mesmo que minimizar a soma dos quadrados o que já foi feito no item a.

Sendo assim os dois métodos resultam nos mesmos estimadores

Estimadores para  $\hat{\beta}_0$  e  $\hat{\beta}_1$

via máxima verossimilhança

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\# \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \#$$

Demonstre as propriedades dos estimadores de mínimos quadrados  $\hat{\beta}_0$  e  $\hat{\beta}_1$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\text{Seja } a_i = \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \text{ podemos}$$

rescrever  $\hat{\beta}_1$  como sendo

$$\hat{\beta}_1 = \sum_{i=1}^n a_i y_i$$

é com isso temos

$$\mathbb{E}(\hat{\beta}_1) = \mathbb{E}\left(\sum_{i=1}^n a_i y_i\right)$$

→ esperança é linear

$$= \sum_{i=1}^n a_i \mathbb{E}(y_i) = \sum_{i=1}^n a_i (\beta_0 + \beta_1 x_i)$$

$$= \underbrace{\beta_0 \sum_{i=1}^n a_i}_{0} + \underbrace{\beta_1 \cdot \sum_{i=1}^n a_i x_i}_{+}$$

$$= \beta_1 \quad \text{em segui} \quad \boxed{\mathbb{E}(\hat{\beta}_1) = \beta_1}$$

$$\text{Var}(\hat{\beta}_1) = \text{Var}\left(\sum_{i=1}^n a_i y_i\right)$$

$$= \sum_{i=1}^n a_i^2 \text{Var}(y_i)$$

$$= \sum_{i=1}^n a_i^2 \sigma^2 = \sigma^2 \cdot \sum_{i=1}^n a_i^2$$

$$= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{S_{xx}}$$

$\therefore \boxed{\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}}$

Temos  $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

$$\begin{aligned}\mathbb{E}(\hat{\beta}_0) &= \mathbb{E}(\bar{y} - \hat{\beta}_1 \bar{x}) \xrightarrow{\mathbb{E}(\bar{y}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(y_i)} \\ &= \mathbb{E}(\bar{y}) - \bar{x} \mathbb{E}(\hat{\beta}_1) \\ &= \beta_0 + \beta_1 \bar{x} - \bar{x} \beta_1 = \beta_0 \\ \therefore \mathbb{E}(\hat{\beta}_0) &= \beta_0\end{aligned}$$

Para a variância temos

$$\begin{aligned}\text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{y} - \hat{\beta}_1 x_i) \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{s_{xx}} \\ &= \text{Var}(\bar{y}) + \bar{x}^2 \text{Var}(\hat{\beta}_1) - 2\bar{x} \text{Cov}(\bar{y}, \hat{\beta}_1) \\ &= \text{Var}(\bar{y}) + \frac{\bar{x}^2 \cdot \sigma^2}{s_{xx}} \\ &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i\right) + \frac{\bar{x}^2}{s_{xx}} \cdot \sigma^2 \\ &= \frac{1}{n^2} \cdot \sum_{i=1}^n \text{Var}(y_i) + \frac{\bar{x}^2}{s_{xx}} \cdot \sigma^2 \\ &= \frac{1}{n} \cdot \sigma^2 + \frac{\bar{x}^2}{s_{xx}} \cdot \sigma^2 = \sigma^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{s_{xx}} \right)\end{aligned}$$

$$c) \text{cov}(\hat{\beta}_0, \hat{\beta}_1) = E[(\hat{\beta}_0 - E(\hat{\beta}_0))(\hat{\beta}_1 - E(\hat{\beta}_1))]$$

$$= E[(\hat{\beta}_0 - \beta_0)(\hat{\beta}_1 - \beta_1)]$$

onde

$$\left\{ \begin{array}{l} \hat{\beta}_0 - \beta_0 = \bar{y} - \beta_0 - \beta_1 \bar{x} \\ \hat{\beta}_1 - \beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{array} \right.$$

Temos também que  $y = \beta_0 + \beta_1 x_i + \varepsilon_i$   
 Substituindo em  $\hat{\beta}_0 - \beta_0$

$$\begin{aligned} \hat{\beta}_0 - \beta_0 &= \cancel{\beta_0} + \beta_1 \bar{x} + \bar{\varepsilon} - \cancel{\beta_0} - \hat{\beta}_1 \bar{x} \\ &= \bar{\varepsilon} - \hat{\beta}_1 \bar{x} \end{aligned}$$

$$\text{então } \text{cov}(\hat{\beta}_0, \hat{\beta}_1) = E[(\bar{\varepsilon} - \hat{\beta}_1 \bar{x})(\hat{\beta}_1 - \beta_1)]$$

$$= E[\bar{\varepsilon}(\hat{\beta}_1 - \beta_1)] - E[\hat{\beta}_1 \bar{x}(\hat{\beta}_1 - \beta_1)]$$

Como  $E(\varepsilon) = 0$

$$\text{cov}(\hat{\beta}_0, \hat{\beta}_1) = -E(\hat{\beta}_1 \bar{x}(\hat{\beta}_1 - \beta_1))$$

$$\text{Assim } E[\hat{\beta}_1 \bar{x}(\hat{\beta}_1 - \beta_1)] = \text{var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\text{Portanto } \text{cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}s^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

3a) Um intervalo de confiança

de 100(1 - 0,05) % = 95% para  $\beta_1$

é dado por:

$$\begin{aligned} & I.C[\hat{\beta}_1, 0,95] \\ &= \left[ \hat{\beta}_1 - t_{n-2, 0,025} \sqrt{\frac{1}{n-2} \cdot \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \right. \end{aligned}$$

$$\left. \hat{\beta}_1 + t_{n-2, 0,025} \sqrt{\frac{1}{n-2} \cdot \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \right]$$

Podemos utilizar

$$T = \frac{\hat{\beta}_1 - \beta_1}{s_{\beta_1}} \sim t_{n-2} \text{ como uma quantidade pivotal}$$

$s_{\beta_1} = \sqrt{s^2} \text{ erro padrão residual}$

## b) Teste de Hipóteses

$H_0: \beta_1 = 0$  vs  $H_1: \beta_1 \neq 0$

Graus existe uma relação linear entre x e y

→ existe uma relação linear entre x e y

$$\varepsilon_i \sim N(0, \sigma^2)$$

Sob  $H_0$  ou seja assumindo  $\beta_1 = 0$ )  
temos que a nossa estatística do teste é dada por:

$$T = \frac{\hat{\beta}_1 - 0}{\text{EP}(\hat{\beta}_1)} = \frac{\hat{\beta}_1}{S_{\sqrt{S_{xx}}}} \sim t_{n-2}$$

Vamos agora fixar um nível de significância  $\alpha$

$$\alpha = 0,05$$

Vamos definir a regiões críticas  
(Teste Bilateral)

$$|T| > t_{\frac{\alpha}{2}, n-2}$$

onde  $t_{\frac{\alpha}{2}, n-2}$  é o valor crítico da distribuição t com  $n-2$  graus de liberdade.

$$\alpha = 0,05 \text{ temos } t_{0,025}$$

Calcular a estatística T a partir dos dados

Um critério de decisão

$$|T| > t_{\frac{\alpha}{2}, n-2} \Rightarrow \text{Rejeitar } H_0$$

$$|T| \leq t_{\frac{\alpha}{2}, n-2} \Rightarrow \text{Aceitar } H_0$$