

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 01 - 2S2025 - Gabarito

Introdução

Uma empresa de pesquisa (Last Resource, Inc., Bellefonte, PA) fez um estudo para verificar qual a relação entre a idade do motorista e a distância que ele consegue enxergar bem.


Foi coletada uma amostra de $n = 30$ motoristas, na qual perguntaram a idade do motorista e mediram a distância (em pés) que eles conseguiam enxergar bem um sinal de trânsito. Esses dados estão disponíveis no Moodle, no arquivo chamado *signdist.txt*.

Atividade

1. Leia o conjunto de dados no R e faça um gráfico de dispersão para visualizar a relação entre a idade (variável preditora X) e distância (variável resposta Y).

```
dados = read_delim("../dados/signdist.txt", show_col_types = FALSE)
```

Age	Distance
18	510
20	590
22	560
23	510
23	460



2. Calcule as estatísticas descritivas das variáveis e também o coeficiente de correlação entre elas.

```
dados %>%  
  summary() %>%  
  kable(booktabs = TRUE, caption = "Estatística Sumárias")
```

Table 2: Estatística Sumárias

Age	Distance
Min. :18.0	Min. :280
1st Qu.:28.2	1st Qu.:362
Median :54.0	Median :420
Mean :51.0	Mean :423
3rd Qu.:70.8	3rd Qu.:460
Max. :82.0	Max. :590

O coeficiente de correlação entre idade e distância é $cor(X, Y) = -0.801$.

3. Utilizando o R como uma calculadora simples, calcule as estatísticas de interesse que serão posteriormente utilizadas para encontrar os estimadores de β_0 e β_1 .

```
x = dados$Age  
y = dados$Distance  
n = nrow(dados)  
  
xbar = mean(x)  
ybar = mean(y)  
sxx = sum(x^2) - n * xbar^2  
sxy = sum(x * y) - n * xbar * ybar
```

4. Usando as estatísticas do item anterior, escreva uma função que, para um dado conjunto de dados, retorna as estimativas de $\hat{\beta}_0$ e $\hat{\beta}_1$. **Nota:** não usar a função `lm()`.

```
fitreg <- function(dados, xcol, ycol){  
  x = dados[[xcol]]  
  y = dados[[ycol]]  
  n = nrow(dados)  
  
  xbar = mean(x)  
  ybar = mean(y)  
  sxx = sum(x^2) - n * xbar^2  
  sxy = sum(x * y) - n * xbar * ybar  
  
  b1 = sxy / sxx  
  b0 = ybar - b1 * xbar  
  
  return(c(b0 = b0, b1 = b1))  
}  
  
fitreg(dados, "Age", "Distance")  
  
##      b0      b1  
## 576.68 -3.01
```


5. Ajuste o modelo de regressão linear simples utilizando a função `lm()` e compare os resultados obtidos no item 3. **Dica:** use as funções `summary()` ou `coef()` para visualizar os coeficientes estimados.

```
fit1 <- lm(Distance ~ Age, data = dados) # Y = b0 + b1Y + e
coef(fit1)
```

```
## (Intercept)      Age
##      576.68      -3.01
```

6. Apresente um gráfico de dispersão dos dados juntamente com a reta de regressão ajustada. Escreva um parágrafo com as interpretação dos parâmetros. **Nota:** utilize a função `geom_abline()`. Você não deve usar a função `geom_smooth()`.

```
betas = coef(fit1)
g1 + geom_abline(intercept = betas[1], slope = betas[2], color = "red")
```



7. Utilizando as fórmulas dadas em aula, encontre as estimativas das variâncias de ε , β_0 e β_1 . Verifique os cálculos com os resultados apresentados na tabela dos coeficientes estimados obtida no R.

```
res = fit1$residuals
df = fit1$df.residual

QME = sum(res^2) / df
varb1 = QME/sxx
varb0 = QME * (1/n + xbar^2/sxx)
```

$$\widehat{Var}(\varepsilon_i) = \hat{\sigma}^2 = QME = 2476.215$$

$$\widehat{Var}(\hat{\beta}_0) = QME \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right) = 2476.215 * \left(\frac{1}{30} + \frac{2601}{1.375 \times 10^4} \right) = 550.882$$

$$\widehat{Var}(\hat{\beta}_1) = \frac{QME}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{QME}{S_{XX}} = \frac{2476.215}{1.375 \times 10^4} = 0.18$$

Obtenha os erros padrão dos resíduos, $\hat{\beta}_0$ e $\hat{\beta}_1$, ou seja, tire a raiz quadrada das estimativas de variâncias acima e compare com o que é apresentado na tabela abaixo:

```
summary(fit1)$coef
```

Table 3: Tabela dos Coeficientes Estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	576.68	23.471	24.57	0
Age	-3.01	0.424	-7.09	0

8. Encontre os intervalos de confiança de 90% para β_0 e β_1 da seguinte forma:

(a) usando as fórmulas dadas em aula

$$IC(\beta_0, 0.90) = \left[\hat{\beta}_0 \pm t_{n-2, \alpha/2} \sqrt{QME \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} \right)} \right] = [528.604, 624.76]$$

$$IC(\beta_1, 0.90) = \left[\hat{\beta}_1 \pm t_{n-2, \alpha/2} \sqrt{\frac{QME}{S_{XX}}} \right] = [-3.876, -2.138]$$

(b) usando a função `confint()`

```
confint(fit1)
```

Table 4: IC de 90% para os coeficientes

	Estimativa	2.5 %	97.5 %
(Intercept)	576.68	528.60	624.76
Age	-3.01	-3.88	-2.14

9. Apresente um teste de hipótese para verificar se o coeficiente β_1 é nulo ou não, usando o seguinte:

Em ambos os testes estamos testando as seguintes hipóteses:

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_1 : \beta_1 \neq 0$$

(a) Teste t

Estatística do Teste:

$$t_{obs} = \frac{\hat{\beta}_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} = \frac{-3.01}{0.424} = -7.09 \stackrel{H_0}{\sim} t_{28}$$

Conclusão: p-valor = $P(|t_{28}| \geq t_{obs}) \approx 0$. Portanto, rejeitamos H_0 , ou seja, temos evidência nos dados para concluir que a relação entre a idade e a distância que é possível visualizar a placa é significativa.

O teste acima pode ser visualizado na tabela abaixo:

Table 5: Tabela dos coeficientes estimados e teste t

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	576.68	23.471	24.57	0
Age	-3.01	0.424	-7.09	0

(b) Teste F

Estatística do Teste:

$$F^* = \frac{QMReg}{QME} = \frac{SQReg/1}{SQE/n-2} = \frac{124333}{2476} = 50.21 \stackrel{H_0}{\sim} F_{1,28}.$$

Conclusão: p-valor = $P(F_{1,28} \geq 50.21) \approx 0$. Portanto, rejeitamos a hipótese H_0 , ou seja, temos evidência nos dados para concluir que a relação entre a idade e a distância que é possível visualizar a placa é significativa.

O teste acima pode ser visualizado na tabela abaixo:

Table 6: Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Age	1	124333	124333	50.2	0
Residuals	28	69334	2476	NA	NA

10. Calcule o coeficiente de determinação R^2 e interprete-o.

$$R^2 = \frac{SQReg}{SQT} = \frac{124333}{124333 + 69334} = 0.642$$

A proporção da variabilidade total da distância explicada pela variável idade é de 64.2% .

11. Centralize a variável preditora em sua média e ajuste uma regressão simples novamente. Compare o resultado com aquele obtido no item 4.

```
fit2 <- lm(Distance ~ I(Age - mean(Age)), data = dados)
summary(fit2)$coef
```

Table 7: Tabela dos coeficientes estimados - Preditor centralizado

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	423.33	9.085	46.60	0
I(Age - mean(Age))	-3.01	0.424	-7.09	0

Veja que o coeficiente $\hat{\beta}_0$ é exatamente o mesmo, mas o $\hat{\beta}_0$ é agora $\bar{Y} = 423.333$. Isso acontece pelo seguinte:

$$\begin{aligned}\hat{Y}_i &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\ &= \bar{Y} - \hat{\beta}_1 \bar{X} + \hat{\beta}_1 X_i \\ &= \bar{Y} + \hat{\beta}_1 (X_i - \bar{X})\end{aligned}$$

12. Se você transformar a distância de pés para metros, como isso afeta os coeficientes da regressão? Note que 1 pé = 0,3048 metros.

```
dados %<>% mutate(Distancia = Distance * 0.3048)
```

Age	Distance	Distancia
18	510	155
20	590	180
22	560	171
23	510	155
23	460	140

```
fit3 <- lm(Distancia ~ Age, data = dados)
summary(fit3)$coef
```

Table 9: Tabela dos coeficientes estimados - Distância em metros

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	175.773	7.154	24.57	0
Age	-0.916	0.129	-7.09	0

Quando você transforma a variável para metros, ou seja, multiplica por 0,3048, ambos os coeficientes da regressão originais são multiplicados por 0,3048 também.

Gráfico de dispersão entre Idade e Distância (metros)

