

ME613A - Análise de Regressão

Profa. Tatiana Benaglia

Atividade Prática 02 - 2S2025 - Gabarito

Introdução: Relação entre palmo e altura

Será que a medida do seu palmo está associada com a sua altura?

Para verificar esta possível relação, foram medidas a largura do palmo e a altura (em polegadas) de 167 estudantes universitários. Também registraram o gênero do estudante. Os dados estão no arquivo `handheight.txt` em anexo.

Considere como variável resposta a altura (`Height`) e como variável preditora a largura do palmo (`HandSpan`).


Atividades

1. Leia o conjunto de dados no R e faça um gráfico de dispersão entre altura e largura do palmo. Comente.

```
dados = read_delim("../dados/handheight.txt", show_col_types = FALSE)
```

Sex	Height	HandSpan
Female	68	21.5
Male	71	23.5
Male	73	22.5
Female	64	18.0
Male	68	23.5

Gráfico de dispersão entre altura e palmo



2. Ajuste o modelo de regressão linear simples utilizando a função `lm()` e apresente os resultados. **Dica:** use a função `summary()`.

```
fit <- lm(Height ~ HandSpan, data = dados)
summary(fit)

##
## Call:
## lm(formula = Height ~ HandSpan, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.727 -1.727 -0.167  1.493  7.493
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   35.525      2.316    15.3   <2e-16 ***
## HandSpan       1.560      0.111    14.1   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.74 on 165 degrees of freedom
## Multiple R-squared:  0.547, Adjusted R-squared:  0.544
## F-statistic: 199 on 1 and 165 DF, p-value: <2e-16
```

3. Apresente a tabela ANOVA e identifique nesta tabela as somas de quadrados $SQReg$, SQE e SQT . Qual a estimativa da variância σ^2 ? **Dica:** use a função `anova()`.

```
anova(fit)
```

Table 2: Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
HandSpan	1	1500	1500.06	199	0
Residuals	165	1243	7.53	NA	NA

Veja a decomposição das somas de quadrados:


$$SQT = SQReg + SQE$$

$$2742.763 = 1500.06 + 1242.703$$

E a estimativa da variância é dada por $\hat{\sigma}^2 = QME = 7.532$.

4. Apresente um gráfico de dispersão dos dados juntamente com a reta de regressão ajustada, usando a função `geom_smooth()`. Escreva um parágrafo com a interpretação dos parâmetros.


Gráfico de dispersão entre altura e palmo





5. Faça a análise de resíduos. Vamos começar pelos gráficos descritos no itens abaixo. O que você observa? Existe alguma tendência aparente nos gráficos?

```
dados %<>% mutate(pred = fitted(fit),  
                  res = residuals(fit),  
                  st_res = rstudent(fit))
```

- a) Resíduos versus a variável preditora.




- b) Resíduos versus valores peditos.



6. Analise a suposição de normalidade dos resíduos das seguintes formas:

a) Gráficamente: boxplot, histograma e QQ-plot. Comente.

```
dados %>% ggplot(aes(sample = st_res)) +
  stat_qq(col="blue", size=2, alpha=0.6) +
  stat_qq_line(col="red", size=1) +
  labs(title = "QQ-Plot", x = "Quantis Teóricos", y = "Quantis Amostrais") +
  theme_bw()
```



b) Teste de hipótese. Escolha um teste apropriado, aplique e comente.

```
shapiro.test(dados$res)
```

```
##
## Shapiro-Wilk normality test
##
## data:  dados$res
## W = 1, p-value = 0.6
```

7. Verifique através de um teste de hipótese se existe homocedasticidade.

Teste de Homocedasticidade de Breusch-Pagan. No R usamos a seguinte função:

```
library(car)
ncvTest(fit)
```

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.968, Df = 1, p = 0.3
```

Estatística do teste:

$$X_{BP}^2 = \frac{SQR^*/2}{(SQE/n)^2} = 0.968 \stackrel{H_0}{\sim} \chi_1^2,$$

em que SQR^* é a soma de quadrados da regressão de e^2 em X e SQE é a soma de quadrados do erro da regressão de Y em X .

Conclusão: Como o p-valor é igual a 0.325, não rejeitamos a hipótese de homocedasticidade.

8. É possível aplicar o teste F de falta de ajuste para esse dados? Se sim, apresente a tabela ANOVA com a decomposição da SQE em SQFA e SQEp. Indique quais hipóteses estão sendo testadas, a estatística do teste e conclusão.

Sim, é possível aplicar o teste pois existem replicações nos níveis da variável preditora.

```
library(EnvStats)
anovaPE(fit)
```

Table 3: Tabela ANOVA com Teste F de Falta de Ajuste

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
HandSpan	1	1500.1	1500.06	193.647	0.000
Lack of Fit	17	96.2	5.66	0.731	0.767
Pure Error	148	1146.5	7.75	NA	NA

Hipóteses:

- H_0 : O modelo assumido é razoável, ou seja, não há falta de ajuste - H_1 : O modelo assumido não é razoável, ou seja, há falta de ajuste

Estatística do teste:

$$F^* = \frac{QMFA}{QME_p} = \frac{SQFA/(c-2)}{SQE_p/(n-c)} = \frac{96.24/17}{1146.46/148} = \frac{5.66}{7.75} = 0.73 \stackrel{H_0}{\sim} F_{17,148}$$

Conclusão: Como o p-valor é grande (0.767), não temos evidência para rejeitar H_0 , ou seja, não há evidências de falta de ajuste e concluímos que o modelo de regressão linear simples é razoável.

9. Depois de verificar as suposições do modelo através da análise dos resíduos, faça agora um teste de hipótese para checar se a relação linear entre **HandSpan** e **Height** é significativa.

```
summary(fit)$coef
```

Table 4: Tabela dos Coeficientes Estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	35.52	2.316	15.3	0
HandSpan	1.56	0.111	14.1	0

Hipóteses: $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$.

Estatística do Teste:

$$t_{obs} = \frac{\hat{\beta}_1}{\sqrt{Var(\hat{\beta}_1)}} = \frac{1.56}{0.11} = 14.11 \stackrel{H_0}{\sim} t_{165}$$

Conclusão: Como o p-valor ≈ 0 rejeitamos H_0 , ou seja, temos evidência nos dados para concluir que a relação entre o palmo e a altura é significativa.

10. Qual é a altura média de estudantes cuja largura do palmo é 17, 21 e 24 polegadas, respectivamente. Apresente também um intervalo de 95% de confiança para estes casos e compare-os. **Dica:** usar a função `predict()`.

```
xnew = tibble(HandSpan = c(17, 21, 24))
ic_conf = predict(fit, xnew, interval = "confidence", level = 0.95)
```

Table 5: Intervalos de Confiança de 95%

HandSpan	fit	lwr	upr
17	62.0	61.1	63.0
21	68.3	67.9	68.7
24	73.0	72.2	73.8

11. Para um novo estudante, qual a estimativa de sua altura dado que sua largura do palmo é 17, 21 e 24 polegadas, respectivamente. Apresente também um intervalo de predição de 95% para esses casos. Compare com os intervalos de confiança obtidos no item anterior. **Dica:** usar a função `predict()` modificando o argumento `interval`.

```
ic_pred = predict(fit, xnew, interval = "prediction", level = 0.95)
```

Table 6: Intervalos de Predição de 95%

HandSpan	fit	lwr	upr
17	62.0	56.5	67.5
21	68.3	62.9	73.7
24	73.0	67.5	78.4

12. Apresente um gráfico de dispersão, juntamente com a reta ajustada e a banda de confiança para estimação da resposta média e o intervalo de predição para uma nova observação, ambos com nível de confiança de 95%.

```
Xnew = data.frame(HandSpan = seq(16, 26, by = 1))
ic = predict(fit, newdata = Xnew, interval = "confidence")
ip = predict(fit, newdata = Xnew, interval = "prediction")

icdf = data.frame(cbind(Xnew, ic))
ipdf = data.frame(cbind(Xnew, ip))
```

Reta ajustada com intervalos de confiança e predição

