

ME613 - Análise de Regressão


Parte 1

Tatiana Benaglia - 2S2025

Introdução

Análise de regressão linear é uma metodologia estatística que modela a relação entre uma variável dependente numérica/contínua e uma ou mais variáveis independentes por meio de uma equação linear, permitindo prever valores e analisar a força e direção dessas relações.

É uma metodologia amplamente utilizada em diversas áreas, pois é relativamente de fácil interpretação.



Francis Galton e os dados sobre altura

Galton inventou os conceitos de **correlação** e **regressão**.

Em um de seus estudos, investigou a ideia de que filhos de pais altos eram altos, mas não tanto quanto seus pais. Filhos de pais mais baixos eram baixos, mas nem tanto quanto seus pais.

Ele se referiu a isso como “regressão para a média” (*Regression through the Mean*).

Seus resultados foram publicados no artigo *Regression towards Mediocrity in Hereditary Stature*.




Figure 1: Francis Galton

Francis Galton e os dados sobre altura

O trabalho de Galton, publicado seu trabalho em 1886, ainda é relevante.

Em 2009 pesquisadores compararam o modelo de Galton com modelos utilizando dados genômicos e o modelo de Galton se mostrou superior. Os resultados foram publicados no artigo Predicting human height by Victorian and genomic methods.



European Journal of Human Genetics (2009) 17, 1070–1075
© 2009 Macmillan Publishers Limited All rights reserved 1018-4813/09 \$32.00

www.nature.com/ejhg

ARTICLE

Predicting human height by Victorian and genomic methods

Yurii S Aulchenko^{*,1,2,7}, Maksim V Struchalin^{1,3,7}, Nadezhda M Belonogova^{2,4},
Tatiana I Axenovich², Michael N Weedon⁵, Albert Hofman¹, Andre G Uitterlinden⁶,
Manfred Kayser³, Ben A Oostra¹, Cornelia M van Duijn¹, A Cecile JW Janssens¹ and
Pavel M Borodin^{2,4}

Algumas questões de interesse...

- Usar a altura dos pais para prever a dos filhos.

Modelos de regressão podem nos ajudar a responder essas perguntas.

Algumas questões de interesse...

- Usar a altura dos pais para prever a dos filhos.
- Encontrar uma maneira simples de explicar a relação entre a altura média dos pais e a altura média dos filhos.

Modelos de regressão podem nos ajudar a responder essas perguntas.

Algumas questões de interesse...

- Usar a altura dos pais para prever a dos filhos.
- Encontrar uma maneira simples de explicar a relação entre a altura média dos pais e a altura média dos filhos.
- Investigar a variação na altura dos filhos que parece não estar relacionada com a altura dos pais (variação residual).

Modelos de regressão podem nos ajudar a responder essas perguntas.

Algumas questões de interesse...

- Usar a altura dos pais para prever a dos filhos.
- Encontrar uma maneira simples de explicar a relação entre a altura média dos pais e a altura média dos filhos.
- Investigar a variação na altura dos filhos que parece não estar relacionada com a altura dos pais (variação residual).
- Descobrir quais as suposições são necessárias para generalizar as descobertas realizadas com os dados em mãos para outros dados.


Modelos de regressão podem nos ajudar a responder essas perguntas.

Algumas questões de interesse...

- Usar a altura dos pais para prever a dos filhos.
- Encontrar uma maneira simples de explicar a relação entre a altura média dos pais e a altura média dos filhos.
- Investigar a variação na altura dos filhos que parece não estar relacionada com a altura dos pais (variação residual).
- Descobrir quais as suposições são necessárias para generalizar as descobertas realizadas com os dados em mãos para outros dados.
- Por que filhos de pais muito altos tendem a ser altos, mas nem tanto quanto seus pais? E por que filhos de pais muito baixos tendem a ser baixos, mas nem tanto quanto seus pais?

Modelos de regressão podem nos ajudar a responder essas perguntas.

Francis Galton e os dados sobre altura



- Dados de 1885 usados por Galton.
- Alturas médias dos pais com altura das mulheres multiplicadas por 1.08.
- Observe as distribuições marginais: dos filhos (esquerda) e dos pais (esquerda).

Encontrando o centro via mínimos quadrados

Considerando apenas as alturas dos filhos:

- Se você fosse tentar adivinhar um valor para a altura de um dos filhos, utilizando apenas o histograma/dados dos filhos, como você faria?

Encontrando o centro via mínimos quadrados

Considerando apenas as alturas dos filhos:

- Se você fosse tentar adivinhar um valor para a altura de um dos filhos, utilizando apenas o histograma/dados dos filhos, como você faria?
- Como descrever o “centro/meio”?

Encontrando o centro via mínimos quadrados

Considerando apenas as alturas dos filhos:

- Se você fosse tentar adivinhar um valor para a altura de um dos filhos, utilizando apenas o histograma/dados dos filhos, como você faria?
- Como descrever o “centro/meio”?
- Uma definição: seja y_i a altura do filho i para $i = 1, \dots, n = 928$, então definimos o centro como o valor de μ que minimiza

$$\sum_{i=1}^n (y_i - \mu)^2$$

- É o centro de massa do histograma.
- Temos que $\mu = \bar{y}$ (demonstrar!)

Encontrando o centro via mínimos quadrados


Usando o R, teste também no seu computador:

```
library(manipulate)
library(UsingR)
data(galton)

myHist <- function(mu){
  mse <- mean((galton$child - mu)^2)
  ggplot(galton, aes(x=child)) +
    geom_histogram(fill="salmon", colour="black", binwidth=1) +
    geom_vline(xintercept=mu, size = 2) +
    ggtitle(paste("mu = ", mu, ", MSE = ", round(mse, 2), sep = "")) +
    theme_bw()
}

manipulate(myHist(mu), mu = slider(62, 74, step = 0.01))
```

A estimativa por mínimos quadrados é a média




A média das alturas dos filhos é $\bar{y} = 68.09$.


$$\begin{aligned}\sum_{i=1}^n (y_i - \mu)^2 &= \sum_{i=1}^n (y_i - \bar{y} + \bar{y} - \mu)^2 \\&= \sum_{i=1}^n (y_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \bar{y})(\bar{y} - \mu) + \sum_{i=1}^n (\bar{y} - \mu)^2 \\&= \sum_{i=1}^n (y_i - \bar{y})^2 + 2(\bar{y} - \mu) \sum_{i=1}^n (y_i - \bar{y}) + \sum_{i=1}^n (\bar{y} - \mu)^2 \\&= \sum_{i=1}^n (y_i - \bar{y})^2 + 2(\bar{y} - \mu) \left(\sum_{i=1}^n y_i - n\bar{y} \right) + \sum_{i=1}^n (\bar{y} - \mu)^2 \\&= \sum_{i=1}^n (y_i - \bar{y})^2 + \sum_{i=1}^n (\bar{y} - \mu)^2 \\&\geq \sum_{i=1}^n (y_i - \bar{y})^2\end{aligned}$$

Utilizando os dados dos pais

- Será que utilizando a informação dos pais conseguimos uma predição melhor para a altura do filho?
- Será que há alguma relação entre essas alturas? Como descobrir?



Utilizando os dados dos pais



Regressão pela origem

O objetivo é encontrar uma reta que melhor se ajusta aos pontos do gráfico.

- Seja X_i a altura média dos pais da i -ésima criança e Y_i é a altura da i -ésima criança.
- Definimos a relação linear como:

$$Y_i = \alpha + \beta X_i + \varepsilon_i,$$

isto é $\alpha + \beta X_i$ é a reta e ε um termo de erro.

- Precisamos encontrar o intercepto (α) e o coeficiente angular (β) para definir a reta. Inicialmente, para simplificar, $\alpha = 0$ (reta passa pela origem).
- Procuramos β que minimiza


$$\sum_{i=1}^n (Y_i - \beta X_i)^2.$$

- Estamos procurando uma reta, a partir da origem, que minimiza o quadrado das distâncias verticais dos pontos do gráfico até ela.

Encontrando β de forma interativa no R

```
myPlot = function(beta){  
  tmp = galton %>% mutate(parent = parent - mean(parent),  
                           child = child - mean(child))  
  mse = with(tmp, mean((child - (parent * beta))^2))  
  ggplot(tmp, aes(parent, child)) +  
    geom_hex() +  
    geom_abline(intercept = 0, slope = beta, color = "red", size = 2) +  
    ggtitle(paste0("beta=", beta, ", MSE=", round(mse, 4))) +  
    theme_bw()  
}  
  
manipulate(myPlot(beta), beta=slider(0.44, 0.84, step=0.02))
```

Regressão pela Origem



O coeficiente angular da reta é $\hat{\beta} = 0.646$.

Modelo de Regressão Linear Simples


Em muitas situações a relação entre duas variáveis pode ser descrita por uma reta.

Podemos assumir que a reta de regressão da variável Y na variável X tem a forma $\beta_0 + \beta_1 X$.

Desta maneira, consideramos o modelo:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

ou seja, para um dado X_i , o valor correspondente de y_i consiste no valor $\beta_0 + \beta_1 X_i$ mais um termo ε_i , que é o incremento indicando a distância de Y_i da reta $\beta_0 + \beta_1 X_i$.



Estimação por Mínimos Quadrados

Equação do modelo de regressão linear:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

em que β_0 , β_1 e ε_i são desconhecidos.


O erro aleatório ε_i depende da observação i , mas os parâmetros β_0 e β_1 são constantes para todo i e, portanto, mais simples de serem estimados.

Suponha então que temos n pares de observações: $(X_1, Y_1), \dots, (X_n, Y_n)$.

A soma dos desvios ao quadrado de cada observação Y_i até a reta $\beta_0 + \beta_1 X_i$ é dada por:

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

Estimação por Mínimos Quadrados



Estimação por Mínimos Quadrados

Queremos encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ de tal forma que a reta resultante, ao substituirmos esses valores no lugar de β_0 e β_1 , minimiza a soma dos desvios ao quadrado.

Estimação por Mínimos Quadrados

Queremos encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ de tal forma que a reta resultante, ao substituirmos esses valores no lugar de β_0 e β_1 , minimiza a soma dos desvios ao quadrado.

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)$$

Estimação por Mínimos Quadrados

Queremos encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ de tal forma que a reta resultante, ao substituirmos esses valores no lugar de β_0 e β_1 , minimiza a soma dos desvios ao quadrado.

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)$$

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i)$$

Estimação por Mínimos Quadrados

Queremos encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ de tal forma que a reta resultante, ao substituirmos esses valores no lugar de β_0 e β_1 , minimiza a soma dos desvios ao quadrado.

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)$$

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i)$$

Igualamos cada equação acima a zero para encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ que minimizam $S(\beta_0, \beta_1)$ e obtemos as chamadas **equações normais**:

$$\sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0$$

$$\sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0$$

Estimação por Mínimos Quadrados

Resolvendo essas equações, chegamos a:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$
$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X},$$

que são os estimadores por mínimos quadrados dos coeficientes β_0 e β_1 .

Estimação por Mínimos Quadrados

Resolvendo essas equações, chegamos a:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$
$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X},$$

que são os estimadores por mínimos quadrados dos coeficientes β_0 e β_1 .


A partir disso, temos a **equação de regressão estimada**:

$$\begin{aligned}\hat{Y}_i &= \hat{\mathbb{E}}(Y \mid X = X_i) \\ &= \hat{\beta}_0 + \hat{\beta}_1 X_i \\ &= \bar{Y} + \hat{\beta}_1 (X_i - \bar{X})\end{aligned}$$

(**Demonstração**: clique aqui e veja esse vídeo)

Dados de Galton

Vamos retomar os dados das alturas e obter os estimadores por mínimos quadrados.



Dados de Galton

Seja Y_i a altura da criança i e X_i a altura média dos pais da criança i .

A relação entre X e Y é dada por:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Objetivo: Encontrar a “melhor reta” (que minimiza S).

Métodos dos Mínimos Quadrados: minimizar

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2$$

Resultado:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \text{Cor}(X, Y) \frac{DP(Y)}{DP(X)} \quad \text{e} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Estimadores de Mínimos Quadrados

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = Cor(X, Y) \frac{DP(Y)}{DP(X)} \quad \text{e} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Calculando os coeficientes pelas fórmulas acima usando o R apenas como calculadora:

```
y <- galton$child
x <- galton$parent
beta1 <- cor(y, x) * sd(y) / sd(x)
beta0 <- mean(y) - beta1 * mean(x)

c(beta0 = beta0, beta1 = beta1)
```

```
beta0  beta1
23.942  0.646
```


Estimadores de Mínimos Quadrados

Também podemos usar a função `lm()` do R para ajustar um modelo de regressão linear:

```
fit <- lm(y ~ x)
summary(fit)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.942	2.811	8.52	0
parent	0.646	0.041	15.71	0

Estimadores de Mínimos Quadrados



As estimativas dos coeficientes são $\hat{\beta}_0 = 23.942$ e $\hat{\beta}_1 = 0.646$.

- Applied Linear Statistical Models: Seções 1.1 a 1.7, 2.1, 2.2.
- Caffo - Regression Models for Data Science in R: Introduction, Notation, Ordinary least squares, Regression to the mean, Statistical linear regression models, Residuals.
- Draper & Smith - Applied Regression Analysis: Capítulo 0, 1.1 a 1.3.
- Weisberg - Applied Linear Regression: Capítulo 1, 2.1 a 2.5, 2.7.

Agradecimentos

Parte deste material foi criado pela profa.
Samara F. Kiihl - IMECC/UNICAMP

