

ME613 - Análise de Regressão

Parte 2

Tatiana Benaglia - 2S2025

Regressão Linear Simples

Nos slides anteriores, definimos o modelo de regressão linear simples:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

e vimos que a *melhor reta* obtida pelos **estimadores de mínimos quadrados** é dada pelos seguintes estimadores:

$$\begin{aligned}\hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2} = \frac{S_{XY}}{S_{XX}}\end{aligned}$$

PERGUNTA: Nós fizemos alguma suposição sobre o modelo até agora?

Suposições do Modelo

Nenhuma suposição sobre o modelo, como distribuição de probabilidade dos erros, foi feita até o momento.

Suposições do Modelo

Nenhuma suposição sobre o modelo, como distribuição de probabilidade dos erros, foi feita até o momento.

A partir de agora faremos as seguintes suposições:

❶ $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, 2, \dots, n$ (linearidade)

Suposições do Modelo

Nenhuma suposição sobre o modelo, como distribuição de probabilidade dos erros, foi feita até o momento.

A partir de agora faremos as seguintes suposições:

- 1 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, 2, \dots, n$ (linearidade)
- 2 ε_i é uma v.a. em que $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.

Suposições do Modelo

Nenhuma suposição sobre o modelo, como distribuição de probabilidade dos erros, foi feita até o momento.

A partir de agora faremos as seguintes suposições:

- 1 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, $i = 1, 2, \dots, n$ (linearidade)
- 2 ε_i é uma v.a. em que $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.
- 3 ε_i e ε_j são não-correlacionados para $i \neq j$, portanto, $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$.

Propriedades de Y_i

O valor esperado da resposta Y_i é:

$$\begin{aligned}\mathbb{E}(Y_i) &= \mathbb{E}(\beta_0 + \beta_1 X_i + \varepsilon_i) \\ &= \beta_0 + \beta_1 X_i + \mathbb{E}(\varepsilon_i) \\ &= \beta_0 + \beta_1 X_i\end{aligned}$$

Propriedades de Y_i

O valor esperado da resposta Y_i é:

$$\begin{aligned}\mathbb{E}(Y_i) &= \mathbb{E}(\beta_0 + \beta_1 X_i + \varepsilon_i) \\ &= \beta_0 + \beta_1 X_i + \mathbb{E}(\varepsilon_i) \\ &= \beta_0 + \beta_1 X_i\end{aligned}$$

A variância da resposta Y_i é:

$$\begin{aligned}\text{Var}(Y_i) &= \text{Var}(\beta_0 + \beta_1 X_i + \varepsilon_i) \\ &= \text{Var}(\varepsilon_i) = \sigma^2\end{aligned}$$

Propriedades de Y_i

O valor esperado da resposta Y_i é:

$$\begin{aligned}\mathbb{E}(Y_i) &= \mathbb{E}(\beta_0 + \beta_1 X_i + \varepsilon_i) \\ &= \beta_0 + \beta_1 X_i + \mathbb{E}(\varepsilon_i) \\ &= \beta_0 + \beta_1 X_i\end{aligned}$$

A variância da resposta Y_i é:

$$\begin{aligned}\text{Var}(Y_i) &= \text{Var}(\beta_0 + \beta_1 X_i + \varepsilon_i) \\ &= \text{Var}(\varepsilon_i) = \sigma^2\end{aligned}$$

A resposta Y_i vem de uma distribuição de probabilidade com média $\mathbb{E}(Y_i) = \beta_0 + \beta_1 X_i$ (**função de regressão**) e variância $\text{Var}(Y_i) = \sigma^2$.

A resposta, Y_i está acima ou abaixo da função de regressão por um termo de erro ε_i .

Propriedades de $\hat{\beta}_1$

Primeiramente, veja que $\hat{\beta}_1$ pode ser reescrito como:

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \\&= \frac{1}{\sum_{i=1}^n (X_i - \bar{X})^2} \left[\sum_{i=1}^n (X_i - \bar{X})Y_i - \sum_{i=1}^n (X_i - \bar{X})\bar{Y} \right] \\&= \frac{1}{\sum_{i=1}^n (X_i - \bar{X})^2} \left[\sum_{i=1}^n (X_i - \bar{X})Y_i - \underbrace{\sum_{i=1}^n (X_i - \bar{X})\bar{Y}}_0 \right] \\&= \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2} = \sum_{i=1}^n a_i Y_i\end{aligned}$$

Ou seja, $\hat{\beta}_1$ pode ser escrito como uma combinação linear dos Y_i 's.

Esperança e Variância de $\hat{\beta}_1$

$$\begin{aligned}\mathbb{E}(\hat{\beta}_1) &= \mathbb{E}\left(\sum_{i=1}^n a_i Y_i\right) \\&= \sum_{i=1}^n a_i \mathbb{E}(Y_i) \\&= \sum_{i=1}^n a_i (\beta_0 + \beta_1 X_i) \\&= \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i X_i \\&= \beta_0 \underbrace{\sum_{i=1}^n a_i}_0 + \beta_1 \underbrace{\sum_{i=1}^n a_i X_i}_1 \\&= \beta_1\end{aligned}$$

Esperança e Variância de $\hat{\beta}_1$

$$\begin{aligned}\mathbb{E}(\hat{\beta}_1) &= \mathbb{E}\left(\sum_{i=1}^n a_i Y_i\right) \\&= \sum_{i=1}^n a_i \mathbb{E}(Y_i) \\&= \sum_{i=1}^n a_i (\beta_0 + \beta_1 X_i) \\&= \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i X_i \\&= \beta_0 \underbrace{\sum_{i=1}^n a_i}_0 + \beta_1 \underbrace{\sum_{i=1}^n a_i X_i}_1 \\&= \beta_1\end{aligned}$$

$$\begin{aligned}Var(\hat{\beta}_1) &= Var\left(\sum_{i=1}^n a_i Y_i\right) \\&= \sum_{i=1}^n a_i^2 Var(Y_i) \\&= \sum_{i=1}^n a_i^2 \sigma^2 \\&= \sigma^2 \sum_{i=1}^n a_i^2 \\&= \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \\&= \frac{\sigma^2}{S_{XX}}\end{aligned}$$

Mostre que:

$$\textcircled{1} \mathbb{E}(\hat{\beta}_0) = \beta_0$$

$$\textcircled{2} \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

$$\textcircled{3} \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\sigma^2 \frac{\bar{X}}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Nota: Até agora, definimos apenas os momentos nas suposições do modelo. Então, não importa a distribuição de probabilidade de ε_i , o método de mínimos quadrados fornece estimadores não-viesados para β_0 e β_1 .

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

A partir de agora iremos assumir:

$$\textcircled{1} Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad i = 1, 2, \dots, n$$

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

A partir de agora iremos assumir:

- 1 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad i = 1, 2, \dots, n$
- 2 ε_i é uma v.a. que segue uma distribuição **Normal** com $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

A partir de agora iremos assumir:

- ❶ $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad i = 1, 2, \dots, n$
- ❷ ε_i é uma v.a. que segue uma distribuição **Normal** com $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.
- ❸ ε_i e ε_j são não-correlacionados para $i \neq j$, portanto, $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$.

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

A partir de agora iremos assumir:

- 1 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad i = 1, 2, \dots, n$
- 2 ε_i é uma v.a. que segue uma distribuição **Normal** com $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.
- 3 ε_i e ε_j são não-correlacionados para $i \neq j$, portanto, $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$.

Mais Suposições do Modelo

Até o momento, apenas suposições sobre esperança, variância e correlação foram feitas. E mostramos que os estimadores são não viesados e sabemos também quão precisos eles são.

No entanto, para construirmos intervalos de confiança, precisamos conhecer a distribuição de probabilidade desses estimadores.

A partir de agora iremos assumir:

- ❶ $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad i = 1, 2, \dots, n$
- ❷ ε_i é uma v.a. que segue uma distribuição **Normal** com $\mathbb{E}(\varepsilon_i) = 0$ e $Var(\varepsilon_i) = \sigma^2$ desconhecida, para $i = 1, 2, \dots, n$.
- ❸ ε_i e ε_j são não-correlacionados para $i \neq j$, portanto, $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$.

A suposição 3, pela normalidade dos erros, implica em independência entre as observações i e j para $i \neq j$. Desta maneira, utilizando as suposições 2 e 3, temos que ε_i 's são iid.

Propriedades de Y_i

Já vimos que valor esperado da resposta Y_i é:

$$\mathbb{E}(Y_i) = \beta_0 + \beta_1 X_i$$

E a variância da resposta Y_i é:

$$Var(Y_i) = \sigma^2$$

Propriedades de Y_i

Já vimos que valor esperado da resposta Y_i é:

$$\mathbb{E}(Y_i) = \beta_0 + \beta_1 X_i$$


E a variância da resposta Y_i é:

$$Var(Y_i) = \sigma^2$$

Utilizando a suposição 2, temos que a resposta Y_i segue uma **distribuição Normal** com $\mathbb{E}(Y_i) = \beta_0 + \beta_1 X_i$ (**função de regressão**) e $Var(Y_i) = \sigma^2$.

A resposta, Y_i está acima ou abaixo da função de regressão por um termo de erro ε_i que segue a **distribuição Normal**.

Propriedades de Y_i



Distribuição amostral de $\hat{\beta}_1$

Sabemos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Distribuição amostral de $\hat{\beta}_1$

Sabemos que

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Suponha que tenhamos X_i 's fixos, mas que observamos Y_i 's várias vezes. A cada vez, $\hat{\beta}_1$ será diferente.

Portanto, $\hat{\beta}_1$ muda conforme mudamos nossa amostra. Desta forma, devemos estudar sua **distribuição amostral**.

A distribuição amostral de $\hat{\beta}_1$ dependerá das suposições que fizermos para o modelo de regressão.

Distribuição amostral de $\hat{\beta}_1$

Vimos que, sem suposição de distribuição de probabilidade, temos apenas os momentos definidos, ou seja:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 \quad \text{e} \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Distribuição amostral de $\hat{\beta}_1$

Vimos que, sem suposição de distribuição de probabilidade, temos apenas os momentos definidos, ou seja:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 \quad \text{e} \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Supondo que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, temos que a distribuição de $\hat{\beta}_1$ é:

$$\hat{\beta}_1 \sim N \left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Distribuição amostral de $\hat{\beta}_1$

Vimos que, sem suposição de distribuição de probabilidade, temos apenas os momentos definidos, ou seja:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 \quad \text{e} \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Supondo que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, temos que a distribuição de $\hat{\beta}_1$ é:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right)$$

Padronizando, temos que:

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim N(0, 1)$$

Distribuição amostral de $\hat{\beta}_1$

Vimos que, sem suposição de distribuição de probabilidade, temos apenas os momentos definidos, ou seja:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 \quad \text{e} \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Supondo que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, temos que a distribuição de $\hat{\beta}_1$ é:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right)$$

Padronizando, temos que:

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim N(0, 1)$$

Problema: $\text{Var}(\hat{\beta}_1)$ depende de σ^2 , portanto é desconhecida. Precisamos então estimar também σ^2 .

Estimador de σ^2

Como σ^2 é desconhecido, $Var(\hat{\beta}_0)$, $Var(\hat{\beta}_1)$ e $Cov(\hat{\beta}_0, \hat{\beta}_1)$ também são desconhecidos.

Sabemos que $Var(\varepsilon_i) = \sigma^2$, mas o erro aleatório ε_i não é algo observado.

Consideremos então uma estimativa do erro aleatório ε_i , conhecido como **resíduo**, definido por:

$$e_i = Y_i - \hat{Y}_i,$$

ou seja, é a diferença entre o valor observado da resposta Y_i e o valor estimado pela reta de regressão $\hat{Y}_i$.

Estimador de σ^2

Como σ^2 é desconhecido, $Var(\hat{\beta}_0)$, $Var(\hat{\beta}_1)$ e $Cov(\hat{\beta}_0, \hat{\beta}_1)$ também são desconhecidos.

Sabemos que $Var(\varepsilon_i) = \sigma^2$, mas o erro aleatório ε_i não é algo observado.

Consideremos então uma estimativa do erro aleatório ε_i , conhecido como **resíduo**, definido por:

$$e_i = Y_i - \hat{Y}_i,$$

ou seja, é a diferença entre o valor observado da resposta Y_i e o valor estimado pela reta de regressão $\hat{Y}_i$.

Um estimador não viesado para σ^2 é:

$$s^2 = QME = \frac{SQE}{n-2} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2},$$

em que *QME* é a sigla usada para *quadrado médio do erro* e *SQE* representa a *soma de quadrado dos erros*.

Distribuição amostral de $\hat{\beta}_1$

Definição da distribuição t -Student: Sejam $Z \sim N(0, 1)$ e $V \sim \chi^2_\nu$, **independentes**, então

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$$

Sabendo que,

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/S_{XX}}} \sim N(0, 1)$$

Além disso, $SQE/\sigma^2 \sim \chi^2_{n-2}$ e é independente de $\hat{\beta}_0$ e $\hat{\beta}_1$. Então, aplicando a definição acima, pode-se mostrar que:

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{QME/S_{XX}}} \sim t_{n-2},$$

em que $QME = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - 2}$.

Intervalo de confiança para β_1

Como

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} \sim t_{n-2},$$

podemos escrever a seguinte probabilidade:

$$P \left(-t_{n-2, \alpha/2} \leq \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} \leq t_{n-2, \alpha/2} \right) = 1 - \alpha$$

Intervalo de confiança para β_1

Como

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} \sim t_{n-2},$$

podemos escrever a seguinte probabilidade:


$$P\left(-t_{n-2,\alpha/2} \leq \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\widehat{Var}(\hat{\beta}_1)}} \leq t_{n-2,\alpha/2}\right) = 1 - \alpha$$

Um intervalo de $100(1 - \alpha)\%$ de confiança para β_1 é dado por:

$$IC(\beta_1, 1 - \alpha) = \left[\hat{\beta}_1 - t_{n-2,\alpha/2} \sqrt{\frac{QME}{S_{XX}}}; \hat{\beta}_1 + t_{n-2,\alpha/2} \sqrt{\frac{QME}{S_{XX}}} \right]$$


Como encontrar $t_{n-2,\alpha/2}$

Seja $T \sim t_{n-2}$, então $P(-t_{n-2,\alpha/2} \leq T \leq t_{n-2,\alpha/2}) = 1 - \alpha$



Distribuição t -student e Normal Padrão

Para n grande a distribuição t -student se aproxima da normal padrão $N(0,1)$.



Intervalo de confiança para β_0

De forma análoga ao que fizemos para β_1 , para o intercepto β_0 , temos que:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

com erro padrão dado por:

$$\widehat{Var}(\hat{\beta}_0) = s^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Intervalo de confiança para β_0

De forma análoga ao que fizemos para β_1 , para o intercepto β_0 , temos que:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

com erro padrão dado por:

$$\widehat{Var}(\hat{\beta}_0) = s^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

Um intervalo de $100(1 - \alpha)\%$ de confiança para β_0 é dado por:

$$IC(\beta_0, 1-\alpha) = \left[\hat{\beta}_0 - t_{n-2, \alpha/2} \sqrt{QME \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} \right)}; \hat{\beta}_0 + t_{n-2, \alpha/2} \sqrt{QME \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} \right)} \right]$$

Exemplo: Dados de Galton

Os de Galton estão disponíveis no R no pacote UsingR. Para obtê-lo, basta fazer:

```
library(UsingR)
data(galton)
```

Usando as funções `lm()` e `summary()` ajustamos o modelo de regressão linear e obtemos os coeficientes estimados da seguinte forma:

```
fit = lm(child ~ parent, data=galton)
summary(fit)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.942	2.811	8.52	0
parent	0.646	0.041	15.71	0

Exemplo: Dados de Galton

Os intervalos de confiança de 95% para os parâmetros podem ser obtidos pela função `confint()` e estão na tabela abaixo:

```
confint(fit)
```

	2.5 %	97.5 %
(Intercept)	18.425	29.458
parent	0.566	0.727

Exemplo: Dados de Galton

Os intervalos de confiança de 95% para os parâmetros podem ser obtidos pela função `confint()` e estão na tabela abaixo:

```
confint(fit)
```

	2.5 %	97.5 %
(Intercept)	18.425	29.458
parent	0.566	0.727

PERGUNTA: Qual a interpretação desses intervalos de confiança?

- Applied Linear Statistical Models: 1.8, 2.1-2.9.
- Caffo - Regression Models for Data Science in R: Regression Inference.
- Draper & Smith - Applied Regression Analysis: 1.4, 1.5, 3.1.
- Weisberg - Applied Linear Regression: Capítulo 2.

Agradecimentos

Parte deste material foi criado pela profa.
Samara F. Kiihl - IMECC/UNICAMP

