

ME613 - Análise de Regressão

Parte 4

Tatiana Benaglia - 2S2025

Análise de Variância (ANOVA)

Quanto da variabilidade dos dados foi capturada pela reta ajustada?

Vimos que o resíduo, dado por

$$e_i = Y_i - \hat{Y}_i$$

é uma estimativa do erro aleatório ε_i .

Podemos reescrever o resíduo como:

$$e_i = Y_i - \hat{Y}_i = (Y_i - \bar{Y}) - (\hat{Y}_i - \bar{Y}),$$

ou seja, o resíduo e_i é a diferença entre:

- 1 o valor observado Y_i e a média $\bar{Y}$
- 2 o valor ajustado $\hat{Y}_i$ e a média $\hat{\bar{Y}} = \bar{Y}$.



Análise de Variância (ANOVA)

A Análise de Variância é uma técnica que permite particionar a variação total dos dados em parcelas atribuíveis a diferentes fontes.

No contexto de regressão, a análise de variância baseia-se na seguinte identidade:

$$\underbrace{Y_i - \bar{Y}}_{\text{desvio em relação à média geral}} = \underbrace{(Y_i - \hat{Y}_i)}_{\text{desvio em relação à reta de regressão}} + \underbrace{(\hat{Y}_i - \bar{Y})}_{\text{desvio da reta em relação à média geral}}$$

Veja cada desvio ilustrado nas figuras abaixo



Decomposição do Desvio Total





Figure 1: Decomposição do desvio de cada observação em relação à sua média no caso de Regressão Linear Simples

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Elevando ambos os lados da equação acima ao quadrado e somando para todo $i = 1, \dots, n$, pode-se mostrar que a **Soma de Quadrados Total** pode ser decomposta em:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SQT} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SQReg} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SQE}$$

- **SQT** é a soma dos quadrados total (ajustada), representa a variação total de Y em torno de sua média.

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Elevando ambos os lados da equação acima ao quadrado e somando para todo $i = 1, \dots, n$, pode-se mostrar que a **Soma de Quadrados Total** pode ser decomposta em:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SQT} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SQReg} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SQE}$$

- **SQT** é a soma dos quadrados total (ajustada), representa a variação total de Y em torno de sua média.
- **SQReg** é a soma de quadrados da regressão, representa a variação total de $\hat{Y}$ em torno de sua média.

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Elevando ambos os lados da equação acima ao quadrado e somando para todo $i = 1, \dots, n$, pode-se mostrar que a **Soma de Quadrados Total** pode ser decomposta em:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SQT} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SQReg} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SQE}$$

- **SQT** é a soma dos quadrados total (ajustada), representa a variação total de Y em torno de sua média.
- **SQReg** é a soma de quadrados da regressão, representa a variação total de $\hat{Y}$ em torno de sua média.
- **SQE** é a soma dos quadrados do erro, representa a variação de Y em torno da reta ajustada.

Decomposição da Soma de Quadrados

$$SQT = SQReg + SQE$$

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Fazemos também a decomposição dos respectivos **graus de liberdade**:

$$gl_T = gl_{Reg} + gl_E$$

$$n - 1 = 1 + (n - 2)$$

Definimos também os **quadrados médios**, ou seja, a razão entre a soma de quadrados e seus respectivos graus de liberdade:

$$QM = \frac{SQ}{gl}.$$




Tabela ANOVA - Regressão Linear Simples

A **Análise de Variância** é resumida numa tabela conhecida como **tabela ANOVA**.

Fonte de Variação	Graus de Liberdade	Soma de Quadrados	Quadrados Médios	F
Regressão	1	$SQReg$	$QMReg$	$F = \frac{QMReg}{QME}$
Erro	$n - 2$	SQE	QME	
Total (ajustada)	$n - 1$	SQT		

Sendo

$$SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad SQReg = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 \quad \text{e} \quad SQE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Distribuições Qui-Quadrado e F

Se $X \sim N(\mu, \sigma^2)$, então

$$Z = (X - \mu)/\sigma \sim N(0, 1),$$

ou seja, Z segue uma distribuição normal padrão.

Distribuição Qui-Quadrado: Sejam $Z_i \stackrel{iid}{\sim} N(0, 1)$, então dizemos que

$$X = \sum_{i=1}^n Z_i^2 \sim \chi_n^2,$$

segue uma distribuição Qui-quadrado com n graus de liberdade.

Distribuição F: Seja $X_1 \sim \chi_{k_1}^2$ e $X_2 \sim \chi_{k_2}^2$, tal que $X_1 \perp X_2$. Então,

$$F = \frac{X_1/k_1}{X_2/k_2} \sim F_{k_1, k_2},$$

segue uma distribuição F com k_1 e k_2 graus de liberdade.

ANOVA - Teste F

Para fazer inferências baseado na técnica de análise de variância, precisamos saber o valor esperado de cada quadrado médio, ou seja,

$$\begin{aligned}\mathbb{E}(QME) &= \sigma^2 \\ \mathbb{E}(QMReg) &= \sigma^2 + \beta_1^2 S_{XX}\end{aligned}$$

Comparar essas duas quantidades nos faz propor uma outra estatística do teste para verificar se $\beta_1 = 0$.

Construção do Teste F

Queremos testar se $H_0 : \beta_1 = 0$ vs $H_A : \beta_1 \neq 0$

Pense no que se espera da razão:

$$\frac{QMReg}{QME}$$

Teste F

No caso de regressão linear simples, queremos testar se:

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_A : \beta_1 \neq 0$$

Estatística do teste:


$$F^* = \frac{QMReg}{QME} = \frac{SQReg/1}{SQE/n-2} \stackrel{H_0}{\sim} F_{1,n-2}$$

F_{obs}^* : valor observado da estatística do teste.

p-valor = $P(F_{1,n-2} \geq F_{obs}^*)$

Conclusão: Para um nível de significância α , rejeita-se H_0 se

- $p\text{-valor} < \alpha$; ou
- $F_{obs}^* > F_{1-\alpha,1,n-2} = F_{critico}$



Exemplo: Empresa Toluca

A tabela ANOVA para o Exemplo Toluca é dada a seguir:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos testar: $H_0 : \beta_1 = 0$ vs $H_A : \beta_1 \neq 0$

Pela tabela acima, temos que $SQE = 54825.46$ e $SQReg = 252377.58$. Portanto, a estatística do teste é calculada da seguinte forma:

$$F_{obs}^* = \frac{252377.58/1}{54825.46/23} = \frac{252377.58}{2383.72} = 105.88 \stackrel{H_0}{\sim} F_{1,23}.$$

Exemplo: Empresa Toluca

A tabela ANOVA para o Exemplo Toluca é dada a seguir:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos testar: $H_0 : \beta_1 = 0$ vs $H_A : \beta_1 \neq 0$

Pela tabela acima, temos que $SQE = 54825.46$ e $SQReg = 252377.58$. Portanto, a estatística do teste é calculada da seguinte forma:

$$F_{obs}^* = \frac{252377.58/1}{54825.46/23} = \frac{252377.58}{2383.72} = 105.88 \stackrel{H_0}{\sim} F_{1,23}.$$

Conclusão: Rejeitamos H_0 , ou seja, temos evidência para concluir existe uma associação linear significativa entre tamanho do lote e número de horas trabalhadas.

Exemplo: Empresa Toluca

A tabela ANOVA para o Exemplo Toluca é dada a seguir:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos testar: $H_0 : \beta_1 = 0$ vs $H_A : \beta_1 \neq 0$

Pela tabela acima, temos que $SQE = 54825.46$ e $SQReg = 252377.58$. Portanto, a estatística do teste é calculada da seguinte forma:

$$F_{obs}^* = \frac{252377.58/1}{54825.46/23} = \frac{252377.58}{2383.72} = 105.88 \stackrel{H_0}{\sim} F_{1,23}.$$

Conclusão: Rejeitamos H_0 , ou seja, temos evidência para concluir existe uma associação linear significativa entre tamanho do lote e número de horas trabalhadas.

Curiosidade: Qual a relação entre as estatísticas t e F^* ?

Coeficiente de Determinação R^2

Queremos avaliar quão bom é nosso modelo de regressão.

Caso ideal: todas as observações se ajustam perfeitamente à reta. Neste caso

$$SQE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = 0.$$

Para avaliar o modelo: observar quanto da SQT está contida em $SQReg$ e quanto está na SQE .

Podemos utilizar para avaliar o modelo o **coeficiente de determinação** (R^2):

$$R^2 = \frac{SQReg}{SQT} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{SQE}{SQT},$$

que é a proporção da variabilidade total da variável resposta explicada pelo modelo de regressão ajustado.

Observe que $0 \leq R^2 \leq 1$ e, muitas vezes, é expresso em termos percentuais.

Exemplo: Empresa Toluca

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos calcular o coeficiente de determinação para o exemplo da empresa Toluca.

$$R^2 = \frac{SQReg}{SQT} = \frac{SQReg}{SQReg + SQE} = \frac{252377.58}{252377.58 + 54825.46} = 0.82.$$

Exemplo: Empresa Toluca

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos calcular o coeficiente de determinação para o exemplo da empresa Toluca.

$$R^2 = \frac{SQReg}{SQT} = \frac{SQReg}{SQReg + SQE} = \frac{252377.58}{252377.58 + 54825.46} = 0.82.$$

Interpretação: O tamanho do lote explica 82.2% da variabilidade total das horas trabalhadas.

Exemplo: Empresa Toluca

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X	1	252378	252378	106	0
Residuals	23	54825	2384		

Vamos calcular o coeficiente de determinação para o exemplo da empresa Toluca.

$$R^2 = \frac{SQReg}{SQT} = \frac{SQReg}{SQReg + SQE} = \frac{252377.58}{252377.58 + 54825.46} = 0.82.$$

Interpretação: O tamanho do lote explica 82.2% da variabilidade total das horas trabalhadas.


Mostre que: No caso de regressão linear simples, o R^2 é o quadrado do coeficiente de correlação entre X e Y , ou seja,

$$R^2 = [\text{cor}(X, Y)]^2.$$

No exemplo Toluca, temos que $\text{cor}(X, Y) = 0.91$.

Coeficiente de Determinação R^2 : Cuidado!

Anscombe's 4 Regression data sets



$R^2 = 0.66$ em todos os exemplos acima.

- Applied Linear Statistical Models: 1.8, 2.1-2.9.
- Caffo - Regression Models for Data Science in R: Regression Inference.
- Draper & Smith - Applied Regression Analysis: 1.4, 1.5, 1.6, 3.1.
- Weisberg - Applied Linear Regression: Capítulo 2.

Agradecimentos

Parte deste material foi criado pela profa.
Samara F. Kiihl - IMECC/UNICAMP

