

ME613 - Análise de Regressão

Parte 5

Tatiana Benaglia - 2S2025

Diagnóstico do Modelo

“All models are wrong but some are useful.”


(*George Box*)

Como saber se a função de regressão é adequada para explicar a relação entre as variáveis observadas?

- Gráficos
- Testes de hipóteses (Normalidade, Homocedasticidade, Falta de Ajuste, etc)

Caso a função de regressão não seja adequada, o que fazer?

- Transformação de variáveis.
- Outro tipo de modelo.



George Box, Professor Emeritus of Statistics, University of Wisconsin-Madison

Exemplo: Precificação de Diamantes

Vamos analisar o conjunto de dados `diamond` disponível no pacote `UsingR` do R.

Os dados são preços (em Singapura dólares) e pesos (em quilates) de 48 diamantes. Quilate é uma medida padrão de massa do diamante que corresponde a 0,2 gramas.


```
library(UsingR)
data(diamond)
```

Veja as primeiras observações do conjunto de dados:

carat	price
0.17	355
0.16	328
0.17	350
0.18	325
0.25	642

Exemplo: Precificação de Diamantes

Primeiramente, veja o gráfico de dispersão do preço em função dos quilates.



Exemplo: Precificação de Diamantes

Ajustamos um modelo de regressão linear simples:

```
fit <- lm(price ~ carat, data = diamond)
summary(fit)$coefficients
```

Os coeficientes estimados e seus respectivos testes t estão na tabela abaixo:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-259.6	17.32	-14.99	0
carat	3721.0	81.79	45.50	0

Exemplo: Precificação de Diamantes

Ajustamos um modelo de regressão linear simples:

```
fit <- lm(price ~ carat, data = diamond)
summary(fit)$coefficients
```

Os coeficientes estimados e seus respectivos testes t estão na tabela abaixo:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-259.6	17.32	-14.99	0
carat	3721.0	81.79	45.50	0

Interpretação

- Estimamos um aumento médio de 3.721 dólares (SIN) no preço para cada aumento de um quilate na massa do diamante.
- O intercepto -260 é o preço médio de um diamante de 0 quilates.

Exemplo: Precificação de Diamantes

Veja agora o gráfico de dispersão do preço em função dos quilates com a reta estimada.



Exemplo: Precificação de Diamantes

Vamos ajustar um modelo com um intercepto mais interpretável.

E como fazemos isso? Centralizando a variável X.

```
fit2 <- lm(price ~ I(carat - mean(carat)), data = diamond)
summary(fit2)$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	500.1	4.596	108.8	0
I(carat - mean(carat))	3721.0	81.786	45.5	0

Exemplo: Precificação de Diamantes

Vamos ajustar um modelo com um intercepto mais interpretável.

E como fazemos isso? Centralizando a variável X.

```
fit2 <- lm(price ~ I(carat - mean(carat)), data = diamond)
summary(fit2)$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	500.1	4.596	108.8	0
I(carat - mean(carat))	3721.0	81.786	45.5	0

Interpretação:

- O novo intercepto, cujo valor é 500, representa o preço médio para um diamante de tamanho médio (0,2042 quilates).
- Observe que a inclinação estimada não mudou em nada.

Exemplo: Precificação de Diamantes

Observe que o aumento de um quilate em um diamante é muito grande. Neste caso, também podemos mudar a escala.

Que tal mudar as unidades para 1/10 de um quilate?

```
fit2 <- lm(price ~ I((carat - mean(carat))*10), data = diamond)
summary(fit2)$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	500.1	4.596	108.8	0
I((carat - mean(carat)) * 10)	372.1	8.179	45.5	0

Exemplo: Precificação de Diamantes

Observe que o aumento de um quilate em um diamante é muito grande. Neste caso, também podemos mudar a escala.

Que tal mudar as unidades para 1/10 de um quilate?

```
fit2 <- lm(price ~ I((carat - mean(carat))*10), data = diamond)
summary(fit2)$coefficients
```


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	500.1	4.596	108.8	0
I((carat - mean(carat)) * 10)	372.1	8.179	45.5	0

Podemos fazer isso apenas dividindo o coeficiente por 10, sem a necessidade de reajustar o modelo.

Assim, esperamos uma mudança média de 372 dólares (SIN) no preço para cada aumento de 0,1 quilate na massa do diamante.

Exemplo: Precificação de Diamantes

Veja os **valores preditos** (pontos vermelhos) para cada valor de quilates presente nos dados, juntamente com os **resíduos** (linhas pretas).



Considerando o nosso modelo:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

temos que gráficos de diagnósticos para Y não são úteis em análise de regressão, pois a variável resposta é uma função da variável preditora.

Considerando o nosso modelo:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

temos que gráficos de diagnósticos para Y não são úteis em análise de regressão, pois a variável resposta é uma função da variável preditora.

Sendo assim, os gráficos de diagnósticos são feitos para os **resíduos**.

Lembrando que:

Erros: $\varepsilon_i = Y_i - \mathbb{E}(Y_i|X)$

Resíduos: $e_i = Y_i - \hat{Y}_i$

Se assumimos $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, esperamos que e_i 's, os resíduos observados, reflitam as propriedades assumidas para ε_i 's.

Propriedades dos Resíduos

Para qualquer modelo linear com intercepto, $\sum_{i=1}^n e_i = 0$.

Média dos resíduos:

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = 0$$

Como o procedimento de mínimos quadrados garante que $\bar{e}$ é sempre nula, não há necessidade em checar que $\bar{e} = 0$.

Propriedades dos Resíduos

Para qualquer modelo linear com intercepto, $\sum_{i=1}^n e_i = 0$.

Média dos resíduos:

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = 0$$

Como o procedimento de mínimos quadrados garante que $\bar{e}$ é sempre nula, não há necessidade em checar que $\bar{e} = 0$.

Variância dos resíduos:

$$S^2 = \frac{1}{n-p} \sum_{i=1}^n (e_i - \bar{e})^2 = \frac{SQE}{n-p} = QME$$

Se o modelo é apropriado, QME é um estimador não viesado para a variância dos erros σ^2 .

Análise de Resíduos: Suposições

Podemos utilizar a análise de resíduos para verificar algumas suposições importantes no modelo de regressão linear simples com erros normais:

- ❶ a função de regressão não é linear
- ❷ erros não possuem variância constante (heterocedasticidade)
- ❸ erros não são independentes
- ❹ erros não seguem distribuição normal
- ❺ o modelo ajustado é adequado, com exceção de algumas observações outliers
- ❻ uma ou mais variáveis preditoras foram omitidas no modelo

Resíduos Semi-Studentizados e Gráficos Apropriados

Resíduos Semi-Studentizados: para detectar outliers, muitas vezes é mais útil observar resíduos padronizados, definidos por

$$e_i^* = \frac{e_i}{\sqrt{QME}}$$


Gráficos utilizados na análise de resíduos:

- Resíduos x Variável preditora (no caso de RLS)
- Resíduos x Valores ajustados/preditos ($\hat{Y}$) (no caso de RLM)
- Resíduos ao longo do tempo/em sequência (nem sempre possível)
- Histograma e Boxplot dos resíduos
- Gráfico de probabilidade normal dos resíduos
- Resíduos x Variável preditora não incluída no modelo

Dependendo do objetivo do gráfico, pode-se utilizar os resíduos, resíduos padronizados (studentizados) ou o valor absoluto dos resíduos.


Exemplo: Precificação de Diamantes

Resíduos x Variável Preditora




Exemplo: Precificação de Diamantes

Resíduos x Valores Preditos




Exemplo: Precificação de Diamantes

Resíduos Studentizados x Valores Preditos




Exemplo: Precificação de Diamantes

Resíduos Studentizados x Valores Preditos




Exemplo: Precificação de Diamantes

Resíduos x Ordem das observações




Análise Gráfica dos Resíduos




Fonte: Kutner et al. Applied Linear Statistical Models. 5th edition (Figura 3.4).

Exemplo: Precificação de Diamantes


Histograma dos Resíduos



Normalidade dos resíduos – QQ plot



Não-Normalidade dos Resíduos



Fonte: Kutner et al. Applied Linear Statistical Models. 5th edition (Figura 3.9).

Exemplo: Não-linearidade

Simulamos um exemplo no qual


$$Y_i = X_i + \sin(X_i) + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.2)^2).$$

Exemplo: Não-linearidade

Simulamos um exemplo no qual

$$Y_i = X_i + \sin(X_i) + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.2)^2).$$

Depois de ajustar uma regressão linear (figura à esquerda), veja como fica o gráfico dos resíduos x variável preditora (figura à direita).





Exemplo: Não-linearidade

Simulamos um exemplo no qual

$$Y_i = X_i + \sin(X_i) + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.2)^2).$$

Depois de ajustar uma regressão linear (figura à esquerda), veja como fica o gráfico dos resíduos x variável preditora (figura à direita).



Exemplo: Heterocedasticidade

Simulamos um exemplo no qual a variância do erro depende do valor de X , ou seja,


$$Y_i = X_i + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.001X_i)^2).$$

Exemplo: Heterocedasticidade

Simulamos um exemplo no qual a variância do erro depende do valor de X , ou seja,

$$Y_i = X_i + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.001X_i)^2).$$

Depois de ajustar uma regressão linear (figura à esquerda), veja como fica o gráfico dos resíduos x variável preditora (figura à direita).





Exemplo: Heterocedasticidade

Simulamos um exemplo no qual a variância do erro depende do valor de X , ou seja,

$$Y_i = X_i + \varepsilon_i, \quad \text{com } \varepsilon_i \sim N(0, (0.001X_i)^2).$$

Depois de ajustar uma regressão linear (figura à esquerda), veja como fica o gráfico dos resíduos x variável preditora (figura à direita).



Análise de Resíduos: Testes de Hipóteses

A análise gráfica dos resíduos para verificar suposições do modelo é bastante utilizada e útil. No entanto, é sempre subjetiva e pode apresentar algumas dificuldades.

Além de gráficos, podemos também utilizar testes de hipóteses para avaliar formalmente algumas suposições do modelo.

Análise de Resíduos: Testes de Hipóteses

A análise gráfica dos resíduos para verificar suposições do modelo é bastante utilizada e útil. No entanto, é sempre subjetiva e pode apresentar algumas dificuldades.

Além de gráficos, podemos também utilizar testes de hipóteses para avaliar formalmente algumas suposições do modelo.

Falaremos e revisaremos alguns dos testes mais relevantes.

Por exemplo, o *QQ-plot* é uma ferramenta muito utilizada para detectar se os resíduos seguem uma distribuição normal, mas podemos também utilizar um teste formal para este fim.

Existem testes de normalidade bem conhecidos na literatura como:

- Teste de Kolmogorov-Smirnov e sua modificação: Teste de Lilliefors
- Teste de Shapiro-Wilks.

Teste de Correlação para Normalidade

Calcular coeficiente de correlação entre os resíduos e_i e seus valores esperados, segundo a distribuição normal. Quanto maior a correlação, maior o indício de normalidade dos resíduos.

Na prática, calcular a correlação entre os resíduos ordenados $e_{(1)}, \dots, e_{(k)}, \dots, e_{(n)}$ e seus valores esperados $r_1, r_2, \dots, r_k, \dots, r_n$ segundo a suposição de normalidade.

Uma boa aproximação para r_k é dada por:

$$r_k \approx \sqrt{QME} \left[z \left(\frac{k - 0.375}{n + 0.25} \right) \right]$$

$z(A)$ é o $A \times 100$ percentil da distribuição normal padrão.

Comparar a correlação observada com os valores críticos para um dado nível α (Appendix B - Table B.6 - Applied Linear Statistical Models).

Se o coeficiente de correlação observado for maior ou igual ao valor crítico, pode-se concluir que os erros são normalmente distribuídos.


Exemplo: Real State

Esses dados representam o preço de venda de uma casa (SalePrice) e várias características.

SalePrice	SqFeet	Beds	Baths	Air	Garage	Pool	Year	Quality	Style	Lot	Highway
360.0	3.032	4	4	1	2	0	1972	2	1	22.22	0
340.0	2.058	4	2	1	2	0	1976	2	1	22.91	0
250.0	1.780	4	3	1	2	0	1980	2	1	21.34	0
205.5	1.638	4	2	1	2	0	1963	2	1	17.34	0
275.5	2.196	4	3	1	2	0	1968	2	7	21.79	0


Inicialmente, vamos verificar a relação entre o preço de venda (SalePrice) e sua área medida em *square feet* (SqFeet). Ajustando um modelo de regressão linear simples, temos:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-82.26	11.433	-7.195	0
SqFeet	159.09	4.824	32.978	0




Exemplo: Real State

Resíduos x Variável Preditora



Exemplo: Real State

Resíduos x Variável Preditora



Este gráfico indica que a variância dos resíduos aumenta à medida que os valores da variável preditora aumentam, o que viola a suposição de variância dos erros constante.

Teste de Homocedasticidade: Brown-Forsythe

- O teste de Brown-Forsythe, uma modificação do teste de Levene, não depende da suposição de normalidade dos erros, isto é, é robusto contra desvios da normalidade.
- Da maneira que iremos descrevê-lo aqui, é aplicável no caso de **regressão linear simples**, quando a variância do erro aumenta ou diminui em relação a variável preditora X .
- Tamanho amostral precisa ser grande o suficiente para que a dependência entre os resíduos possa ser ignorada.
- O teste é baseado na variabilidade dos resíduos.
- Ideia parecida com um teste t para duas amostras.

Teste de Homocedasticidade: Brown-Forsythe

Procedimento

- Dividir os dados em dois grupos de acordo com os níveis de X : X_1 (valores mais baixos de X) e X_2 (valores mais altos de X).
- e_{i1} é o i -ésimo resíduo para o grupo 1 e e_{i2} é o i -ésimo resíduo para o grupo 2.
- n_j é o número de observações no grupo j , $j = 1, 2$, tal que $n = n_1 + n_2$.
- $\tilde{e}_j$ é a mediana dos resíduos do grupo j .
- Calcula os desvios absolutos dos resíduos em relação à mediana do grupo:

$$d_{i1} = |e_{i1} - \tilde{e}_1| \quad \text{e} \quad d_{i2} = |e_{i2} - \tilde{e}_2|$$

Teste de Homocedasticidade: Brown-Forsythe

Estatística do teste:

$$t_{BF}^* = \frac{\bar{d}_1 - \bar{d}_2}{S_d \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}},$$

sendo $\bar{d}_1$ e $\bar{d}_2$ as médias amostrais de d_{i1} e d_{i2} , respectivamente, e S_d^2 a variância combinada:

$$S_d^2 = \frac{\sum_{i=1}^{n_1} (d_{i1} - \bar{d}_1)^2 + \sum_{i=1}^{n_2} (d_{i2} - \bar{d}_2)^2}{n - 2}.$$

Se a variância é constante e n_1 e n_2 grandes o suficiente, então t_{BF}^* segue distribuição t com $n - 2$ graus de liberdade.

Valores altos de t_{BF}^* indicam heterocedasticidade.

Exemplo: Real State

```
data <- read.table("dados/realstate.txt", header = TRUE)
summary(data$SqFeet)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.98	1.70	2.06	2.26	2.64	5.03

Vamos separar os resíduos em dois grupos

```
ind1 = which(data$SqFeet < 2.06) # Grupo 1
ind2 = which(data$SqFeet >= 2.06) # Grupo 2
```

```
resi = fit$resi
resi1 = resi[ind1] # Resíduos Grupo 1
resi2 = resi[ind2] # Resíduos Grupo 2
```

Exemplo: Real State

```
data <- read.table("dados/realstate.txt", header = TRUE)
summary(data$SqFeet)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.98	1.70	2.06	2.26	2.64	5.03

Vamos separar os resíduos em dois grupos

```
ind1 = which(data$SqFeet < 2.06) # Grupo 1
ind2 = which(data$SqFeet >= 2.06) # Grupo 2
```

```
resi = fit$resi
resi1 = resi[ind1] # Resíduos Grupo 1
resi2 = resi[ind2] # Resíduos Grupo 2
```

E calculamos os desvios absolutos em relação à mediana dos grupos:

```
d1 = abs(resi1 - median(resi1))
d2 = abs(resi2 - median(resi2))
```

Exemplo: Real State

Aplicando o teste t para as duas amostras de desvios, temos:

```
t.test(d1, d2, var.equal = TRUE)
```

Two Sample t-test

data: d1 and d2

t = -11, df = 519, p-value <2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-60.54 -41.60

sample estimates:

mean of x mean of y

25.54 76.61

Exemplo: Real State

Aplicando o teste t para as duas amostras de desvios, temos:

```
t.test(d1, d2, var.equal = TRUE)
```

Two Sample t-test

data: d1 and d2

t = -11, df = 519, p-value <2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-60.54 -41.60

sample estimates:

mean of x mean of y

25.54 76.61

Conclusão: Como o p-valor é bem pequeno, rejeitamos H_0 , isto é, temos evidências para rejeitar a hipótese de homocedasticidade dos erros.

Teste de Homocedasticidade: Breusch-Pagan

Assume que $\varepsilon_i \sim N(0, \sigma_i^2)$, ou seja, a variância não é constante.

Da maneira que iremos descrevê-lo aqui, é aplicável no caso de **regressão linear simples**, mas pode ser generalizado para o caso de **regressão linear múltipla**.

Teste de Homocedasticidade: Breusch-Pagan

Assume que $\varepsilon_i \sim N(0, \sigma_i^2)$, ou seja, a variância não é constante.

Da maneira que iremos descrevê-lo aqui, é aplicável no caso de **regressão linear simples**, mas pode ser generalizado para o caso de **regressão linear múltipla**.

O seguinte modelo assume que a variância σ_i^2 depende de X da seguinte forma:

$$\ln \sigma_i^2 = \gamma_0 + \gamma_1 X_i.$$

Logo, se $\gamma_1 = 0$ temos constância na variância dos erros (homocedasticidade). É possível utilizar outros modelos, ou seja, assumir que $\sigma_i^2 = h(X)$.

Teste de Homocedasticidade: Breusch-Pagan

Assume que $\varepsilon_i \sim N(0, \sigma_i^2)$, ou seja, a variância não é constante.

Da maneira que iremos descrevê-lo aqui, é aplicável no caso de **regressão linear simples**, mas pode ser generalizado para o caso de **regressão linear múltipla**.

O seguinte modelo assume que a variância σ_i^2 depende de X da seguinte forma:

$$\ln \sigma_i^2 = \gamma_0 + \gamma_1 X_i.$$

Logo, se $\gamma_1 = 0$ temos constância na variância dos erros (homocedasticidade). É possível utilizar outros modelos, ou seja, assumir que $\sigma_i^2 = h(X)$.

Curiosidade: esse teste foi desenvolvido de forma independente também por Cook e Weisberg. Não estranhe se encontrar na literatura o nome “Cook-Weisberg test”.

Teste de Homocedasticidade: Breusch-Pagan

Neste caso, iremos testar

$$H_0 : \gamma_1 = 0 \text{ (homocedasticidade)} \quad \text{vs} \quad H_1 : \gamma_1 \neq 0 \text{ (heterocedasticidade)}$$

Depois de ajustar a regressão de Y em X , usaremos uma regressão auxiliar, na qual ajustaremos a regressão dos resíduos quadrados e_i^2 em X_i , ou seja,

$$e_i^2 = \gamma_0 + \gamma_1 X_i + \epsilon_i,$$

e aplicamos o teste para γ_1 de forma similar ao que fazemos para β_1 .

Teste de Homocedasticidade: Breusch-Pagan

Neste caso, iremos testar

$$H_0 : \gamma_1 = 0 \text{ (homocedasticidade)} \quad \text{vs} \quad H_1 : \gamma_1 \neq 0 \text{ (heterocedasticidade)}$$

Depois de ajustar a regressão de Y em X , usaremos uma regressão auxiliar, na qual ajustaremos a regressão dos resíduos quadrados e_i^2 em X_i , ou seja,

$$e_i^2 = \gamma_0 + \gamma_1 X_i + \epsilon_i,$$

e aplicamos o teste para γ_1 de forma similar ao que fazemos para β_1 .

Estatística do teste:

$$X_{BP}^2 = \frac{SQReg^*/2}{(SQE/n)^2} \stackrel{H_0}{\sim} \chi_1^2,$$

em que $SQReg^*$ é a soma de quadrados da regressão de e^2 em X e SQE é a soma de quadrados do erro da regressão de Y em X .

Exemplo: Real State

Regressão de Y em X :

```
fit = lm(SalePrice ~ SqFeet, data = data)
a1 <- anova(fit)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
SqFeet	1	6666447	6666447	1088	0
Residuals	519	3181416	6130		

Exemplo: Real State

Regressão de Y em X :

```
fit = lm(SalePrice ~ SqFeet, data = data)
a1 <- anova(fit)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
SqFeet	1	6666447	6666447	1088	0
Residuals	519	3181416	6130		

Regressão auxiliar dos resíduos quadrados em X :

```
fit2 = lm(residuos^2 ~ SqFeet, data = data)
a2 <- anova(fit2)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
SqFeet	1	1.717e+10	1.717e+10	87.43	0
Residuals	519	1.019e+11	1.964e+08		

Teste de Homocedasticidade: Breusch-Pagan

Calculando a estatística do teste Breusch-Pagan para homocedasticidade, temos:

$$X_{BP}^2 = \frac{SQReg^*/2}{(SQE/n)^2} = 230.28$$

Teste de Homocedasticidade: Breusch-Pagan

Calculando a estatística do teste Breusch-Pagan para homocedasticidade, temos:

$$X_{BP}^2 = \frac{SQReg^*/2}{(SQE/n)^2} = 230.28$$

Para executar esse teste no R, existem várias funções:

- `ncvTest()` do pacote `car`
- `bptest()` do pacote `lmtest`
- `plmtest()` do pacote `plm`
- `breusch_pagan()` do pacote `skedastic`


```
library(car)
ncvTest(fit)
```

Non-constant Variance Score Test

Variance formula: ~ fitted.values

Chisquare = 230.3, Df = 1, p = <2e-16

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition: Seções 3.1-3.7 e 6.8.
- Draper & Smith - Applied Regression Analysis: Capítulo 2.
- Caffo - Regression Models for Data Science in R: Residuals.
- Brown, M. B., & Forsythe, A. B. (1974). Robust Tests for the Equality of Variances. Journal of the American Statistical Association, 69(346), 364–367.
<https://doi.org/10.2307/2285659>
- Breusch, T. S., & Pagan, A. R. (1979). A Simple Test for Heteroscedasticity and Random Coefficient Variation. Econometrica, 47(5), 1287–1294.
<https://doi.org/10.2307/1911963>



"It's a non-linear pattern with outliers.....but for some reason I'm very happy with the data."