


ME613 - Análise de Regressão

Parte 6

Tatiana Benaglia - 2S2025

Exemplo: Agências bancárias

Neste exemplo referente a dados de 11 agências bancárias, queremos verificar a relação entre o número de novas contas abertas (Y) e o depósito mínimo exigido para abertura da conta (X).



Explore o gráfico interativo: <https://online.stat.psu.edu/stat501/lesson/2/2.9>

Falta de Ajuste


No exemplo anterior, você acredita que a função linear abaixo é apropriada?

$$\text{Contas} = \beta_0 + \beta_1 \text{Deposito} + \varepsilon$$

Veja o ajuste da Regressão Linear Simples e o gráfico dos resíduos ao lado:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	50.7225	39.3979	1.287	0.2301
Deposito	0.4867	0.2747	1.772	0.1102

Pergunta: O que você observa no gráfico?



Falta de Ajuste

Existem dois motivos plausíveis pelo qual nossos pontos podem não cair exatamente na linha de regressão estimada:

- 1) nosso modelo de regressão não descreva bem a tendência dos dados, ou seja, o modelo pode apresentar uma “falta de ajuste”.
- 2) Há apenas uma variação aleatória nos dados.

Falta de Ajuste

Existem dois motivos plausíveis pelo qual nossos pontos podem não cair exatamente na linha de regressão estimada:

- 1) nosso modelo de regressão não descreva bem a tendência dos dados, ou seja, o modelo pode apresentar uma “falta de ajuste”.
- 2) Há apenas uma variação aleatória nos dados.

Isso sugere que devemos decompor o erro em duas componentes:

- uma parte devido à **falta de ajuste** do modelo;
- uma segunda parte apenas devido ao **erro aleatório** (erro puro).

Falta de Ajuste

Existem dois motivos plausíveis pelo qual nossos pontos podem não cair exatamente na linha de regressão estimada:

- 1) nosso modelo de regressão não descreva bem a tendência dos dados, ou seja, o modelo pode apresentar uma “falta de ajuste”.
- 2) Há apenas uma variação aleatória nos dados.

Isso sugere que devemos decompor o erro em duas componentes:

- uma parte devido à **falta de ajuste** do modelo;
- uma segunda parte apenas devido ao **erro aleatório** (erro puro).

No entanto, para que seja possível decompor a Soma de Quadrados dos Erros (SQE), é preciso que tenhamos mais de uma observação para cada valor distinto de X (replicações).

Teste F para Falta de Ajuste

Queremos então testar se a função de regressão proposta é adequada para os dados.

Primeiramente, vamos estabelecer uma notação antes de elaborar o teste de falta de ajuste.

Suponha que tenhamos c níveis ou valores distintos do preditor X : $x_1, x_2, \dots, x_c$. E para cada x_i , temos n_i observações, ou seja,

$$n = \sum_{i=1}^c n_i$$

Considere a seguinte notação:

- Y_{ij} denota a j -ésima resposta para o i -ésimo valor de X
- $\bar{Y}_i$ denota a média de todos os valores de Y para o i -ésimo valor de X
- $\hat{Y}_{ij}$ é o valor predito para a j -ésima resposta feita no i -ésimo valor de X

Decomposição da Soma de Quadrados dos Erros

A Soma de Quadrados dos Erros (SQE) pode ser particionada em:

$$\underbrace{\sum_{i=1}^c \sum_{j=1}^{n_i} (Y_{ij} - \hat{Y}_i)^2}_{SQE} = \underbrace{\sum_{i=1}^c n_i (\bar{Y}_i - \hat{Y}_i)^2}_{SQFA} + \underbrace{\sum_{i=1}^c \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2}_{SQE_p}$$

- SQE é a soma de quadrados dos resíduos, representando a variação em torno da reta.
- SQE_p é a soma de quadrados do erro puro, representando a variação de Y , para X fixo, independente do modelo (pois utilizamos as replicações).
- $SQFA$ é a soma de quadrados da falta de ajuste, representando a falta de ajuste do modelo.

Demonstre!

Ilustração da decomposição da SQE : <https://online.stat.psu.edu/stat501/lesson/2/2.10>

Os graus de liberdade associados a cada soma de quadrados na decomposição anterior seguem uma decomposição similar, ou seja,

$$n - 2 = (c - 2) + (n - c)$$

Definimos também os respectivos Quadrados Médios:

$$QMF A = \frac{SQFA}{c - 2}$$
$$QME_p = \frac{SQE_p}{n - c}$$

Estimação de σ^2

Com replicações para cada $X = x_i$, temos um estimador para $\sigma^2 = \text{Var}(Y|X = x_i)$.

Por exemplo, quando $X = x_1$, podemos usar $Y_{11}, Y_{12}, \dots, Y_{1n_1}$ e o seguinte estimador para $\text{Var}(Y|X = x_1)$:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (Y_{1j} - \bar{Y}_1)^2$$

Estimação de σ^2

Com replicações para cada $X = x_i$, temos um estimador para $\sigma^2 = \text{Var}(Y|X = x_i)$.

Por exemplo, quando $X = x_1$, podemos usar $Y_{11}, Y_{12}, \dots, Y_{1n_1}$ e o seguinte estimador para $\text{Var}(Y|X = x_1)$:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (Y_{1j} - \bar{Y}_1)^2$$

Combinando todas as observações em cada nível de X , temos o seguinte estimador para σ^2 :

$$S_p^2 = \frac{\sum_{i=1}^c \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2}{\sum_{i=1}^c (n_i - 1)} = \frac{SQE_p}{n - c} = QME_p,$$

de forma que $\mathbb{E}(QME_p) = \sigma^2$.

Estimação de σ^2

Com replicações para cada $X = x_i$, temos um estimador para $\sigma^2 = \text{Var}(Y|X = x_i)$.

Por exemplo, quando $X = x_1$, podemos usar $Y_{11}, Y_{12}, \dots, Y_{1n_1}$ e o seguinte estimador para $\text{Var}(Y|X = x_1)$:

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (Y_{1j} - \bar{Y}_1)^2$$

Combinando todas as observações em cada nível de X , temos o seguinte estimador para σ^2 :

$$S_p^2 = \frac{\sum_{i=1}^c \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2}{\sum_{i=1}^c (n_i - 1)} = \frac{SQE_p}{n - c} = QME_p,$$

de forma que $\mathbb{E}(QME_p) = \sigma^2$.

Também pode-se mostrar que

$$\mathbb{E}(QMFA) = \sigma^2 + \frac{1}{c-2} \sum_{i=1}^c n_i [\mu_i - (\beta_0 + \beta_1 X_i)]^2, \quad \text{sendo } \mu_i = \mathbb{E}(Y_{ij}|X = x_i).$$

Teste F para Falta de Ajuste

Hipóteses

H_0 : Não há falta de ajuste, ou seja, o modelo assumido é razoável.

H_1 : Há falta de ajuste, ou seja, o modelo assumido não é razoável.

Estatística do teste:

$$F^* = \frac{QMFA}{QME_p} = \frac{SQFA/(c-2)}{SQE_p/(n-c)} \stackrel{H_0}{\sim} F_{c-2, n-c}$$

Valores relativamente altos de $SQFA$ indicam discrepância entre esses dois estimadores e, consequentemente, indicam evidência contra a adequação do modelo.

Quanto mais alto o valor de $SQFA$, pior é o ajuste do modelo, pois, se o modelo fosse perfeito, teríamos que $SQFA = 0$.

Tabela ANOVA

Table 2: Tabela ANOVA com Teste F de Falta de Ajuste

Fonte de Variação	gl	SQ	QM	F
Regressão	1	$SQReg$	$QMReg = SQReg/1$	$F = \frac{QMReg}{QME}$
Erro	$n - 2$	SQE	$QME = SQE/n - 2$	
Falta de Ajuste	$c - 2$	$SQFA$	$QMFA = SQFA/c - 2$	$F^* = \frac{QMFA}{QME_p}$
Puro Erro	$n - c$	SQE_p	$QME_p = SQE_p/n - c$	
Total	$n - 1$	SQT		

Essa tabela ANOVA é para o caso de Regressão Linear Simples, mas é possível generalizar para o caso de $p \geq 2$ preditores (Regressão Linear Múltipla).

Exemplo: Agências Bancárias

Esse teste também pode ser feito usando a ideia de **modelo completo** e **modelo reduzido**.

Modelo Completo (*unrestricted*):

$$Y_{ij} = \mu_i + \varepsilon_{ij}.$$

Temos que $\mathbb{E}(Y_{ij}) = \mu_i$, isto é, temos esperança diferente para cada $X = x_i$.

Exemplo: Agências Bancárias

Esse teste também pode ser feito usando a ideia de **modelo completo** e **modelo reduzido**.

Modelo Completo (*unrestricted*):

$$Y_{ij} = \mu_i + \varepsilon_{ij}.$$

Temos que $\mathbb{E}(Y_{ij}) = \mu_i$, isto é, temos esperança diferente para cada $X = x_i$.

Modelo Reduzido (*restricted*): Reta de Regressão

$$Y_{ij} = \beta_0 + \beta_1 X_i + \varepsilon_{ij}.$$

Compara-se então a Soma de Quadrados dos Erros desses dois modelos para verificar se existe uma diferença significativa entre eles.

Agências bancárias - Modelo Completo

```
full = lm(y ~ as.factor(x) - 1)
```

Table 3: Tabela dos coeficientes estimados - Modelo Completo

	Estimate	Std. Error	t value	Pr(> t)
as.factor(x)75	35	10.71	3.267	0.0223
as.factor(x)100	124	10.71	11.573	0.0001
as.factor(x)125	155	10.71	14.466	0.0000
as.factor(x)150	152	15.15	10.031	0.0002
as.factor(x)175	140	10.71	13.066	0.0000
as.factor(x)200	114	10.71	10.640	0.0001

Table 4: Tabela ANOVA - Modelo Completo

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
as.factor(x)	6	169548	28258.0	123.1	0
Residuals	5	1148	229.6		

Agências Bancárias - Modelo Reduzido

```
reduced = lm(y ~ x)
```

Table 5: Tabela dos coeficientes estimados - Modelo Reduzido

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	50.7225	39.3979	1.287	0.2301
x	0.4867	0.2747	1.772	0.1102

Table 6: Tabela ANOVA - Modelo Reduzido

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
x	1	5141	5141	3.139	0.1102
Residuals	9	14742	1638		

Observe que a SQE no modelo reduzido é maior que no modelo completo? Por que?

Exemplo: Agências Bancárias

Comparando os dois modelos através da função `anova()`:

```
full = lm(y ~ as.factor(x) - 1) # unrestricted  
reduced = lm(y ~ x) # restricted
```

```
anova(reduced, full)
```

Table 7: Tabela ANOVA - Comparação dos Modelos

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
9	14742				
5	1148	4	13594	14.8	0.0056

Analiticamente, esta estatística é igual a que vimos no slide anterior:

$$F_{obs}^* = \frac{[SQE(reduced) - SQE(full)]/4}{SQE(full)/5} = \frac{1.3594 \times 10^4/4}{1148/5} = 14.8$$

Exemplo: Agências Bancárias

Estatística do teste no teste de Falta de Ajuste:

$$F^* = \frac{QMFA}{QME_p} = \frac{SQFA/(c-2)}{SQE_p/(n-c)} \stackrel{H_0}{\sim} F_{c-2, n-c} = F_{4,5}$$

Esta estatística pode ser calculada usando a comparação do modelo completo e modelo reduzido:

$$F_{obs}^* = \frac{[SQE(reduced) - SQE(full)]/4}{SQE(full)/5} = \frac{1.3594 \times 10^4/4}{1148/5} = 14.8$$

P-valor: 0.0056

Valor crítico para $\alpha = 0.05$: 5.19

Conclusão: Como o p-valor é bem pequeno (< 0.01), temos evidência para rejeitar H_0 e concluir que existe uma falta de ajuste.

Exemplo: Agências Bancárias

No R, para obter a tabela ANOVA com o teste de Falta de Ajuste, podemos usar a função `anovaPE()` do pacote `EnvStats`.

```
library(EnvStats)  
anovaPE(reduced)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
x	1	5141	5141.3	22.39	0.0052
Lack of Fit	4	13594	3398.4	14.80	0.0056
Pure Error	5	1148	229.6		

Conclusão: Como o p-valor é bem pequeno (< 0.01), temos evidência para rejeitar H_0 e concluir que existe uma falta de ajuste.

Regressão Polinomial

A **Regressão Polinomial** é uma extensão da regressão linear simples, ou seja,

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \dots + \beta_p X_i^p + \varepsilon$$

É uma técnica utilizada quando a relação entre Y e X não é bem representada por uma reta.

Veja alguns exemplos da relação entre as variáveis:

- **Linear:** $Y_i = \beta_0 + \beta_1 X_i + \varepsilon$
- **Quadrática** (polinômio de 2º grau): $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon$
- **Cúbica** (polinômio de 3º grau): $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \beta_3 X_i^3 + \varepsilon$

Apesar do modelo representar uma relação não linear, ele ainda continua **linear nos parâmetros** e, portanto, podemos estimar os parâmetros através do Métodos de Mínimos Quadrados normalmente.

Exemplo: Agências Bancárias

No exemplo das agências bancárias, vamos então ajustar um modelo incluindo um termo quadrático, ou seja,

$$\text{Contas} = \beta_0 + \beta_1 \text{Deposito} + \beta_2 \text{Deposito}^2 + \varepsilon$$



Veja a tabela dos coeficientes estimados:

```
fit2 = lm(Contas ~ Deposito + I(Deposito^2), data = data)
summary(fit2)$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-325.509	55.8926	-5.824	4e-04
Deposito	6.569	0.8744	7.513	1e-04
I(Deposito^2)	-0.022	0.0031	-7.011	1e-04

Observe a diferença na significância da variável *Deposito* comparada ao modelo de regressão linear simples.

Exemplo: Agências Bancárias



Observe a melhora tanto no ajuste quanto no gráfico dos resíduos.

- Escolher o grau correto do polinômio é um ponto crucial. Para isso, podemos usar métricas de comparações de modelos (teste F, AIC, BIC). Veremos essas métricas mais adiante.
- Pode-se também olhar os gráficos dos resíduos para verificar adequação.

Atenção: graus de polinômio muito altos podem levar ao superajuste (*overfitting*), além do modelo se tornar muito complexo.

Interpretação: regressão polinomial é uma ferramenta matemática poderosa, mas a interpretação requer cuidado.

E se o diagnóstico não melhorar?

Se nos testes e/ou gráficos de diagnóstico do modelo determinarmos que o mesmo não é adequado, o que fazer?

- Aplicar alguma transformação nos dados, de maneira que a regressão linear simples fique adequada.
- Se o caso for de heterocedasticidade, pode-se usar também o método de “Mínimos Quadrados Ponderados”.
- Abandonar o modelo de regressão linear e buscar um modelo mais adequado: regressão logística, regressão não-paramétrica, regressão robusta, entre outros.

Vimos que, a partir da análise de diagnóstico do modelo, determinarmos que o mesmo não é adequado, podemos:



- Aplicar alguma transformação nos dados, de maneira que a regressão linear simples fique adequada.
- Abandonar o modelo e procurar outro mais adequado.

Falaremos agora sobre algumas transformações e dividiremos em dois casos:

- Relações não lineares, mas a suposição de normalidade dos erros com variância constante é adequada;
- Quando não temos normalidade dos erros e a variância é não constante.

Transformações: Relações Não-Lineares

- Linearizar uma relação não linear, em casos que a suposição de normalidade dos erros com variância constante é adequada.
- Tentar encontrar transformação em X ?
- Avaliar os gráficos de resíduos para decidir qual a melhor transformação.

	Prototype Regression Pattern	Transformations of X
(a)		$X' = \log_{10} X$ $X' = \sqrt{X}$
(b)		$X' = X^2$ $X' = \exp(X)$
(c)		$X' = 1/X$ $X' = \exp(-X)$

Exemplo: Treinamento e Performance


Esse exemplo é sobre um experimento para verificar o efeito do número de dias de treinamento recebido (X) na performance (Y) em várias situações de vendas para 10 indivíduos.

Os dados estão na tabela abaixo:

Parte 1		Parte 2	
Days	Performance	Days	Performance
0.5	42.5	1.5	99.6
0.5	50.6	2.0	105.3
1.0	68.5	2.0	111.8
1.0	80.7	2.5	112.3
1.5	89.0	2.5	125.7



O modelo ajustado é dado por:

$$\hat{Y} = 34.945 + 35.77X$$



Exemplo: Treinamento e Performance



Gráfico dos resíduos: e_i versus X_i (preditor) e $\hat{Y}_i$ (valores preditos).




Exemplo: Treinamento e Performance

Modelo ajustado com o preditor sendo $\sqrt{Days}$.

$$\hat{Y} = -10.33 + 83.45\sqrt{X}$$



Transformações: não normalidade e variância não constante



Neste caso

- Tentar encontrar transformação em Y .
- Pode ser combinada com uma transformação também em X .

Exemplo: Idade e nível de poliamina



Esse exemplo relaciona a idade (X) e o nível plasmático de uma poliamina (Y) para uma amostra de 25 crianças saudáveis.

Os dados estão na tabela abaixo

Parte 1		Parte 2		Parte 3	
Idade	Poliamina	Idade	Poliamina	Idade	Poliamina
0	13.44	2	9.83	4	4.86
0	12.84	2	9.00	4	5.10
0	11.91	2	8.65	4	5.67
0	20.09	2	7.85	4	5.75
0	15.60	2	8.88	4	6.23
1	10.11	3	7.94		
1	11.38	3	6.01		
1	10.28	3	5.14		
1	8.96	3	6.90		
1	8.59	3	6.77		

Exemplo: Idade e nível de poliamina



Modelo ajustado: $\hat{Y} = 13.4752 - 2.182X$



Exemplo: Idade e nível de poliamina

Usando a transformação: $Y' = \log_{10}(Y)$, temos o seguinte modelo ajustado

$$\hat{Y}' = 1.13 - 0.1X$$



Algumas transformações em Y

- $\log_e(Y)$: para estabilizar a variância quando esta tende a crescer à medida que Y cresce.
- $\sqrt{Y}$: estabilizar a variância quando esta é proporcional à média dos Y 's.
- $\frac{1}{Y}$: estabilizar a variância, minimizando o efeito de valores muito altos de Y .
- Y^2 : estabilizar a variância quando esta tende a decrescer com a média de Y 's.
- $\arcsin \sqrt{Y}$: estabilizar a variância quando os dados são proporções.
- etc...

Transformações de Box-Cox

Muitas vezes é difícil determinar, através de gráficos, qual a melhor transformação a ser feita.

O procedimento de Box-Cox identifica automaticamente uma transformação:

$$Y' = Y^\lambda$$

em que λ é um parâmetro a ser determinado a partir dos dados.

Modelo com dados transformados:

$$Y_i^\lambda = \beta_0 + \beta_1 X_i + \varepsilon_i$$

O procedimento de Box-Cox utiliza o método de máxima verossimilhança para estimar λ .

Observação: Na prática usa-se uma padronização de Y_i^λ . Veja a Seção 13.2 de Draper & Smith.

Leitura e Agradecimentos

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition, McGraw-Hill, Irwin, New York. Seções 3.8 a 3.11.
- Draper, N. R. and Smith, H. - Applied Regression Analysis: Capítulo 13.

Agradecimentos: parte de material foi criado pela profa. Samara Kiihl - IMECC/Unicamp.

