

ME613 - Análise de Regressão

Parte 7

Tatiana Benaglia - 2S2025

Considerando o modelo de regressão linear simples:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

em que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$.


Dada uma amostra, obtemos as estimativas $\hat{\beta}_0$ e $\hat{\beta}_1$ dos coeficientes e denotamos por

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

os **valores preditos** de Y . Nos referimos a essa equação como “**reta de regressão**” estimada.

A reta de regressão estimada pode ser usada para obter valores preditos da variável resposta dado qualquer valor do preditor para **uma nova observação** ou para **um conjunto de observações**.

Reta de Regressão



É importante distinguir dois problemas diferentes:

- **estimação da resposta média**
- **predição de uma nova observação.**

Seja X_h o nível do preditor X para o qual queremos uma das estimativas a seguir:

$$\hat{Y}_h = \hat{\mathbb{E}}(Y|X = X_h) = \hat{\beta}_0 + \hat{\beta}_1 X_h \quad \text{resposta média } \mathbb{E}(Y | X = X_h)$$

$$\hat{Y}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h + \varepsilon \quad \text{nova observação } Y_h$$

Em ambos os casos, a estimativa pontual é a mesma, mas a variabilidade (incerteza) ao redor do estimador é diferente.

Estimação da Resposta Média $\mathbb{E}(Y_h)$

Seja X_h o nível do preditor X para o qual queremos estimar a resposta média $\mathbb{E}(Y|X = X_h)$ que iremos denotar por $\mathbb{E}(Y_h)$.

Já vimos que estimativa pontual de $\mathbb{E}(Y_h)$ é dada por

$$\hat{Y}_h = \hat{\mathbb{E}}(Y|X = X_h) = \hat{\beta}_0 + \hat{\beta}_1 X_h.$$

Note que X_h pode ser um valor observado na amostra ou pode ser um valor do preditor dentro da amplitude observada de X .

Vamos agora pensar na distribuição amostral de $\hat{Y}_h$.

Distribuição Amostral de $\hat{Y}_h$

Assumindo que os erros são normais, a distribuição amostral de $\hat{Y}_h$ também é normal com:

$$\begin{aligned}\mathbb{E}(\hat{Y}_h) &= \beta_0 + \beta_1 X_h, \\ \text{Var}(\hat{Y}_h) &= \sigma^2 \left[\frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]\end{aligned}$$

Então, vemos que $\mathbb{E}(\hat{Y}_h)$ é um estimador não viesado de $\mathbb{E}(Y_h)$.

Como σ^2 é desconhecido, usamos seu estimador QME e então temos um estimador para a $\text{Var}(\hat{Y}_h)$, ou seja,

$$\widehat{\text{Var}}(\hat{Y}_h) = QME \left[\frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]$$

Observe que a variância de $\hat{Y}_h$ aumenta à medida que X_h se afasta de $\bar{X}$.

Intervalo de Confiança para a Resposta Média

Similar ao que já fizemos anteriormente, pode-se mostrar que:

$$\frac{\hat{Y}_h - \mathbb{E}(Y_h)}{\sqrt{\widehat{Var}(\hat{Y}_h)}} \sim t_{n-2}.$$

Portanto, um intervalo de confiança para a resposta média $\mathbb{E}(Y_h) = \mathbb{E}(Y|X = X_h)$ é dado por:

$$\hat{Y}_h \pm t_{n-2, \alpha/2} \sqrt{QME \left[\frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]}.$$

O intervalo acima pode ser obtido para cada observação X_i observada no conjunto de dados, resultado assim em uma **banda de confiança** para a resposta média.

Exemplo: Empresa Toluca

No exemplo da empresa Toluca, sendo X o tamanho do lote e Y o nº de horas trabalhadas, obtivemos a seguinte tabela com os coeficientes estimados:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	62.37	26.177	2.382	0.02585
X	3.57	0.347	10.290	0.00000

Reta de Regressão Estimada: $\hat{Y} = 62.37 + 3.57X$

Valores Preditos

X	Y	Ypred	Residuos
80	399	348.0	51.018
30	121	169.5	-48.472
50	221	240.9	-19.876
90	376	383.7	-7.684
70	361	312.3	48.720

Estimando a Resposta Média

Vamos encontrar um intervalo de confiança de 90% para a resposta média $\mathbb{E}(Y_h)$ quando o tamanho do lote é $X_h = 65$ unidades.

E a resposta média quando o tamanho do lote é $X_h = 100$ unidades?

Compare ambos os intervalos. Em qual deles o erro padrão é menor? Por que?

Estimando a Resposta Média

No R podemos usar a função `predict()` e especificar o tipo de intervalo.


```
xnew = data.frame(X = c(65, 100))  
predict(fit, newdata = xnew, interval = "confidence", level = 0.90)
```

	X	fit	lwr	upr
1	65	294.4	277.4	311.4
2	100	419.4	394.9	443.8

Compare esses resultados com os intervalos que você obteve nos slides anterior.

Regressão Linear Simples com Banda de Confiança

Horas trabalhadas pelo tamanho do lote



Predição de Uma Nova Observação

Falamos até agora da predição da resposta média. Em outras palavras, estimamos a resposta média para todos as unidades amostrais assumindo um valor específico do preditor X .

Exemplo: Qual o número médio de horas trabalhadas para todos os lotes com $X_h = 65$ unidades?

Predição de Uma Nova Observação

Falamos até agora da predição da resposta média. Em outras palavras, estimamos a resposta média para todos as unidades amostrais assumindo um valor específico do preditor X .


Exemplo: Qual o número médio de horas trabalhadas para todos os lotes com $X_h = 65$ unidades?

Uma outra pergunta seria: qual seria um intervalo de valores plausíveis da resposta Y para uma futura observação quando a variável preditora assume valor X_h ?

Exemplo: No exemplo da empresa Toluca, podemos perguntar quais seria os valores possíveis de número de horas trabalhadas para um lote de $X_h = 65$ unidades com um certo nível de confiança?

Reta de Regressão

Horas trabalhadas pelo tamanho do lote



Intervalo de Predição

Intervalo de confiança refere-se a um intervalo para um parâmetro, cujos valores são fixos mas desconhecidos. No caso, a resposta média $\mathbb{E}(Y|X)$.

Quando falamos de um valor futuro de Y , isto não é um parâmetro, mas sim uma variável aleatória. Por esta razão, nos referimos a um intervalo de valores plausíveis para um Y futuro de **intervalo de predição**.

Intervalo de Predição

Intervalo de confiança refere-se a um intervalo para um parâmetro, cujos valores são fixos mas desconhecidos. No caso, a resposta média $\mathbb{E}(Y|X)$.

Quando falamos de um valor futuro de Y , isto não é um parâmetro, mas sim uma variável aleatória. Por esta razão, nos referimos a um intervalo de valores plausíveis para um Y futuro de **intervalo de predição**.

Determinar um intervalo de predição para Y requer um modelo para o erro envolvido na predição da variável Y .

Para um dado valor do preditor X_h , o erro de predição é dado por:

$$Y_h - \hat{Y}_h = Y_h - (\hat{\beta}_0 + \hat{\beta}_1 X_h),$$

isto é, a diferença entre duas variáveis aleatórias.

Distribuição do Erro de Predição

Assumindo que os erros são normais, a distribuição amostral de $Y_h - \hat{Y}_h$ também é normal com:

$$\begin{aligned}\mathbb{E}(Y_h - \hat{Y}_h) &= \mathbb{E}(Y_h) - \mathbb{E}(\hat{Y}_h) = 0, \\ \text{Var}(Y_h - \hat{Y}_h) &= \text{Var}(Y_h) + \text{Var}(\hat{Y}_h) \\ &= \sigma^2 + \sigma^2 \left[\frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right], \\ &= \sigma^2 \left[1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]\end{aligned}$$

já que Y_h é independente de $\hat{Y}_h$ (obtido com os valores observados de Y na amostra).

Como σ^2 é desconhecido, usamos seu estimador QME e então temos um estimador para a $\text{Var}(\hat{Y}_h)$, ou seja,

$$\widehat{\text{Var}}(Y - \hat{Y}_h) = QME \left[1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]$$

Observe que a variância do erro de predição aumenta à medida que X_h se afasta de $\bar{X}$.

Intervalo de Predição

Similar ao que já fizemos anteriormente, pode-se mostrar que a variável padronizada tem a seguinte distribuição:

$$\frac{Y - \hat{Y}_h}{\sqrt{\widehat{Var}(Y - \hat{Y}_h)}} \sim t_{n-2}.$$

Portanto, para um nível de confiança $1 - \alpha$, um intervalo de predição para Y_h é dado por:

$$\hat{Y}_h \pm t_{n-2, \alpha/2} \sqrt{QME \left[1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{S_{XX}} \right]}.$$

Intervalo de Predição

Considerando ainda o exemplo da Empresa Toluca, encontrar um intervalo de predição de 90% para Y quando o lote é de $X_h = 65$ unidades.

E um intervalo de predição para Y quando o lote é de $X_h = 100$ unidades?

Compare os resultados obtidos aqui com os intervalos de confiança calculados anteriormente.

Comparando Intervalo de Confiança e Intervalo de Predição

Intervalo de confiança (IC) de 90% para a resposta média para $X = 65$ e $X = 100$:

```
xnew <- data.frame(X = c(65, 100))  
ic <- predict(fit, newdata = xnew, interval = "confidence", level = 0.90)
```

X	fit	lwr	upr
65	294.4	277.4	311.4
100	419.4	394.9	443.9

Comparando Intervalo de Confiança e Intervalo de Predição

Intervalo de confiança (IC) de 90% para a resposta média para $X = 65$ e $X = 100$:

```
xnew <- data.frame(X = c(65, 100))  
ic <- predict(fit, newdata = xnew, interval = "confidence", level = 0.90)
```

X	fit	lwr	upr
65	294.4	277.4	311.4
100	419.4	394.9	443.9

Intervalo de predição (IP) de 90% para Y quando $X = 65$ e $X = 100$:


```
ip <- predict(fit, newdata = xnew, interval = "prediction", level = 0.90)
```

X	fit	lwr	upr
65	294.4	209.0	379.8
100	419.4	332.2	506.6

Exemplo Toluca: Intervalos de Confiança e de Predição

```
Xnew <- data.frame(X = seq(from = 20, to = 120, length.out = 50))  
ic <- predict(fit, newdata = Xnew, interval = "confidence")  
ip <- predict(fit, newdata = Xnew, interval = "prediction")
```

Horas trabalhadas pelo tamanho do lote



- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition: Seções 2.4 e 2.5.
- Caffo - Regression Models for Data Science in R: Regression Inference.

Agradecimentos

Parte deste material foi criado pela profa.
Samara F. Kiihl - IMECC/UNICAMP

