

ME613 - Análise de Regressão

Parte 9

Tatiana Benaglia - 2S2025

Matrizes são estruturas retangulares de dados, organizadas em linhas e colunas, muito utilizadas para simplificar e resolver problemas complexos.

Utilizada em diversas áreas, como estatística, ciência da computação e engenharia.

O uso de matriz faz com que os cálculos fiquem mais rápidos e limpos.

Facilita, por exemplo, passar de um modelo mais simples como regressão linear simples, para modelos mais complexos, como regressão linear múltipla.

Tarefa: Revisão de matrizes pelo anexo do Wooldridge - Introdução a Econometria: Uma abordagem moderna - Apêndice D

Um vetor aleatório é simplesmente um vetor cujas componentes são variáveis aleatórias, ou seja,

$$\mathbf{Y}_{n \times 1} = \begin{bmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_n \end{bmatrix}$$

é um vetor aleatório com função de distribuição acumulada conjunta

$$F(y_1, \dots, y_n) = P(Y_1 \leq y_1, \dots, Y_n \leq y_n).$$

Esperança de Vetores e Matrizes Aleatórios

- 1) Se $\mathbf{Y}_{n \times 1}$ é um vetor aleatório, o valor esperado de $\mathbf{Y}$, sinalizado por $\mathbb{E}(\mathbf{Y})$, é o vetor dos valores esperados

$$\mathbb{E}(\mathbf{Y}) = [\mathbb{E}(Y_1), \mathbb{E}(Y_2), \dots, \mathbb{E}(Y_n)]'.$$

Esperança de Vetores e Matrizes Aleatórios

- 1) Se $\mathbf{Y}_{n \times 1}$ é um vetor aleatório, o valor esperado de $\mathbf{Y}$, sinalizado por $\mathbb{E}(\mathbf{Y})$, é o vetor dos valores esperados

$$\mathbb{E}(\mathbf{Y}) = [\mathbb{E}(Y_1), \mathbb{E}(Y_2), \dots, \mathbb{E}(Y_n)]'.$$

- 2) Se $\mathbf{X}_{n \times m}$ é uma matriz aleatória, $\mathbb{E}(\mathbf{X})$ é a matriz de mesma dimensão dos valores esperados:

$$\mathbb{E}(\mathbf{X}) = \begin{bmatrix} \mathbb{E}(X_{11}) & \mathbb{E}(X_{12}) & \dots & \mathbb{E}(X_{1m}) \\ \mathbb{E}(X_{21}) & \mathbb{E}(X_{22}) & \dots & \mathbb{E}(X_{2m}) \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}(X_{n1}) & \mathbb{E}(X_{n2}) & \dots & \mathbb{E}(X_{nm}) \end{bmatrix} = [\mathbb{E}(X_{ij})]$$

Propriedades do Valor Esperado

1) Seja $\mathbf{A}_{m \times n}$ uma matriz e $\mathbf{b}_{n \times 1}$ um vetor, ambos não aleatórios, então

$$\mathbb{E}(\mathbf{A}\mathbf{Y} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{Y}) + \mathbf{b}$$

Propriedades do Valor Esperado

- 1) Seja $\mathbf{A}_{m \times n}$ uma matriz e $\mathbf{b}_{n \times 1}$ um vetor, ambos não aleatórios, então

$$\mathbb{E}(\mathbf{A}\mathbf{Y} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{Y}) + \mathbf{b}$$

- 2) Sejam as matrizes $\mathbf{A}_{p \times n}$ e $\mathbf{B}_{m \times k}$, ambas não aleatórias, então

$$\mathbb{E}(\mathbf{A}\mathbf{X}\mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{X})\mathbf{B}$$

Propriedades do Valor Esperado

- 1) Seja $\mathbf{A}_{m \times n}$ uma matriz e $\mathbf{b}_{n \times 1}$ um vetor, ambos não aleatórios, então

$$\mathbb{E}(\mathbf{A}\mathbf{Y} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{Y}) + \mathbf{b}$$

- 2) Sejam as matrizes $\mathbf{A}_{p \times n}$ e $\mathbf{B}_{m \times k}$, ambas não aleatórias, então

$$\mathbb{E}(\mathbf{A}\mathbf{X}\mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{X})\mathbf{B}$$

- 3) Sejam $\mathbf{X}$ e $\mathbf{Y}$ duas matrizes (ou vetores) aleatórios, com as matrizes $\mathbf{A}$ e $\mathbf{B}$ compatíveis, então

$$\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{B}\mathbb{E}(\mathbf{Y}).$$

Propriedades do Valor Esperado

- 1) Seja $\mathbf{A}_{m \times n}$ uma matriz e $\mathbf{b}_{n \times 1}$ um vetor, ambos não aleatórios, então

$$\mathbb{E}(\mathbf{A}\mathbf{Y} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{Y}) + \mathbf{b}$$

- 2) Sejam as matrizes $\mathbf{A}_{p \times n}$ e $\mathbf{B}_{m \times k}$, ambas não aleatórias, então

$$\mathbb{E}(\mathbf{A}\mathbf{X}\mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{X})\mathbf{B}$$

- 3) Sejam $\mathbf{X}$ e $\mathbf{Y}$ duas matrizes (ou vetores) aleatórios, com as matrizes $\mathbf{A}$ e $\mathbf{B}$ compatíveis, então

$$\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{B}\mathbb{E}(\mathbf{Y}).$$

- 4) Seja $\mathbf{X}_{n \times 1}$ um vetor aleatório e $\mathbf{A}$ uma matriz simétrica. Se $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$ e $\text{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$, então

$$\mathbb{E}(\mathbf{X}'\mathbf{A}\mathbf{X}) = \text{tr}(\mathbf{A}\boldsymbol{\Sigma}) + \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}.$$

Covariância de Vetores Aleatórios

Sejam $\mathbf{X}_{m \times 1}$ e $\mathbf{Y}_{n \times 1}$ dois vetores aleatórios.

A covariância entre $\mathbf{X}$ e $\mathbf{Y}$ é uma matrix $m \times n$ definida por:

$$\begin{aligned}\text{Cov}(\mathbf{X}, \mathbf{Y}) &= \mathbb{E}[(\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))'] \\ &= \mathbb{E}(\mathbf{X}\mathbf{Y}') - \mathbb{E}(\mathbf{X})\mathbb{E}(\mathbf{Y})' \\ &= [\text{Cov}(X_i, Y_j)]\end{aligned}$$

Covariância de Vetores Aleatórios

Sejam $\mathbf{X}_{m \times 1}$ e $\mathbf{Y}_{n \times 1}$ dois vetores aleatórios.

A covariância entre $\mathbf{X}$ e $\mathbf{Y}$ é uma matrix $m \times n$ definida por:

$$\begin{aligned}\text{Cov}(\mathbf{X}, \mathbf{Y}) &= \mathbb{E}[(\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))'] \\ &= \mathbb{E}(\mathbf{X}\mathbf{Y}') - \mathbb{E}(\mathbf{X})\mathbb{E}(\mathbf{Y})' \\ &= [\text{Cov}(X_i, Y_j)]\end{aligned}$$

Teorema: Se $\mathbf{X}_{m \times 1}$ e $\mathbf{Y}_{n \times 1}$ são vetores aleatórios e, $\mathbf{A}_{l \times m}$ e $\mathbf{B}_{p \times n}$ matrizes de constantes, então:

$$\text{Cov}(\mathbf{A}\mathbf{X}, \mathbf{B}\mathbf{Y}) = \mathbf{A}\text{Cov}(\mathbf{X}, \mathbf{Y})\mathbf{B}'.$$

Matriz de Variância-Covariância

Se $\mathbf{X}_{n \times 1}$ é um vetor aleatório, sua matriz de variância-covariância, indicada por $\Sigma = \text{Var}(\mathbf{X}) = \text{Cov}(\mathbf{X}, \mathbf{X})$, é definida como:

$$\Sigma_{n \times n} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_n^2 \end{bmatrix},$$

em que $\sigma_j^2 = \text{Var}(X_j)$ e $\sigma_{ij} = \text{Cov}(X_i, X_j)$.

A matriz de covariâncias do vetor $\mathbf{X}$ satisfaz propriedades fundamentais, mas por enquanto, observe que ela é simétrica.

Propriedades da Matriz de Variância-Covariância

- 1) Note que se os elementos de $\mathbf{X}$ são não correlacionados, Σ será uma matriz diagonal. Se além disso, $\text{Var}(X_i) = \sigma^2$ para todo $i = 1, \dots, n$, então

$$\Sigma = \sigma^2 \mathbf{I}_n.$$

Propriedades da Matriz de Variância-Covariância

- 1) Note que se os elementos de $\mathbf{X}$ são não correlacionados, Σ será uma matriz diagonal. Se além disso, $\text{Var}(X_i) = \sigma^2$ para todo $i = 1, \dots, n$, então

$$\Sigma = \sigma^2 \mathbf{I}_n.$$

- 2) Se $\mathbf{b}_{n \times 1}$ é um vetor de escalares, então

$$\text{Var}(\mathbf{X} + \mathbf{b}) = \text{Var}(\mathbf{X}).$$

Propriedades da Matriz de Variância-Covariância

- 1) Note que se os elementos de $\mathbf{X}$ são não correlacionados, Σ será uma matriz diagonal. Se além disso, $\text{Var}(X_i) = \sigma^2$ para todo $i = 1, \dots, n$, então

$$\Sigma = \sigma^2 \mathbf{I}_n.$$

- 2) Se $\mathbf{b}_{n \times 1}$ é um vetor de escalares, então

$$\text{Var}(\mathbf{X} + \mathbf{b}) = \text{Var}(\mathbf{X}).$$


- 3) Se $\mathbf{A}_{m \times n}$ é uma matriz de escalares, então

$$\text{Var}(\mathbf{AX}) = \mathbf{A} \text{Var}(\mathbf{X}) \mathbf{A}'.$$

Distribuição Normal Multivariada

A Distribuição Normal Multivariada é uma generalização da distribuição normal univariada para altas dimensões.

É comumente usada em muitas áreas incluindo Estatística, Engenharia e Finanças.



Definição da Distribuição Normal Multivariada


Um vetor aleatório $\mathbf{Y} = (Y_1, Y_2, \dots, Y_n)'$ segue uma distribuição normal multivariada com vetor de média μ e matriz de variância Σ , denotada por $\mathbf{Y} \sim N(\mu, \Sigma)$, se sua função de densidade de probabilidade é dada por:

$$f(\mathbf{y}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{y} - \mu)^T \Sigma^{-1} (\mathbf{y} - \mu) \right),$$

em que

- $\mathbf{y}$ é o vetor de variáveis aleatórias multivariadas
- μ é o vetor de médias
- $\Sigma_{n \times n}$ é a matriz de covariância
- n é o número de variáveis aleatórias no vetor $\mathbf{y}$

Distribuição Normal Multivariada



Propriedades

Se $\mathbf{Y} \sim N(\mu, \Sigma)$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.

Propriedades

Se $\mathbf{Y} \sim N(\mu, \Sigma)$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.
- 2) Y_i e Y_j serão independentes se, e somente se, $\sigma_{ij} = \text{Cov}(Y_i, Y_j) = 0$, ou seja, se forem não correlacionados.

Propriedades

Se $\mathbf{Y} \sim N(\mu, \Sigma)$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.
- 2) Y_i e Y_j serão independentes se, e somente se, $\sigma_{ij} = \text{Cov}(Y_i, Y_j) = 0$, ou seja, se forem não correlacionados.
- 3) Se $\mathbf{A}_{m \times n}$ e $\mathbf{b}_{n \times 1}$ uma matriz e um vetor não aleatórios, então

$$\mathbf{AY} + \mathbf{b} \sim N(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}')$$

Propriedades

Se $\mathbf{Y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.
- 2) Y_i e Y_j serão independentes se, e somente se, $\sigma_{ij} = \text{Cov}(Y_i, Y_j) = 0$, ou seja, se forem não correlacionados.
- 3) Se $\mathbf{A}_{m \times n}$ e $\mathbf{b}_{n \times 1}$ uma matriz e um vetor não aleatórios, então

$$\mathbf{AY} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

- 4) Para matrizes não aleatórias $\mathbf{A}$ e $\mathbf{B}$, temos que $\mathbf{AY}$ e $\mathbf{BY}$ são independentes se, e somente se, $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}' = \mathbf{0}$.

Propriedades

Se $\mathbf{Y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.
- 2) Y_i e Y_j serão independentes se, e somente se, $\sigma_{ij} = \text{Cov}(Y_i, Y_j) = 0$, ou seja, se forem não correlacionados.
- 3) Se $\mathbf{A}_{m \times n}$ e $\mathbf{b}_{n \times 1}$ uma matriz e um vetor não aleatórios, então

$$\mathbf{AY} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

- 4) Para matrizes não aleatórias $\mathbf{A}$ e $\mathbf{B}$, temos que $\mathbf{AY}$ e $\mathbf{BY}$ são independentes se, e somente se, $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}' = \mathbf{0}$.
- 5) Se $\mathbf{Y} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ e $\mathbf{A}_{m \times n}$ é uma matriz não aleatória e $\mathbf{B}_{n \times n}$ é uma matriz simétrica idempotente, então $\mathbf{AY}$ e $\mathbf{Y}'\mathbf{BY}$ são independentes se, e somente se, $\mathbf{AB} = \mathbf{0}$.

Propriedades

Se $\mathbf{Y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então temos as seguintes propriedades:

- 1) Cada elemento Y_i é uma variável aleatória normalmente distribuída, ou seja, as marginais de uma distribuição normal multivariada também são normais.
- 2) Y_i e Y_j serão independentes se, e somente se, $\sigma_{ij} = \text{Cov}(Y_i, Y_j) = 0$, ou seja, se forem não correlacionados.
- 3) Se $\mathbf{A}_{m \times n}$ e $\mathbf{b}_{n \times 1}$ uma matriz e um vetor não aleatórios, então

$$\mathbf{AY} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$$

- 4) Para matrizes não aleatórias $\mathbf{A}$ e $\mathbf{B}$, temos que $\mathbf{AY}$ e $\mathbf{BY}$ são independentes se, e somente se, $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}' = \mathbf{0}$.
- 5) Se $\mathbf{Y} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ e $\mathbf{A}_{m \times n}$ é uma matriz não aleatória e $\mathbf{B}_{n \times n}$ é uma matriz simétrica idempotente, então $\mathbf{AY}$ e $\mathbf{Y}'\mathbf{B}\mathbf{Y}$ são independentes se, e somente se, $\mathbf{AB} = \mathbf{0}$.
- 6) Se $\mathbf{Y} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ e $\mathbf{A}$ e $\mathbf{B}$ são matrizes não aleatórias, simétricas e idempotentes, então $\mathbf{Y}'\mathbf{A}\mathbf{Y}$ e $\mathbf{Y}'\mathbf{B}\mathbf{Y}$ são independentes se, e somente se, $\mathbf{AB} = \mathbf{0}$.

Distribuição Qui-Quadrado

Se $X \sim N(\mu, \sigma^2)$, então

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1),$$

ou seja, Z segue uma **distribuição normal padrão**.

Distribuição Qui-Quadrado

Se $X \sim N(\mu, \sigma^2)$, então

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1),$$

ou seja, Z segue uma **distribuição normal padrão**.

Sejam $Z_i \stackrel{iid}{\sim} N(0, 1)$, então dizemos que

$$X = \sum_{i=1}^n Z_i^2 \sim \chi_n^2,$$

segue uma distribuição Qui-quadrado com n graus de liberdade.

Distribuição Qui-Quadrado

Se $X \sim N(\mu, \sigma^2)$, então

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1),$$

ou seja, Z segue uma **distribuição normal padrão**.

Sejam $Z_i \stackrel{iid}{\sim} N(0, 1)$, então dizemos que

$$X = \sum_{i=1}^n Z_i^2 \sim \chi_n^2,$$

segue uma distribuição Qui-quadrado com n graus de liberdade.

Em notação matricial, seja $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$, então

$$\mathbf{Z}'\mathbf{Z} \sim \chi_n^2.$$

Distribuição Qui-Quadrado

Algumas propriedades relevantes:

- ① Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}_{n \times n}$ é uma matriz simétrica, idempotente com $\text{posto}(\mathbf{A}) = q$, então

$$\mathbf{Z}'\mathbf{A}\mathbf{Z} \sim \chi_q^2.$$

Distribuição Qui-Quadrado

Algumas propriedades relevantes:

- ① Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}_{n \times n}$ é uma matriz simétrica, idempotente com $\text{posto}(\mathbf{A}) = q$, então

$$\mathbf{Z}'\mathbf{A}\mathbf{Z} \sim \chi_q^2.$$

- ② Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}$ e $\mathbf{B}$ são matrizes $n \times n$, simétricas, idempotentes de modo que $\mathbf{AB} = \mathbf{0}$, então $\mathbf{Z}'\mathbf{A}\mathbf{Z}$ e $\mathbf{Z}'\mathbf{B}\mathbf{Z}$ são independentes e seguem uma distribuição Qui-quadrados com os respectivos postos de $\mathbf{A}$ e $\mathbf{B}$.

Distribuição Qui-Quadrado

Algumas propriedades relevantes:

- ① Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}_{n \times n}$ é uma matriz simétrica, idempotente com $\text{posto}(\mathbf{A}) = q$, então


$$\mathbf{Z}'\mathbf{A}\mathbf{Z} \sim \chi_q^2.$$

- ② Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}$ e $\mathbf{B}$ são matrizes $n \times n$, simétricas, idempotentes de modo que $\mathbf{AB} = \mathbf{0}$, então $\mathbf{Z}'\mathbf{A}\mathbf{Z}$ e $\mathbf{Z}'\mathbf{B}\mathbf{Z}$ são independentes e seguem uma distribuição Qui-quadrados com os respectivos postos de $\mathbf{A}$ e $\mathbf{B}$.

- ③ Se $\mathbf{W} \sim N(\mathbf{0}, \Sigma)$, em que $\Sigma_{m \times m}$ é uma matriz não singular, então

$$\mathbf{W}'\Sigma^{-1} \sim \chi_m^2.$$

Distribuição Qui-Quadrado



Se $Z \sim N(0, 1)$ e $X \sim \chi_n^2$, tal que $Z \perp X$. Então,

$$T = \frac{Z}{\sqrt{X/n}} \sim t_n.$$

Se $Z \sim N(0, 1)$ e $X \sim \chi_n^2$, tal que $Z \perp X$. Então,


$$T = \frac{Z}{\sqrt{X/n}} \sim t_n.$$

Propriedade

- Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$, $\mathbf{c}_{n \times 1}$ é um vetor de constantes e $\mathbf{A}_{n \times n}$ uma matriz não aleatório, simétrica, idempotente com $\text{posto}(\mathbf{A}) = q$ e $\mathbf{A}\mathbf{c} = \mathbf{0}$, então

$$\frac{\mathbf{c}'\mathbf{Z}/\sqrt{\mathbf{c}'\mathbf{c}}}{\sqrt{\mathbf{Z}'\mathbf{A}\mathbf{Z}/q}} \sim t_q.$$

Distribuição t



Distribuição F

Seja $X_1 \sim \chi_{k_1}^2$ e $X_2 \sim \chi_{k_2}^2$, tal que $X_1 \perp X_2$. Então,

$$F = \frac{X_1/k_1}{X_2/k_2} \sim F_{k_1, k_2}.$$

Seja $X_1 \sim \chi_{k_1}^2$ e $X_2 \sim \chi_{k_2}^2$, tal que $X_1 \perp X_2$. Então,


$$F = \frac{X_1/k_1}{X_2/k_2} \sim F_{k_1, k_2}.$$

Propriedade

- Se $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_n)$, $\mathbf{A}$ e $\mathbf{B}$ matrizes $n \times n$ não aleatórias, simétricas, idempotentes com $\text{posto}(\mathbf{A}) = k_1$, $\text{posto}(\mathbf{B}) = k_2$ e $\mathbf{AB} = \mathbf{0}$, então

$$\frac{\mathbf{Z}'\mathbf{A}\mathbf{Z}/k_1}{\mathbf{Z}'\mathbf{B}\mathbf{Z}/k_2} \sim F_{k_1, k_2}.$$

Distribuição F



Exemplo: Teste de esforço cardiopulmonar

Considere um estudo sobre teste de esforço cardiopulmonar em pacientes com insuficiência cardíaca realizado no InCor da Faculdade de Medicina da USP pela Dra. Ana Fonseca Braga.

- Um dos objetivos do estudo é saber se alguma das características observadas (ou combinação delas), pode ser utilizada para explicar respostas respiratórias e metabólicas obtidas do teste de esforço cardiopulmonar.
- Outro objetivo é comparar os grupos formados pelas diferentes etiologias cardíacas quanto às respostas ao teste de esforço cardiopulmonar.

Dentre essas características, algumas são: sexo, idade, altura, peso, superfície corporal, IMC, carga utilizada na esteira, etiologia cardíaca.

A variável resposta que iremos utilizar é consumo de oxigênio (em ml/kg/min), chamado de $\dot{V}O_2$.

Exemplo: teste de esforço cardiopulmonar

Vamos dar uma olhada nas primeiras linhas do conjunto de dados

ID	Etiologia	Sexo	Idade	Altura	Peso	Superfície	IMC	Carga	VO2
1	CH	M	38	149	54	1.48	24.32	41	10.0
2	CH	M	49	167	80	1.89	27.68	56	11.5
3	ID	F	65	153	56	1.52	23.93	8	7.0
4	ID	M	52	175	78	1.94	25.49	53	8.9
5	IS	F	52	157	59	1.59	23.98	22	8.7
6	CH	F	58	150	62	1.57	27.55	32	10.5
7	ID	F	24	155	42	1.36	17.50	0	6.5
8	IS	F	39	149	55	1.48	24.77	26	9.1
9	ID	F	48	160	77	1.80	30.07	26	8.0
10	CH	M	50	171	81	1.94	27.73	82	13.1

Exemplo: Teste de esforço cardiopulmonar

Considere que o objetivo é o de explicar a variação do consumo de oxigênio no limiar anaeróbio (medido em ml/kg/min) em função da carga utilizada na esteira ergométrica para pacientes com diferentes etiologias (causas) de insuficiência cardíaca.


A grosso modo o Limiar Anaeróbio é um ponto (limite), de divisão entre metabolismo essencialmente aeróbio e metabolismo essencialmente anaeróbio.

Aeróbio (com a utilização de oxigênio); anaeróbio (sem a utilização de oxigênio).

Como responder à pergunta de interesse? Vamos utilizar apenas a carga na esteira e ignorar as etiologias cardíacas e outros preditores num primeiro momento.

Exemplo: Teste de esforço cardiopulmonar

Consumo de oxigênio em função da carga na esteira



Regressão Linear Simples em Termos Matriciais

Considere o modelo de regressão simples:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ e $i = 1, 2, \dots, n$.

Usando notação matricial

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

sendo

$$\mathbf{Y}_{n \times 1} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \quad \mathbf{X}_{n \times 2} = \begin{bmatrix} 1 & X_1 \\ 1 & X_2 \\ \vdots & \vdots \\ 1 & X_n \end{bmatrix} \quad \beta_{2 \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} \quad \varepsilon_{n \times 1} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Regressão Linear com Duas Variáveis Preditoras

Considere o modelo de regressão linear agora com dois preditores:


$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i,$$

em que X_{i1} e X_{i2} são valores de duas variáveis preditoras para a observação i .

Assumindo que $\mathbb{E}(\varepsilon_i) = 0, \forall i$, a função de regressão é dada por:


$$\mathbb{E}(Y) = \mathbb{E}(Y|X_1, X_2) = \beta_0 + \beta_1 X_1 + \beta_2 X_2.$$

Veja que aqui a função de regressão é um plano, análogo ao modelo de Regressão Linear Simples em que essa função era um reta.



Exemplo

No caso de dois preditores, veja a representação da função de regressão:




Nota: Em Regressão Linear Múltipla a função de regressão é também chamada na literatura de *superfície de regressão* ou *superfície de resposta*.

Interpretação dos Coeficientes

- β_0 (intercepto): valor esperado de Y quando $X_1 = 0$ e $X_2 = 0$.
- β_1 : indica a mudança no valor esperado de Y para cada unidade de aumento de X_1 , quando X_2 é mantida constante.
- β_2 : indica a mudança no valor esperado de Y para cada unidade de aumento de X_2 , quando X_1 é mantida constante.

Usando cálculo:

$$\frac{\partial \mathbb{E}(Y)}{\partial X_1} = \beta_1 \quad \text{e} \quad \frac{\partial \mathbb{E}(Y)}{\partial X_2} = \beta_2.$$



Exemplo

Exemplo, se fixamos $X_2 = 2$:


$$\mathbb{E}(Y) = 10 + 2X_1 + 5 \times 2 = 20 + 2X_1$$

Se $\beta_1 = 2$: o valor esperado de Y aumenta 2 unidades a cada aumento de 1 unidade de X_1 , para X_2 mantida constante.

Veja que isso vale para qualquer nível de X_2 , apenas o intercepto é que muda.

De forma equivalente, temos a interpretação de β_2 , fixando X_1 em algum valor:

Se $\beta_2 = 5$: o valor esperado de Y aumenta 5 unidades a cada aumento de 1 unidade de X_2 .



Modelo de Regressão Linear Múltipla Geral

No caso geral, quando temos mais que duas variáveis preditoras, temos:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_{p-1} X_{i,p-1} + \varepsilon_i,$$

para $i = 1, 2, \dots, n$ e assumimos que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$.

Lembrando que o modelo é **linear nos parâmetros**.

Por exemplo, veja os modelos abaixo, todos são lineares (ou linearizáveis) nos parâmetros.

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \beta_3 X_i^3 + \varepsilon_i,$$

$$Y_i = \beta_0 + \beta_1 \cos(t_i) + \beta_2 \sin(t_i) + \varepsilon_i,$$

$$Y_i = e^{(\beta_0 + \beta_1 X_i)} \eta_i \quad \Rightarrow \quad \log(Y_i) = \beta_0 + \beta_1 X_i + \log(\eta_i)$$

Modelo de Regressão Linear Múltipla Geral

No modelo:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_{p-1} X_{i,p-1} + \varepsilon_i,$$

se definirmos $X_{i0} = 1$, podemos escrever:

$$Y_i = \sum_{k=0}^{p-1} \beta_k X_{ik} + \varepsilon_i.$$

Função de regressão (hiperplano):

$$\mathbb{E}(Y|\mathbf{X}) = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1}.$$

Regressão Linear Múltipla

Usando notação matricial, podemos escrever o modelo anterior como:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

sendo

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \quad \mathbf{X}_{n \times p} = \begin{bmatrix} 1 & X_{11} & \dots & X_{1,p-1} \\ 1 & X_{21} & \dots & X_{2,p-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \dots & X_{n,p-1} \end{bmatrix} \quad \beta_{p \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

A matriz $\mathbf{X}$ é chamada de **matriz de delineamento** ou **matriz de regressão**.

Existem vários métodos que podem ser usados para estimar os parâmetros do modelo, mas por enquanto concentraremos em dois métodos:

- Mínimos Quadrados Ordinários (do inglês, *ordinary least squares*);
- Máxima Verossimilhança

Estimador de Mínimos Quadrados

Queremos encontrar um estimador $\hat{\beta}$ que minimiza a soma de quadrados dos erros:

$$\begin{aligned} S(\beta) &= \sum_{i=1}^n \varepsilon_i^2 = \varepsilon' \varepsilon = \|\mathbf{Y} - \mathbf{X}\beta\|^2 \\ &= (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) \\ &= \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\beta - \beta'\mathbf{X}'\mathbf{Y} + \beta'\mathbf{X}'\mathbf{X}\beta \\ &= \mathbf{Y}'\mathbf{Y} - 2\beta'\mathbf{X}'\mathbf{Y} + \beta'\mathbf{X}'\mathbf{X}\beta \end{aligned}$$

ou seja

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} S(\beta)$$

Estimador de Mínimos Quadrados

Então, para minimizar $S(\beta)$ derivamos em relação a $\hat{\beta}$,

$$\frac{\partial S(\beta)}{\partial \beta'} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\beta$$


e igualamos a zero, obtendo assim as **equações normais**:

$$-2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = 0 \quad \Leftrightarrow \quad \mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$$

Se $\mathbf{X}'\mathbf{X}$ tiver posto completo, então sua inversa existe e:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Intuição Geométrica



Voltando na Regressão Linear Simples

Encontre os estimadores de mínimos quadrados usando a forma matricial e verifique que eles coincidem com as fórmulas que apresentamos na aula 1.

Exemplo: teste de esforço cardiopulmonar


Para os dados do teste de esforço cardiopulmonar, ajustamos o modelo de regressão linear simples usando a função `lm` do R:

```
fit.rs = lm(VO2 ~ Carga, data = braga)
```

	x
(Intercept)	6.564
Carga	0.086

Portanto, o modelo ajustado é:

$$VO2 = 6.564 + 0.086Carga$$



Suposições sobre os Erros Aleatórios

Assumindo que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$ temos

$$\mathbb{E}(\varepsilon)_{n \times 1} = \mathbf{0}_{n \times 1} \quad \text{e} \quad \text{Var}(\varepsilon)_{n \times n} = \sigma^2 \mathbf{I}_n.$$

Suposições sobre os Erros Aleatórios

Assumindo que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$ temos

$$\mathbb{E}(\varepsilon)_{n \times 1} = \mathbf{0}_{n \times 1} \quad \text{e} \quad \text{Var}(\varepsilon)_{n \times n} = \sigma^2 \mathbf{I}_n.$$

Dessa forma, podemos mostrar que:

$$\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\mathbf{X}\beta + \varepsilon) = \mathbf{X}\beta$$

e

$$\text{Var}(\mathbf{Y}) = \text{Var}(\mathbf{X}\beta + \varepsilon) = \text{Var}(\varepsilon) = \sigma^2 \mathbf{I}$$

Suponha que $\mathbb{E}(\varepsilon) = \mathbf{0}$ e $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}$. Então,

1) $\mathbb{E}(\hat{\beta}) = \beta$

Suponha que $\mathbb{E}(\varepsilon) = \mathbf{0}$ e $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}$. Então,

1) $\mathbb{E}(\hat{\beta}) = \beta$

2) $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}$

$$\begin{aligned}\text{Var}(\hat{\beta}) &= \text{Var} [(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}] \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\text{Var}(\mathbf{Y})\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\sigma^2\mathbf{I}\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

O valor predito do vetor $\mathbf{Y}$, chamado de $\hat{\mathbf{Y}}$, é:

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{\mathbf{H}} \mathbf{Y} = \mathbf{H}\mathbf{Y},$$

ou seja, $\mathbf{H}$ é a matriz de projeção ortogonal no espaço coluna de $\mathbf{X}$.

O valor predito do vetor $\mathbf{Y}$, chamado de $\hat{\mathbf{Y}}$, é:


$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{\mathbf{H}} \mathbf{Y} = \mathbf{H}\mathbf{Y},$$

ou seja, $\mathbf{H}$ é a matriz de projeção ortogonal no espaço coluna de $\mathbf{X}$.

E o vetor de resíduos é dado por:

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{H}\mathbf{Y} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$$

Projeção Ortogonal



Exemplo: teste de esforço cardiopulmonar


Vamos voltar no exemplo do teste de esforço cardiopulmonar.

ID	Etiologia	Sexo	Idade	Altura	Peso	Superfície	IMC	Carga	VO2
1	CH	M	38	149	54	1.48	24.32	41	10.0
2	CH	M	49	167	80	1.89	27.68	56	11.5
3	ID	F	65	153	56	1.52	23.93	8	7.0
4	ID	M	52	175	78	1.94	25.49	53	8.9
5	IS	F	52	157	59	1.59	23.98	22	8.7
6	CH	F	58	150	62	1.57	27.55	32	10.5
7	ID	F	24	155	42	1.36	17.50	0	6.5
8	IS	F	39	149	55	1.48	24.77	26	9.1
9	ID	F	48	160	77	1.80	30.07	26	8.0
10	CH	M	50	171	81	1.94	27.73	82	13.1

Lembrando que o objetivo é o de explicar a variação do consumo de oxigênio (VO_2) em função de alguns preditores.

Exemplo: Teste de esforço cardiopulmonar

Consumo de oxigênio em função da carga na esteira



Exemplo: teste de esforço cardiopulmonar

Veja a tabela dos coeficientes estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.564	0.3560	18.44	0
Carga	0.086	0.0069	12.52	0

Residual standard error: 1.892 on 122 degrees of freedom

Multiple R-squared: 0.5622, Adjusted R-squared: 0.5586

F-statistic: 156.6 on 1 and 122 DF, p-value: $< 2.2e-16$

Exemplo: teste de esforço cardiopulmonar

Veja a tabela dos coeficientes estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.564	0.3560	18.44	0
Carga	0.086	0.0069	12.52	0

Residual standard error: 1.892 on 122 degrees of freedom

Multiple R-squared: 0.5622, Adjusted R-squared: 0.5586


F-statistic: 156.6 on 1 and 122 DF, p-value: $< 2.2e-16$

E observe também a tabela ANOVA:

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Carga	1	560.6	560.599	156.6	0
Residuals	122	436.6	3.579		



Exemplo: Teste de esforço cardiopulmonar

Vamos considerar agora a variável Peso como um segundo preditor.




Exemplo: Teste de esforço cardiopulmonar

Veja alguns gráficos de dispersão em 3D para os preditores Carga e Peso.



Exemplo: Teste de esforço cardiopulmonar

Queremos encontrar um plano que melhor se ajuste a essa nuvem de pontos.



Exemplo: Teste de esforço cardiopulmonar

Ajustamos o modelo de regressão linear múltipla usando Carga e Peso como preditores:

```
fit.rm = lm(V02 ~ Carga + Peso, data = braga)
summary(fit.rm)
```

Veja abaixo a tabela dos coeficientes estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.8609	0.8213	14.442	0
Carga	0.0998	0.0062	16.185	0
Peso	-0.0825	0.0119	-6.937	0

Residual standard error: 1.607 on 121 degrees of freedom

Multiple R-squared: 0.6868, Adjusted R-squared: 0.6816

F-statistic: 132.6 on 2 and 121 DF, p-value: < 2.2e-16

Pergunta: O que você observa?

Exemplo: Teste de esforço cardiopulmonar

E se adicionarmos Carga, Peso, Altura, Idade e IMC como preditores?

```
fit.rm2 = lm(VO2 ~ Carga + Peso + Altura + Idade + IMC, data = braga)
summary(fit.rm2)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	13.3926	6.0314	2.2205	0.0283
Carga	0.1080	0.0064	16.8190	0.0000
Peso	-0.0804	0.0374	-2.1477	0.0338
Altura	-0.0226	0.0367	-0.6171	0.5384
Idade	0.0409	0.0117	3.4897	0.0007
IMC	-0.0145	0.1028	-0.1413	0.8879

Residual standard error: 1.539 on 118 degrees of freedom

Multiple R-squared: 0.7199, Adjusted R-squared: 0.708

F-statistic: 60.66 on 5 and 118 DF, p-value: < 2.2e-16

Pergunta: E agora, o que você observa?

Leitura e Agradecimentos

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition, McGraw-Hill, Irwin, New York.
- Wooldridge - Introdução a Econometria: Uma abordagem moderna - Apêndices B e D

Agradecimentos: parte de material foi criado pela profa. Samara Kiihl - IMECC/Unicamp.

