

ME613 - Análise de Regressão

Parte 10

Tatiana Benaglia - 2S2025

Regressão Linear Múltipla

Estamos trabalhando com o modelo de regressão linear múltipla:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

assumindo que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$.

Vimos em aulas anteriores como estimar o vetor de parâmetros β pelo método de Mínimos Quadrados, ou seja,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y},$$

considerando que $\mathbf{X}'\mathbf{X}$ é inversível.

Estimação de σ^2

Veja que o método de Mínimos Quadrados não nos dá um estimador para σ^2 , como veremos no método de Máxima Verossimilhança. Mas podemos encontrá-lo através do teorema a seguir.

Teorema: Se $\mathbb{E}(\mathbf{Y}) = \mathbf{X}\beta$, com $\text{posto}(\mathbf{X}) = r \leq p$, e $\text{Var}(\mathbf{Y}) = \sigma^2\mathbf{I}$, então

$$S^2 = \frac{(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta})}{n - r} = \frac{SQE}{n - r},$$

é um estimador não viesado de σ^2 . SQE é a Soma de Quadrados dos Resíduos.

Quando $\mathbf{X}$ tem posto completo,

$$S^2 = \frac{(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta})}{n - p} = \frac{SQE}{n - p}.$$

Até agora as únicas suposições que usamos sobre o vetor de erros aleatórios é que $\mathbb{E}(\varepsilon) = \mathbf{0}$ e $\text{Var}(\varepsilon) = \sigma^2 \mathbf{I}_n$.

Se além disso assumirmos que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$, temos as seguintes distribuições para algumas estatísticas.

Teorema: Se $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$, com $\mathbf{X}_{n \times p}$ de posto completo p , então:

(i) $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$

(ii) $(\hat{\beta} - \beta)' \mathbf{X}' \mathbf{X} (\hat{\beta} - \beta) / \sigma^2 \sim \chi_p^2$

(iii) $\hat{\beta}$ é independente de $S^2 = \frac{SQE}{n-p}$

(iv) $\frac{SQE}{\sigma^2} = \frac{(n-p)S^2}{\sigma^2} \sim \chi_{n-p}^2$

Estimador de Máxima Verossimilhança

Voltando ao modelo de regressão linear múltipla:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon.$$

Assumindo que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, então $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$.

Portanto, a função de verossimilhança do modelo proposto é dada por

$$f(\mathbf{Y}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)' (\mathbf{Y} - \mathbf{X}\beta) \right\},$$

e a função de log-verossimilhança por

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)' (\mathbf{Y} - \mathbf{X}\beta).$$

Vamos então derivar a log-verossimilhança em relação aos parâmetros β e σ^2 e igualar a zero.

Estimador de Máxima Verossimilhança

Os estimadores de máxima verossimilhança (MV) são as soluções das equações:

$$\frac{\partial \ell(\beta, \sigma^2)}{\partial \beta} \Big|_{\beta=\hat{\beta}} = \mathbf{0} \quad \text{e} \quad \frac{\partial \ell(\beta, \sigma^2)}{\partial \sigma^2} \Big|_{\sigma^2=\hat{\sigma}^2} = \mathbf{0}.$$

Temos que,

$$\begin{aligned} \frac{\partial \ell(\beta, \sigma^2)}{\partial \beta} &= -\frac{1}{2\sigma^2}(-2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\beta) \\ \frac{\partial \ell(\beta, \sigma^2)}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) \end{aligned}$$

Então,

$$\begin{aligned} \mathbf{X}'\mathbf{X}\hat{\beta} &= \mathbf{X}'\mathbf{Y} \quad (\text{equações normais}) \\ \hat{\beta}_{MV} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \end{aligned}$$

desde que $\mathbf{X}'\mathbf{X}$ seja invertível.

Como $n \gg p$, tal inversibilidade ocorrerá se, e somente se, a matriz $\mathbf{X}$ tiver posto coluna completo.

Voltando na segunda equação, temos o estimador de σ^2 :

$$\hat{\sigma}_{MV}^2 = \frac{1}{n}(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) = \frac{SQE}{n}$$

Observe que este é um estimador viesado para σ^2 . Falaremos disso em breve.

Matriz Inversa Generalizada

Seja $\mathbf{A}$ uma matriz $m \times n$. A matriz $\mathbf{A}^-_{n \times m}$ é a inversa generalizada de $\mathbf{A}$, também conhecida como pseudoinversa, se:

$$\mathbf{A}\mathbf{A}^-\mathbf{A} = \mathbf{A}.$$

A matriz inversa generalizada $\mathbf{A}^-$ sempre existe e tem as seguintes propriedades:

- i) $\mathbf{A}\mathbf{A}^-\mathbf{A} = \mathbf{A}$
- ii) $\mathbf{A}^-\mathbf{A}\mathbf{A}^- = \mathbf{A}^-$
- iii) $(\mathbf{A}^-\mathbf{A})' = \mathbf{A}^-\mathbf{A}$
- iv) $(\mathbf{A}\mathbf{A}^-)' = \mathbf{A}\mathbf{A}^-$

A matriz inversa generalizada pode ser usada para resolver sistemas de equações lineares, mesmo quando a matriz $\mathbf{A}$ não é invertível.

Sobre a inversa da matrix $\mathbf{X}'\mathbf{X}$

O sistema de equações normais é consistente, ou seja, apresenta pelo menos uma solução.

- Se $\mathbf{X}'\mathbf{X}$ for invertível, ou seja, $\text{posto}(\mathbf{X}) = p$, a solução única.
- Se $\mathbf{X}'\mathbf{X}$ for não invertível, ou seja, $\text{posto}(\mathbf{X}) < p$, podemos considerar uma inversa generalizada de $\mathbf{X}'\mathbf{X}$. Neste caso, uma solução é dada por

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{Y}.$$

Note que ao usar a inversa generalizada, o sistema pode apresentar infinitas soluções e as funções estimáveis passam a ter uma importância maior do que os parâmetros isoladamente.

No momento, vamos trabalhar com modelos em que a matrix $\mathbf{X}$ é de **posto completo** e, portanto, a **solução é única**.

$$\hat{\beta}_{MV} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Sabemos que $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2\mathbf{I}_n)$. Pelas propriedades associadas à vetores aleatórios e a distribuição normal multivariada, temos:

- (a) $\mathbb{E}(\hat{\beta}_{MV}) = \beta$ (não viesado)
- (b) $\text{Var}(\hat{\beta}_{MV}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$
- (c) $\hat{\beta}_{MV} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$ (normalidade)
- (d) $\hat{\beta}_j \sim N(\beta_j, \sigma^2 c_{jj})$, sendo c_{jj} é o j-ésimo elemento da diagonal principal da matriz $\mathbf{C} = (\mathbf{X}'\mathbf{X})^{-1}$

Propriedades do EMV de σ^2

$$\hat{\sigma}_{MV}^2 = \frac{1}{n}(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta})$$

Temos as seguintes propriedades:

- (a) $\mathbb{E}(\hat{\sigma}_{MV}^2) = \frac{(n-p)}{n}\sigma^2$, ou seja, é um estimador viesado.

Mas se tomarmos

$$\hat{\sigma}^2 = \frac{n}{(n-p)}\hat{\sigma}_{MV}^2 = \frac{1}{(n-p)}(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) = \frac{SQE}{n-p} = QME,$$

temos um estimador não viesado para σ^2 , sendo QME o Quadrado Médio do Erro.

(b) $\frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi_{(n-p)}^2$

(c) $\hat{\sigma}^2 \perp \hat{\beta}_{MV}$

Independência

Veja alguns resultados importantes sobre independência.

Theorem (Seber & Lee - Teorema 2.4)

Seja $\mathbf{Y} \sim N_n(\mu, \Sigma)$ tal que $\mathbf{Y}$, μ e Σ podem ser particionados em

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad e \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

Então, $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são independentes se, e somente se, $\Sigma_{12} = \mathbf{0}$.

Theorem (Seber & Lee - Teorema 2.5)

Seja $\mathbf{Y} \sim N_n(\mu, \Sigma)$ e defina $\mathbf{U} = \mathbf{A}\mathbf{Y}$ e $\mathbf{V} = \mathbf{B}\mathbf{Y}$. Então, $\mathbf{U}$ e $\mathbf{V}$ são independentes se, e somente se, $\text{Cov}(\mathbf{U}, \mathbf{V}) = \mathbf{A}\Sigma\mathbf{B}' = \mathbf{0}$.

Formas Quadráticas

Formas quadráticas de variáveis aleatórias normais são usadas muito frequentemente em análise de regressão nos mais diversos testes de hipóteses.

Definition

Seja $\mathbf{Y} \sim N_n(\mu, \Sigma)$ e considere a forma quadrática

$$U = \mathbf{Y}'\mathbf{A}\mathbf{Y} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} Y_i Y_j,$$

em que Σ é uma matriz positiva definida e $\mathbf{A}$ é uma matriz simétrica.

- Tipicamente em regressão linear múltipla tem-se que $\mu = \mathbf{X}\beta$ e $\Sigma = \sigma^2 \mathbf{I}_n$.
- Pode-se assumir que $\mathbf{A}$ é sempre simétrica, dado que podemos substituir a_{ij} por $(a_{ij} + a_{ji})/2$ sem alterar o valor da forma quadrática.
- Se $\mathbf{A}$ é simétrica, então $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}'$, com $\mathbf{\Lambda}$ sendo uma matriz diagonal cujos elementos são os autovalores de $\mathbf{A}$.

Theorem (Seber & Lee - Teorema 2.6)

Seja $\mathbf{A}$ uma matriz simétrica. Então $\mathbf{A}$ tem r autovalores em $\{0, 1\}$ se, e somente se, $\mathbf{A}^2 = \mathbf{A}$ (idempotente) e $\text{posto}(\mathbf{A}) = r$.

Theorem (Seber & Lee - Teorema 2.7)

Seja $\mathbf{Y} \sim N_n(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}$ uma matriz simétrica. Então

$$U = \mathbf{Y}'\mathbf{A}\mathbf{Y} \sim \chi_r^2,$$

se, e somente se, $\mathbf{A}$ é idempotente e $\text{posto}(\mathbf{A}) = r$.

Resultados de Formas Quadráticas

O teorema anterior pode ser apresentado em uma forma mais geral.

Theorem (Resultado 1)

Seja $\mathbf{Y} \sim N_n(\mu, \Sigma)$. Se $\mathbf{A}\Sigma$ ou $\Sigma\mathbf{A}$ é idempotente de posto r , então

$$U = \mathbf{Y}'\mathbf{A}\mathbf{Y} \sim \chi_r^2(\lambda),$$

ou seja, U segue uma distribuição Qui-quadrado não central, sendo λ o parâmetro de não centralidade de forma que $\lambda = \mu'\mathbf{A}\mu$.

Em particular, se $\Sigma = \sigma^2\mathbf{I}_n$ e $\mathbf{A}$ idempotente de posto r , então

$$\frac{U}{\sigma^2} = \frac{\mathbf{Y}'\mathbf{A}\mathbf{Y}}{\sigma^2} \sim \chi_r^2(\lambda),$$

em que $\lambda = \mu'\mathbf{A}\mu/\sigma^2$.

Resultados de Formas Quadráticas

Exemplo (Seber and Lee - Exemplo 2.10): Seja $\mathbf{Y} \sim N_n(\mu, \sigma^2 \mathbf{I}_n)$ e S^2 a variância amostral. Então,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Exemplo (Seber and Lee - Exemplo 2.11): Suponha que $\mathbf{A}$ é simétrica e $\mathbf{Y} \sim N_n(\mathbf{0}, \mathbf{I}_n)$. Então se $\mathbf{Y}'\mathbf{A}\mathbf{Y} \sim \chi_r^2$, a forma quadrática $\mathbf{Y}'(\mathbf{I}_n - \mathbf{A})\mathbf{Y} \sim \chi_{n-r}^2$.

Prova:

- $\mathbf{A}$ é idempotente, então cheque que $(\mathbf{I}_n - \mathbf{A})$ também é idempotente.
- $\text{posto}(\mathbf{I}_n - \mathbf{A}) = \text{tr}(\mathbf{I}_n - \mathbf{A}) = \text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{A}) = n - r$.

Theorem (Resultado 2)

Seja $\mathbf{Y} \sim N_n(\mu, \Sigma)$ e $\mathbf{A}$ e $\mathbf{B}$ duas matrizes de constantes $n \times n$. Considere as formas quadráticas

$$U = \mathbf{Y}'\mathbf{A}\mathbf{Y} \quad \text{e} \quad W = \mathbf{Y}'\mathbf{B}\mathbf{Y}.$$

Então U e W são independentes se, e somente se, $\mathbf{B}\Sigma\mathbf{A} = \mathbf{0}$.

Em particular, se $\Sigma = \sigma^2\mathbf{I}_n$, então U e W são independentes se, e somente se, $\mathbf{B}\mathbf{A} = \mathbf{0}$.


Análise de Variância (ANOVA)

Já vimos Análise de Variância anteriormente, ou seja, a técnica que permite particionar a variação total dos dados em parcelas atribuíveis a diferentes fontes.

No contexto de regressão, a análise de variância baseia-se na seguinte identidade:

$$\underbrace{Y_i - \bar{Y}}_{\text{desvio em relação à média geral}} = \underbrace{(Y_i - \hat{Y}_i)}_{\text{desvio em relação à reta de regressão}} + \underbrace{(\hat{Y}_i - \bar{Y})}_{\text{desvio da reta em relação à média geral}}$$

Veja cada desvio ilustrado nas figuras abaixo



Decomposição do Desvio Total





Figure 1: Decomposição do desvio de cada observação em relação à sua média no caso de Regressão Linear Simples

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Elevando ambos os lados da equação acima ao quadrado e somando para todo $i = 1, \dots, n$, pode-se mostrar que a **Soma de Quadrados Total** pode ser decomposta em:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SQT} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SQReg} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SQE}$$

- **SQT** é a soma dos quadrados total (ajustada), representa a variação total de Y em torno de sua média.
- **SQReg** é a soma de quadrados da regressão, representa a variação total de $\hat{Y}$ em torno de sua média.
- **SQE** é a soma dos quadrados do erro, representa a variação de Y em torno da reta ajustada.

ANOVA em forma matricial

Reescrevendo SQT em forma matricial, temos:

$$\begin{aligned}SQT &= \sum_{i=1}^n (Y_i - \bar{Y})^2 \\&= \sum_{i=1}^n Y_i^2 - \frac{1}{n} \left(\sum_{i=1}^n Y_i \right)^2 = \\&= \mathbf{Y}'\mathbf{Y} - \frac{1}{n} \mathbf{Y}'\mathbf{1}\mathbf{1}'\mathbf{Y} \\&= \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{1}(\mathbf{1}'\mathbf{1})^{-1}\mathbf{1}'\mathbf{Y} \\&= \mathbf{Y}' [\mathbf{I} - \mathbf{1}(\mathbf{1}'\mathbf{1})^{-1}\mathbf{1}'] \mathbf{Y}\end{aligned}$$

Nota: $SQT = \|\mathbf{Y} - \bar{Y}\mathbf{1}_n\|^2$

ANOVA em forma matricial

Reescrevendo $SQReg$ em forma matricial:

$$\begin{aligned} SQReg &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \sum_{i=1}^n \hat{Y}_i^2 - \frac{1}{n} \left(\sum_{i=1}^n Y_i \right)^2 \\ &= (\mathbf{HY})' \mathbf{HY} - \frac{1}{n} \mathbf{Y}' \mathbf{1} \mathbf{1}' \mathbf{Y} \\ &= \mathbf{Y}' \mathbf{HY} - \mathbf{Y}' \mathbf{1} (\mathbf{1}' \mathbf{1})^{-1} \mathbf{1}' \mathbf{Y} \\ &= \mathbf{Y}' [\mathbf{H} - \mathbf{1} (\mathbf{1}' \mathbf{1})^{-1} \mathbf{1}'] \mathbf{Y} \end{aligned}$$

em que $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

Nota: $SQReg = \|\hat{\mathbf{Y}} - \bar{Y}\mathbf{1}_n\|^2$

ANOVA em forma matricial

Reescrevendo SQE em forma matricial:


$$\begin{aligned}SQE &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\&= \sum_{i=1}^n e_i^2 = \mathbf{e}'\mathbf{e} \\&= (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}}) \\&= (\mathbf{Y} - \mathbf{HY})'(\mathbf{Y} - \mathbf{HY}) \\&= \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{HY} - \mathbf{Y}'\mathbf{H}'\mathbf{Y} + \mathbf{Y}'\mathbf{H}'\mathbf{HY} \\&= \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{HY} \\&= \mathbf{Y}'(\mathbf{I} - \mathbf{H})\mathbf{Y}\end{aligned}$$

Nota: $SQE = ||\mathbf{Y} - \hat{\mathbf{Y}}||^2$

ANOVA: Interpretação Geométrica

Observe na figura ao lado a representação geométrica da regressão, ou seja, pelo Teorema de Pitágoras:

$$\begin{aligned}\|\mathbf{Y} - \bar{Y}\mathbf{1}_n\|^2 &= \|\hat{\mathbf{Y}} - \bar{Y}\mathbf{1}_n\|^2 + \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 \\ \sum_{i=1}^n (Y_i - \bar{Y})^2 &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\ SQT &= SQReg + SQE\end{aligned}$$



Theorem (Seber and Lee - Teorema 3.1)

Suponha que $\mathbf{X}$ é uma matriz $n \times p$ de posto p , tal que

$$\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'.$$

Então,

(i) $\mathbf{H}$ e $\mathbf{I}_n - \mathbf{H}$ são simétricas e idempotentes.

(ii) $\text{posto}(\mathbf{I}_n - \mathbf{H}) = \text{tr}(\mathbf{I}_n - \mathbf{H}) = n - p$.

(iii) $\mathbf{HX} = \mathbf{X}$.

Demonstração: Exercício!

Theorem (Teorema de Cochran)

Seja $X_i \stackrel{iid}{\sim} N(0, \sigma^2)$ e suponha que

$$\sum_{i=1}^n X_i^2 = Q_1 + Q_2 + \dots + Q_k,$$

em que

$$Q_i = \mathbf{X}' \mathbf{A}_i \mathbf{X}, \quad \text{posto}(\mathbf{A}_i) = r_i \quad \text{e} \quad r_1 + r_2 + \dots + r_k = n.$$

Então, temos que:

- (i) $Q_1, Q_2, \dots, Q_k$ são independentes
- (ii) $\frac{Q_i}{\sigma^2} \sim \chi^2(r_i)$, para $i = 1, 2, \dots, k$.

Análise de Variância

A Análise de Variância é geralmente resumida na tabela a seguir (tabela ANOVA).

Fonte de Variação	gl	SQ	QM	F
Regressão	$p - 1$	$SQReg$	$\frac{SQReg}{p - 1}$	$F = \frac{QMReg}{QME}$
Erro	$n - p$	SQE	$\frac{SQE}{n - p}$	
Total (ajustada)	$n - 1$	SQT		

Sendo

$$SQReg = \mathbf{Y}' \left[\mathbf{H} - \frac{1}{n} \mathbf{1}\mathbf{1}' \right] \mathbf{Y}, \quad SQE = \mathbf{Y}'(\mathbf{I} - \mathbf{H})\mathbf{Y} \quad \text{e} \quad SQT = \mathbf{Y}' \left[\mathbf{I} - \frac{1}{n} \mathbf{1}\mathbf{1}' \right] \mathbf{Y}$$

Esperança dos Quadrados Médios

Já falamos anteriormente que o QME é um estimador não viesado para σ^2 , ou seja,

$$\mathbb{E}(QME) = \mathbb{E}\left(\frac{SQE}{n-p}\right) = \sigma^2$$

Pode-se mostrar também que

$$\mathbb{E}(QMReg) = \mathbb{E}\left(\frac{SQReg}{p-1}\right) = \sigma^2 + \Delta,$$

em que $\Delta > 0$ e depende de $\beta_1^2, \beta_2^2, \dots, \beta_{p-1}^2$.

Portanto, se todos os coeficiente β_k forem nulos, o $QMReg$ também é um estimador não viesado para σ^2 .

Com base nisso, podemos comparar essas duas quantidades, o que nos dá a intuição para construção do teste F, apresentado a seguir.

Teste F

No caso de regressão linear múltipla, queremos testar se:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0$$


H_A : pelo menos um $\beta_j \neq 0, j = 1, 2, \dots, p-1$.

Estatística do teste:

$$F = \frac{QMReg}{QME} = \frac{SQReg/(p-1)}{SQE/(n-p)} \stackrel{H_0}{\sim} F_{p-1, n-p}$$

$$\text{p-valor} = P(F_{p-1, n-p} \geq F_{obs})$$

F_{obs} : valor observado da estatística do teste.



Conclusão: Para um nível de significância α , rejeita-se H_0 se

- $\text{p-valor} < \alpha$; ou
- $F_{obs} > F_{1-\alpha, p-1, n-p} = F_{critico}$

Exemplo: teste de esforço cardiopulmonar

Voltamos no modelo que ajustamos para os dados de esforço cardiopulmonar:

$$VO2 = \beta_0 + \beta_1 \text{Carga} + \beta_2 \text{Peso} + \beta_3 \text{Altura} + \beta_4 \text{Idade} + \beta_5 \text{IMC} + \varepsilon$$

Table 1: Tabela dos Coeficientes Estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	13.393	6.031	2.220	0.028
Carga	0.108	0.006	16.819	0.000
Peso	-0.080	0.037	-2.148	0.034
Altura	-0.023	0.037	-0.617	0.538
Idade	0.041	0.012	3.490	0.001
IMC	-0.015	0.103	-0.141	0.888

Residual standard error: 1.54 on 118 degrees of freedom

Multiple R-squared: 0.72, Adjusted R-squared: 0.708

F-statistic: 60.7 on 5 and 118 DF, p-value: <2e-16

Exemplo: teste de esforço cardiopulmonar

Construa a tabela ANOVA para este modelo a partir da saída abaixo:

```
anova(fit.rm2)
```

Table 2: Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Carga	1	560.599	560.599	236.83	0.000
Peso	1	124.232	124.232	52.48	0.000
Altura	1	4.185	4.185	1.77	0.186
Idade	1	28.824	28.824	12.18	0.001
IMC	1	0.047	0.047	0.02	0.888
Residuals	118	279.318	2.367		

Exercício: Aplique o teste F, escreva as hipóteses sendo testadas e sua conclusão.

Exemplo: Marketing

Neste exemplo queremos verificar o impacto de três mídias publicitárias (youtube, facebook e jornal) nas vendas.

Os dados são orçamentos de publicidade em milhares de dólares e suas vendas. A experiência publicitária foi repetida 200 vezes.


O conjunto de dados marketing está disponível no pacote datarium do R.

```
library(datarium)  
data(marketing)
```

youtube	facebook	newspaper	sales
276.1	45.4	83.0	26.52
53.4	47.2	54.1	12.48
20.6	55.1	83.2	11.16
181.8	49.6	70.2	22.20
217.0	13.0	70.1	15.48
10.4	58.7	90.0	8.64

Exemplo: Marketing

Gráfico de dispersão e correlação entre os pares de variáveis:



Exemplo: Marketing (Regressão Linear Simples)

Inicialmente, vamos ajustar um modelo de regressão linear simples utilizando a variável que apresenta maior correlação com a variável resposta *sales*, que no caso é *youtube*.

```
mkt.rls <- lm(sales ~ youtube, data = marketing)
```

	x
(Intercept)	8.439
youtube	0.048



Exemplo: Marketing (Regressão Linear Simples)

Table 5: Tabela dos coeficientes estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	8.439	0.549	15.4	0
youtube	0.048	0.003	17.7	0

Residual standard error: 3.91 on 198 degrees of freedom

Multiple R-squared: 0.612, Adjusted R-squared: 0.61

F-statistic: 312 on 1 and 198 DF, p-value: $<2e-16$

Table 6: Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
youtube	1	4773	4773.1	312	0
Residuals	198	3028	15.3		

Pergunta: O que estamos testando aqui?

Exemplo: Marketing (Regressão Linear Múltipla)

Agora vamos utilizar todas as variáveis disponíveis: youtube, facebook e newspaper, ou seja,

$$\text{sales} = \beta_0 + \beta_1 \text{youtube} + \beta_2 \text{facebook} + \beta_3 \text{newspaper} + \varepsilon.$$

```
mkt.rlm <- lm(sales ~ ., data = marketing)
summary(mkt.rlm)
```

Table 7: Tabela dos Coeficientes Estimados

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.527	0.374	9.422	0.00
youtube	0.046	0.001	32.809	0.00
facebook	0.189	0.009	21.893	0.00
newspaper	-0.001	0.006	-0.177	0.86

Residual standard error: 2.02 on 196 degrees of freedom

Multiple R-squared: 0.897, Adjusted R-squared: 0.896

F-statistic: 570 on 3 and 196 DF, p-value: <2e-16

Tabela ANOVA e Teste F

```
anova(mkt.rlm)
```

Table 8: Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
youtube	1	4773.050	4773.050	1166.731	0.00
facebook	1	2225.688	2225.688	544.050	0.00
newspaper	1	0.128	0.128	0.031	0.86
Residuals	196	801.828	4.091		

Tabela ANOVA e Teste F

Hipóteses:

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

H_A : pelo menos um $\beta_j \neq 0$, para $j = 1, 2, 3$.

Tabela ANOVA e Teste F

Hipóteses:

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

H_A : pelo menos um $\beta_j \neq 0$, para $j = 1, 2, 3$.

Estatística do teste:

$$F = \frac{QMReg}{QME} = \frac{SQReg/(p-1)}{SQE/(n-p)} = \frac{(4773.05 + 2225.69 + 0.128)/3}{801.83/196} = 570 \stackrel{H_0}{\sim} F_{3,196}$$

Tabela ANOVA e Teste F

Hipóteses:

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

H_A : pelo menos um $\beta_j \neq 0$, para $j = 1, 2, 3$.

Estatística do teste:

$$F = \frac{QMReg}{QME} = \frac{SQReg/(p-1)}{SQE/(n-p)} = \frac{(4773.05 + 2225.69 + 0.128)/3}{801.83/196} = 570 \stackrel{H_0}{\sim} F_{3,196}$$

$$\text{p-valor} = P(F_{3,196} \geq 570) \approx 0.$$

Tabela ANOVA e Teste F

Hipóteses:

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

H_A : pelo menos um $\beta_j \neq 0$, para $j = 1, 2, 3$.

Estatística do teste:

$$F = \frac{QMReg}{QME} = \frac{SQReg/(p-1)}{SQE/(n-p)} = \frac{(4773.05 + 2225.69 + 0.128)/3}{801.83/196} = 570 \stackrel{H_0}{\sim} F_{3,196}$$

$$\text{p-valor} = P(F_{3,196} \geq 570) \approx 0.$$

Conclusão: Como o p-valor é extremamente pequeno ($\ll \alpha$), temos evidência para rejeitar H_0 e concluir que pelo menos um coeficiente é diferente de zero.

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seções 6.5 e 6.6.
- YouTube ME613 - Análise de Regressão - Aula 10
- Penn State - STAT501 - Regression Models - Lesson 5
- Penn State - STAT501 - Regression Models - Lesson 6