

ME613 - Análise de Regressão

Parte 11

Tatiana Benaglia - 2S2025

Teste de Hipóteses e Intervalo de Confiança para β_j

Na aula anterior, vimos como construir a tabela ANOVA e aplicar o teste F para verificar se todos os coeficientes são nulos. Depois de verificar que pelo menos um preditor é significativo, queremos saber qual ou quais são.

Vamos relembrar algumas propriedades importantes dos estimadores de β e σ^2 .

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad \text{e} \quad \hat{\sigma}^2 = QME = \frac{SQE}{n - p}$$

Já demonstramos que:

- $\mathbb{E}(\hat{\beta}) = \beta$ (não viesado para β)
- $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$.

Teste de Hipóteses e Intervalo de Confiança para β_j

Na aula anterior, vimos como construir a tabela ANOVA e aplicar o teste F para verificar se todos os coeficientes são nulos. Depois de verificar que pelo menos um preditor é significativo, queremos saber qual ou quais são.

Vamos relembrar algumas propriedades importantes dos estimadores de β e σ^2 .

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad \text{e} \quad \hat{\sigma}^2 = QME = \frac{SQE}{n - p}$$

Já demonstramos que:

- $\mathbb{E}(\hat{\beta}) = \beta$ (não viesado para β)
- $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$.

Além disso, para o modelo com erros normais, temos $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2\mathbf{I}_n)$ e

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad \implies \quad \hat{\beta}_j \sim N(\beta_j, \sigma^2 c_{jj}),$$

sendo c_{jj} é o j-ésimo elemento da diagonal principal da matriz $\mathbf{C} = (\mathbf{X}'\mathbf{X})^{-1}$.

Distribuição Amostral de $\hat{\beta}_j$

Vimos também que um estimador da variância é dado por:

$$\hat{\sigma}^2 = QME = \frac{SQE}{n-p} = \frac{1}{n-p}(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}),$$

tendo as seguintes propriedades:

$$\mathbb{E}(QME) = \sigma^2 \quad \text{e} \quad \frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-p)}$$

Distribuição Amostral de $\hat{\beta}_j$

Vimos também que um estimador da variância é dado por:

$$\hat{\sigma}^2 = QME = \frac{SQE}{n-p} = \frac{1}{n-p}(\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}),$$

tendo as seguintes propriedades:

$$\mathbb{E}(QME) = \sigma^2 \quad \text{e} \quad \frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-p)}$$

Além disso, como $\hat{\sigma}^2 \perp \hat{\beta}$, temos que

$$t = \frac{\frac{\hat{\beta}_j - \beta_j}{\sqrt{\sigma^2 c_{jj}}}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2} c_{jj}} = \frac{\hat{\beta}_j - \beta_j}{\sqrt{QME} c_{jj}} \sim t_{n-p}$$

Testes de Hipóteses para β_j

Depois de verificar que o teste F é significativo, tem-se o interesse em testar se

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0, \quad \text{para algum } j = 1, \dots, p$$

Testes de Hipóteses para β_j

Depois de verificar que o teste F é significativo, tem-se o interesse em testar se

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0, \quad \text{para algum } j = 1, \dots, p$$

Estatística do teste:

$$t = \frac{\hat{\beta}_j}{\sqrt{QME c_{jj}}} \stackrel{H_0}{\sim} t_{n-p}$$

No caso de hipóteses bilaterais, o p-valor é dado por

$$\text{p-valor} = 2P(t_{n-p} > |t_{obs}|),$$

t_{obs} : valor observado da estatística do teste.

Testes de Hipóteses para β_j

Depois de verificar que o teste F é significativo, tem-se o interesse em testar se

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0, \quad \text{para algum } j = 1, \dots, p$$

Estatística do teste:

$$t = \frac{\hat{\beta}_j}{\sqrt{QME c_{jj}}} \stackrel{H_0}{\sim} t_{n-p}$$


No caso de hipóteses bilaterais, o p-valor é dado por

$$\text{p-valor} = 2P(t_{n-p} > |t_{obs}|),$$

t_{obs} : valor observado da estatística do teste.

Conclusão: Para um nível de significância α , rejeita-se H_0 se:

$$\text{p-valor} < \alpha \quad \text{ou} \quad |t_{obs}| > t_{1-\alpha/2, n-p} = t_c$$



Exemplo: Marketing

No exemplo do Marketing (200 observações) usando os três preditores, temos a seguinte tabela dos coeficientes:

```
summary(mkt.rlm)$coefficient
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.527	0.374	9.422	0.00
youtube	0.046	0.001	32.809	0.00
facebook	0.189	0.009	21.893	0.00
newspaper	-0.001	0.006	-0.177	0.86

Exemplo: Marketing

No exemplo do Marketing (200 observações) usando os três preditores, temos a seguinte tabela dos coeficientes:

```
summary(mkt.rlm)$coefficient
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.527	0.374	9.422	0.00
youtube	0.046	0.001	32.809	0.00
facebook	0.189	0.009	21.893	0.00
newspaper	-0.001	0.006	-0.177	0.86

Por exemplo, queremos testar se newspaper contribui para explicar as vendas (sales):

$$H_0 : \beta_3 = 0 \quad \text{vs} \quad H_1 : \beta_3 \neq 0$$

Olhando a tabela acima, qual o valor da estatística do teste, sua distribuição sob H_0 , o p-valor e a conclusão?

Exemplo: Marketing

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.527	0.374	9.422	0.00
youtube	0.046	0.001	32.809	0.00
facebook	0.189	0.009	21.893	0.00
newspaper	-0.001	0.006	-0.177	0.86

Estatística do teste:

$$t = \frac{\hat{\beta}_j}{\sqrt{QME c_{jj}}} = \frac{-0.001}{0.006} = -0.177 \stackrel{H_0}{\sim} t_{196}$$

O p-valor é dado por

$$\text{p-valor} = 2P(t_{196} > 0.0177) = 0.86$$

Exemplo: Marketing

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.527	0.374	9.422	0.00
youtube	0.046	0.001	32.809	0.00
facebook	0.189	0.009	21.893	0.00
newspaper	-0.001	0.006	-0.177	0.86

Estatística do teste:

$$t = \frac{\hat{\beta}_j}{\sqrt{QME c_{jj}}} = \frac{-0.001}{0.006} = -0.177 \stackrel{H_0}{\sim} t_{196}$$

O p-valor é dado por

$$\text{p-valor} = 2P(t_{196} > 0.0177) = 0.86$$

Conclusão: Dado um nível de significância $\alpha = 0.05$, temos que o p-valor > 0.05 , portanto, não temos evidência para rejeitar a hipótese que o coeficiente β_3 é nulo.

Exemplo: Marketing

Reajustando o modelo apenas com as variáveis youtube e facebook:

```
mkt.red <- lm(sales ~ youtube + facebook, data = marketing)
summary(mkt.red)$coefficients
```

Tabela dos coeficientes estimados depois de retirar o preditor newspaper:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.5053	0.35339	9.92	0
youtube	0.0458	0.00139	32.91	0
facebook	0.1880	0.00804	23.38	0

Residual standard error: 2.02 on 197 degrees of freedom

Multiple R-squared: 0.897, Adjusted R-squared: 0.896

F-statistic: 860 on 2 and 197 DF, p-value: <2e-16

Intervalo de Confiança para β_j

Dado que $t = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \sim t_{n-p}$, se $\beta_j \neq 0$, então

$$P \left(-t_{\alpha/2, n-p} \leq \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \leq t_{\alpha/2, n-p} \right) = 1 - \alpha$$

$$P \left(\hat{\beta}_j - t_{\alpha/2, n-p} \sqrt{\hat{\sigma}^2 c_{jj}} \leq \beta_j \leq \hat{\beta}_j + t_{\alpha/2, n-p} \sqrt{\hat{\sigma}^2 c_{jj}} \right) = 1 - \alpha$$

Intervalo de Confiança para β_j

Dado que $t = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \sim t_{n-p}$, se $\beta_j \neq 0$, então

$$P \left(-t_{\alpha/2, n-p} \leq \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \leq t_{\alpha/2, n-p} \right) = 1 - \alpha$$

$$P \left(\hat{\beta}_j - t_{\alpha/2, n-p} \sqrt{\hat{\sigma}^2 c_{jj}} \leq \beta_j \leq \hat{\beta}_j + t_{\alpha/2, n-p} \sqrt{\hat{\sigma}^2 c_{jj}} \right) = 1 - \alpha$$

Portanto, um intervalo com nível de confiança de $(1 - \alpha)100\%$ para β_j é dado por:

$$\begin{aligned} IC(\beta_j, 1 - \alpha) &= \hat{\beta}_j \pm t_{\alpha/2, n-p} \sqrt{\hat{\sigma}^2 c_{jj}} \\ &= \hat{\beta}_j \pm t_{\alpha/2, n-p} \sqrt{QME c_{jj}} \end{aligned}$$

Exemplo: Marketing

Usando a fórmula anterior, encontre o intervalo de confiança de 95% para β_3 .

Os IC's podem ser obtidos através da função `confint()`.

```
confint(mkt.rlm)
```

	2.5 %	97.5 %
(Intercept)	2.789	4.265
youtube	0.043	0.049
facebook	0.172	0.206
newspaper	-0.013	0.011

Qual a interpretação do IC para β_3 ?

Compare com o resultado obtido no teste t para verificar se β_3 é nulo.

Coeficiente de Determinação Múltiplo

Queremos avaliar quão bom é nosso modelo de regressão. Para isso, podemos utilizar o **Coeficiente de Determinação**, chamado de R^2 , como já vimos em Regressão Linear Simples.

O coeficiente de determinação R^2 é definido como:

$$R^2 = \frac{SQReg}{SQT} = 1 - \frac{SQE}{SQT},$$

ou seja, é a proporção da variabilidade de Y explicada pelo conjunto de preditores $X_1, \dots, X_{p-1}$.

Coeficiente de Determinação Múltiplo

Queremos avaliar quão bom é nosso modelo de regressão. Para isso, podemos utilizar o **Coeficiente de Determinação**, chamado de R^2 , como já vimos em Regressão Linear Simples.

O coeficiente de determinação R^2 é definido como:

$$R^2 = \frac{SQReg}{SQT} = 1 - \frac{SQE}{SQT},$$

ou seja, é a proporção da variabilidade de Y explicada pelo conjunto de preditores $X_1, \dots, X_{p-1}$.

Temos que $0 \leq R^2 \leq 1$, de forma que:

- $R^2 = 0$ se todos os $\beta_k = 0$, para $k = 1, \dots, p - 1$ e
- $R^2 = 1$ se todos os valores observados caem exatamente na superfície de regressão ajustada.

Coeficiente de Determinação Múltiplo Ajustado

O R^2 irá sempre aumentar à medida que mais preditores são inseridos no modelo, já que SQE irá sempre diminuir com novos preditores e SQT é constante.

Nesse sentido, sugere-se usar o **coeficiente de determinação múltiplo ajustado** R_{adj}^2 , que ajusta o R^2 dividindo as somas de quadrados pelos seus respectivos graus de liberdade:

$$R_{adj}^2 = 1 - \frac{\frac{SQE}{n-p}}{\frac{SQT}{n-1}} = 1 - \left(\frac{n-1}{n-p} \right) \frac{SQE}{SQT}.$$

Com isso, esse coeficiente de determinação pode se tornar menor à medida que novos preditores são inseridos no modelo, ou seja, ele penaliza o R^2 pelo número de preditores.

Exemplo: Marketing

Compare o R^2 e R_{adj}^2 para os modelos ajustados.

Preditores	R^2	R_{adj}^2
YouTube	0.6119	0.6099
YouTube, Facebook	0.8972	0.8962
YouTube, Facebook, Newspaper	0.8972	0.8956

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 6.5 e 6.6.
- YouTube ME613 - Análise de Regressão - Aula 10
- Penn State - STAT501 - Regression Models - Lesson 6