

ME613 - Análise de Regressão

Parte 12

Tatiana Benaglia - 2S2025


Exemplo: Conjunto de dados swiss

Conjunto de dados disponível no pacote `datasets` do R com 47 observações e 6 variáveis.

- `Fertility`: lg, 'common standardized fertility measure'
- `Agriculture`: % of males involved in agriculture as occupation
- `Examination`: % draftees receiving highest mark on army examination
- `Education`: % education beyond primary school for draftees.
- `Catholic`: % 'catholic' (as opposed to 'protestant').
- `Infant.Mortality`: live births who live less than 1 year.

Todas as variáveis, exceto `Fertility`, são porcentagens da população [0, 100].

Exemplo: Conjunto de dados swiss



Exemplo: conjunto de dados swiss

Ajustando o modelo de regressão múltipla usando todas as variáveis como preditores:

```
modelo <- lm(Fertility ~ . , data = swiss)
summary(modelo)$coefficients
```

A tabela dos coeficientes estimados está abaixo:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	66.9152	10.7060	6.250	0.0000
Agriculture	-0.1721	0.0703	-2.448	0.0187
Examination	-0.2580	0.2539	-1.016	0.3155
Education	-0.8709	0.1830	-4.758	0.0000
Catholic	0.1041	0.0353	2.953	0.0052
Infant.Mortality	1.0770	0.3817	2.822	0.0073

Residual standard error: 7.165 on 41 degrees of freedom

Multiple R-squared: 0.7067, Adjusted R-squared: 0.671

F-statistic: 19.76 on 5 and 41 DF, p-value: 5.594e-10

Exemplo: Conjunto de dados swiss

O preditor Agriculture é expresso em porcentagem de 0 a 100 e a estimativa do seu coeficiente é -0.1721.

Segundo o modelo, espera-se um decréscimo de 0.17 na fertilidade para cada 1% de aumento de pessoas do sexo masculino envolvidas na agricultura, mantendo as demais variáveis fixas.

O teste-t para $H_0 : \beta_{Agri} = 0$ versus $H_A : \beta_{Agri} \neq 0$ é significativa.

A título de curiosidade, a estimativa do efeito de agricultura, sem ajustar pelas demais variáveis, ou seja, na regressão simples é:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	60.3044	4.2513	14.185	0.0000
Agriculture	0.1942	0.0767	2.532	0.0149

O que aconteceu com o efeito de agricultura?

Já ouviram falar em Paradoxo de Simpson?

Paradoxo de Simpson


Vamos supor que queremos verificar a relação entre o número de horas de exercício físico por semana e o BMI.



A reta de regressão mostra que a cada hora adicional de exercício físico por semana o BMI varia em -0.436 pontos.

Paradoxo de Simpson


Será que o comportamento é o mesmo se fizermos, para os mesmos dados, esta análise separa por faixa etária?



Agora, para cada grupo etário o que temos é que o BMI aumenta quando o exercício físico aumenta.


Exemplo: Taxa de sucesso em cirurgias

Vamos supor que vamos ser operados e queremos escolher o melhor hospital. Qual hospital você escolheria?



Exemplo: Taxa de sucesso em cirurgias

Mas vamos analisar a taxa de sucesso por tipo de cirurgia.




E agora, você continua com o mesmo hospital?

Paradoxo de Simpson

Esses fenômenos que vimos são explicados pelo **Paradoxo de Simpson**.

O **Paradoxo de Simpson** ocorre quando uma tendência observada em vários grupos separados se inverte ou desaparece quando os dados são combinados.

Ele evidencia a importância do contexto e das variáveis de confundimento (ou ocultas) na análise estatística.




Paradoxo de Simpson

Aparentemente este fenômeno foi descoberto em 1934 por dois filósofos americanos mas foi apenas em 1951 que o estatístico britânico Edward H. Simpson chamou a atenção para este paradoxo e foi quem observou a sua relação com a inversão da desigualdade acima mencionada.

O **Paradoxo de Simpson** é um lembrete poderoso de que **observar uma correlação não é entender uma relação/causa.**

A análise estatística deve sempre considerar a estrutura dos dados e as possíveis variáveis escondidas.



Paradoxo de Simpson: Por que é importante?

- **Porque evita conclusões enganosas:** um resultado global pode sugerir uma relação oposta à que realmente ocorre dentro dos subgrupos.
- **Reforça a necessidade de controle de variáveis:** Mostra a importância de ajustar análises por fatores como idade, gênero, tamanho da amostra ou outras covariáveis relevantes.
- **Tem aplicações reais em várias áreas:**
 - Em medicina, pode mudar a interpretação de eficácia de um tratamento.
 - Em políticas públicas, pode influenciar decisões sobre desigualdade.
 - Em machine learning e ciência de dados, alerta sobre viés em bases de dados e sobre como o agrupamento de variáveis pode distorcer padrões.

No seu livro “Causality”, Judea Pearl faz uma afirmação ainda mais poderosa relativamente ao paradoxo de Simpson: *“Any statistical relationship between two variables may be reversed by including additional factors in the analysis.”* [Pearl2009].

Ao considerarmos outras variáveis no modelo, o sinal do efeito (coeficiente β) de uma dada variável pode inverter.

Vamos simular um caso para exemplificar.

Simulamos 100 v.a. com relação linear: Y , X_1 e X_2 .

- X_1 tem relação linear com X_2 .
- X_1 tem um efeito ajustado negativo sobre Y .
- X_2 tem um efeito ajustado positivo sobre Y .

Sendo que

$$\begin{aligned} Y &= -X_1 + X_2 + \varepsilon, & \varepsilon &\sim N(0, (0.01)^2) \\ X_1 &= 0.01X_2 + \nu, & \nu &\sim N(-0.01, (0.1)^2) \end{aligned}$$


Tabela dos coeficientes estimados usando X_1 como preditor:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.7166	1.276	0.5618	0.5756
X1	97.0237	2.186	44.3900	0.0000

Tabela dos coeficientes estimados usando X_1 e X_2 como preditores:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0001	0.0020	-0.0564	0.9551
X1	-0.9946	0.0160	-62.2592	0.0000
X2	0.9999	0.0002	6283.2122	0.0000

Simulação: Relação entre Y e X_1 (não ajustada por X_2)



Y e X_1 têm relação positiva (não ajustada), mas observe que X_2 também aumenta com Y .

Simulação: Relação entre Y e X_1 , ajustada pelo efeito de X_2



Ajustando X_1 e Y através do resíduo da regressão de cada uma com X_2 , temos a relação correta entre Y e X_1 .

Regressão Múltipla com Preditores Qualitativos

Tradicionalmente, as variáveis preditoras são quantitativas, ou seja, assumem valores numéricos contínuos ou discretos.

No entanto, em muitas situações, é comum encontrar **variáveis qualitativas** (ou categóricas), como gênero, grupo étnico ou nível educacional, que também podem influenciar o resultado de interesse.

Para incorporar preditores qualitativos em um modelo de regressão linear, utilizamos uma técnica conhecida como **codificação de variáveis categóricas**.

A forma mais comum dessa codificação é a criação de variáveis fictícias ou dummies, que transformam as categorias de uma variável qualitativa em uma série de variáveis binárias. Cada uma dessas variáveis indica a presença ou ausência de uma categoria específica, permitindo que o modelo considere o efeito de diferentes grupos qualitativos sobre a variável dependente.

Regressão Múltipla com Preditores Qualitativos

Voltando no exemplo do teste cardiopulmonar, e se quisermos considerar como preditor uma das variáveis qualitativas disponíveis: Sexo ou Etiologia?

Vamos voltar no exemplo do teste de esforço cardiopulmonar.

ID	Etiologia	Sexo	Idade	Altura	Peso	Superfície	IMC	Carga	VO2
1	CH	M	38	149	54	1.48	24.32	41	10.0
2	CH	M	49	167	80	1.89	27.68	56	11.5
3	ID	F	65	153	56	1.52	23.93	8	7.0
4	ID	M	52	175	78	1.94	25.49	53	8.9
5	IS	F	52	157	59	1.59	23.98	22	8.7

Podemos então ajustar o seguinte modelo:


$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i$$

Resposta: VO2 (Y_i)

Preditores: Carga (X_{i1}) e Sexo (X_{i2})

Exemplo

VO2 em função da carga e sexo



Regressão Múltipla com Preditores Qualitativos

No modelo:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i,$$

temos que:

- se $X_{i2} = 0$: $Y_i = \beta_0 + \beta_1 X_{i1} + \varepsilon_i$
- se $X_{i2} = 1$: $Y_i = (\beta_0 + \beta_2) + \beta_1 X_{i1} + \varepsilon_i$

Ou seja, temos duas retas paralelas ajustadas (uma para cada categoria da variável Sexo).


```
fit.rm = lm(V02 ~ Carga + Sexo, data = braga)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.4558	0.4755	13.5776	0.000
Carga	0.0851	0.0073	11.6329	0.000
SexoM	0.1732	0.5024	0.3446	0.731

Segundo o modelo, 0.17 é a mudança esperada no intercepto da relação linear entre Carga e VO2 quando comparamos homens a mulheres.

Exemplo

Retas paralelas ajustadas



Regressão Múltipla com Preditores Qualitativos

Podemos também considerar um modelo que permite diferentes interceptos e diferentes coeficientes angulares (retas não paralelas). Isto é obtido considerando o termo de **interação**.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i1} X_{i2} + \varepsilon_i$$

Portanto, temos que:


- Quando $X_{i2} = 0$: $Y_i = \beta_0 + \beta_1 X_{i1} + \varepsilon_i$
- Quando $X_{i2} = 1$: $Y_i = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) X_{i1} + \varepsilon_i$

```
fit.rm2 = lm(V02 ~ Carga + Sexo + Carga*Sexo, data = braga)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.8686	0.9954	6.9006	0.0000
Carga	0.0693	0.0343	2.0184	0.0458
SexoM	-0.2769	1.0777	-0.2570	0.7976
Carga:SexoM	0.0166	0.0351	0.4725	0.6374

Exemplo

Retas distintas ajustadas



Codificação da Matriz X

Os preditores sendo usados são
Carga e Sexo

Carga	Sexo
41	M
56	M
8	F
53	M
22	F
32	F

Veja como a matriz X é codificada:

```
model.matrix(fit.rm2)
```

(Intercept)	Carga	SexoM	Carga:SexoM
1	41	1	41
1	56	1	56
1	8	0	0
1	53	1	53
1	22	0	0
1	32	0	0

Exemplo: algumas considerações

Segundo o modelo ajustado, -0.277 é a mudança esperada estimada no intercepto da reta de relação entre $V02$ e Carga quando comparamos homens a mulheres.

O termo de interação 0.0166 é a mudança esperada estimada no coeficiente angular.

O intercepto estimado entre as mulheres é 6.869 e o intercepto estimado entre os homens é $6.869 - 0.277$.

O coeficiente angular da relação entre $V02$ e Carga para mulheres é 0.069 .

O coeficiente angular da relação entre $V02$ e Carga para homens é $0.069 + 0.0166$.

Preditores Qualitativos com Mais de Duas Categorias

No caso anterior, o preditor qualitativos tinha duas categorias. Mas e se considerarmos a variável Etiologia, que tem quatro categorias distintas?

Veja o que acontece.

```
fit.rm3 = lm(V02 ~ Carga + Etiologia + Carga*Etiologia, data = braga)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.5610	0.7144	9.1838	0.0000
Carga	0.0885	0.0116	7.6189	0.0000
EtiologiaCH	0.0711	1.0332	0.0688	0.9453
EtiologiaID	0.7857	1.0556	0.7444	0.4582
EtiologiaIS	0.2402	0.9714	0.2473	0.8051
Carga:EtiologiaCH	0.0099	0.0180	0.5491	0.5840
Carga:EtiologiaID	-0.0388	0.0211	-1.8367	0.0688
Carga:EtiologiaIS	-0.0114	0.0199	-0.5750	0.5664


Preditores Qualitativos com Mais de Duas Categorias

```
model.matrix(fit.rm3)[1:10, 1:5]
```

	(Intercept)	Carga	EtiologiaCH	EtiologiaID	EtiologiaIS
1	1	41	1	0	0
2	1	56	1	0	0
3	1	8	0	1	0
4	1	53	0	1	0
5	1	22	0	0	1
6	1	32	1	0	0
7	1	0	0	1	0
8	1	26	0	0	1
9	1	26	0	1	0
10	1	82	1	0	0

Exemplo


Retas distintas ajustadas



Regressão com Interação

Interação: Uma interação ocorre quando uma variável independente tem um efeito diferente na resposta dependendo dos valores de outras variável independente.

Quando temos um preditor quantitativo e outro qualitativo:



Regressão com Interação

Um modelo de regressão com $p - 1$ variáveis preditoras com **efeitos aditivos** tem função de regressão da forma:

$$\mathbb{E}(Y) = f_1(X_1) + f_2(X_2) + \dots + f_{p-1}(X_{p-1})$$

em que $f_1, f_2, \dots, f_{p-1}$ podem ser quaisquer funções.

Por exemplo:

$$\mathbb{E}(Y) = \underbrace{\beta_0 + \beta_1 X_1 + \beta_2 X_1^2}_{f_1(X_1)} + \underbrace{\beta_3 X_2}_{f_2(X_2)}$$

O efeito de X_1 e X_2 em Y é **aditivo**.

Já no exemplo a seguir, o efeito não é aditivo, há **efeito de interação**:

$$\mathbb{E}(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_1 X_2 + \beta_5 X_1 X_3$$

O efeito de uma variável sobre Y irá depender do nível da variável com a qual ela interage.

Interpretação: interação e efeitos lineares

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon$$

Suponha que $X_1 = a$:

$$\mathbb{E}(Y) = \beta_0 + \beta_1 a + \beta_2 X_2 + \beta_3 a X_2$$

Suponha que $X_1 = a + 1$:

$$\mathbb{E}(Y) = \beta_0 + \beta_1(a + 1) + \beta_2 X_2 + \beta_3(a + 1)X_2$$

Diferença no valor esperado de Y quando aumentamos X_1 em 1 unidade:

$$\begin{aligned} & \beta_0 + \beta_1(a + 1) + \beta_2 X_2 + \beta_3(a + 1)X_2 - (\beta_0 + \beta_1 a + \beta_2 X_2 + \beta_3 a X_2) \\ &= \beta_1 + \beta_3 X_2 \end{aligned}$$

Interpretação: interação e efeitos lineares

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon$$

Suponha que $X_2 = a$:

$$\mathbb{E}(Y) = \beta_0 + \beta_1 X_1 + \beta_2 a + \beta_3 X_1 a$$

Suponha que $X_2 = a + 1$:

$$\mathbb{E}(Y) = \beta_0 + \beta_1 X_1 + \beta_2(a + 1) + \beta_3 X_1(a + 1)$$

Diferença no valor esperado de Y quando aumentamos X_2 em 1 unidade:

$$\begin{aligned} & \beta_0 + \beta_1 X_1 + \beta_2(a + 1) + \beta_3 X_1(a + 1) - (\beta_0 + \beta_1 X_1 + \beta_2 a + \beta_3 X_1 a) \\ &= \beta_2 + \beta_3 X_1 \end{aligned}$$

Interpretação: interação e efeitos lineares

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon$$

Diferença no valor esperado de Y quando aumentamos X_1 em 1 unidade:

$$\frac{\partial \mathbb{E}(Y)}{\partial X_1} = \beta_1 + \beta_3 X_2$$

Diferença no valor esperado de Y quando aumentamos X_2 em 1 unidade:

$$\frac{\partial \mathbb{E}(Y)}{\partial X_2} = \beta_2 + \beta_3 X_1$$


Interpretação: interação e efeitos lineares

Modelo aditivo:

$$E(Y) = 10 + 2X_1 + 5X_2$$

β_1 : mudança no valor esperado de Y quando X_1 aumenta em 1 unidade, mantendo X_2 constante.

Mantendo X_2 constante: não importa se $X_2 = 1$ ou $X_2 = 3$ o efeito é sempre β_1 no valor esperado quando X_1 aumenta em 1 unidade (retas paralelas).



Interpretação: interação e efeitos lineares

Modelo com interação:

$$\mathbb{E}(Y) = 10 + 2X_1 + 5X_2 + 0.5X_1X_2$$


Se $X_2 = 1$:

$$\begin{aligned}\mathbb{E}(Y) &= 10 + 2X_1 + 5 \times 1 + 0.5X_1 \times 1 \\ &= 15 + 2.5X_1\end{aligned}$$

Se $X_2 = 3$:

$$\begin{aligned}\mathbb{E}(Y) &= 10 + 2X_1 + 5 \times 3 + 0.5X_1 \times 3 \\ &= 25 + 3.5X_1\end{aligned}$$

Para avaliarmos o efeito de 1 unidade de aumento em X_1 , devemos considerar o valor de X_2 (retas não paralelas).



Leitura e Agradecimentos

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition, McGraw-Hill, Irwin, New York.

Agradecimentos: parte de material foi criado pela profa. Samara Kiihl - IMECC/Unicamp.

