

ME613 - Análise de Regressão

Parte 13

Tatiana Benaglia - 2S2025

Motivação

Partindo do fato que:

$$SQT = SQReg + SQE$$

- Já falamos que a SQE sempre diminui à medida que novos preditores são adicionados ao modelo, da mesma forma que a $SQReg$ sempre aumenta.
- Uma soma extra de quadrados mede a redução marginal na SQE quando uma ou mais variáveis preditoras são adicionadas ao modelo de regressão, dado que outras variáveis já estão no modelo.
- De forma equivalente, pode-se visualizar uma soma extra de quadrados como medindo o aumento marginal na $SQReg$ quando uma ou várias variáveis preditoras são adicionadas ao modelo de regressão.
- Dessa forma, a soma extra de quadrados pode nos auxiliar na decisão de inclusão ou retirada de variáveis no modelo.

Exemplo: Gordura Corporal

Vamos trabalhar com dados referentes à taxa de gordura corporal e 3 outras medidas corporais para 20 pessoas, sendo

Y : taxa de gordura corporal;

X_1 : espessura da dobra cutânea do tríceps;

X_2 : circunferência da coxa; e

X_3 : circunferência do meio do braço.

Veja as primeiras observações dos dados:

Y	X1	X2	X3
11.9	19.5	43.1	29.1
22.8	24.7	49.8	28.2
18.7	30.7	51.9	37.0
20.1	29.8	54.3	31.1
12.9	19.1	42.2	30.9
21.7	25.6	53.9	23.7

Exemplo: Regressão de Y em X_1

Regressão Linear Simples: $Y = \beta_0 + \beta_1 X_1 + \varepsilon$

No R ajustamos o modelo da seguinte forma:

```
modelo1 <- lm(Y ~ X1, data = dados)
```

Table 1: Coeficientes estimados da Regressão de Y em X_1

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.4961	3.3192	-0.4507	0.6576
X1	0.8572	0.1288	6.6562	0.0000

Table 2: Tabela ANOVA da Regressão de Y em X_1

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.3	352.27	44.3	0
Residuals	18	143.1	7.95		

Exemplo: Regressão de Y em X_2

Regressão Linear Simples: $Y = \beta_0 + \beta_2 X_2 + \varepsilon$

No R ajustamos o modelo da seguinte forma:

```
modelo2 <- lm(Y ~ X2, data = dados)
```

Table 3: Coeficientes estimados da Regressão de Y em X_2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-23.6345	5.657	-4.178	6e-04
X2	0.8565	0.110	7.786	0e+00

Table 4: Tabela ANOVA da Regressão de Y em X_2

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X2	1	382.0	382.0	60.62	0
Residuals	18	113.4	6.3		

Exemplo: Regressão de Y em X_1 e X_2

Regressão Linear Múltipla: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$

```
modelo12 <- lm(Y ~ X1 + X2, data = dados)
```

Table 5: Coeficientes estimados da Regressão de Y em X_1 e X_2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-19.1742	8.3606	-2.2934	0.0348
X1	0.2224	0.3034	0.7328	0.4737
X2	0.6594	0.2912	2.2646	0.0369

Table 6: Tabela ANOVA da Regressão de Y em X_1 e X_2

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	54.47	0.00
X2	1	33.17	33.17	5.13	0.04
Residuals	17	109.95	6.47		

Exemplo: Soma Extra de Quadrados

Quando ambos X_1 e X_2 estão no modelo, temos que

$$SQE(X_1, X_2) = 109.95 < 143.12 = SQE(X_1).$$

Esta diferença é denominada **Soma Extra de Quadrados**:

$$\begin{aligned} SQReg(X_2 \mid X_1) &= SQE(X_1) - SQE(X_1, X_2) \\ &= 143.12 - 109.95 = 33.17 \end{aligned}$$

Equivalentemente:

$$\begin{aligned} SQReg(X_2 \mid X_1) &= SQReg(X_1, X_2) - SQReg(X_1) \\ &= 385.44 - 352.27 = 33.17 \end{aligned}$$

Exemplo: Soma Extra de Quadrados

Regressão Linear Múltipla: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$

```
modelo12 <- lm(Y ~ X1 + X2, data = dados)
```

Obtendo a tabela ANOVA para este modelo:

```
anova(modelo12)
```

Table 7: Tabela ANOVA da Regressão de Y em X_1 e X_2

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	54.47	0.00
X2	1	33.17	33.17	5.13	0.04
Residuals	17	109.95	6.47		

Exemplo: Soma Extra de Quadrados

Regressão Linear Múltipla: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$

```
modelo12 <- lm(Y ~ X1 + X2, data = dados)
```

Obtendo a tabela ANOVA para este modelo:

```
anova(modelo12)
```

Table 7: Tabela ANOVA da Regressão de Y em X_1 e X_2

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	54.47	0.00
X2	1	33.17	33.17	5.13	0.04
Residuals	17	109.95	6.47		

Observe que tabela ANOVA acima, a linha referente a X_2 contém $SQReg(X_2 | X_1)$.

Em geral, se temos X_1 e X_2 no modelo, podemos escrever:

$$SQReg(X_1, X_2) = SQReg(X_1) + SQReg(X_2 \mid X_1)$$

ou, dado que a ordem de entrada das variáveis é arbitrária no modelo, temos:

$$SQReg(X_1, X_2) = SQReg(X_2) + SQReg(X_1 \mid X_2)$$

Veja a comparação nos ajustes a seguir.

Soma Extra de Quadrados

Definimos dois modelos com os mesmos preditores, mas inseridos em ordem diferente:

```
modelo12 <- lm(Y ~ X1 + X2, data = dados)
modelo21 <- lm(Y ~ X2 + X1, data = dados)
```

Table 8: Tabela ANOVA: modelo12

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	54.47	0.00
X2	1	33.17	33.17	5.13	0.04
Residuals	17	109.95	6.47		

Table 9: Tabela ANOVA: modelo21

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X2	1	381.97	381.97	59.06	0.00
X1	1	3.47	3.47	0.54	0.47
Residuals	17	109.95	6.47		

Exemplo: Regressão de Y em X_1 , X_2 e X_3

```
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados)
```

Table 10: Coeficientes estimados da Regressão de Y em X_1 , X_2 e X_3

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	117.08	99.78	1.17	0.26
X1	4.33	3.02	1.44	0.17
X2	-2.86	2.58	-1.11	0.28
X3	-2.19	1.60	-1.37	0.19

Table 11: Tabela ANOVA da Regressão de Y em X_1 , X_2 e X_3

	Df	SS	MS	F	P
Source	3	397.0	132.33	21.52	0
Error	16	98.4	6.15		
Total	19	495.4	26.07		

Exemplo: Soma Extra de Quadrados

Quando X_1 , X_2 e X_3 estão no modelo, temos que

$$SQE(X_1, X_2, X_3) = 98.40 < 109.95 = SQE(X_1, X_2).$$

Esta diferença é denominada **Soma Extra de Quadrados**:

$$\begin{aligned} SQReg(X_3 \mid X_1, X_2) &= SQE(X_1, X_2) - SQE(X_1, X_2, X_3) \\ &= 109.95 - 98.40 = 11.55 \end{aligned}$$

Equivalentemente:

$$\begin{aligned} SQReg(X_3 \mid X_1, X_2) &= SQReg(X_1, X_2, X_3) - SQReg(X_1, X_2) \\ &= 396.99 - 385.44 = 11.55 \end{aligned}$$

Exemplo: Soma Extra de Quadrados

```
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados)
anova(modelo123)
```

Table 12: Tabela ANOVA da Regressão de Y em X_1 , X_2 e X_3

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	57.28	0.00
X2	1	33.17	33.17	5.39	0.03
X3	1	11.55	11.55	1.88	0.19
Residuals	16	98.40	6.15		

Na tabela, a linha X_2 contém $SQReg(X_2 | X_1)$

Na tabela, a linha X_3 contém $SQReg(X_3 | X_1, X_2)$

Exemplo: Soma Extra de Quadrados

Podemos avaliar, também, a adição de mais de uma variável ao mesmo tempo. Por exemplo, podemos avaliar o efeito de incluir X_2 e X_3 a um modelo com apenas X_1 :

$$\begin{aligned}SQReg(X_2, X_3 \mid X_1) &= SQE(X_1) - SQE(X_1, X_2, X_3) \\ &= 143.12 - 98.40 = 44.72\end{aligned}$$

Equivalentemente:

$$\begin{aligned}SQReg(X_2, X_3 \mid X_1) &= SQReg(X_1, X_2, X_3) - SQReg(X_1) \\ &= 396.99 - 352.27 = 44.72\end{aligned}$$

Exemplo: Soma Extra de Quadrados

Podemos comparar dois modelos da seguinte forma:

```
modelo1 <- lm(Y ~ X1, data = dados) # Modelo Reduzido
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados) # Modelo Completo

anova(modelo1, modelo123)
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	18	143.1				
2	16	98.4	2	44.72	3.635	0.05

A diferença entre os dois modelos é a adição de X_2 e X_3 depois que X_1 já estava no modelo. Então, a contribuição na $SQReg$ de X_2 e X_3 dados que X_1 estava no modelo é:

$$SQReg(X_2, X_3 \mid X_1) = 44.72$$

Se temos X_1 , X_2 e X_3 no modelo, podemos escrever $SQReg(X_1, X_2, X_3)$ de várias formas:

$$\begin{aligned} SQReg(X_1, X_2, X_3) &= SQReg(X_1) + SQReg(X_2 \mid X_1) \\ &\quad + SQReg(X_3 \mid X_1, X_2) \end{aligned}$$

Se temos X_1 , X_2 e X_3 no modelo, podemos escrever $SQReg(X_1, X_2, X_3)$ de várias formas:

$$SQReg(X_1, X_2, X_3) = SQReg(X_1) + SQReg(X_2 \mid X_1) \\ + SQReg(X_3 \mid X_1, X_2)$$

$$SQReg(X_1, X_2, X_3) = SQReg(X_2) + SQReg(X_3 \mid X_2) \\ + SQReg(X_1 \mid X_2, X_3)$$

Se temos X_1 , X_2 e X_3 no modelo, podemos escrever $SQReg(X_1, X_2, X_3)$ de várias formas:

$$\begin{aligned} SQReg(X_1, X_2, X_3) &= SQReg(X_1) + SQReg(X_2 \mid X_1) \\ &\quad + SQReg(X_3 \mid X_1, X_2) \end{aligned}$$

$$\begin{aligned} SQReg(X_1, X_2, X_3) &= SQReg(X_2) + SQReg(X_3 \mid X_2) \\ &\quad + SQReg(X_1 \mid X_2, X_3) \end{aligned}$$

$$SQReg(X_1, X_2, X_3) = SQReg(X_1) + SQReg(X_2, X_3 \mid X_1)$$

Tabela ANOVA

Tabela ANOVA com a decomposição da $SSReg$ quando X_1 , X_2 e X_3 são inseridos no modelo sequencialmente.

Fonte de Variação	gl	SQ	QM
Regressão	3	$SQReg(X_1, X_2, X_3)$	$QMReg(X_1, X_2, X_3)$
X_1	1	$SQReg(X_1)$	$QMReg(X_1)$
$X_2 \mid X_1$	1	$SQReg(X_2 \mid X_1)$	$QMReg(X_2 \mid X_1)$
$X_3 \mid X_1, X_2$	1	$SQReg(X_3 \mid X_1, X_2)$	$QMReg(X_3 \mid X_1, X_2)$
Erro	$n - 4$	$SQE(X_1, X_2, X_3)$	$QME(X_1, X_2, X_3)$
Total (ajustada)	$n - 1$	SQT	

Teste para β_k usando a Soma Extra de Quadrados

Queremos testar : $H_0 : \beta_k = 0$ vs $H_A : \beta_k \neq 0$.

Vimos anteriormente que podemos usar a seguinte estatística do teste:

$$t = \frac{\hat{\beta}_k}{\sqrt{\widehat{Var}(\hat{\beta}_k)}} \stackrel{H_0}{\sim} t_{n-p}$$

Rejeita-se H_0 se $|t_{obs}| > t_{1-\alpha/2, n-p}$.

. . .

Equivalentemente, podemos utilizar soma extra de quadrados para testar as mesmas hipóteses, usando a seguinte **estatística do teste**:

$$F = \frac{SQReg(X_k \mid X_1, \dots, X_{k-1}, X_{k+1}, \dots, X_{p-1})}{1} \div \frac{SQE(X_1, \dots, X_{p-1})}{n-p} \stackrel{H_0}{\sim} F_{1, n-p}$$

Rejeita-se H_0 se $F_{obs} > F_{1-\alpha, 1, n-p}$.

Exemplo: Regressão de Y em X_1 , X_2 e X_3

Queremos testar se X_3 pode ser excluída do modelo.

No R podemos ajustar o modelo completo e o modelo reduzido da seguinte forma:

```
modelo12 <- lm(Y ~ X1 + X2, data = dados) # Modelo Reduzido
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados) # Modelo Completo

anova(modelo12, modelo123)
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	17	110.0				
2	16	98.4	1	11.55	1.877	0.19

$F_{obs} = 1.88$ e $p\text{-valor} = 0.19$. Portanto, não temos evidências para rejeitar $H_0: \beta_3 = 0$.

Teste para vários β_k 's usando soma extra de quadrados

Para testar se vários β_k 's são simultaneamente nulos, ou seja,

- H_0 : $\beta_q = \beta_{q+1} = \dots = \beta_{p-1} = 0$.
- H_1 : pelo menos um $\beta_q, \dots, \beta_{p-1}$ não é nulo.

Estatística do teste:

$$F = \frac{SQReg(X_q, \dots, X_{p-1} \mid X_1, \dots, X_{q-1})}{p - q} \div \frac{SQE(X_1, \dots, X_{p-1})}{n - p} \stackrel{H_0}{\sim} F_{p-q, n-p}$$

Conclusão: Rejeita-se H_0 se $F_{obs} > F_{1-\alpha, p-q, n-p}$.

Obs.: Por conveniência, a notação assume que os últimos $p - q$ coeficientes do modelo serão testados.

Exemplo: Regressão de Y em X_1 , X_2 e X_3

Queremos testar se X_2 e X_3 podem ser excluídas do modelo.

```
modelo1 <- lm(Y ~ X1, data = dados)
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados)

anova(modelo1, modelo123)
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	18	143.1				
2	16	98.4	2	44.72	3.635	0.05

Qual o valor da estatística do teste? E a conclusão?

Coeficiente de Determinação Parcial

Como já vimos, podemos utilizar o R^2 ou R_{adj}^2 para avaliar o modelo, lembrando que:

Coeficiente de Determinação Múltiplo

$$R^2 = \frac{SQReg}{SQT} = 1 - \frac{SQE}{SQT}$$

Coeficiente de Determinação Múltiplo Ajustado

$$R_{adj}^2 = 1 - \frac{\frac{SQE}{n-p}}{\frac{SQT}{n-1}} = 1 - \left(\frac{n-1}{n-p} \right) \frac{SQE}{SQT}.$$

Agora vamos falar sobre o **Coeficiente de Determinação Parcial**, que é utilizado para avaliar a contribuição marginal de alguma(s) preditor(a)s, dado que as demais já estão no modelo.

Coeficiente de Determinação Parcial

Considere o modelo com dois preditores:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i.$$

Vamos utilizar as **Somas Extras de Quadrados** para calcular o **Coeficiente de Determinação Parcial**.

- Coeficiente de determinação parcial entre Y e X_1 , dado que X_2 está no modelo:

$$R_{Y1|2}^2 = \frac{SQE(X_2) - SQE(X_1, X_2)}{SQE(X_2)} = \frac{SQReg(X_1 | X_2)}{SQE(X_2)}$$

- Coeficiente de determinação parcial entre Y e X_2 , dado que X_1 está no modelo:

$$R_{Y2|1}^2 = \frac{SQE(X_1) - SQE(X_1, X_2)}{SQE(X_1)} = \frac{SQReg(X_2 | X_1)}{SQE(X_1)}$$

O coeficiente de determinação parcial também assume valores entre 0 e 1.

$$R_{Y1|23}^2 = \frac{SQReg(X_1 | X_2, X_3)}{SQE(X_2, X_3)}$$

$$R_{Y2|13}^2 = \frac{SQReg(X_2 | X_1, X_3)}{SQE(X_1, X_3)}$$

$$R_{Y3|12}^2 = \frac{SQReg(X_3 | X_1, X_2)}{SQE(X_1, X_2)}$$

$$R_{Y4|123}^2 = \frac{SQReg(X_4 | X_1, X_2, X_3)}{SQE(X_1, X_2, X_3)}$$

Exemplo: Gordura corporal

Voltando nos dados sobre taxa de gordura corporal para 20 pessoas cujas medidas são:

Y : taxa de gordura corporal;

X_1 : espessura da dobra cutânea do tríceps;

X_2 : circunferência da coxa; e

X_3 : circunferência do meio do braço.

Ajustamos os seguintes modelos:

```
dados = read.table('../dados/fat.txt', col.names = c("X1", "X2", "X3", "Y"))

modelo1 <- lm(Y ~ X1, data = dados)
modelo2 <- lm(Y ~ X2, data = dados)
modelo12 <- lm(Y ~ X1 + X2, data = dados)
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados)
```

Exemplo: Gordura corporal

Para calcular as Somas de Quadrados dos Erros de cada modelos podemos usar a função `deviance()`:

```
SQE1 <- deviance(modelo1) # SQE modelo só com X1
SQE2 <- deviance(modelo2) # SQE modelo só com X2
SQE12 <- deviance(modelo12) # SQE modelo com X1 e X2
SQE123 <- deviance(modelo123) # SQE modelo com X1, X2 e X3
```

A partir disso, podemos calcular as Somas Extras de Quadrados:

```
SQReg2.1 <- SQE1 - SQE12 # SQReg(X2|X1)
SQReg3.12 <- SQE12 - SQE123 # SQReg(X3|X1, X2)
```

Exemplo: Gordura corporal

Coeficiente de determinação parcial de Y com X_2 dado que X_1 está no modelo

```
RY2.1 <- SQReg2.1 / SQE1
```

$$R_{Y2|1}^2 = \frac{SQE(X_1) - SQE(X_1, X_2)}{SQE(X_1)} = \frac{SQReg(X_2 | X_1)}{SQE(X_1)} = 0.2318$$

Quando X_2 é adicionada ao modelo contendo apenas X_1 , a $SQE(X_1)$ é reduzida em 23%. A inclusão de X_2 no modelo explica 23% da variação em Y que não pode ser explicada apenas por X_1 .

Exemplo: Gordura corporal

Coeficiente de determinação parcial de Y com X_3 dado X_1 e X_2 no modelo

```
RY3.12 <- SQReg3.12 / SQE12
```

$$R_{Y3|12}^2 = \frac{SQReg(X_3 | X_1, X_2)}{SQE(X_1, X_2)} = 0.105$$

Quando X_3 é adicionada ao modelo contendo X_1 e X_2 , a $SQE(X_1, X_2)$ é reduzida em 10%. Isto é, 10% da variação em Y que não pode ser explicada pelo modelo com X_1 e X_2 é explicada pela inclusão de X_3 no modelo.

Coeficiente de Determinação Parcial

Outra maneira de obter $R^2_{Y2|1}$:

- Obtenha os resíduos da regressão de Y em X_1 : $e(Y | X_1)$.
- Obtenha os resíduos da regressão de X_2 em X_1 : $e(X_2 | X_1)$.
- Calcule R^2 entre $e(Y | X_1)$ e $e(X_2 | X_1)$.

Veja como calcular no R:

```
modelo1 = lm(Y ~ X1, data = dados)
res1 = residuals(modelo1)

modelox2x1 = lm(X2 ~ X1, data = dados)
resx2x1 = residuals(modelox2x1)


modelo_res = lm(res1 ~ resx2x1)
summary(modelo_res)$r.squared
```

```
[1] 0.2318
```


Gráfico de Regressão Parcial

O gráfico de dispersão de $e(Y | X_1)$ versus $e(X_2 | X_1)$ fornece uma representação gráfica da relação entre Y e X_2 , ajustada por X_1 .

É também chamado de **Gráfico de Regressão Parcial** (em inglês *Added Variable Plot*).




Exemplo Gordura Corporal


Podemos obter os gráficos de regressão parcial usando a função `avPlots()` do pacote `car`:

```
modelo12 = lm(Y ~ X1 + X2, data = dados)
library(car)
avPlots(modelo12)
```

Added-Variable Plots



X1 | others



X2 | others

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 7.1, 7.2, 7.3, 7.4 e 10.1.
- YouTube ME613 - Análise de Regressão - Aula 11
- YouTube ME613 - Análise de Regressão - Aulas 12 e 23

Agradecimentos

Parte deste material e vídeos foram criados pela profa. Samara F. Kiihl e pelos profs. Benilton Carvalho e Rafael Maia - IMECC/UNICAMP