

ME613 - Análise de Regressão

Parte 14

Tatiana Benaglia - 2S2025

Diagnóstico em Regressão Linear Múltipla

A análise de diagnóstico tem um papel fundamental no desenvolvimento e avaliação de modelos de Regressão Linear Múltipla.

A maioria das ferramentas que utilizados para diagnóstico em Regressão Linear Simples podem ser utilizadas em Regressão Linear Múltipla, lembrando que estudamos tanto ferramentas gráficas quanto testes de hipóteses

Considerando o modelo:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

assumindo que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$, temos:

Erros: $\varepsilon = \mathbf{Y} - \mathbf{X}\beta$

Resíduos: $\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$

Esperamos que o vetor de resíduos $\mathbf{e}$ reflita as propriedades assumidas para ε . Portanto, o diagnóstico do modelo é feito através da análise dos resíduos.

Análise de Resíduos: Suposições

Podemos utilizar a análise de resíduos para verificar algumas suposições importantes no modelo de regressão linear simples com erros normais:

- 1 Linearidade da função de regressão
- 2 Homocedasticidade dos erros
- 3 Independência dos erros
- 4 Normalidade dos erros
- 5 Adequidade do modelo, com exceção de algumas observações outliers
- 6 Uma ou mais variáveis preditoras foram omitidas no modelo

Resíduos Semi-Studentizados e Gráficos Apropriados

Resíduos Semi-Studentizados: para detectar outliers, muitas vezes é mais útil observar resíduos padronizados, definidos por

$$e^* = \frac{e}{\sqrt{QME}}$$

Gráficos utilizados na análise de resíduos em RLM:

- Resíduos x Valores preditos ($\hat{Y}$)
- Resíduos ao longo do tempo/em sequência (nem sempre possível)
- Resíduos x cada variável preditora
- Histograma e Boxplot dos resíduos
- Gráfico de probabilidade normal dos resíduos
- Gráficos de Regressão Parcial

Dependendo do objetivo do gráfico, pode-se utilizar os resíduos, resíduos padronizados (studentizados) ou o valor absoluto dos resíduos.

Exemplo: Dwaine Studios

Os dados referem-se a um estúdio de fotografia que opera em 21 cidades de médio porte. Eles são especializados em retratos de crianças e estão pensando em expandir para outras cidades de médio porte.

Y : vendas

X_1 : população com idade até 16 anos

X_2 : renda per capita

Veja as primeiras observações do conjunto de dados:

Sales	Population	Income
174.4	68.5	16.7
164.4	45.2	16.8
244.2	91.3	18.2
154.6	47.8	16.3
181.6	46.9	17.3

Exemplo: Dwaine Studios

Ajuste do model de regressão múltipla:

```
fit <- lm(Sales ~ Population + Income, data=dados)
summary(fit)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-68.857	60.0170	-1.147	0.2663
Population	1.455	0.2118	6.868	0.0000
Income	9.366	4.0640	2.304	0.0333



Residual standard error: 11 on 18 degrees of freedom

Multiple R-squared: 0.917, Adjusted R-squared: 0.907



F-statistic: 99.1 on 2 and 18 DF, p-value: 1.92e-10

Exemplo: Dwaine Studios

Gráfico dos Resíduos x Variáveis Predictoras




Exemplo: Dwaine Studios




Exemplo: Dwaine Studios

Histograma dos Resíduos



Normalidade dos resíduos – QQ plot



Gráficos de Regressão Parcial

Em análise de resíduos já comentamos sobre alguns gráficos:

- Gráfico dos **resíduos x variável preditora**: podemos usar para checar presença de curvatura.
- Gráfico dos **resíduos x variável preditora não inclusa no modelo**: decidir se deve ser incluída.

Problema: estes gráficos não mostram o efeito marginal de uma variável, dado que as demais já estão no modelo.

Gráfico de Regressão Parcial: fornecem informação sobre a importância marginal de X_k , considerando as demais variáveis já incluídas no modelo.

Para o efeito marginal de X_k , consideramos os resíduos da regressão de Y nas demais variáveis e os resíduos da regressão de X_k nas demais variáveis. O gráfico destes dois resíduos mostra a importância marginal de X_k na redução da variabilidade do resíduo. E também pode fornecer informação sobre a natureza da relação marginal de X_k com Y .


Exemplo

Considere uma regressão múltipla de primeira ordem com duas variáveis preditoras: X_1 e X_2 .

Queremos estudar o efeito de X_1 , dado que X_2 já está no modelo:

- Fazemos a regressão Y em X_2 e obtemos os resíduos: $e(Y|X_2)$
- Fazemos a regressão de X_1 em X_2 e obtemos os resíduos: $e(X_1|X_2)$
- Fazemos o gráfico de $e(Y|X_2)$ versus $e(X_1|X_2)$

Protótipos dos gráfico de $e(Y|X_2)$ versus $e(X_1|X_2)$



Exemplo: Marketing

```
library(datarium)
data(marketing)




mkt.rlm <- lm(sales ~ ., data = marketing)
summary(mkt.rlm)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.5267	0.3743	9.4223	0.0000
youtube	0.0458	0.0014	32.8086	0.0000
facebook	0.1885	0.0086	21.8935	0.0000
newspaper	-0.0010	0.0059	-0.1767	0.8599

Veja por esta tabela que não há evidências para rejeitar a hipótese que $\beta_3 = 0$.

Gráficos de Regressão Parcial

Added-Variable Plots



Além da análise gráfica dos resíduos para verificar suposições do modelo, podemos também utilizar testes de hipóteses para avaliar formalmente algumas suposições do modelo, como fizemos na regressão linear simples.

- Teste de Correlação para Normalidade
- Teste de Homocedasticidade: Brown-Forsythe
- Teste de Homocedasticidade: Breusch-Pagan
- Teste F para falta de ajuste

Ações depois da análise de diagnóstico

Se nos gráficos e/ou testes de diagnóstico do modelo determinarmos que o mesmo não é adequado, o que fazer?

- Aplicar alguma transformação nos dados, de maneira que a regressão linear simples fique adequada.
- Se o caso for de heterocedasticidade, pode-se usar também o método de “Mínimos Quadrados Ponderados”.
- Abandonar o modelo de regressão linear e buscar um modelo mais adequado: regressão logística, regressão não-paramétrica, regressão robusta, entre outros.

Predição

A função ajustada, $\hat{Y}_i = \hat{E}(Y | \mathbf{X} = \mathbf{X}_i)$ pode ser usada para obter valores para a variável resposta para quaisquer valores das variáveis preditoras.

Já discutimos lá em Regressão Linear Simples como distinguir dois problemas diferentes:

- Estimação da resposta média, ou seja, $\mathbb{E}(Y|X)$;
- Predição de novas observações.


Seja X_h o nível do preditor X para o qual queremos uma das estimativas a seguir:

Resposta média:

$$\hat{Y}_h = \hat{E}(Y|X = X_h) = \hat{\beta}_0 + \hat{\beta}_1 X_h$$

Nova observação:

$$\hat{Y}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h$$



Veja que em ambos os casos, a estimativa pontual é a mesma, ou seja,

$$\hat{Y}_h = \hat{\beta}_0 + \hat{\beta}_1 X_h,$$

mas o que muda é a precisão desta estimativa, dependendo do objetivo:

$$Var(\hat{Y}_h) = \sigma^2 \left(\frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right) \quad \text{reposta média } \hat{E}(Y|X = X_h)$$

$$Var(\hat{Y}_h) = \sigma^2 \left(\frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right) + \sigma^2 \quad \text{nova observação}$$

Também vimos como obter os **intervalos de confiança** para a resposta média e os **intervalos de predição**, usando as estimativas das variâncias acima para obter os erros padrão.

O raciocínio é bem parecido no caso de Regressão Linear Múltipla.

Valores Preditos e Resíduos

Considerando o modelo de regressão:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon,$$

em que $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$.

Dado que $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, então denotamos por

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \mathbf{H}\mathbf{Y}$$

os **valores preditos** de $\mathbf{Y}$.

Além disso, seja

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\beta}$$

uma estimativa do vetor de erros aleatórios ε , chamado de **resíduos**.

Superfície de Regressão

A equação

$$\begin{aligned}\hat{Y} &= \mathbf{X}\hat{\beta} \\ &= \hat{\beta}_0 + \hat{\beta}_1 \mathbf{X}_1 + \cdots + \hat{\beta}_{p-1} \mathbf{X}_{p-1}\end{aligned}$$

corresponde à equação de um **hiperplano** no espaço formado pelas colunas da matriz $\mathbf{X}$.


No caso de regressão linear múltipla, nos referimos a esse hiperplano como “**superfície de regressão**”.

Por exemplo:

- Se $p = 2$, então $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1$ é a **reta de regressão**.
- Se $p = 3$, então $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$ é um **plano de regressão**.
- Se $p > 3$, então $\hat{Y} = \hat{\beta}_0 + \dots + \hat{\beta}_{p-1} X_{p-1}$ é um **hiperplano ou superfície de regressão**.

Superfície de Regressão ($p \geq 2$)

Exemplo ($p=3$): $\hat{Y} = 2.032 + 2.955X_1 - 1.002X_2$



A superfície de regressão estimada

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta},$$

pode ser usada para obter valores preditos da variável resposta dado quaisquer valores dos preditores para uma observação ou para um conjunto de observações.

Considerando um vetor de preditores $\mathbf{x}_h$ para uma única observação:


$$\hat{Y}_h = \hat{\mathbb{E}}(Y \mid \mathbf{X} = \mathbf{x}_h) = \mathbf{x}_h' \hat{\beta} \quad (\text{resposta média})$$

$$\hat{Y}_h = \mathbf{x}_h' \hat{\beta} \quad (\text{nova observação})$$

Assim como vimos anteriormente, em ambos os casos, a estimativa pontual continua a mesma, mas a variabilidade (incerteza) ao redor do estimador é diferente.


CUIDADO com extrapolação!

Regressão Linear Simples - Extrapolação



Regressão Linear Múltipla - Extrapolação

Caso $p=3$ (visto de cima)



Intervalo de Confiança para a Resposta Média

Sabemos que $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$. Então,

$$\begin{aligned}\mathbb{E}(\hat{\mathbf{Y}}_h) &= \mathbb{E}(\mathbf{x}'_h \hat{\beta}) = \mathbf{x}'_h \mathbb{E}(\hat{\beta}) = \mathbf{x}'_h \beta, \\ \text{Var}(\hat{\mathbf{Y}}_h) &= \text{Var}(\mathbf{x}'_h \hat{\beta}) = \mathbf{x}'_h \text{Var}(\hat{\beta}) \mathbf{x}_h = \sigma^2 \mathbf{x}'_h (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_h.\end{aligned}$$

Portanto,

$$\hat{\mathbf{Y}}_h \sim N(\mathbf{x}'_h \beta, \sigma^2 \mathbf{x}'_h (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_h)$$

Similar ao que fizemos em Regressão Linear Simples, podemos construir um intervalo de confiança para a resposta média $Y_h = \mathbb{E}(Y|\mathbf{X} = \mathbf{x}_h) = \mathbf{x}'_h \beta$

$$\hat{Y}_h \pm t_{n-p, 1-\alpha/2} \sqrt{QME \mathbf{x}'_h (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_h}.$$

O intervalo acima pode ser obtido para cada vetor de observação $\mathbf{x}_i$ do conjunto de dados, resultando assim em uma **banda de confiança** para a resposta média (superfície de regressão).

Estimação da Resposta Média

Considerando o caso de regressão linear simples ($p = 2$).

Neste caso, como $\mathbf{x}'_h = (1 \quad x_h)$, temos

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

e

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i\right)^2} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix} = \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n x_i^2 & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix}$$

Estimação da Resposta Média

Dessa forma,

$$\begin{aligned}\mathbf{x}'_h(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_h &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} (1 \quad x_h) \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n x_i^2 & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix} \begin{pmatrix} 1 \\ x_h \end{pmatrix} \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} (1 \quad x_h) \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}x_h \\ x_h - \bar{x} \end{pmatrix} \\ &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \left(\frac{1}{n} \sum_{i=1}^n x_i^2 - 2\bar{x}x_h + x_h^2 \right) = \frac{1}{n} + \frac{(x_h - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\end{aligned}$$

Observe que o intervalo atinge largura mínima quando $x_h = \bar{x}$.

Predição de Uma Nova Observação

Agora nosso interesse está na predição de uma nova observação, dado um vetor de preditores $\mathbf{X} = \mathbf{x}_h$, chamada de $\hat{Y}_h$.

Lembrando que:

Intervalo de confiança refere-se a um intervalo para um parâmetro, cujos valores são fixos mas desconhecidos. No caso, a resposta média $\mathbb{E}(Y|\mathbf{X})$.

Quando falamos de um valor novo de Y , isto não é um parâmetro, mas sim uma variável aleatória. Por esta razão, nos referimos a este intervalo de valores plausíveis de Y como **intervalo de predição**.

Determinar um intervalo de predição para Y requer um modelo para o erro envolvido na predição da variável Y .

Para um dado valor do vetor de preditores $\mathbf{x}_h$, o erro de predição é dado por:

$$Y_h - \hat{Y}_h = Y_h - \mathbf{x}_h' \hat{\beta},$$

isto é, a diferença entre duas variáveis aleatórias.

Distribuição do Erro de Predição

Assumindo que os erros são normais, a distribuição amostral de $Y_h - \hat{Y}_h$ também é normal com:

$$\begin{aligned}\mathbb{E}(Y_h - \hat{Y}_h) &= \mathbb{E}(Y_h) - \mathbb{E}(\hat{Y}_h) = 0, \\ \text{Var}(Y_h - \hat{Y}_h) &= \text{Var}(Y_h) + \text{Var}(\hat{Y}_h) \\ &= \sigma^2 + \sigma^2 \mathbf{x}_h' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_h, \\ &= \sigma^2 [1 + \mathbf{x}_h' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_h]\end{aligned}$$

já que Y_h é independente de $\hat{Y}_h$ (obtido com os valores observados de Y na amostra).

Como σ^2 é desconhecido, usamos seu estimador QME e então temos um estimador para a $\text{Var}(Y - \hat{Y}_h)$, ou seja,

$$\widehat{\text{Var}}(Y - \hat{Y}_h) = QME[1 + \mathbf{x}_h' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_h]$$

Similar ao que já fizemos anteriormente, pode-se mostrar que:

$$\frac{Y - \hat{Y}_h}{\sqrt{\widehat{Var}(Y - \hat{Y}_h)}} \sim t_{n-p}.$$

Portanto, para um nível de confiança $1 - \alpha$, um intervalo de predição para Y_h é dado por:

$$\hat{Y}_h \pm t_{n-p, \alpha/2} \sqrt{QME[1 + \mathbf{x}_h'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_h]}.$$

Exemplo: FEV

Considere o conjunto de dados sobre a função respiratória (FEV), medida pelo volume expiratório forçado em litros, e outras variáveis como idade, altura, gênero e fumante. São 654 crianças com idade entre 8 e 19 anos.









```
fev <- read.delim("../dados/fev.txt", sep = "")
```

Veja as primeiras observações dos dados:

id	age	fev	height	sex	smoke
1	9	1.708	57.0	2	2
2	8	1.724	67.5	2	2
3	7	1.720	54.5	2	2
4	9	1.558	53.0	1	2
5	9	1.895	57.0	1	2

Referência: Michael Kahn (2005) An Exhalent Problem for Teaching Statistics, Journal of Statistics Education, 13:2, DOI: 10.1080/10691898.2005.11910559

Panorama dos dados FEV



Exemplo: FEV

Iremos usar como preditores altura e idade, ou seja,

$$Y_i = \beta_0 + \beta_1 \text{idade}_i + \beta_2 \text{altura}_i + \varepsilon_i,$$

para $i = 1, 2, \dots, 654$.

```
fev <- read.delim("../dados/fev.txt", sep = "")  
model <- lm(fev ~ height + age, data = fev)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.61047	0.22427	-20.558	0
height	0.10971	0.00472	23.263	0
age	0.05428	0.00911	5.961	0

Exemplo: FEV

No R podemos obter predições usando a função `predict()` para objetos do tipo `lm`, mas os valores novos precisam estar organizados como `data.frame`.

Por exemplo, suponha que tenho uma criança de 6 anos com altura 53 polegadas. Neste caso:

```
xnew = data.frame(height = 53, age = 6)
predict(model, xnew, se.fit = TRUE)
```

```
$fit
```

```
1
```

```
1.53
```

```
$se.fit
```

```
[1] 0.02912
```

```
$df
```

```
[1] 651
```

```
$residual.scale
```

Exemplo: FEV

Se mudarmos o argumento `interval`, podemos obter um intervalo de confiança ou um intervalo de predição:

```
predict(model, xnew, interval = "confidence", level = 0.95)
```

```
      fit    lwr    upr  
1 1.53 1.473 1.587
```

```
predict(model, xnew, interval = "prediction", level = 0.95)
```

```
      fit    lwr    upr  
1 1.53 0.7038 2.356
```

Veja que podemos calcular esses intervalos para vários vetores de preditores e, possivelmente, usar a correção de Bonferroni.

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 6.7, 6.8 e 6.9.

Agradecimentos

Parte deste material e vídeos foram criados pela profa. Samara F. Kiihl e pelos profs. Benilton Carvalho e Rafael Maia - IMECC/UNICAMP