

ME613 - Análise de Regressão

Parte 15

Tatiana Benaglia - 2S2025

Na análise de regressão múltipla, a natureza e o significado das relações entre os variáveis preditivas ou explicativas e a variável de resposta são frequentemente de particular interesse.

Algumas perguntas frequentes são:

- 1 Qual é a importância relativa dos efeitos das diferentes variáveis preditoras?
- 2 Qual é a magnitude do efeito de uma determinada variável preditora sobre a variável de resposta?
- 3 Qualquer variável preditora pode ser retirada do modelo porque tem pouco ou nenhum efeito na variável de resposta?
- 4 Será que alguma variável preditora ainda não incluída no modelo seja considerada para possível inclusão?

Regressão Múltipla Centralizada e Padronizada

Respostas para essas perguntas podem ser influenciadas pela estabilidade da matriz $\mathbf{X}'\mathbf{X}$.

Pode acontecer erros de precisão numérica quando:

- $\mathbf{X}'\mathbf{X}$ tem determinante próximo de 0.
- elementos de $\mathbf{X}'\mathbf{X}$ diferem substancialmente em ordem de magnitude.

Para cada um destes problemas, há soluções propostas.

O primeiro caso é o que chamamos de **multicolinearidade** e falaremos mais adiante nesta aula. Vamos inicialmente tratar do problema de **ordem de magnitude** dos preditores.

Falta de comparabilidade entre coeficientes

Em geral, não podemos comparar os coeficientes de regressão entre si, dado que não estão nas mesmas unidades.

Exemplo:

$$\hat{Y} = 200 + 20000X_1 + 0.2X_2$$

Pode-se pensar que apenas X_1 é relevante no modelo. Mas suponha que a resposta Y é medida em dólares e os preditores:

- X_1 em milhares de dólares
- X_2 em centavos de dólares.

O efeito na resposta média do aumento de 1000 dólares em X_1 (1 unidade de aumento, X_1 está em milhares) quando X_2 é constante, é de 20000 dólares.

O efeito na resposta média do aumento de 1000 dólares em X_2 (100000 unidades de aumento, X_2 está em centavos) quando X_1 é constante, é de 20000 dólares.

O que você sugeriria para resolver esse problema?

Já demonstramos o efeito de centralizar a variável preditora no caso de regressão linear simples. E esse conceito pode ser estendido para o caso de $p - 1$ preditores.

O modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_{p-1} X_{ip-1} + \varepsilon_i,$$

pode ser reescrito como:

$$\begin{aligned} Y_i &= \beta_0 + (\beta_1 \bar{X}_1 + \dots + \beta_{p-1} \bar{X}_{p-1}) + \beta_1 (X_{i1} - \bar{X}_1) + \dots + \beta_{p-1} (X_{ip-1} - \bar{X}_{p-1}) + \varepsilon_i \\ &= \beta_0^* + \beta_1 (X_{i1} - \bar{X}_1) + \dots + \beta_{p-1} (X_{ip-1} - \bar{X}_{p-1}) + \varepsilon_i \end{aligned}$$

sendo $\hat{\beta}_0^* = \bar{Y}$ e as estimativas dos demais coeficientes $\hat{\beta}_j$ são as mesmas que as obtidas com os dados não centralizados.

Na padronização usual de uma variável, subtraímos a média e dividimos pelo desvio padrão, ou seja,

$$z_{Y_i} = \frac{Y_i - \bar{Y}}{s_Y} \quad \text{e} \quad z_{X_{ik}} = \frac{X_{ik} - \bar{X}_k}{s_k},$$

para $k = 1, \dots, p - 1$ e sendo

$$s_Y = \sqrt{\frac{\sum_i (Y_i - \bar{Y})^2}{n - 1}} \quad \text{e} \quad s_k = \sqrt{\frac{\sum_i (X_{ik} - \bar{X}_k)^2}{n - 1}},$$

Note que s_Y e s_k são os desvios padrão amostrais de Y e X_k , respectivamente.

Transformação de Correlação

A **transformação de correlação** é uma função das variáveis padronizadas:

$$Y_i^* = \frac{z_{Y_i}}{\sqrt{n-1}} = \frac{1}{\sqrt{n-1}} \left(\frac{Y_i - \bar{Y}}{s_Y} \right)$$
$$X_{ik}^* = \frac{z_{X_{ik}}}{\sqrt{n-1}} = \frac{1}{\sqrt{n-1}} \left(\frac{X_{ik} - \bar{X}_k}{s_k} \right), \quad k = 1, 2, \dots, p-1$$

Ao utilizarmos a transformação de correlação, obtemos que todos os elementos de $\mathbf{X}'\mathbf{X}$ variam entre 1 e -1 .

Isto gera uma estabilidade para obter a inversa de $\mathbf{X}'\mathbf{X}$, pois acarreta menos problemas de arredondamento.

Modelo de Regressão Padronizado

O modelo de regressão com as variáveis transformadas Y^* e X_k^* usando a transformação de correlação é chamado de **Modelo de Regressão Padronizado**:

$$Y_i^* = \beta_1^* X_{i1}^* + \dots + \beta_{p-1}^* X_{i,p-1}^* + \varepsilon_i^*$$

Note que esse modelo não inclui o intercepto. Por que?

Considere a matriz $\mathbf{X}^*$ transformada e $\mathbf{r}_{\mathbf{X}\mathbf{X}}$ a matriz de correlação de $\mathbf{X}$:

$$\mathbf{X}_{n \times p-1}^* = \begin{bmatrix} X_{11}^* & X_{12}^* & \dots & X_{1,p-1}^* \\ X_{21}^* & X_{22}^* & \dots & X_{2,p-1}^* \\ \vdots & \vdots & \vdots & \vdots \\ X_{n1}^* & X_{n2}^* & \dots & X_{n,p-1}^* \end{bmatrix} \quad \text{e} \quad \mathbf{r}_{\mathbf{X}\mathbf{X}} = \begin{bmatrix} 1 & r_{12} & \dots & r_{1,p-1} \\ r_{21} & 1 & \dots & r_{2,p-1} \\ \vdots & \vdots & \vdots & \vdots \\ r_{p-1,1} & r_{p-1,2} & \dots & 1 \end{bmatrix}$$

em que r_{jk} é o coeficiente de correlação entre X_j e X_k .

Modelo de Regressão Padronizado

Pode-se mostrar que:

$$\mathbf{X}^{*'} \mathbf{X}^* = \mathbf{r}_{\mathbf{X}\mathbf{X}}$$

De maneira similar:

$$\mathbf{X}^{*'} \mathbf{Y}_{p-1 \times 1}^* = \mathbf{r}_{\mathbf{Y}\mathbf{X}}$$

em que $\mathbf{r}_{\mathbf{Y}\mathbf{X}}$ é o vetor de correlações entre $\mathbf{Y}$ e cada coluna de $\mathbf{X}$.

Equações normais:

$$\mathbf{X}^{*'} \mathbf{X}^* \hat{\beta}^* = \mathbf{X}^{*'} \mathbf{Y}$$

Estimador de Mínimos Quadrados:

$$\hat{\beta}^* = (\mathbf{X}^{*'} \mathbf{X}^*)^{-1} \mathbf{X}^{*'} \mathbf{Y} \quad \Rightarrow \quad \hat{\beta}^* = \mathbf{r}_{\mathbf{X}\mathbf{X}}^{-1} \mathbf{r}_{\mathbf{Y}\mathbf{X}}$$

Modelo de Regressão Padronizado

A partir dos coeficientes estimados na regressão padronizada, pode-se obter os coeficientes da regressão original através da seguinte relação:

$$\hat{\beta}_k = \left(\frac{s_Y}{s_k} \right) \hat{\beta}_k^* \quad k = 1, 2, \dots, p-1$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \dots - \hat{\beta}_{p-1} \bar{X}_{p-1}$$

Exercício: Demonstre para o caso da regressão linear simples, ou seja, $p = 2$.

Exemplo: Dwaine Studios

Vamos voltar no exemplo Dwaine Studios. As variáveis são:

Y : vendas

X_1 : população

X_2 : renda per capita

Veja as primeiras linhas desses dados:

Sales	Population	Income
174.4	68.5	16.7
164.4	45.2	16.8
244.2	91.3	18.2
154.6	47.8	16.3
181.6	46.9	17.3

Exemplo: Dwaine Studios

Modelo sem padronização:

```
modelo <- lm(Sales ~ Population + Income, data=dados)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-68.857	60.0170	-1.147	0.2663
Population	1.455	0.2118	6.868	0.0000
Income	9.366	4.0640	2.304	0.0333

Modelo padronizado

```
dadosPadrao <- as.data.frame(scale(dados)/sqrt(dim(dados)[1]-1))  
modeloPadrao <- lm(Sales ~ Population + Income - 1, data = dadosPadrao)
```

	Estimate	Std. Error	t value	Pr(> t)
Population	0.7484	0.1061	7.056	0.0000
Income	0.2511	0.1061	2.368	0.0287

Exemplo: Dwaine Studios

Os coeficientes também podem ser obtidos usando a função `lm.beta()` do pacote `QuantPsyc`. Esta função calcula os coeficientes de regressão padronizada para um objeto da classe `lm`.

```
library(QuantPsyc)
lm.beta(modelo)
```

Population	Income
0.7484	0.2511

Note que o comando apenas libera as estimativas (sem erro padrão, testes, etc...)

Multilinearidade

Vamos considerar o modelo de regressão linear múltipla:

$$Y_i = \beta_1 X_{i1} + \beta_2 X_{i2} + \epsilon_i, \quad i = 1, \dots, n, \quad \epsilon_i \text{ iid } \sim N(0, \sigma^2)$$

em que X_1 e X_2 são **variáveis transformadas via transformação de correlação** (ou seja estão centradas no 0 e limitadas entre -1 e 1).

A matrix de desenho do modelo é dada por

$$\mathbf{X} = \begin{bmatrix} X_{11} & X_{12} \\ X_{21} & X_{22} \\ \vdots & \vdots \\ X_{n1} & X_{n2} \end{bmatrix} \quad \text{e} \quad \mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum X_{i1}^2 & \sum X_{i1}X_{i2} \\ \sum X_{i1}X_{i2} & \sum X_{i2}^2 \end{bmatrix}$$

Daí temos que

$$\det(\mathbf{X}'\mathbf{X}) = \sum X_{i1}^2 \sum X_{i2}^2 - \left(\sum X_{i1}X_{i2} \right)^2$$

Multicolinearidade

Se X_1 e X_2 são não colineares, ou seja, não correlacionados, então temos que $\sum X_{i1}X_{i2} = 0$ e a matrix $\mathbf{X}'\mathbf{X} = \text{diag}(\sum X_{i1}^2, \sum X_{i2}^2)$.

Daí temos que

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \frac{\sum X_{i1}Y_i}{\sum X_{i1}^2} \\ \frac{\sum X_{i2}Y_i}{\sum X_{i2}^2} \end{bmatrix}$$

E neste caso obter os estimados para β_1 e β_2 na regressão múltipla é equivalente a estimá-los separadamente via modelos de regressão linear simples independentes.

Além disso,

$$SQReg(X_1 | X_2) = SQReg(X_1)$$

$$SQReg(X_2 | X_1) = SQReg(X_2)$$

Por outro lado se X_1 e X_2 são perfeitamente correlacionadas, ou seja, $Cor(X_1, X_2) = 1$, então

$$\sum X_{i1}^2 \sum X_{i2}^2 = \left(\sum X_{i1} X_{i2} \right)^2$$

Portanto,

$$\det(\mathbf{X}'\mathbf{X}) = 0.$$

Neste caso não é possível obter a inversa da matriz $\mathbf{X}'\mathbf{X}$, ou seja, essa matriz é singular, e o sistema de equações normais não possui solução única.

Quanto mais próximo de 1 for a correlação entre as variáveis mais próximo de 0 será o determinante da matriz $\mathbf{X}'\mathbf{X}$. Isso gera imprecisões numéricas na obtenção dos estimadores.

Exemplo 1: Preditores Não Correlacionados

Y : produtividade

X_1 : tamanho da equipe

X_2 : pagamento (dólares)

```
dados = read.table('dados/CH07TA06.txt', col.names = c("X1", "X2", "Y"))
```

X1	X2	Y
4	2	42
4	2	39
4	3	48
4	3	51
6	2	49

```
cor(dados$X1, dados$X2)
```

```
[1] 0
```

Exemplo 1: Preditores Não Correlacionados

Regressão de Y em X_1 : $\hat{\beta}_1$

```
modelo1 <- lm(Y ~ X1, data=dados)
```

Tabela dos coeficientes estimados:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.500	10.111	2.324	0.0591
X1	5.375	1.983	2.711	0.0351

Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	231.1	231.12	7.347	0.0351
Residuals	6	188.8	31.46		

Exemplo 1: Preditores Não Correlacionados

Regressão de Y em X_2 : $\hat{\beta}_2$

```
modelo2 <- lm(Y ~ X2, data=dados)
```

Tabela dos coeficientes estimados:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	27.25	11.608	2.348	0.0572
X2	9.25	4.553	2.032	0.0885

Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X2	1	171.1	171.12	4.128	0.0885
Residuals	6	248.8	41.46		

Exemplo 1: Preditores Não Correlacionados

Regressão de Y em X_1 e X_2 : $\hat{\beta}_1^*$ e $\hat{\beta}_2^*$

```
modelo12a <- lm(Y ~ X1 + X2, data=dados)
```

Tabela dos coeficientes estimados:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.375	4.7405	0.0791	0.9400
X1	5.375	0.6638	8.0974	0.0005
X2	9.250	1.3276	6.9675	0.0009

Veja que os coeficientes estimados:

$$\hat{\beta}_1^* = 5.375 \quad \text{e} \quad \hat{\beta}_2^* = 9.25,$$

são exatamente os coeficientes estimados nas regressões simples de Y em X_1 e X_2 , respectivamente.

Exemplo 1: Preditores Não Correlacionados

Tabela ANOVA $Y = X_1 + X_2$

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	231.12	231.125	65.57	5e-04
X2	1	171.12	171.125	48.55	9e-04
Residuals	5	17.62	3.525		

$$SQReg(X_2|X_1) = SQE(X_2) - SQE(X_1, X_2) = 171.12 = SQReg(X_2)$$

Tabela ANOVA $Y = X_2 + X_1$

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X2	1	171.12	171.125	48.55	9e-04
X1	1	231.12	231.125	65.57	5e-04
Residuals	5	17.62	3.525		

$$SQReg(X_1|X_2) = SQE(X_1) - SQE(X_1, X_2) = 231.12 = SQReg(X_1)$$

Exemplo 2: Preditores Perfeitamente Correlacionados

Veja agora um exemplo em que os preditores X_1 e X_2 são perfeitamente correlacionados.

```
dados = read.table('./dados/CH07TA08.txt', col.names = c("X1", "X2", "Y"))
```

X1	X2	Y
2	6	23
8	9	83
6	8	63
10	10	103

```
cor(dados$X1, dados$X2)
```

```
[1] 1
```

Exemplo 2: Preditores Perfeitamente Correlacionados

```
modelo1 <- lm(Y ~ X1 + X2, data=dados)
```

Warning in summary.lm(modelo1): essentially perfect fit: summary may be unreliable

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3	0	4.633e+14	0
X1	10	0	1.103e+16	0

Este modelo produz valores ajustados perfeitos (resíduo nulo):

X1	X2	Y	fitted	residuos
2	6	23	23	0
8	9	83	83	0
6	8	63	63	0
10	10	103	103	0

Exemplo 2: Preditores Perfeitamente Correlacionados

Outros possíveis soluções:

$$\hat{Y} = -87 + X_1 + 18X_2$$

$$\hat{Y} = -7 + 9X_1 + 2X_2$$

E estas também fornecem os mesmos valores para $\hat{Y}$.

Problema: X_1 e X_2 são perfeitamente correlacionadas ($X_2 = 5 + 0.5X_1$).

Podemos obter bons valores ajustados/preditos, mas não podemos interpretar os parâmetros do modelo (pois temos infinitas possibilidades).

Detectando Multicolinearidade

Na prática, dificilmente encontraremos variáveis preditoras que sejam não correlacionadas ou perfeitamente correlacionadas entre si.

Algumas indicações da presença de multicolinearidade:

- Valores altos das correlações entre os preditores;
- Grandes mudanças nas estimativas dos parâmetros de regressão quando uma variável é incluída ou excluída do modelo;
- Estimativa dos parâmetros de regressão com sinal oposto do que seria esperado, segundo informações/conhecimento prévio;
- A rejeição de H_0 no teste F, mas nenhuma rejeição nos testes t sobre os coeficientes individuais β_j ;
- Intervalos de confiança muito amplos para os coeficientes, associados a variáveis preditoras importantes;
- Examinar o **Fator de Inflação da Variância (VIF)**.

Exemplo - Gordura corporal

Modelo com X_1 e X_2 :

	Estimativa	Erro Padrão	t	p-valor
(Intercept)	-19.1742	8.3606	-2.2934	0.0348
X1	0.2224	0.3034	0.7328	0.4737
X2	0.6594	0.2912	2.2646	0.0369

Modelo com X_1 , X_2 e X_3 :

	Estimativa	Erro Padrão	t	p-valor
(Intercept)	117.085	99.782	1.173	0.2578
X1	4.334	3.015	1.437	0.1699
X2	-2.857	2.582	-1.106	0.2849
X3	-2.186	1.595	-1.370	0.1896

Teste F: $F=21.5$ on 3 and 16 DF, p-value: $7.34e-06$

VIF - Fator de Inflação da Variância

A **variância dos coeficientes estimados** é dada por:

$$Var(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

Para medir o impacto da multicolinearidade, é mais útil trabalhar com as variáveis com transformação de correlação, vistas anteriormente. Dessa forma, temos

$$Var(\hat{\beta}^*) = (\sigma^*)^2 \mathbf{r}_{XX}^{-1},$$

em que $(\sigma^*)^2$ é a variância do erro para o modelo transformado.

Definindo VIF_k (**fator de inflação da variância** para $\hat{\beta}_k^*$) como o k -ésimo elemento de $\mathbf{r}_{XX}^{-1}$, temos:

$$Var(\hat{\beta}_k^*) = (\sigma^*)^2 VIF_k$$

Pode-se mostrar que :

$$VIF_k = (1 - R_k^2)^{-1},$$

em que R_k^2 é o coeficiente de determinação da regressão de X_k nas demais variáveis preditoras.

VIF - Fator de Inflação da Variância

Seja o fator de inflação da variância (VIF) dado por:

$$VIF_k = \frac{1}{1 - R_k^2}$$

- $VIF_k = 1$ quando $R_k^2 = 0$, ou seja, quando X_k não está linearmente relacionada com os outros preditores.
- Quando $R_k^2 = 1$, ou seja, quando X_k tem uma perfeita relação linear com os outros preditores, $VIF_k = 0$ e a variância dos coeficientes são ilimitados.
- Quando $R_k^2 \neq 0$, que é a maioria dos casos, então $VIF_k > 1$. E este é o fator que inflaciona a variância dos coeficientes.

- Sugere-se que se qualquer VIF exceder 10, então a multicolinearidade causará efeitos nas estimativas dos coeficientes de regressão.
- O VIF médio também fornece informação sobre a severidade da multicolinearidade em termos do quão longe os coeficientes estimados estão dos verdadeiros coeficientes.
- $VIF > 1$ indica sério problemas de multicolinearidade.

Exemplo - Gordura corporal

Variáveis na escala original:

```
modelo2 <- lm(Y ~ X1 + X2 + X3, data=dados)
```

	Estimativa	Erro Padrão	t	p-valor
(Intercept)	117.085	99.782	1.173	0.2578
X1	4.334	3.015	1.437	0.1699
X2	-2.857	2.582	-1.106	0.2849
X3	-2.186	1.595	-1.370	0.1896

Residual standard error: 2.48 on 16 degrees of freedom

Multiple R-squared: 0.8014, Adjusted R-squared: 0.7641

F-statistic: 21.52 on 3 and 16 DF, p-value: 7.343e-06

Note que X_2 é a variável menos significativa, considerando que as demais estão no modelo. E o coeficiente de determinação ajustado é $R_{adj}^2 = 0.764$.

Exemplo - Gordura corporal

Variáveis padronizadas (transformação de correlação):

	Estimativa	Erro Padrão	t	p-valor
X1	4.264	2.878	1.482	0.1568
X2	-2.929	2.568	-1.141	0.2699
X3	-1.561	1.106	-1.412	0.1759

Podemos calcular o VIF_k usando a função `vif()` do pacote `car`.

```
car::vif(modelo2)
```

```
      X1      X2      X3  
708.8 564.3 104.6
```

Observe que os valores dos VIF's são altíssimos. Nesse caso, devemos remover alguma variável do modelo para tentar solucionar o problema de multicolinearidade.

Exemplo - Gordura corporal

Fazendo alguns testes, a sugestão é remover a variável X_2 .

```
modelo3 <- lm(Y ~ X1 + X3, data = dados)
```

	Estimativa	Erro Padrão	t	p-valor
(Intercept)	6.7916	4.4883	1.513	0.1486
X1	1.0006	0.1282	7.803	0.0000
X3	-0.4314	0.1766	-2.443	0.0258

Multiple R-squared: 0.7862, Adjusted R-squared: 0.761

F-statistic: 31.25 on 2 and 17 DF, p-value: 2.022e-06

```
car::vif(modelo3)
```

```
      X1      X3  
1.265 1.265
```

Agora todos os VIF's são pequenos. Além disso, todas as variáveis são significativas e o $R_{adj}^2 = 0.761$ permaneceu praticamente inalterado.

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 7.5, 7.6 e 10.5.
- YouTube ME613 - Análise de Regressão - Aula 14 (parte 1 e 2) e Aula 25

Agradecimentos

Parte deste material e vídeos foram criados pela profa. Samara F. Kiihl e pelos profs. Benilton Carvalho e Rafael Maia - IMECC/UNICAMP

