


ME613 - Análise de Regressão

Parte 16

Tatiana Benaglia - 2S2025

Outliers - Introdução



Outliers: podem gerar grandes resíduos e efeitos drásticos na função de regressão estimada.

É preciso analisar esses valores extremos (*outliers*) com cuidado e decidir se eles permanecem ou devem ser eliminados.

Outliers em Y : Resíduos e Resíduos Semi-Studentizados

Para detectar outliers em Y , geralmente trabalhamos com os resíduos ou resíduos padronizados. Relembrando:

Resíduos: $e_i = Y_i - \hat{Y}_i$

Resíduo Semi-Studentizado

$$e_i^* = \frac{e_i}{\sqrt{QME}} = \frac{Y_i - \hat{Y}_i}{\sqrt{QME}}$$


De modo geral, para n grande, quando $|e_i^*| > 4$ considera-se a i -ésima observação como *outlier*.

Exemplo: Gordura corporal

Dados sobre gordura corporal (Y) em função da dobra cutânea do tríceps (X_1) e circunferência do meio braço (X_3).


```
modelo1 <- lm(Y ~ X1 + X3, data=dados)
dados$res_std = rstandard(modelo1)
```

Histograma – Resíduos Padronizados



Resíduos Padronizados

QQ Plot – Resíduos Padronizados



Theoretical Quantiles

Iremos introduzir dois refinamentos para que a análise de resíduos seja mais efetiva para detectar outliers em Y . Para isso, vamos voltar na **matriz chapéu** $\mathbf{H}$.

$$\mathbf{H}_{n \times n} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \quad \Rightarrow \quad \hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$$

Dessa forma, assim como os valores preditos $\hat{\mathbf{Y}}$, os resíduos podem ser expressos como combinações lineares das observações Y_i :

$$\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$$

Além disso,

$$\text{Var}(\mathbf{e}) = \sigma^2(\mathbf{I} - \mathbf{H}) \quad \text{e} \quad \text{Var}(e_i) = \sigma^2(1 - h_{ii}),$$

em que $h_{ii} = \mathbf{X}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}_i$, ou seja, o i -ésimo elemento da diagonal principal da matriz chapéu.

Resíduo Studentizado

A covariância entre e_i e e_j :

$$\text{Cov}(e_i, e_j) = -h_{ij}\sigma^2, \quad i \neq j.$$

Para estimar essas variâncias e covariâncias usamos QME como estimador de σ^2 . Então:

$$\widehat{\text{Var}}(e_i) = QME(1 - h_{ii}) \quad \text{e} \quad \widehat{\text{Cov}}(e_i, e_j) = -h_{ij}QME \quad i \neq j.$$

Resíduo Studentizado: note que os resíduos e_i podem ter variâncias substancialmente diferentes. Então, o primeiro refinamento é considerar:

$$r_i = \frac{e_i}{\sqrt{QME(1 - h_{ii})}}$$

Veja que r_i tem variância constante, quando o modelo é apropriado. Esses resíduos são também conhecido como *resíduos studentizados internamente*.

Quando $|r_i^*| > 4$, considera-se a i -ésima observação como *outlier*.

Resíduo Deletado

Se uma observação é muito discrepante, ela pode influenciar no ajuste.

Então, o segundo refinamento consiste em medir o resíduo e_i quando o modelo estimado é baseado em todas as observações, exceto pela i -ésima.

Procedimento:

- excluir a i -ésima observação
- ajustar o modelo com as $n - 1$ observações restantes
- obter $\hat{Y}_{i(i)}$: o valor predito para a i -ésima observação quando esta foi excluída no ajuste do modelo.
- calcula-se o **resíduo deletado**:

$$d_i = Y_i - \hat{Y}_{i(i)} = \frac{e_i}{1 - h_{ii}}$$

Obs: quanto maior h_{ii} , maior será d_i em comparação com e_i .

Resíduo Deletado Studentizado

A variância de d_i pode ser estimada como:

$$\widehat{Var}(d_i) = QME_{(i)}(1 + \mathbf{X}_i'(\mathbf{X}_{(i)}'\mathbf{X}_{(i)})^{-1}\mathbf{X}_i) = \frac{QME_{(i)}}{1 - h_{ii}},$$

em que $QME_{(i)}$ é o QME do modelo sem a i -ésima observação.

Resíduo Deletado Studentizado

$$t_i = \frac{d_i}{\sqrt{\widehat{Var}(d_i)}} = \frac{e_i}{\sqrt{QME_{(i)}(1 - h_{ii})}} \sim t_{n-p-1}$$

Esses resíduos são também conhecidos como resíduos studentizados externamente, em contraste com r_i .

Resíduo Deletado Studentizado

Podemos calcular t_i sem de fato fazer ajustes separados para cada observação excluída, pela seguinte relação:

$$(n - p)QME = (n - p - 1)QME_{(i)} + \frac{e_i^2}{1 - h_{ii}}$$

Dessa forma, reescrevemos:

$$t_i = e_i \left[\frac{n - p - 1}{SQE(1 - h_{ii}) - e_i^2} \right]^{1/2},$$

ou seja, t_i pode ser calculado baseado em informações da regressão ajustada com as n observações.

Teste para outliers: A observação i é um *outlier* se $|t_i| > t_{n-p-1}(1 - \alpha/2n)$, utilizando Bonferroni.

Exemplo: Gordura corporal

No exemplo da gordura corporal com dois preditores, temos que se $|t_i| > 3.25$, então a i -ésima observação é um *outlier* em Y .

id	e	h	t	id	e	h	t	
1	-1.848	0.178	-0.808	11	11	0.433	0.121	0.180
2	3.461	0.054	1.473	12	12	2.200	0.109	0.930
3	-2.846	0.399	-1.527	13	13	-3.879	0.170	-1.818
4	-3.091	0.112	-1.345	14	14	3.636	0.156	1.666
5	0.329	0.273	0.150	15	15	0.590	0.327	0.280
6	-0.481	0.131	-0.201	16	16	0.578	0.093	0.236
7	0.798	0.148	0.337	17	17	-0.820	0.099	-0.337
8	3.894	0.086	1.724	18	18	-0.996	0.208	-0.437
9	2.405	0.128	1.034	19	19	-3.013	0.065	-1.270
10	-2.307	0.092	-0.968	20	20	0.958	0.050	0.384

Veja que mesmo para os maiores resíduos (observações 8 e 13), os valores de t_i ainda estão abaixo de 3.25.

Ainda falando da matriz chapéu:

- $0 \leq h_{ii} \leq 1$
- $\sum_{i=1}^n h_{ii} = p$, lembrando que p é o número de parâmetros no modelo, incluindo o intercepto.
- Alavanca (*leverage*): h_{ii} mede a distância entre os valores de X da i -ésima observação e os valores médios de X para as n observações.

Lembre que $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$, portanto cada $\hat{Y}_i$ é uma combinação linear de todos os valores de Y e o peso de cada Y_i para o valor ajustado $\hat{Y}_i$ depende de h_{ii} , chamado de *leverage* ou alavanca:


$$\hat{Y}_i = h_{ii}Y_i + \sum_{j \neq i} h_{ij}Y_j,$$

de forma que quanto maior h_{ii} , maior o peso de Y_i em $\hat{Y}_i$.

Exemplo

```
X1 <- c(14, 19, 12, 11)
X2 <- c(25, 32, 22, 15)
Y <- c(301, 327, 246, 187)
Xmatriz <- matrix(cbind(rep(1, length(X1)), X1, X2), ncol=3)
H <- Xmatriz %*% solve(crossprod(Xmatriz)) %*% t(Xmatriz)
hii <- diag(H)
```

X1	X2	hii
14	25	0.388
19	32	0.951
12	22	0.661
11	15	1.000



Matriz chapéu e Ponto de Alavanca

$$\hat{Y}_i = h_{ii}Y_i + \sum_{j \neq i} h_{ij}Y_j$$

h_{ii} é uma função que depende apenas dos valores de X , portanto, mede o papel dos valores de X na determinação da importância de cada Y_i no valor ajustado $\hat{Y}_i$.

Quanto maior h_{ii} , menor a variância de e_i e, portanto, mais próximo $\hat{Y}_i$ tenderá a estar de Y_i .


Um valor h_{ii} é considerado alto se é duas vezes maior que o valor de alavanca médio, denotado por $\bar{h}$:

$$\bar{h} = \frac{\sum_{i=1}^n h_{ii}}{n} = \frac{p}{n}$$

Desta maneira, observações em que $h_{ii} > 2p/n$ são consideradas *outliers* com respeito aos valores de X .

Exemplo: Gordura corporal

No caso deste exemplo, $2p/n = 6/20 = 0.3$.



Vemos então que as observações 3 e 15 são consideradas *outliers* com respeito a X .

Após identificar casos *outliers* com respeito a Y e/ou X , o próximo passo é verificar se esses casos são *influentes*.

Uma observação é considerada influente se sua exclusão causa grandes mudanças no modelo de regressão ajustado.

Para identificar observações influentes vamos falar de algumas métricas, descritas a seguir:

- **DFFITS**: influência em um único valor ajustado
- **Cook's Distance**: influência em todos os valores ajustados
- **DFBETAS** - influência nos coeficientes da regressão

DFFITS - Influência em um único valor ajustado

A influência que a i -ésima observação tem no valor ajustado $\hat{Y}_i$ é medida por:

$$DFFITS_i = \frac{\hat{Y}_i - \hat{Y}_{i(i)}}{\sqrt{QME_{(i)}h_{ii}}}$$

O denominador é o desvio padrão estimado de $\hat{Y}_i$.

$$Var(\hat{\mathbf{Y}}) = \mathbf{H}Var(\mathbf{Y})\mathbf{H}' = \mathbf{H}(\sigma^2\mathbf{I})\mathbf{H}' = \sigma^2\mathbf{H}\mathbf{H}'$$

Como $\mathbf{H} = \mathbf{H}'$ (simétrica) e $\mathbf{H}\mathbf{H} = \mathbf{H}$ (idempotente), temos que:

$$Var(\hat{\mathbf{Y}}) = \sigma^2\mathbf{H}$$

DFFITS - Influência em um único valor ajustado

Assim como no caso dos resíduos deletados studentizados, podemos calcular $DFFITs_i$ da seguinte forma:

$$DFFITs_i = e_i \left[\frac{n - p - 1}{SSE(1 - h_{ii} - e_i^2)} \right]^{1/2} \left(\frac{h_{ii}}{1 - h_{ii}} \right)^{1/2} = t_i \left(\frac{h_{ii}}{1 - h_{ii}} \right)^{1/2}$$

Se uma observação é um *outlier* em X e tem alto valor de alavanca, $DFFITs$ tenderá a ter um alto valor.

Regra geral:

- Para pequenos conjuntos de dados, se $|DFFITs_i| > 1$, a observação é considerada influente.
- Para grandes conjuntos de dados, se $|DFFITs_i| > 2\sqrt{p/n}$, a observação é considerada influente.

Exemplo: Gordura corporal

No R, podemos calcular os DFFITS com a função `dffits()`:

```
dffits(modelo1)
```

id	e	h	t	DFFIT	id	e	h	t	DFFIT	
1	-1.848	0.178	-0.808	-0.377	11	11	0.433	0.121	0.180	0.067
2	3.461	0.054	1.473	0.351	12	12	2.200	0.109	0.930	0.326
3	-2.846	0.399	-1.527	-1.244	13	13	-3.879	0.170	-1.818	-0.824
4	-3.091	0.112	-1.345	-0.477	14	14	3.636	0.156	1.666	0.716
5	0.329	0.273	0.150	0.092	15	15	0.590	0.327	0.280	0.195
6	-0.481	0.131	-0.201	-0.078	16	16	0.578	0.093	0.236	0.075
7	0.798	0.148	0.337	0.141	17	17	-0.820	0.099	-0.337	-0.112
8	3.894	0.086	1.724	0.531	18	18	-0.996	0.208	-0.437	-0.224
9	2.405	0.128	1.034	0.396	19	19	-3.013	0.065	-1.270	-0.334
10	-2.307	0.092	-0.968	-0.308	20	20	0.958	0.050	0.384	0.088

Cook's Distance - Influência em todos os valores ajustados

Medida para avaliar a influência de uma observação i no ajuste das n observações:

$$D_i = \frac{\sum_{j=1}^n (\hat{Y}_j - \hat{Y}_{j(i)})^2}{p \text{ QME}}$$

Em forma matricial:

$$D_i = \frac{(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)})'(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_{(i)})}{p \text{ QME}}$$

Como fizemos anteriormente, também podemos calcular D_i usando a regressão ajustada para todas as observações:

$$D_i = \frac{e_i^2}{p \text{ QME}} \left[\frac{h_{ii}}{(1 - h_{ii})^2} \right]$$

Comparamos D_i com percentis de $F_{p,n-p}$: se for maior que o percentil 50, a i -ésima observação deve ser investigada como possível ponto influente.

Exemplo: Gordura corporal

No R, podemos calcular a distância de Cook com a função `cooks.distance()`:

```
cooks.distance(modelo1)
```

id	e	h	DFFIT	CookD	id	e	h	DFFIT	CookD
1	-1.848	0.178	-0.377	0.048	11	11	0.433	0.121	0.067
2	3.461	0.054	0.351	0.039	12	12	2.200	0.109	0.326
3	-2.846	0.399	-1.244	0.478	13	13	-3.879	0.170	-0.824
4	-3.091	0.112	-0.477	0.073	14	14	3.636	0.156	0.716
5	0.329	0.273	0.092	0.003	15	15	0.590	0.327	0.195
6	-0.481	0.131	-0.078	0.002	16	16	0.578	0.093	0.075
7	0.798	0.148	0.141	0.007	17	17	-0.820	0.099	-0.112
8	3.894	0.086	0.531	0.084	18	18	-0.996	0.208	-0.224
9	2.405	0.128	0.396	0.052	19	19	-3.013	0.065	-0.334
10	-2.307	0.092	-0.308	0.032	20	20	0.958	0.050	0.088

Caso 3 tem o maior valor: $D_3 = 0.478$. Este valor corresponde ao percentil 29.8 da $F_{3,17}$, ou seja, menor que o percentil 50 ($F_{3,17,0.5} = 0.82$).

DFBETAS - influência nos coeficientes da regressão

Medida de influência da i -ésima observação no coeficiente $\hat{\beta}_k$:

$$DFBETAS_{k(i)} = \frac{\hat{\beta}_k - \hat{\beta}_{k(i)}}{\sqrt{QME_{(i)} c_{kk}}}$$

em que $QME_{(i)}$ é o QME do modelo sem a i -ésima observação e c_{kk} é o k -ésimo elemento da diagonal de $(\mathbf{X}'\mathbf{X})^{-1}$.

Regra geral:

- Para pequenos conjuntos de dados, se $|DFBETAS_{k(i)}| > 1$, a observação é considerada influente.
- Para grandes conjuntos de dados, se $|DFBETAS_{k(i)}| > 2/\sqrt{n}$, a observação é considerada influente.

Exemplo: Gordura corporal

No R, podemos calcular DFBETAS com a função `dfbetas()`:

```
dfbetas(modelo1)
```

id	X.Intercept.	X1	X3	id	X.Intercept.	X1	X3	
1	-0.014	0.309	-0.215	11	11	-0.032	0.042	0.006
2	0.006	-0.076	0.084	12	12	-0.067	0.236	-0.071
3	1.056	0.053	-1.057	13	13	-0.701	0.379	0.342
4	0.300	-0.169	-0.201	14	14	0.073	-0.580	0.365
5	-0.013	-0.075	0.066	15	15	0.167	-0.118	-0.067
6	-0.050	-0.031	0.061	16	16	-0.038	0.033	0.019
7	-0.015	0.115	-0.053	17	17	-0.036	-0.066	0.068
8	-0.292	0.066	0.270	18	18	-0.065	-0.172	0.162
9	0.333	-0.024	-0.263	19	19	-0.113	0.154	-0.032
10	-0.179	-0.103	0.207	20	20	0.014	-0.001	-0.002

Veja que a observação 3 tem influência na estimação do coeficiente β_3 .

Exemplo: Gordura corporal

De modo geral, podemos calcular as medidas de influência usando a função abaixo:

```
influence.measures(modelo1)
```

id	dfb.1_	dfb.X1	dfb.X3	dffit	cov.r	cook.d	hat
1	-0.014	0.309	-0.215	-0.377	1.295	0.048	0.178
2	0.006	-0.076	0.084	0.351	0.865	0.039	0.054
3	1.056	0.053	-1.057	-1.244	1.327	0.478	0.399
4	0.300	-0.169	-0.201	-0.477	0.979	0.073	0.112
5	-0.013	-0.075	0.066	0.092	1.643	0.003	0.273
6	-0.050	-0.031	0.061	-0.078	1.370	0.002	0.131
7	-0.015	0.115	-0.053	0.141	1.379	0.007	0.148
8	-0.292	0.066	0.270	0.531	0.787	0.084	0.086
9	0.333	-0.024	-0.263	0.396	1.133	0.052	0.128
10	-0.179	-0.103	0.207	-0.308	1.113	0.032	0.092

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 10.2 a 10.4.
- YouTube ME613 - Análise de Regressão - Aulas 24 e 25

Agradecimentos

Parte deste material e vídeos foram criados pela profa. Samara F. Kiihl e pelos profs. Benilton Carvalho e Rafael Maia - IMECC/UNICAMP

