

ME613 - Análise de Regressão

Parte 17

Tatiana Benaglia - 2S2025

Testes de Hipóteses do Tipo $C\beta = 0$

Dado o que vimos até agora sobre testes de hipóteses para os coeficientes, em geral, a grande maioria das hipóteses de interesse podem ser descritas como:

$$H_0 : C\beta = 0 \quad \text{vs} \quad H_1 : C\beta \neq 0,$$

em que C é uma matriz $q \times p$, $q \leq p$.

Exemplo da gordura corporal: suponha que queremos testar se $\beta_2 = \beta_3$.

Como podemos testar hipóteses deste tipo?

Testes de Hipóteses do Tipo $C\beta = 0$

Seja $\theta = C\beta$. Então, $\hat{\theta} = C\hat{\beta}$ é um estimador de θ e sabemos que:

$$\hat{\theta} = C\hat{\beta} \sim N_q(C\beta, \sigma^2 C(\mathbf{X}'\mathbf{X})^{-1}C').$$

Além disso, como $\hat{\beta} \perp \hat{\sigma}^2$ então $C\hat{\beta} \perp \hat{\sigma}^2$, sendo

$$\hat{\sigma}^2 = \frac{SQE}{n-p} = QME \quad \text{e} \quad (n-p) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p}^2$$

Portanto, sob $H_0 : C\beta = 0$, e usando alguns resultados sobre as distribuições de formas quadráticas, temos que

$$Q = \frac{1}{\sigma^2} (C\hat{\beta})' (C(\mathbf{X}'\mathbf{X})^{-1}C')^{-1} C\hat{\beta} \sim \chi_q^2$$

Testes de Hipóteses do Tipo $C\beta = 0$

Portanto, para testar:

$$H_0 : C\beta = 0 \quad \text{vs} \quad H_1 : C\beta \neq 0,$$

podemos utilizar a seguinte **estatística do teste**:

$$F = \frac{Q/q}{QME/\sigma^2} = \frac{1}{qQME} (C\hat{\beta})' (C(X'X)^{-1}C')^{-1} C\hat{\beta} \stackrel{H_0}{\sim} F_{q,n-p}$$

p-valor: $P(F_{q,n-p} \geq F_{obs})$.

Conclusão: Rejeita-se H_0 se $F_{obs} > F_{1-\alpha,q,n-p}$.

Exemplo: Gordura Corporal

No exemplo da gordura corporal, temos a seguinte tabela dos coeficientes estimados e respectivos testes t:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	117.085	99.782	1.173	0.2578
X1	4.334	3.015	1.437	0.1699
X2	-2.857	2.582	-1.106	0.2849
X3	-2.186	1.595	-1.370	0.1896

Tabela ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	352.27	352.27	57.277	0.0000
X2	1	33.17	33.17	5.393	0.0337
X3	1	11.55	11.55	1.877	0.1896
Residuals	16	98.40	6.15		

Exemplo: Gordura Corporal

Suponha que queremos testar as seguintes hipóteses:

$$H_0 : \beta_2 = \beta_3 \quad \text{vs} \quad H_1 : \beta_2 \neq \beta_3$$

Podemos reescrever a hipótese nula como:

$$H_0 : \beta_2 = \beta_3 \quad \Leftrightarrow \quad H_0 : \beta_2 - \beta_3 = 0 \quad \Leftrightarrow \quad H_0 : \mathbf{C}\beta = \mathbf{0},$$

em que

$$\mathbf{C}_{1 \times 4} = [0 \quad 0 \quad 1 \quad -1] \quad \text{e} \quad \beta_{4 \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

Exemplo: Gordura Corporal

No R, podemos utilizar a função `linearHypothesis()` do pacote `car`.

```
library(car)
linearHypothesis(modelo123, c("X2 - X3 = 0"))
```

Linear hypothesis test:

$X_2 - X_3 = 0$

Model 1: restricted model

Model 2: $Y \sim X_1 + X_2 + X_3$

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	17	101.1				
2	16	98.4	1	2.7	0.44	0.52

Exemplo: Gordura Corporal

Também podemos usar a função `anova()` com o modelo completo e o modelo sob H_0 .

```
modelo123 <- lm(Y ~ X1 + X2 + X3, data = dados) # Modelo Completo
modelo.restrito <- lm(Y ~ X1 + I(X2 + X3), data = dados) # Modelo sob H0

anova(modelo.restrito, modelo123)
```

Analysis of Variance Table

Model 1: $Y \sim X1 + I(X2 + X3)$

Model 2: $Y \sim X1 + X2 + X3$

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	17	101.1				
2	16	98.4	1	2.7	0.44	0.52

Pergunta: Qual a conclusão para esse teste de hipóteses?

Modelo de regressão linear múltipla

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_{p-1} X_{i,p-1} + \varepsilon_i, \quad i = 1, \dots, n$$

Notação matricial

$$\mathbf{Y}_{n \times 1} = \mathbf{X}_{n \times p} \boldsymbol{\beta}_{p \times 1} + \boldsymbol{\varepsilon}_{n \times 1}$$

$$\mathbf{Y}_{n \times 1} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \quad \mathbf{X}_{n \times p} = \begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1,p-1} \\ 1 & X_{21} & X_{22} & \dots & X_{2,p-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{n,p-1} \end{bmatrix} \quad \boldsymbol{\beta}_{p \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} \quad \boldsymbol{\varepsilon}_{n \times 1} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Estimador de Mínimos Quadrados

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Relembrando...

Supondo que

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n$$

equivalente a escrever

$$\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$$

E daí temos que

$$\hat{\beta}_{p \times 1} \sim N_p(\beta, (\mathbf{X}'\mathbf{X})^{-1}\sigma^2)$$

Já vimos que um intervalo de $100(1 - \alpha)$ de confiança para um β_k específico é dado por:

$$IC(\beta_k, 1 - \alpha) = \left[\hat{\beta}_k - t_{n-p, \alpha/2} \sqrt{\widehat{Var}(\hat{\beta}_k)}; \hat{\beta}_k + t_{n-p, \alpha/2} \sqrt{\widehat{Var}(\hat{\beta}_k)} \right]$$

Exemplo: Diversidade de Espécies

Estudo sobre diversidade das espécies em Galápagos.

O conjunto de dados possui 30 ilhas e 7 variáveis:

Species: the number of plant species found on the island

Endemics: the number of endemic species

Area: the area of the island (km²)

Elevation: the highest elevation of the island (m)

Nearest: the distance from the nearest island (km)

Scruz: the distance from Santa Cruz island (km)

Adjacent: the area of the adjacent island (square km)

```
library(faraway)
```

```
data(gala)
```

	Species	Endemics	Area	Elevation	Nearest	Scruz	Adjacent
Baltra	58	23	25.09	346	0.6	0.6	1.84
Bartolome	31	21	1.24	109	0.6	26.3	572.33
Caldwell	3	3	0.21	114	2.8	58.7	0.78

Exemplo: Diversidade de Espécies

Ajuste do modelo e tabela dos coeficientes estimados:

```
model <- lm(Species ~ Area + Elevation + Nearest + Scrutz + Adjacent,  
            data = gala)  
summary(model)$coeff %>% kable()
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.0682	19.1542	0.3690	0.7154
Area	-0.0239	0.0224	-1.0676	0.2963
Elevation	0.3195	0.0537	5.9532	0.0000
Nearest	0.0091	1.0541	0.0087	0.9932
Scrutz	-0.2405	0.2154	-1.1166	0.2752
Adjacent	-0.0748	0.0177	-4.2262	0.0003

Residual standard error: 60.98 on 24 degrees of freedom

Multiple R-squared: 0.7658, Adjusted R-squared: 0.7171

F-statistic: 15.7 on 5 and 24 DF, p-value: 6.838e-07

Exemplo

Suponha que queremos um IC de 95% para $\beta_{Adjacent}$:

```
confint(model)
```

	2.5 %	97.5 %
(Intercept)	-32.4641	46.6005
Area	-0.0702	0.0223
Elevation	0.2087	0.4302
Nearest	-2.1665	2.1848
Scruz	-0.6851	0.2040
Adjacent	-0.1113	-0.0383

Qual a interpretação desse intervalo de confiança?

E qual a relação desses intervalos com os teste t da tabela anterior?

Intervalos de Confiança Simultâneos de Bonferroni

Já vimos anteriormente que podemos fazer intervalos de confiança simultâneos para $\beta_1, \dots, \beta_{p-1}$ empregando a correção de Bonferroni, que utiliza os intervalos marginais, isto é, baseados na quantidade pivotal

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{QME(\mathbf{X}'\mathbf{X})_{jj}^{-1}}} \sim t_{n-p},$$

mas corrigindo seu nível de confiança marginal $(1 - \alpha)100\%$ para $(1 - \alpha/p)100\%$

```
confint(model, level = 1 - .05/6)
```

	0.417 %	99.583 %
(Intercept)	-48.002	62.138
Area	-0.088	0.041
Elevation	0.165	0.474
Nearest	-3.022	3.040
Scruz	-0.860	0.379
Adjacent	-0.126	-0.024

Região de Confiança

Falamos de **intervalos marginais simultâneos de confiança**, mas agora iremos discutir sobre **regiões de confiança**.

Tomando $\theta = \mathbf{C}\beta$, ou seja, um conjunto de q contraste do vetor β . A equação

$$P\left((\hat{\theta} - \theta)' \mathbf{L}^{-1}(\hat{\theta} - \theta) \leq m\right) = 1 - \alpha,$$

resulta em uma elipsóide sólida centrada em $\hat{\theta}$ e é, portanto, uma **região de confiança** de $(1 - \alpha)100\%$ para θ .

Se nosso interesse está apenas no vetor β , podemos tomar $\mathbf{C} = \mathbf{I}_p$ e $\theta = \beta$, tal que

$$P\left((\hat{\beta} - \beta)' \mathbf{X}' \mathbf{X}(\hat{\beta} - \beta) \leq p \text{ QME } F_{p, n-p, 1-\alpha}\right) = 1 - \alpha$$

nos dá uma elipsóide de confiança de $(1 - \alpha)100\%$ para o vetor β .

Observação: Se q for pequeno (2 ou 3), podemos usar curvas de nível para visualizar e descrever essas regiões de confiança. Já no caso de q muito grande, a região de confiança será de difícil interpretação.

Relembrando:

$$\hat{\beta}_{p \times 1} \sim N_p(\beta, (\mathbf{X}'\mathbf{X})^{-1}\sigma^2) \quad \Rightarrow \quad \frac{1}{\sigma}(\mathbf{X}'\mathbf{X})^{1/2}(\beta - \hat{\beta}) \sim N_p(\mathbf{0}, \mathbf{I})$$

Se tomarmos a forma quadrática de $\beta - \hat{\beta}$, temos

$$\frac{1}{\sigma^2}(\beta - \hat{\beta})'(\mathbf{X}'\mathbf{X})(\beta - \hat{\beta}) \sim \chi_p^2$$

Também sabemos que

$$(n - p) \frac{QME}{\sigma^2} \sim \chi_{n-p}^2$$

Região de Confiança para β

Pela independência de β e QME , temos:

$$\frac{1}{pQME}(\beta - \hat{\beta})' \mathbf{X}' \mathbf{X} (\beta - \hat{\beta}) \sim F_{p, n-p}$$

Portanto, uma região (elipse) de confiança de $100 \times (1 - \alpha)\%$ é dada por:

$$\frac{1}{p QME}(\beta - \hat{\beta})' \mathbf{X}' \mathbf{X} (\beta - \hat{\beta}) \leq F_{p, n-p; 1-\alpha}$$


Essas elipses de confiança também são conhecidas como **Elipses de Confiança de Scheffé**.

Exemplo: Diversidade

Vamos encontrar uma elipse de confiança de 95% para os coeficientes $\beta_{Adjacent}$ e β_{Area} .


Para isso, podemos usar a função `confidenceEllipse()` do pacote `car`:

```
library(car)
confidenceEllipse(model, which.coef=c(2, 6), levels=0.95, Scheffe=TRUE)
```



Comparação entre IC's de Bonferroni e Elipses de Confiança

Intervalos de Confiança de 95%: marginal sem correção (linha sólida, vermelha), marginal com correção de Bonferroni (linha pontilhada, preto) e elipse de confiança Scheffé (azul):



- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition. Seção 6.6 e 7.3.
- YouTube ME613 - Análise de Regressão - Aulas 18 e 19

Agradecimentos

Parte deste material e vídeos foram criados pela profa. Samara F. Kiihl e pelos profs. Benilton Carvalho e Rafael Maia - IMECC/UNICAMP