

ME613 - Análise de Regressão

Parte 18

Tatiana Benaglia - 2S2025

Critérios para Seleção de Modelos

Se tivermos $p - 1$ variáveis preditoras, podemos construir 2^{p-1} modelos diferentes.

Mesmo se considerarmos todos esses modelos (computacionalmente intenso), precisaríamos de algum critério para selecionar entre eles.

Métodos para seleção de modelos/variáveis foram desenvolvidos para identificar um subgrupo de variáveis que são “boas” para o modelo, segundo algum critério.

Há vários critérios desenvolvidos na literatura. Neste curso, focaremos em seis:

- R_p^2 e $R_{adj,p}^2$
- C_p de Mallows
- AIC : Akaike's Information Criterion
- BIC : Bayesian Information Criterion
- $PRESS$: *Prediction Sum of Squares*

Para o critério R_p^2 , a ideia é utilizar o **coeficiente de determinação**, R^2 para identificar subgrupos das variáveis preditoras que, quando incluídas no modelo, produzem um alto valor para R^2 .

Lembrando que o **coeficiente de determinação** é dado por:

$$R_p^2 = 1 - \frac{SQE_p}{SQT},$$

sendo que R_p^2 indica que temos p parâmetros no modelo, isto é, $p - 1$ variáveis preditoras incluídas no modelo.

O objetivo deste critério não é maximização, já que R_p^2 sempre irá aumentar conforme mais variáveis preditoras são incluídas no modelo.

A ideia é comparar os diversos R_p^2 's e verificar se adicionar mais variáveis ainda traz um aumento significativo.

Exemplo: Cirurgias

Uma unidade cirúrgica está interessada na predição da sobrevida em pacientes submetidos a um determinado tipo de operação hepática.

Uma seleção aleatória de 108 pacientes está disponível para análise. No registro de cada paciente, as seguintes informações foram extraídas da avaliação pré-operatória:

Y : tempo de sobrevivência

X_1 : score de coagulação sanguínea

X_2 : índice de prognóstico

X_3 : teste de função enzimática

X_4 : teste de função do fígado

X_5 : idade (anos)

X_6 : gênero (0=masculino, 1=feminino)

X_7 e X_8 : indicadores uso de álcool (nenhum, moderado, severo)

Exemplo: Cirurgias

Vamos olhar as primeiras observações do conjunto de dados. Iremos trabalhar com metade dos dados apenas, ou seja, 54 pacientes. E como variável resposta, iremos considerar o log do tempo de sobrevivência, $\ln(Y)$.

X1	X2	X3	X4	X5	X6	X7	X8	Y	lnY
6.7	62	81	2.59	50	0	1	0	695	6.544
5.1	59	66	1.70	39	0	0	0	403	5.999
7.4	57	83	2.16	55	0	0	0	710	6.565
6.5	73	41	2.01	48	0	0	0	349	5.854
7.8	65	115	4.30	45	0	0	1	2343	7.759
5.8	38	72	1.42	65	1	1	0	348	5.852
5.7	46	63	1.91	49	1	0	1	518	6.250
3.7	68	81	2.57	69	1	1	0	749	6.619
6.0	67	93	2.50	58	0	1	0	1056	6.962
3.7	76	94	2.40	48	0	1	0	968	6.875


Exemplo

Considerando apenas os primeiros quatro preditores X_1 , X_2 , X_3 e X_4 , teríamos $2^4 = 16$ modelos possíveis.

Table 2: R_p^2 para vários modelos

Variáveis no Modelo	p	R_p^2	Variáveis no Modelo	p	R_p^2
Somente intercepto	1	0	$X_2 X_3$	3	0.663
X_1	2	0.061	$X_2 X_4$	3	0.483
X_2	2	0.221	$X_3 X_4$	3	0.599
X_3	2	0.428	$X_1 X_2 X_3$	4	0.757
X_4	2	0.422	$X_1 X_2 X_4$	4	0.487
$X_1 X_2$	3	0.263	$X_1 X_3 X_4$	4	0.612
$X_1 X_3$	3	0.549	$X_2 X_3 X_4$	4	0.718
$X_1 X_4$	3	0.43	$X_1 X_2 X_3 X_4$	5	0.759

Exemplo: R_p^2 versus o número de preditor



Como R^2_p não leva em conta o **número de parâmetros** no modelo e sempre aumenta conforme temos mais variáveis incluídas, uma alternativa é usar o **coeficiente de determinação ajustado**:

$$R^2_{adj,p} = 1 - \left(\frac{n-1}{n-p} \right) \frac{SQE_p}{SQT} = 1 - \frac{QME_p}{SQT/(n-1)}$$


$R^2_{adj,p}$ aumenta se e somente se QME_p diminui.

Neste caso, podemos considerar como melhor modelo aquele que maximiza o $R^2_{adj,p}$.

Table 3: $R_{adj,p}^2$ para vários modelos

Variáveis no Modelo	p	$R_{adj,p}^2$	Variáveis no Modelo	p	$R_{adj,p}^2$
Somente intercepto	1	0	$X_2 X_3$	3	0.65
X_1	2	0.043	$X_2 X_4$	3	0.463
X_2	2	0.206	$X_3 X_4$	3	0.584
X_3	2	0.417	$X_1 X_2 X_3$	4	0.743
X_4	2	0.41	$X_1 X_2 X_4$	4	0.456
$X_1 X_2$	3	0.234	$X_1 X_3 X_4$	4	0.589
$X_1 X_3$	3	0.531	$X_2 X_3 X_4$	4	0.701
$X_1 X_4$	3	0.408	$X_1 X_2 X_3 X_4$	5	0.74

Exemplo: $R^2_{adj, p}$ versus o número de preditor



Este critério avalia o **erro quadrático médio total** dos n valores ajustados segundo um modelo a ser considerado.

O erro total em cada valor ajustado é dado por:

$$\hat{Y}_i - \mu_i,$$

em que μ_i é o valor verdadeiro da resposta média.

Este erro total é composto por duas partes: o viés e o erro aleatório.

- **Viés:** $\mathbb{E}(\hat{Y}_i) - \mu_i$
- **Erro aleatório:** $\hat{Y}_i - \mathbb{E}(\hat{Y}_i)$

Podemos então escrever o erro quadrático total como:

$$(\hat{Y}_i - \mu_i)^2 = [(\mathbb{E}(\hat{Y}_i) - \mu_i) + (\hat{Y}_i - \mathbb{E}(\hat{Y}_i))]^2$$

Calculando a esperança da equação anterior, temos o **Erro Quadrático Médio (EQM)** para cada observação:

$$EQM_i = \mathbb{E}(\hat{Y}_i - \mu_i)^2 = [\mathbb{E}(\hat{Y}_i) - \mu_i]^2 + Var(\hat{Y}_i)$$

Somando o EQM para todas as observações, temos o **Erro Quadrático Médio** total:

$$EQM = \sum_{i=1}^n [\mathbb{E}(\hat{Y}_i) - \mu_i]^2 + \sum_{i=1}^n Var(\hat{Y}_i)$$

Medida para o critério:

$$\Gamma_p = \frac{1}{\sigma^2} \left[\sum_{i=1}^n [\mathbb{E}(\hat{Y}_i) - \mu_i]^2 + \sum_{i=1}^n Var(\hat{Y}_i) \right],$$

ou seja, o erro quadrático médio total dividido pela verdadeira variância do erro σ^2 .

Estamos considerando incluir $p - 1$ variáveis, mas assuma que o número ideal de variáveis a serem incluídas no modelo seja $P - 1 > p - 1$.

Se assumirmos que o modelo incluindo as $P - 1$ variáveis é correto, temos que $QME(X_1, \dots, X_{P-1})$ é um estimador não viesado para σ^2 .

Pode-se mostrar que um estimador para Γ_p é dado por:

$$C_p = \frac{SQE_p}{QME(X_1, \dots, X_{p-1})} - (n - 2p),$$

em que SQE_p é a soma de quadrados do erro para o modelo com p parâmetros, ou seja, $p - 1$ preditores.

Pode-se mostrar que um estimador para Γ_p é dado por:

$$C_p = \frac{SQE_p}{QME(X_1, \dots, X_{p-1})} - (n - 2p),$$

em que SQE_p é a soma de quadrados do erro para o modelo com p parâmetros, ou seja, $p - 1$ preditores.

Se o modelo com $p - 1$ variáveis é adequado, não existe viés, isto é, $\mathbb{E}(\hat{Y}_i) = \mu_i$, então $\mathbb{E}(SQE_p) = (n - p)\sigma^2$, de maneira que $\mathbb{E}\left[\frac{SQE_p}{QME(X_1, \dots, X_{p-1})}\right] = n - p$ e, portanto,

$$\mathbb{E}(C_p) \approx n - p - (n - 2p) = p.$$

Dessa forma, procuramos o menor C_p tal que $C_p \approx p$.

Exemplo

Modelo considerando as variáveis X_1 , X_2 , X_3 e X_4 ($P - 1 = 4$)

Incluindo apenas X_4 ($p = 2$): $C_p = \frac{SQE(X_4)}{QME(X_1, \dots, X_4)} - (n - 2p)$

ANOVA do modelo com X_4

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X4	1	5.399	5.3990	37.89	0
Residuals	52	7.409	0.1425		

Calculando o C_p :


$$C_p = \frac{7.4087}{0.0629} - (54 - 2 \times 2) \\ = 67.7148$$

ANOVA do modelo com X_1, X_2, X_3, X_4

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
X1	1	0.7763	0.7763	12.3337	0.0010
X2	1	2.5888	2.5888	41.1325	0.0000
X3	1	6.3341	6.3341	100.6408	0.0000
X4	1	0.0246	0.0246	0.3905	0.5349
Residuals	49	3.0840	0.0629		

Exemplo

```
library(leaps)
leaps <- regsubsets(lnY ~ X1 + X2 + X3 + X4, data=dados, nbest = 6)
plot(leaps, scale="Cp")
```



Esses dois critérios são bem utilizados na literatura, não somente para modelos de regressão.

- **AIC: Critério de Informação de Akaike** (*Akaike's Information Criterion*)
- **BIC: Critério de Informação de Bayesiano** (*Bayesian Information Criterion*)

Sendo estes definidos por:

$$AIC_p = -2 \log L(\hat{\beta}) + 2p = n \ln(SQE_p) - n \ln n + 2p$$

$$BIC_p = -2 \log L(\hat{\beta}) + \ln(n)p = n \ln(SQE_p) - n \ln n + \ln(n)p$$


Critério: buscar modelos com valores pequenos do *AIC* e *BIC*.

Veja que a diferença entre os dois critérios está apenas na penalização do número de parâmetros.

Para $n \geq 8$, a penalização no número de preditores é maior no *BIC* e, portanto, este critério é favorável a modelos mais parcimoniosos e mais simples do que o *AIC*.

Exemplo

```
plot(leaps, scale="bic")
```



$PRESS_p$ (*Prediction Sum of Squares*): critério para medir quão adequado é o uso dos valores ajustados obtidos a partir de um modelo com menos variáveis para prever os valores observados de Y .

A $SQE = \sum (Y_i - \hat{Y}_i)^2$ também serve para este propósito, mas a medida $PRESS$ é obtida após a exclusão da i -ésima observação e estimação do modelo com as $n - 1$ observações restantes, e então usar este modelo para prever o valor de Y para a i -ésima observação.

Seja $\hat{Y}_{i(i)}$ o valor predito para a i -ésima observação quando esta foi excluída na obtenção do modelo e $d_i = Y_i - \hat{Y}_{i(i)}$. Então,

$$PRESS_p = \sum_{i=1}^n d_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_{i(i)})^2,$$

sendo que d_i pode ser reescrito como $d_i = \frac{e_i}{1-h_{ii}}$ e, portanto, obtido a partir do modelo de regressão com todas as observações incluídas.

Modelos com $PRESS_p$ pequenos são considerados bons candidatos (com erro de predição pequeno).

Seleção de Modelos - Métodos Clássicos

Muitas vezes, algumas ou muitas das variáveis usadas em um modelo de regressão múltipla não estão de fato associadas à variável resposta.

A inclusão de tais variáveis irrelevantes leva a uma complexidade desnecessária ao modelo resultante.

Infelizmente, filtrar manualmente e comparar modelos de regressão pode ser tedioso. Felizmente, existem várias abordagens para executar automaticamente a seleção de variáveis.

Nesta aula iremos abordar os seguintes métodos clássicos:

- **Seleção Best Subsets:** Encontrar a melhor combinação entre todos os modelos possíveis
- **Seleção Stepwise:** abordagem computacionalmente mais eficiente que o **Best Subsets** para selecionar variáveis.

Na próxima aula, falaremos de métodos mais modernos, como os métodos de **penalização**.

Algoritmo Best Subests

Para o exemplo anterior, se considerarmos todas as variáveis, temos $2^8 = 256$ modelos possíveis.

Vamos usar a variável $\ln Y$ como resposta e os 8 preditores disponíveis. Além disso, utilizaremos o AIC_p como critério.

```
Xy <- dados %>% dplyr::select(-Y) %>% rename(y = "lnY")

library(bestglm)
modelos <- bestglm(Xy, IC="AIC")
modelos$Subsets
```

	X.Intercept.	X1	X2	X3	X4	X5	X6	X7	X8	logLikelihood	AIC
0	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	FALSE	38.85	-77.7
1	TRUE	FALSE	FALSE	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	53.91	-105.8
2	TRUE	FALSE	TRUE	TRUE	FALSE	FALSE	FALSE	FALSE	FALSE	68.24	-132.5
3	TRUE	FALSE	TRUE	TRUE	FALSE	FALSE	FALSE	FALSE	TRUE	79.49	-153.0
4	TRUE	TRUE	TRUE	TRUE	FALSE	FALSE	FALSE	FALSE	TRUE	86.68	-165.4
5	TRUE	TRUE	TRUE	TRUE	FALSE	FALSE	TRUE	FALSE	TRUE	87.90	-165.8
6*	TRUE	TRUE	TRUE	TRUE	FALSE	TRUE	TRUE	FALSE	TRUE	88.92	-165.8
7	TRUE	TRUE	TRUE	TRUE	FALSE	TRUE	TRUE	TRUE	TRUE	89.37	-164.7
8	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	89.39	-162.8

Exemplo - Melhor modelo usando AIC_p

Variáveis incluídas no modelo

	X1	X2	X3	X4	X5	X6	X7	X8
6*	TRUE	TRUE	TRUE	FALSE	TRUE	TRUE	FALSE	TRUE

Tabela do coeficientes estimados para o melhor modelo.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.0540	0.2348	17.266	0.0000
X1	0.0715	0.0186	3.837	0.0004
X2	0.0138	0.0017	8.047	0.0000
X3	0.0151	0.0014	10.912	0.0000
X5	-0.0035	0.0026	-1.341	0.1862
X6	0.0873	0.0577	1.513	0.1369
X8	0.3509	0.0764	4.593	0.0000

Exemplo - $R^2_{adj,p}$, BIC_p e C_p


A escolha do melhor modelo depende do critério utilizado.

```
best_subset <- regsubsets(y ~ ., data=Xy, nbest=2, nvmax = 8)
```

	p	X.Intercept.	X1	X2	X3	X4	X5	X6	X7	X8	R2adj	BIC	Cp
X1	2	1	0	0	1	0	0	0	0	0	0.42	-22.15	117.41
X1.1	2	1	0	0	0	1	0	0	0	0	0.41	-21.58	119.17
X2	3	1	0	1	1	0	0	0	0	0	0.65	-46.81	50.47
X2.1	3	1	0	0	1	1	0	0	0	0	0.58	-37.44	69.13
X3	4	1	0	1	1	0	0	0	0	1	0.76	-65.33	18.91
X3.1	4	1	1	1	1	0	0	0	0	0	0.74	-60.50	24.98
X4	5	1	1	1	1	0	0	0	0	1	0.82	-75.70	5.75
X4.1	5	1	0	1	1	1	0	0	0	1	0.80	-71.01	10.27
X5	6	1	1	1	1	0	0	1	0	1	0.82	-74.17	5.54
X5.1	6	1	1	1	1	0	1	0	0	1	0.82	-73.63	6.02
X6	7	1	1	1	1	0	1	1	0	1	0.82	-72.21	5.79
X6.1	7	1	1	1	1	0	0	1	1	1	0.82	-70.76	7.03
X7	8	1	1	1	1	0	1	1	1	1	0.82	-69.12	7.03
X7.1	8	1	1	1	1	1	1	1	0	1	0.82	-68.28	7.74
X8	9	1	1	1	1	1	1	1	1	1	0.82	-65.17	9.00

Exemplo - $R^2_{adj,p}$, BIC_p e C_p

A escolha do melhor modelo depende do critério utilizado.



Método *Stepwise*

Vimos que o **Best Subsets** examina todas as combinações possíveis de preditores e escolhe o melhor modelo de acordo com algum critério (AIC , BIC , C_p , R_{adj}^2 , etc.).

Ele é conceitualmente perfeito: uma busca exaustiva no universo de modelos.

Mas há um problema: à medida que o número de variáveis cresce, o número de modelos possíveis cresce exponencialmente (2^p).

- Quando $p = 20$, já são 1.048.576 modelos.
- Quando $p = 30$, passam de 1 bilhão de modelos.

Ou seja, *Best Subsets* é ideal em teoria, mas inviável quando p é moderado ou grande.

Aqui entra nossa estrela histórica: o **Método Stepwise**.

Método *Stepwise*

O **Stepwise** é um algoritmo que não explora todo o espaço de modelos, mas faz um caminho rápido e heurístico, **acrescentando ou removendo variáveis de forma sequencial**.

Ele tenta montar o modelo como quem constrói uma torre de blocos: empilha, testa, recua, avança — mas nunca enxerga o mapa inteiro.

Existem duas versões principais do método Stepwise:

- **Forward:** Começa com nenhum preditor e vai adicionando variáveis (uma a uma) que mais melhoram o modelo.
- **Backward:** Começa com todos os preditores e vai removendo aqueles que menos contribuem com o modelo.

Ambos seguem a mesma lógica: avaliar apenas vizinhos do modelo atual, não todo o espaço como o Best Subsets.

Seleção Stepwise *Forward*


A seleção *forward* começa com um modelo que não contém preditores e, em seguida, vai adicionando preditores ao modelo, um por vez, até que todos os preditores estejam no modelo. A cada passo é adicionada ao modelo a variável que dá a maior melhoria ao ajuste.

O algoritmo de seleção *forward* pode ser descrito em três passos:

- ❶ Seja M_0 o modelo nulo, que contém apenas o intercepto, ou seja, não tem preditores.
- ❷ Para $k = 1, \dots, p - 1$
 - Considere todos os $p - k$ modelos que aumentam os preditores em M_{k-1} com um preditor adicional.
 - Escolha o melhor entre esses $p - k$ modelos e chame-o de M_k . Aqui o melhor é definido como tendo a menor SQE ou maior R^2 .
 - Alternativamente, vá adicionando as variáveis cuja estatística t é a mais significativa, ou seja, maior p-valor.
- ❸ Selecione um único melhor modelo entre $M_0, \dots, M_{p-1}$ segundo algum dos critérios $R_{adj,p}^2$, AIC_p , BIC_p , C_p ou $PRESS_p$.

Seleção Stepwise Forward

Forward stepwise selection example with 5 variables:



Fonte da figura: <https://quantifyinghealth.com/stepwise-selection/>

Exemplo: Seleção *Forward*

No R, podemos executar a seleção *forward* usando a função `regsubsets()` com o argumento `method = "forward"`.

```
forward <- regsubsets(y ~ ., Xy, nvmax = 8, method = "forward")
```


p	X.Intercept.	X1	X2	X3	X4	X5	X6	X7	X8	R2adj	SQE	BIC	Cp
2	1	0	0	1	0	0	0	0	0	0.417	7.332	-22.15	117.409
3	1	0	1	1	0	0	0	0	0	0.650	4.312	-46.81	50.472
4	1	0	1	1	0	0	0	0	1	0.765	2.843	-65.33	18.914
5	1	1	1	1	0	0	0	0	1	0.816	2.179	-75.70	5.751
6	1	1	1	1	0	0	1	0	1	0.821	2.082	-74.17	5.541
7	1	1	1	1	0	1	1	0	1	0.823	2.005	-72.21	5.787
8	1	1	1	1	0	1	1	1	1	0.823	1.972	-69.12	7.029
9	1	1	1	1	1	1	1	1	1	0.819	1.971	-65.17	9.000

Por exemplo, qual modelo minimiza o *BIC*?

```
which.min(summary(forward)$bic)
```

```
[1] 4
```

Exemplo: Seleção *Forward*



Seleção Stepwise *Backward*


A seleção *backward* fornece uma alternativa eficiente para a seleção do melhor subconjunto de preditores. No entanto, ao contrário da seleção *forward*, ela inicia com o modelo completo contendo todos os $p - 1$ preditores e, em seguida, remove iterativamente o preditor menos significativo, um de cada vez.

O algoritmo de seleção *backward* pode ser descrito em três passos:

- ❶ Seja M_{p-1} o modelo completo, que contém todos os $p - 1$ preditores.
- ❷ Para $k = p - 1, \dots, 1$:
 - Considere todos os k modelos que contém todos os preditores em M_k menos um, tendo um total de $k - 1$ preditores.
 - Escolha o melhor entre esses k modelos e chame-o de M_{k-1} . Aqui o melhor é definido como tendo a menor SQR ou maior R^2 .
 - Alternativamente, vá retirando as variáveis cuja estatística t é a menos significativa, ou seja, menor $p - \text{valor}$.
- ❸ Selecione um único melhor modelo entre $M_0, \dots, M_{p-1}$ segundo algum dos critérios $R^2_{adj,p}$, AIC_p , BIC_p , C_p ou $PRESS_p$.

Seleção Stepwise *Backward*

Backward stepwise selection example with 5 variables:



Fonte da figura: <https://quantifyinghealth.com/stepwise-selection/>

Exemplo: Seleção *Backward*

No R, podemos executar a seleção *backward* usando a função `regsubsets()` com o argumento `method = "backward"`.

```
backward <- regsubsets(y ~ ., Xy, nvmax = 8, method = "backward")
```


p	X.Intercept.	X1	X2	X3	X4	X5	X6	X7	X8	R2adj	SQE	BIC	Cp
2	1	0	0	1	0	0	0	0	0	0.417	7.332	-22.15	117.409
3	1	0	1	1	0	0	0	0	0	0.650	4.312	-46.81	50.472
4	1	0	1	1	0	0	0	0	1	0.765	2.843	-65.33	18.914
5	1	1	1	1	0	0	0	0	1	0.816	2.179	-75.70	5.751
6	1	1	1	1	0	0	1	0	1	0.821	2.082	-74.17	5.541
7	1	1	1	1	0	1	1	0	1	0.823	2.005	-72.21	5.787
8	1	1	1	1	0	1	1	1	1	0.823	1.972	-69.12	7.029
9	1	1	1	1	1	1	1	1	1	0.819	1.971	-65.17	9.000

Por exemplo, qual modelo minimiza o *BIC*?

```
which.min(summary(backward)$bic)
```

```
[1] 4
```

Exemplo: Seleção *Backward*



Comparação entre Best Subsets e Stepwise

Comparação de Métodos Clássicos de Seleção de Modelos

Característica	Best Subset	Stepwise
 Busca	Exaustiva	Local (Sequencial)
 Garantia de Modelo Ótimo	Sim	Não
 Custo Computacional	Alto	Baixo
 Qualidade da Solução	Ótima	Boa

Por que o Stepwise se tornou tão popular?

Mesmo com limitações (que falaremos melhor na próxima aula), ele foi amplamente usado por décadas porque:

- É rápido;
- É fácil de implementar;
- Softwares Estatísticos como SAS, SPSS e R o incluíram como default;
- Funciona razoavelmente quando p é baixo e há pouca colinearidade;
- Gera modelos interpretáveis (1 modelo final, limpo).


Stepwise é um método clássico que cumpre seu papel num cenário antigo, quando:

- p é pequeno,
- datasets são limpos,
- interpretabilidade é absoluta.

Mas ele caiu em **desuso** e não deve ser tratado como método “ótimo” ou “automatizável”. É um artefato histórico importante, mas superado para busca automática de modelos.

Leitura e Agradecimentos

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition, McGraw-Hill, Irwin, New York. Capítulo 9.
- Draper, N. R. and Smith, H. - Applied Regression Analysis: Capítulo 15.
- Linear Model Selection - UC Business Analytics R Programming Guide:
https://uc-r.github.io/model_selection



Agradecimentos: parte de material foi criado pela profa. Samara Kiihl - IMECC/Unicamp.