

ME613 - Análise de Regressão

Parte 19

Tatiana Benaglia - 2S2025

```
dados <- read.table("./dados/CH09TA01.txt",  
                    col.names = c(paste0("X", 1:8), "Y", "lnY"))
```

Critérios Modernos para Seleção de Variáveis

Na aula anterior falamos dos métodos: **Best Subsets** e **Stepwise**. Esses métodos representam as primeiras tentativas de automatizar a seleção de variáveis.

Limitações:

- **Best Subsets**: avalia todos os subconjuntos de modelos para escolher “o melhor” conforme algum critério. Embora mais exaustivo, ele pode levar a modelos que “parecem bons no conjunto de dados” mas não generalizam bem.
- **Stepwise** (forward/backward ou ambos): têm sido muito usados, mas sofrem de vários problemas (por exemplo instabilidade de seleção, viés de estimação, excesso de confiança nos p-valores, “capitalização” do conjunto de dados).

Ambos os métodos foram concebidos num cenário onde o número de variáveis não era muito grande e onde se buscava tanto interpretação quanto ajuste. Porém, no mundo atual (grandes p , multicolinearidade, enfoque em predição, validação out-of-sample) surgem novos desafios.

Hoje vamos falar como métodos modernos superam essas limitações, especialmente em cenários com muitos preditores ou colinearidade.

Métodos clássicos de seleção de variáveis são úteis, mas podem:

- Ser instáveis à pequena variação dos dados;
- Sofrer com multicolinearidade;
- Superestimar a evidência para variáveis incluídas (inferência pós-seleção);
- Tornar-se custosos quando p cresce.

Surgem então os métodos mais modernos, dentre eles estão os métodos de regularização.

Métodos de Regularização/Penalização:

- Propõe controlar a complexidade do modelo diretamente no processo de estimação.
- Evitar que ele se ajuste demais aos dados (o chamado *overfitting*).

Regularização

A ideia da regularização é ainda **minimizar o erro** de ajuste, adicionando uma **penalização** na complexidade, ou seja, queremos minimizar:

$$\min_{\beta_0, \beta} \left\{ \sum_{i=1}^n (y_i - \beta_0 - x'_i \beta)^2 + \lambda P(\beta) \right\}, \quad \lambda \geq 0.$$

- Primeiro termo: soma de quadrado dos erros, como no modelo tradicional (MQO).
- Segundo termo: penalização coeficientes grandes.
- O coeficiente $\lambda \geq 0$ é um parâmetro de controle: quando maior λ , maior é a penalização, diminuindo a complexidade.

Intuição: A regularização atua como um “freio” no processo de estimação:

- Impede que os coeficientes cresçam demais (comuns em presença de multicolinearidade);
- Reduz a variância dos estimadores, mesmo à custa de introduzir um pequeno viés;
- Favorece modelos mais parcimoniosos e estáveis.

Métodos de Regularização: LASSO e Ridge

Regularização: reduz a variância dos estimadores (aceitando pequeno viés), criando modelos mais estáveis e parsimoniosos.

Dois dos principais métodos são:

Método	Penalização $P(\beta)$	Efeito Típico
LASSO	$\sum_{j=1}^{p-1} \beta_j $	Encolhe coeficientes; zerando alguns
Ridge	$\sum_{j=1}^{p-1} \beta_j^2$	Encolhe coeficientes; não zera exatamente


- LASSO faz estimação e, ao zerar alguns coeficientes, faz seleção automática de variáveis.
- Ridge é ótimo para **multicolinearidade**, pois suaviza os coeficientes.

O método **LASSO** (*Least Absolute Shrinkage and Selection Operator*) foi proposto originalmente por Robert Tibshirani em 1996, no artigo:

- Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. JRSS B, 58(1), 267–288.

Esse trabalho é a principal referência quando se fala em LASSO, pois:

- Introduziu formalmente a penalização L_1 no contexto da regressão linear;
- Mostrou que ela realiza encolhimento (*shrinkage*) e seleção de variáveis simultaneamente;
- forneceu uma base teórica e computacional para estimação penalizada, que inspirou extensões como o *Elastic Net* e o *Adaptive LASSO*.



Em vez de estimar os parâmetros $\beta_0, \beta_1, \dots, \beta_{p-1}$ apenas minimizando a soma dos quadrados dos erros — como na regressão linear clássica — o método de regularização LASSO adiciona uma penalização sobre o tamanho dos coeficientes, ou seja,

$$\min_{\beta_0, \beta} \left\{ \sum_{i=1}^n (y_i - \beta_0 - x'_i \beta)^2 + \lambda \sum_{j=1}^{p-1} |\beta_j| \right\}, \quad \lambda \geq 0.$$

Como escolher λ ?

- Critérios de informação adaptados (AIC/BIC penalizados);
- Validação cruzada K-fold (conceito) para equilibrar ajuste e parcimônia.

Exemplo: Cirurgias

Voltando no exemplo das cirurgias. Ajustamos o modelo de Regressão Linear Múltipla.

```
fit_rlm <- lm(lnY ~ X1 + X2 + X3 + X4 + X5 + X6 + X7 + X8, data = dados)
summary(fit_rlm)$coef %>% kable()
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.0505	0.2518	16.0891	0.0000
X1	0.0685	0.0254	2.6950	0.0099
X2	0.0135	0.0019	6.9089	0.0000
X3	0.0150	0.0018	8.2640	0.0000
X4	0.0080	0.0467	0.1716	0.8645
X5	-0.0036	0.0028	-1.2959	0.2016
X6	0.0842	0.0607	1.3861	0.1725
X7	0.0579	0.0675	0.8575	0.3957
X8	0.3884	0.0884	4.3945	0.0001

Variáveis selecionadas por Stepwise: X_1 , X_2 , X_3 e X_8 .

Exemplo: Cirugias


O método LASSO pode ser ajustando usando a função `glmnet()` do pacote `glmnet`:

```
library(glmnet)
X <- dados %>% select(X1:X8) %>% as.matrix()
y <- dados$lnY

# Ajuste LASSO (alpha = 1)
fit_lasso <- glmnet(X, y, alpha = 1, standardize = TRUE)
```

Exemplo: Cirurgias

```
# Caminhos dos coeficientes vs log(lambda)
plot(fit_lasso, xvar = "lambda", las = 1, lwd = 2)
```




Exemplo: Cirurgias

Escolha do valor de λ :

```
set.seed(123)
cvfit <- cv.glmnet(X, y, alpha = 1, nfolds = 10)
plot(cvfit, las = 1) # Erro médio vs log(lambda)
```

0 3 4 4 5 6 7 8 8 8 8 8 8



Exemplo: Cirurgias

Coeficientes estimados:

```
# Modelo mais parcimonioso (regra 1-SE)
coef(cvfit, s = "lambda.1se")
```

9 x 1 sparse Matrix of class "dgCMatrix"

lambda.1se

(Intercept)	4.431419
X1	0.027584
X2	0.010635
X3	0.011869
X4	0.070299
X5	.
X6	0.009621
X7	.
X8	0.293682

Verificar se um modelo candidato tem bom desempenho em dados independentes daqueles usados para ajuste.

- Coletar novos dados para verificar o modelo e seu poder preditivo.
- Deixar parte dos dados de fora do ajuste e utilizá-los na validação.

Esta segunda alternativa é a abordagem utilizada em aprendizado de máquina, quando o conjunto de dados é separado em **treinamento** e **teste**.

Validação do Modelo

Quando temos um grande número de observações, podemos dividir os dados em duas partes: **treinamento** e **teste**.

- **Conjunto de treinamento:** usado para estimar os parâmetros do modelo.
- **Conjunto de teste:** usado para avaliar o desempenho do modelo.



Validação do Modelo

Depois de ajustado o modelo usando o conjunto de **treinamento**, calculamos o Erro de Predição Quadrático Médio (*Mean Squared Prediction Error*) no conjunto de **teste**:


$$MSPE = \frac{1}{n^*} \sum_{i=1}^{n^*} (Y_i - \hat{Y}_i)^2$$

em que Y_i é o valor da variável resposta da i -ésima observação do conjunto teste, $\hat{Y}_i$ é o valor predito para a i -ésima observação do conjunto teste segundo o modelo usando o conjunto treinamento e n^* é o total de observações no conjunto teste.

Quando o conjunto de dados não é muito grande e, portanto, não permite a separação em treinamento e teste, pode-se usar **validação cruzada**.

Validação Cruzada K-Fold

Aqui está uma ilustração do Método de Validação Cruzada *K-fold* (K dobras).



Se em cada dobra nós deixarmos apenas uma observação, temos o método de validação cruzada conhecido como “Leave-one-out*”.

Exemplo

Temos 54 observações que não foram utilizadas na escolha do modelo para os dados sobre cirurgia. Este será o conjunto de dados **teste**.

Com os dados de **treinamento**, obtemos os seguintes modelos.

Usando BIC_p temos o **Modelo 1**:

$$\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_8 X_8 + \varepsilon$$

Usando C_p , temos o **Modelo 2**:

$$\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_8 X_8 + \varepsilon$$

Usando $R_{adj,p}^2$, temos o **Modelo 3**:

$$\ln(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_6 X_6 + \beta_8 X_8 + \varepsilon$$

Exemplo - Modelo 1

```
dadosT <- read.table("./dados/CH09TA05.txt")  
colnames(dadosT) = c("X1", "X2", "X3", "X4", "X5", "X6", "X7", "X8", "Y", "lnY")  
  
modelo1 <- lm(lnY ~ X1 + X2 + X3 + X8, data=dados)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.85242	0.19270	19.992	0.00000
X1	0.07332	0.01897	3.865	0.00033
X2	0.01419	0.00173	8.196	0.00000
X3	0.01545	0.00140	11.072	0.00000
X8	0.35297	0.07719	4.573	0.00003

Predição para os dados de teste:

```
yhat <- predict(modelo1, newdata=dadosT)
```

MSE é 0.044 e $MSPE$ é 0.077

Exemplo - Modelo 2

```
modelo2 <- lm(lnY ~ X1 + X2 + X3 + X5 + X8, data=dados)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.0381	0.2377	16.989	0.0000
X1	0.0736	0.0188	3.908	0.0003
X2	0.0141	0.0017	8.166	0.0000
X3	0.0155	0.0014	11.157	0.0000
X5	-0.0034	0.0026	-1.316	0.1944
X8	0.3412	0.0771	4.423	0.0001

Predição para os dados de teste:

```
yhat <- predict(modelo2, newdata=dadosT)
```

MSE é 0.044 e $MSPE$ é 0.08

Exemplo - Modelo 3

```
modelo3 <- lm(lnY ~ X1 + X2 + X3 + X5 + X6 + X8, data=dados)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.0540	0.2348	17.266	0.0000
X1	0.0715	0.0186	3.837	0.0004
X2	0.0138	0.0017	8.047	0.0000
X3	0.0151	0.0014	10.912	0.0000
X5	-0.0035	0.0026	-1.341	0.1862
X6	0.0873	0.0577	1.513	0.1369
X8	0.3509	0.0764	4.593	0.0000

Predição para os dados de teste:

```
yhat <- predict(modelo3, newdata=dadosT)
```

MSE é 0.043 e $MSPE$ é 0.079

Comparando os três modelos ajustados, temos:

Modelo	Preditores	MSE	$MSPE$
Modelo 1	X_1, X_2, X_3, X_8	0.044	0.077
Modelo 2	X_1, X_2, X_3, X_5, X_8	0.044	0.080
Modelo 3	$X_1, X_2, X_3, X_5, X_6, X_8$	0.043	0.079

Qual modelo você consideraria o melhor?

Comparando os três modelos ajustados, temos:


Modelo	Preditores	MSE	$MSPE$
Modelo 1	X_1, X_2, X_3, X_8	0.044	0.077
Modelo 2	X_1, X_2, X_3, X_5, X_8	0.044	0.080
Modelo 3	$X_1, X_2, X_3, X_5, X_6, X_8$	0.043	0.079

Qual modelo você consideraria o melhor?

Lembre-se sempre que **menos é mais!** Portanto, se pela métrica dois modelos são equivalentes, escolha sempre o menos complexo, pois ele terá maior interpretabilidade.

Leitura e Agradecimentos

- Kutner, M.H., Nachtsheim, C.J., Neter, J. and Li, W. (2005) Applied Linear Statistical Models. 5th Edition, McGraw-Hill, Irwin, New York. Capítulo 9.
- Draper, N. R. and Smith, H. - Applied Regression Analysis: Capítulo 15.
- Linear Model Selection - UC Business Analytics R Programming Guide:
https://uc-r.github.io/model_selection
- Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. JRSS B, 58(1), 267–288.



Agradecimentos: parte de material foi criado pela profa. Samara Kiihl - IMECC/Unicamp.