



AUTORES:

DANIELA CIELO

LUCAS LIMA

GEOVANI ARIEL

Contexto

- Base retirada do Kaggle com informações de 2000 a 2015 para 193 países.
- Abrange variáveis de imunização (Hepatite B, Polio, Difteria), Mortalidade, Percentual Despesa, aspectos sociais e outros indicadores de saúde.
- Finalidade: ajudar países a identificar quais fatores mais contribuem para baixa expectativa de vida, orientando políticas públicas

Pais	Ano	Status_Pais	Expectativa_Vida	Mortalidade_Adulto	Mortalidade_Infantil	Alcool	Percentual_Despesa	Hepatite_B	Sarampo	IMC	Mortes_Menores_Cinco_Anos	Poliomielite	Despesa_Total	Difteria	HIV_AIDS	PIB
Afghanistan	2015	Developing	65.0	263	62	0.01	7.127962e+01	65	1154	19.1	83	6	8.16	65	0.1	584.259210
Afghanistan	2014	Developing	59.9	271	64	0.01	7.352358e+01	62	492	18.6	86	58	8.18	62	0.1	612.696514
Afghanistan	2013	Developing	59.9	268	66	0.01	7.321924e+01	64	430	18.1	89	62	8.13	64	0.1	631.744976
Afghanistan	2012	Developing	59.5	272	69	0.01	7.818422e+01	67	2787	17.6	93	67	8.52	67	0.1	669.959000
Afghanistan	2011	Developing	59.2	275	71	0.01	7.097109e+00	68	3013	17.2	97	68	7.87	68	0.1	63.537231
Afghanistan	2010	Developing	58.8	279	74	0.01	7.967937e+01	66	1989	16.7	102	66	9.20	66	0.1	553.328940
Afghanistan	2009	Developing	58.6	281	77	0.01	5.676222e+01	63	2861	16.2	106	63	9.42	63	0.1	445.893298
Afghanistan	2008	Developing	58.1	287	80	0.03	2.587393e+01	64	1599	15.7	110	64	8.33	64	0.1	373.361116
Afghanistan	2007	Developing	57.5	295	82	0.02	1.091016e+01	63	1141	15.2	113	63	6.73	63	0.1	369.835796
Afghanistan	2006	Developing	57.3	295	84	0.03	1.717152e+01	64	1990	14.7	116	58	7.43	58	0.1	272.563770
Afghanistan	2005	Developing	57.3	291	85	0.02	1.388648e+00	66	1296	14.2	118	58	8.70	58	0.1	25.294130
Afghanistan	2004	Developing	57.0	293	87	0.02	1.529607e+01	67	466	13.8	120	5	8.79	5	0.1	219.141353
Afghanistan	2003	Developing	56.7	295	87	0.01	1.108905e+01	65	798	13.4	122	41	8.82	41	0.1	198.728544
Afghanistan	2002	Developing	56.2	3	88	0.01	1.688735e+01	64	2486	13.0	122	36	7.76	36	0.1	187.845950

Introdução / Motivação

- Expectativa de vida é um indicador central de desenvolvimento e saúde populacional.
- Países com maior renda, melhor infraestrutura de saúde e mais escolaridade tendem a apresentar maior expectativa de vida.

Perguntas

- Quais fatores estão mais associados à expectativa de vida ?
- Quanto a escolaridade média contribui após controlar por outros indicadores?
- Mais escolaridade → maior expectativa de vida ?

Objetivo

- Construir um modelo de regressão linear para explicar e prever a expectativa de vida
- Utilizar a Expectativa de vida como **variável resposta** (Y) .
- Considerar múltiplas variáveis independentes, incluindo :
 - **Escolaridade**
 - **Mortalidade adulta e infantil**
 - **Indicadores de saúde e condições socioeconômicas**
- Fornecer evidências que ajudem a entender quais variáveis estão mais associadas a maior ou menor expectativa de vida.

Limitação da Base de Dados

- O conjunto de dados possui informações de vários países ao longo de diversos anos.
- Isso gera dependência temporal : as observações de um mesmo país em anos consecutivos não são independentes
- Conjunto de dados em painel
- Violação da **independência dos erros**

Base de Dados

Tabela 1: Resumo Geral da Base de Dados

Nº total de observações	Nº de países	Cobertura Temporal		
		Ano inicial	Ano final	Período (anos)
2938	193	2000	2015	15

Nota:

Dados referentes ao período 2000 – 2015, abrangendo 193 países

- Contém 22 variáveis por observação, combinando dados demográficos, socioeconômicos, de saúde, mortalidade, imunização, e outros fatores relevantes
- Indicadores econômicos e demográficos: PIB , população, composição de renda/recursos, despesa pública com saúde, anos médios de escolaridade
- Combina múltiplos domínios (saúde + economia + educação), possibilitando uma análise multivariada rica.

Base de Dados

- Durante o pré-processamento, foram adotados os seguintes procedimentos:
- Verificação de consistência e remoção de valores manifestamente inválidos.
- Padronização dos tipos de variáveis e tradução dos nomes para o português (sem acentos), facilitando a interpretação.
- Remoção de variáveis com grande proporção de valores faltantes ou baixa relevância empírica.
- Tratamento de colinearidade, com combinação de variáveis altamente correlacionadas quando apropriado.
- As variáveis País e Ano foram mantidas apenas para identificação e visualização, já que não representam observações independentes e por isso não entram diretamente na modelagem de regressão.

ANÁLISE EXPLORATÓRIA



n	media	sd	min	q1	mediana	q3	max
2928	69.22493	9.523867	36.3	63.1	72.1	75.7	89

A variável resposta deste estudo é a Expectativa_Vida, medida em anos. O resumo descritivo indica:

- Média: 69.22 anos
- Desvio-padrão: 9.52 anos
- Mínimo / Máximo: 36.3 – 89 anos
- Mediana: 72.1 anos

A amplitude elevada revela a coexistência de países muito desenvolvidos (acima de 80 anos) e países em situação sanitária crítica (abaixo de 50 anos).

EVOLUÇÃO AO LONGO DOS ANOS




PROPORCAO DE VALORES FALTANTES POR STATUS DO PAIS

Proporção de valores faltantes por status do país

Status_Pais	Variavel	Prop_NA
Em desenvolvimento	alcool	0.068
Em desenvolvimento	composicao_renda_recursos	0.049
Em desenvolvimento	despesa_total	0.080
Em desenvolvimento	escolaridade	0.047
Em desenvolvimento	hepatitis_b	0.157
Em desenvolvimento	pib	0.158
Em desenvolvimento	populacao	0.229
Desenvolvido	alcool	0.055
Desenvolvido	composicao_renda_recursos	0.094
Desenvolvido	despesa_total	0.062
Desenvolvido	escolaridade	0.094
Desenvolvido	hepatitis_b	0.338
Desenvolvido	pib	0.125
Desenvolvido	populacao	0.188

Matriz de correlação das variáveis selecionadas



CORRELAÇÕES

Pares de variáveis numéricas com correlação forte ($|r| \geq 0,7$)

Var1	Var2	Cor
mortalidade_infantil	mortes_menores_cinco_anos	0.997
magreza	magreza_5_9_anos	0.985
magreza	magreza_1_19_anos	0.984
magreza_1_19_anos	magreza_5_9_anos	0.939
percentual_despesa	pib	0.899
composicao_renda_recursos	escolaridade	0.800

As variáveis Magreza_1_19 e Magreza_5_9 foram combinadas em um único indicador Magreza reduzindo redundância e melhorando estabilidade do modelo.

TRATAMENTO DE DADOS

APÓS REMOVER VARIÁVEIS COM MUITOS NA E LIDAR COM COLINEARIDADE:

- A BASE FINAL PARA MODELAGEM PASSOU DE **2938** PARA **2562** OBSERVAÇÕES.
- O NÚMERO DE PREDITORES FICOU REDUZIDO A **11** **VARIÁVEIS** NO MODELO COMPLETO.

RESULTADOS DO MODELO INICIAL

Coefficientes do modelo completo

Termo	Estimate	Std. Error	t value	Pr(t)
Intercepto	50.95	0.534	95.447	$< 2 \times 10^{-16}$
mortalidade_adulto	-0.0166	0.00083	-20.005	$< 2 \times 10^{-16}$
alcool	-0.0309	0.0246	-1.258	0.20868
percentual_despesa	0.00036	0.00004	8.625	$< 2 \times 10^{-16}$
imc	0.0354	0.00530	6.674	3.0×10^{-11}
poliomielite	0.0258	0.00475	5.427	6.3×10^{-8}
difteria	0.0315	0.00473	6.662	3.3×10^{-11}
hiv_aids	-0.4946	0.0175	-28.353	$< 2 \times 10^{-16}$
composicao_renda_recursos	7.455	0.625	11.938	$< 2 \times 10^{-16}$
escolaridade	0.942	0.0454	20.734	$< 2 \times 10^{-16}$
magreza	-0.0625	0.0223	-2.799	0.00516

RESULTADOS DO MODELO INICIAL

Medidas de ajuste do modelo completo

Medida	Valor
R^2	0.8223
R^2 ajustado	0.8216
Erro padrão residual	3.97
Estatística F (p-valor)	1180 ($p < 2 \times 10^{-16}$)

VIF (MULTICOLINEARIDAD)

A TABELA APRESENTA OS FATORES DE INFLAÇÃO DA VARIÂNCIA (VIF) PARA O MODELO COMPLETO. OS VALORES VARIAM APROXIMADAMENTE ENTRE 1,3 E 3,5, SENDO ESCOLARIDADE ($VIF \approx 3,46$) E COMPOSICAO_RENDA_RECURSOS ($VIF \approx 2,76$) AS VARIÁVEIS COM MAIOR VIF. ESSES RESULTADOS SÃO COMPATÍVEIS COM A CORRELAÇÃO ELEVADA OBSERVADA ANTERIORMENTE ENTRE ESSES DOIS INDICADORES SOCIOECONÔMICOS.

Variavel	VIF
Escolaridad	3.46
Composicao_Renda_Recurso	2.76
Difteria	1.95
Poliomielite	1.93
IMC	1.78

Mortalidade_Adulto	1.73
Magreza_media	1.62
Alcool	1.58
HIV_AIDS	1.43
Percentual_Despesa	1.29

MODELO STEPWISE

A PARTIR DO MODELO COMPLETO, FOI REALIZADA UMA SELEÇÃO AUTOMÁTICA DE VARIÁVEIS VIA CRITÉRIO DE INFORMAÇÃO DE AKAIKE (AIC), UTILIZANDO UM PROCEDIMENTO STEPWISE BIDIRECIONAL.

Tabela: Estimativas dos coeficientes do modelo selecionado (stepwise)				
Term	Estimate	Std.Error	Statistic	P.value
(Intercept)	50.994	0.532	95.786	0.00
Mortalidade_Adulto	-0.017	0.001	-20.173	0.00
Percentual_Despesa	0.000	0.000	8.534	0.00
IMC	0.036	0.005	6.726	0.00
Poliomielite	0.026	0.005	5.435	0.00
Difteria	0.032	0.005	6.686	0.00
HIV_AIDS	-0.496	0.017	-28.518	0.00
Composicao_Renda_Recursos	7.431	0.624	11.902	0.00
Escolaridade	0.925	0.043	21.298	0.00
Magreza_media	-0.056	0.022	-2.590	0.01

MODELO STEPWISE

Medidas de ajuste do modelo stepwise

Medida	Valor
R^2	0,822
R^2 ajustado	0,822
Erro padrão residual	3,970

O MODELO SELECIONADO REMOVEU APENAS A VARIÁVEL ****ALCOOL****,
RESULTANDO EM:


- MENOR AIC E BIC
- R^2 AJUSTADO LIGEIRAMENTE MAIOR
- CLAREZA INTERPRETATIVA APRIMORADA

MODELO FINAL

O MODELO DE REGRESSAO LINEAR MULTIPLA AJUSTADO E:

$$\begin{aligned} \text{Expectativa_Vida} = & \beta_0 + \beta_1 \cdot \text{Mortalidade_Adulto} + \beta_2 \cdot \text{Percentual_Despesa} + \beta_3 \cdot \text{Imc} + \beta_4 \cdot \text{Poliomielite} \\ & + \beta_5 \cdot \text{Difteria} + \beta_6 \cdot \text{Hiv_Aids} + \beta_7 \cdot \text{Composicao_Renda_Recursos} + \beta_8 \cdot \text{Escolaridade} \\ & + \beta_9 \cdot \text{Magreza} + \varepsilon. \end{aligned}$$

DISTANCIA DE COOK





A ANÁLISE DAS DISTÂNCIAS DE COOK MOSTRA DIVERSOS PONTOS COM VALORES MAIS ALTOS, INDICANDO OBSERVAÇÕES INFLUENTES.

ESSES PONTOS CORRESPONDEM A PAÍSES COM CONDIÇÕES EXTREMAS, TAIS COMO:



- EPIDEMIAS SEVERAS (EX.: HIV INTENSO),**
- CONFLITOS ARMADOS,**
- CRISES HUMANITÁRIAS,**
- VARIAÇÕES ABRUPTAS NA COBERTURA VACINAL,**
- VALORES POPULACIONAIS ATÍPICOS.**

DIAGNÓSTICO DO MODELO



Heterocedasticidade:
tratada com erros robustos

Resíduos:
levemente não normais, mas
aceitáveis



Presença de pontos
influentes, porém sem
comprometer o modelo

CONCLUSÕES

- O modelo final explica mais de 82% da variabilidade da expectativa de vida.
- Todas as variáveis incluídas são estatisticamente significativas, mesmo com erros robustos à heterocedasticidade.
- A direção dos efeitos é coerente com o que se espera em epidemiologia e economia da saúde.
- Não há multicolinearidade problemática nem pontos excessivamente dominantes, de acordo com os VIFs e as distâncias de Cook.
- Há, de fato, heterocedasticidade, mas a inferência é corrigida por meio de erros-padrão robustos.

REFERÊNCIAS

- World Health Organization (WHO). World Health Statistics.
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). Introduction to Linear Regression Analysis.

(OBRIGADO)

