

Trabalho 1 - ME613 : Analise de Regressao

Daniela Cielo: RA: 298825

Geovani Ariel: RA: 236124

Lucas Lima: RA: 263267

2º semestre de 2025

Sumário

Introducao e Motivacao	1
Materiais e Metodos	2
Base de dados e variaveis	2
Avaliacao de valores faltantes	3
Estrategia de análise	3
Analise da variavel resposta	4
Construcao pratica da base de modelagem	7

Introducao e Motivacao

A expectativa de vida é um indicador fundamental para avaliar o nível de saúde e desenvolvimento de uma população, refletindo não apenas as condições médicas, mas também fatores socioeconômicos, ambientais e de políticas públicas. Ao sintetizar o tempo médio de vida que uma coorte hipotética de indivíduos teria, caso permanecessem expostos as taxas de mortalidade observadas em determinado período, esse indicador fornece uma visão abrangente das condições de vida em diferentes países e contextos históricos.

Nas últimas décadas, o aumento da expectativa de vida tem sido um dos fenômenos demográficos mais marcantes em grande parte do mundo, especialmente em países desenvolvidos. No entanto, essa evolução não é homogênea: muitas regiões ainda enfrentam desafios importantes relacionados a mortalidade infantil, doenças infecciosas, desnutrição, desigualdade de renda e acesso limitado a serviços básicos de saúde e educação. Essas disparidades revelam que ganhos agregados em expectativa de vida podem ocultar heterogeneidades relevantes entre países, grupos populacionais e períodos de tempo.

Do ponto de vista de políticas públicas, compreender os determinantes da expectativa de vida é essencial para orientar decisões estratégicas, como priorização de investimentos em saúde, educação e infraestrutura social. Além disso, a análise conjunta de variáveis de mortalidade, indicadores econômicos e fatores sociais permite investigar em que medida os avanços em desenvolvimento humano se traduzem, de fato, em melhores condições de sobrevivência e bem-estar da população.

Nesse contexto, este trabalho analisa a relação entre a expectativa de vida e um conjunto de variáveis explicativas associadas a fatores de mortalidade, imunização, condições econômicas e fatores sociais, utilizando um conjunto de dados em painel com países observados ao longo do tempo. A partir de técnicas de análise exploratória e modelagem de regressão, busca-se identificar quais fatores apresentam maior associação com a expectativa de vida e discutir implicações para políticas públicas e planejamento em saúde.

Materiais e Metodos

Nesta seção descrevemos o banco de dados utilizado, as variáveis consideradas e os principais procedimentos adotados no tratamento e na preparação dos dados para análise.

Base de dados e variáveis

O conjunto de dados utilizado contém informações anuais sobre diversos países, incluindo:

- **Expectativa_Vida**: variável resposta, medida em anos;
- Indicadores de **Mortalidade** (Mortalidade_Adulto, Mortalidade_Infantil);
- Indicadores de **Saúde e Imunização** (Hepatite_B, Poliomielite, Difteria, HIV_AIDS);
- Variáveis **Econômicas e Sociais** (PIB, Composição_Renda_Recursos, Escolaridade, Percentual_Despesa, Despesa_Total);
- Variáveis **Nutricionais e Demográficas** (IMC, Magreza_1_19_Anos, Magreza_5_9_Anos, População).

Tabela 1: Resumo Geral da Base de Dados

Nº total de observações	Nº de países	Cobertura Temporal		
		Ano inicial	Ano final	Período (anos)
2938	193	2000	2015	15

Nota:

Dados referentes ao período 2000 – 2015, abrangendo 193 países

Tabela 2: Valores Faltantes por Coluna

Coluna	Quantidade_NA	Percentual_NA
Populacao	652	22.19
Hepatite_B	553	18.82
PIB	448	15.25
Despesa_Total	226	7.69
Alcool	194	6.60
Composicao_Renda_Recursos	167	5.68
Escolaridade	163	5.55
IMC	34	1.16
Magreza_1_19_Anos	34	1.16
Magreza_5_9_Anos	34	1.16
Poliomielite	19	0.65
Difteria	19	0.65
Expectativa_Vida	10	0.34
Mortalidade_Adulto	10	0.34

Avaliacao de valores faltantes

Antes da modelagem, e necessario avaliar a presenca de **valores faltantes (NA)**, pois colunas com muitos NA podem reduzir bastante o numero de observacoes utilizaveis e comprometer a estabilidade das estimativas.

Para um modelo de regressão linear, a presença de valores NA pode ser problemática porque a maioria dos algoritmos não lida bem com dados faltantes. As opções comuns são:

1.**Remover observações com NA:** Isso pode ser feito se a quantidade de NA não for muito grande e se a remoção não introduzir viés. No entanto, se removermos todas as observações que têm pelo menos um NA, podemos acabar com um conjunto de dados muito pequeno.

2.**Remover colunas com muitos NA:** Se uma variável tem muitos NA, ela pode não ser muito informativa. Além disso, se a coluna não for muito relevante para o modelo, pode ser melhor removê-la.

3.**Imputação de valores:** Em vez de remover, podemos preencher os valores faltantes com alguma estatística (média, mediana, moda).

Estrategia de análise

A estratégia de análise utilizada neste trabalho segue os seguintes passos:

1. **Análise descritiva da variavel resposta**, incluindo resumo estatistico e comparacao por Status_Pais e ao longo do tempo;

2. Análise de correlacao, avaliando:

- correlacao entre cada variavel numerica e a Expectativa_Vida;
- correlacao entre os proprios preditores, para identificar possivel multicolinearidade;

3. Definicao da base para modelagem, com:

- exclusao de colunas com alta proporcao de NA e baixa correlacao com a variavel resposta (**Populacao e Hepatite_B**) ;
- combinacao de variaveis altamente correlacionadas e conceitualmente proximas (Magreza_1_19_Anos e Magreza_5_9_Anos) em uma unica variavel **Magreza**.

A modelagem de regressao (na etapa seguinte do trabalho) sera realizada utilizando essa base reduzida, mais adequada em termos de qualidade da informacao e estabilidade numerica.

Analise da variavel resposta

Tabela 3: Resumo descritivo da variavel resposta

n	Média	Desvio Padrão	Mínimo	Q1	Mediana	Q3	Máximo
2938	69.22	9.52	36.3	63.1	72.1	75.7	89


O resumo descritivo indica que a expectativa de vida apresenta ampla variacao entre observacoes, mas com concentracao em torno de valores intermediarios a altos, sugerindo heterogeneidade entre contextos mais e menos desenvolvidos.

Tabela 4: Resumo da expectativa de vida por status do pais


Status_Pais	n	media	sd	min	q1	mediana	q3	max
Developed	512	79.20	3.93	69.9	76.8	79.25	81.7	89
Developing	2416	67.11	9.01	36.3	61.1	69.00	74.0	89

Os resultados por **Status_Pais** evidenciam que paises desenvolvidos tendem a apresentar maior expectativa de vida media e menor variabilidade, ao passo que paises em desenvolvimento exibem media menor e maior dispersao.

Evolução temporal da expectativa de vida (média global)



Evolução da expectativa de vida por status do país




Os graficos temporais mostram uma tendencia de aumento da expectativa de vida ao longo dos anos para ambos os grupos de paises, com nivel consistentemente mais alto entre os paises desenvolvidos.

Tabela 5: Resumo da expectativa de vida por status do país

Status_Pais	n	media	sd	min	q1	mediana	q3	max
Developed	512	79.20	3.93	69.9	76.8	79.25	81.7	89
Developing	2416	67.11	9.01	36.3	61.1	69.00	74.0	89

A identificacao de pares de preditores com **alta correlacao** e importante para evitar problemas de multicolinearidade na regressao. Nesse contexto, destaca-se o par formado por **Magreza_1_19_Anos** e **Magreza_5_9_Anos**, que apresentam correlacao elevada entre si e medem fenomenos muito proximos (magreza em faixas etarias infantis semelhantes).



A matriz de correlacao para esse subconjunto reforca a interpretacao de que:

- a expectativa de vida esta fortemente associada a fatores de mortalidade, nutricionais e socioeconomicos;
- Magreza_1_19_Anos e Magreza_5_9_Anos sao fortemente correlacionadas entre si, justificando a criacao de um indicador sintetico para a fase de modelagem.

Construcao pratica da base de modelagem

Com base nas informacoes de NA e de correlacao, adotamos duas decisoes para a construcao da base de modelagem:

1. **Exclusao de Populacao e Hepatite_B:** ambas apresentaram **alta proporcao de valores faltantes** e **correlacao fraca com Expectativa_Vida**, de modo que sua inclusao no modelo reduziria o numero de casos disponiveis sem trazer ganho relevante de explicacao.
2. **Combinacao de Magreza_1_19_Anos e Magreza_5_9_Anos em Magreza:** as duas variaveis sao altamente correlacionadas e representam a mesma dimensao (magreza infantil em faixas etarias proximas). Para reduzir dimensionalidade e multicolinearidade, definimos uma unica variavel: