

Trabalho Final - ME613 : Analise de Regressao

Daniela Cielo: RA: 298825

Geovani Ariel: RA: 236124

Lucas Lima: RA: 263267

2º semestre de 2025

Introdução

A **expectativa de vida** é um indicador central de saúde e desenvolvimento humano. Em geral, países com maior renda, melhor infraestrutura sanitária e maior escolaridade tendem a apresentar maior longevidade, embora essas relações nem sempre sejam lineares ou independentes.

Este estudo analisa dados em painel de **193 países (2000–2015)** para modelar a expectativa de vida a partir de diversos indicadores socioeconômicos e de saúde, avaliando seus efeitos relativos e as limitações do modelo linear utilizado.

Perguntas de pesquisa

1. Quais fatores estão mais associados à expectativa de vida após controlar pelos demais?
2. Quanto a escolaridade média contribui para a expectativa de vida?
3. O status de país desenvolvido explica diferenças de longevidade mesmo após controle?
4. Há tendência temporal positiva ao longo dos anos analisados?

Hipóteses

- **H1:** Escolaridade maior $\rightarrow$ expectativa de vida maior.
- **H2:** Mortalidade adulta maior $\rightarrow$ expectativa de vida menor.
- **H3:** Mortalidade infantil maior $\rightarrow$ expectativa de vida menor.
- **H4:** Países desenvolvidos apresentam maior expectativa de vida mesmo após controle.
- **H5:** A expectativa de vida cresce ao longo do tempo.

Essas hipóteses servem como base teórica para as análises realizadas.

Materiais e Métodos

Table 1: Resumo Geral da Base de Dados

Nº total de observações	Nº de países	Ano inicial	Ano final	Período (anos)
2938	193	2000	2015	15

Base de dados e pré-processamento

A base utilizada neste estudo é o conjunto “**Life Expectancy (WHO)**”, que reúne dados anuais de até **193 países** entre **2000 e 2015**, incluindo indicadores de mortalidade, imunização, condições socioeconômicas, nutrição e características demográficas.

No pré-processamento, foram realizados:

- **Verificação e limpeza dos dados**, removendo valores inconsistentes.
- **Padronização e renomeação** das variáveis para facilitar a interpretação.
- **Exclusão de variáveis com muitos valores faltantes** ou baixa relevância.
- **Tratamento de colinearidade**, combinando variáveis altamente correlacionadas.

As variáveis **Pais** e **Ano** foram mantidas apenas para fins de identificação e visualização, pois **não representam observações independentes** e, portanto, não foram incluídas na modelagem de regressão.

Principais variáveis analisadas

A seguir, listamos as variáveis utilizadas na etapa exploratória e de modelagem:

- **Expectativa_Vida**: variável resposta, medida em anos.
- **Mortalidade_Adulto**: probabilidade de morte entre 15 e 60 anos por 1.000 habitantes.
- **Mortalidade_Infantil**: número de óbitos de menores de 1 ano por 1.000 nascidos vivos.
- **Mortes_Menores_Cinco_Anos**: óbitos de crianças menores de 5 anos por 1.000 habitantes.
- **Alcool**: consumo médio estimado de álcool per capita.
- **IMC**: índice de massa corporal médio da população adulta.
- **Sarampo**: casos notificados por unidade populacional (indicador de morbidade e imunização).
- **Poliomielite**: cobertura vacinal contra poliomielite (%).
- **Difteria**: cobertura vacinal DTP3 (%).
- **HIV_AIDS**: taxa de mortalidade associada ao HIV/AIDS por 100.000 habitantes.

- **Percentual_Despesa:** gasto público com saúde (% do PIB).
- **Despesa_Total:** gasto total per capita (público + privado).
- **PIB:** produto interno bruto per capita em dólares internacionais.
- **Composicao_Renda_Recursos:** componente de renda do IDH (0 a 1).
- **Escolaridade:** anos médios de estudo da população adulta.
- **Magreza_1_19_Anos** e **Magreza_5_9_Anos:** prevalência de magreza em diferentes faixas etárias infantis.
- **Populacao:** população total do país.
- **Status_Pais:** fator indicando se o país é **Desenvolvido** ou **Em desenvolvimento**.

Análise exploratória

Table 2: Resumo descritivo da variavel resposta



n	Média	Desvio Padrão	Mínimo	Q1	Mediana	Q3	Máximo
2938	69.22	9.52	36.3	63.1	72.1	75.7	89

A variável resposta deste estudo é a **Expectativa_Vida**, medida em anos. O resumo descritivo (Tabela 2) indica:

- **Média:** 69.22 anos
- **Desvio-padrão:** 9.52 anos
- **Mínimo / Máximo:** 36.3 — 89 anos
- **Mediana:** 72.1 anos

A amplitude elevada revela a coexistência de países muito desenvolvidos (acima de **80 anos**) e países em situação sanitária crítica (abaixo de **50 anos**).

A distribuição apresenta **assimetria à esquerda**, com maior concentração entre 60 e 80 anos, indicando que a maior parte dos países se encontra em faixas intermediárias, enquanto valores muito baixos são menos frequentes, mas extremamente problemáticos.



Status x Expectativa



O boxplot mostra clara separação entre os grupos:

- Países **Desenvolvidos** apresentam expectativa de vida entre **78 e 82 anos**, com baixa dispersão.
- Países **Em desenvolvimento** variam muito mais, entre **60 e 72 anos**, com presença de valores extremos baixos.

Evolução temporal da expectativa de vida

O gráfico de média global por ano mostra:

- **Tendência claramente crescente** entre 2000 e 2015.
- Aumento de aproximadamente **4 anos** no período analisado.
- Crescimento acelerado entre **2005 e 2011**.
- Leve desaceleração após 2011, mas ainda positiva.



Já o gráfico separado por status mostra que:

- Ambos os grupos apresentam crescimento claro.
- Países desenvolvidos começam em ~78 anos e chegam a >80 anos.
- Países em desenvolvimento começam em ~65 anos e chegam a ~70 anos.
- **A distância entre os grupos permanece praticamente constante.**

A ausência de convergência sugere que melhorias absolutas ocorrem, mas diferenças estruturais profundas (renda, desigualdade, sistemas de saúde) impedem que países emergentes alcancem rapidamente os níveis dos desenvolvidos.

Valores Faltantes (NA)

Antes da modelagem, é essencial avaliar a presença de **valores faltantes (NA)**, pois modelos de regressão linear não lidam automaticamente com dados ausentes. A Tabela 3 resume as proporções de NA por variável e por status do país.

As diferenças entre países desenvolvidos e em desenvolvimento existem, mas **não são suficientemente grandes para sugerir viés sistemático**. Remover variáveis com alta proporção de NA e, em seguida, remover apenas observações restantes com NA nas variáveis finais (**listwise deletion**). Essa abordagem preserva a consistência e evita introduzir incerteza de imputações artificiais.

Table 3: Proporção de valores faltantes por coluna

variavel	na_total	percentual
alcool	194	6.603
hepatitis_b	553	18.822
despesa_total	226	7.692
pib	448	15.248
populacao	652	22.192
composicao_renda_recursos	167	5.684
escolaridade	163	5.548

Table 4: Proporção de valores faltantes por variável e status do país (NA Alto).

variavel	Em desenvolvimento	Desenvolvido
alcool	0.068	0.055
composicao_renda_recursos	0.049	0.094
despesa_total	0.080	0.062
escolaridade	0.047	0.094
hepatitis_b	0.157	0.338
pib	0.158	0.125
populacao	0.229	0.188


Colinearidade

Table 5: Pares de va's numéricas com correlacao forte ($|r| \geq 0.7$)

var1	var2	cor
------	------	-----

mortalidade_infantil	mortes_menores_cinco_anos	0.997
magreza_1_19_anos	magreza_5_9_anos	0.939
percentual_despesa	pib	0.899
composicao_renda_recursos	escolaridade	0.800

As variáveis **Magreza_1_19** e **Magreza_5_9** foram combinadas em um único indicador **magreza**, reduzindo redundância e melhorando estabilidade do modelo.



Modelagem

Seleção de variáveis e preparação para modelagem

- A base final para modelagem passou de **2938 para 2562 observações**.
- O número de preditores ficou reduzido a **11 variáveis** no modelo completo.

Após o pré-processamento, a base de dados final para modelagem passou a conter **2562 observações** e **11 variáveis preditoras**. O primeiro modelo ajustado foi um **modelo de regressão linear múltipla completo**, contendo todas as variáveis selecionadas.

Os principais resultados do modelo completo foram:

- $R^2 = 0.8223$, indicando excelente capacidade explicativa.
- R^2 ajustado = **0.8216**, reforçando que o modelo não está superajustado.
- A maioria dos coeficientes apresentou **alta significância estatística**.

- O erro padrão residual foi de **3.97 anos**, o que é razoável em dados de países.

Interpretação inicial:

Um R^2 acima de **0.80** é raro em estudos comparativos internacionais de saúde. Isso mostra que o conjunto de variáveis escolhidas captura grande parte da variação observada entre países, reforçando a relevância dos determinantes analisados.

Avaliação de Multicolinearidade (VIF)

A Tabela 6 apresenta os **Fatores de Inflação da Variância (VIF)**. Nenhuma variável apresentou VIF > 5, e todas ficaram abaixo de 3.5. Valores bem aceitáveis.

Table 6: Fatores de inflacao da variancia (VIF) - modelo completo

Variavel	VIF
escolaridade	3.46
composicao_renda_recursos	2.76
difteria	1.95
poliomielite	1.93
imc	1.78
mortalidade_adulto	1.73
magreza	1.62
alcool	1.58
hiv_aids	1.43
percentual_despesa	1.29

Seleção do modelo via Stepwise (AIC)

Para aprimorar parcimônia e comparar desempenho, foi realizado um procedimento **stepwise bidirecional** baseado no critério de informação de Akaike (AIC). O modelo selecionado removeu apenas a variável **alcool**, resultando em:

- Menor AIC e BIC
- R^2 ajustado ligeiramente maior
- Clareza interpretativa aprimorada

Modelo Final

$$\begin{aligned} \text{Expectativa_Vida} = & \beta_0 + \beta_1 \cdot \text{Mortalidade_Adulto} + \beta_2 \cdot \text{Percentual_Despesa} + \beta_3 \cdot \text{IMC} \\ & + \beta_4 \cdot \text{Poliomielite} + \beta_5 \cdot \text{Difteria} + \beta_6 \cdot \text{HIV_AIDS} \\ & + \beta_7 \cdot \text{Composicao_Renda_Recursos} + \beta_8 \cdot \text{Escolaridade} + \beta_9 \cdot \text{Magreza} + \varepsilon. \end{aligned}$$

O modelo final apresenta:

- excelente ajuste ($R^2 > 0.82$)
- coeficientes consistentes com literatura epidemiológica

- variáveis estatisticamente significativas e substantivamente relevantes
- ausência de multicolinearidade relevante

Esses resultados sustentam a robustez da análise e permitem avançar para os diagnósticos do modelo.

Table 7: Coeficientes Estimados do Modelo Stepwise

Variável	Estimativa	Erro Padrão	Estatística t	Valor-p
Intercepto	50.9944	0.5324	95.7864	0.000000
Mortalidade Adulto	-0.0167	0.0008	-20.1734	0.000000
Percentual Despesa	0.0004	0.0000	8.5337	0.000000
IMC	0.0356	0.0053	6.7265	0.000000
Poliomielite	0.0258	0.0047	5.4348	0.000000
Difteria	0.0316	0.0047	6.6858	0.000000
HIV/AIDS	-0.4962	0.0174	-28.5180	0.000000
Composição de Renda/Recursos	7.4306	0.6243	11.9025	0.000000
Escolaridade	0.9249	0.0434	21.2983	0.000000
Magreza	-0.0564	0.0218	-2.5896	0.009665

Table 8: Coeficientes do modelo stepwise (IC 95%, erros-padrão clássicos)

Termo	Estimate	2.5 \%	97.5 \%
Intercepto	50.994	49.950	52.038
mortalidade_adulto	-0.017	-0.018	-0.015
percentual_despesa	0.000	0.000	0.000
imc	0.036	0.025	0.046
poliomielite	0.026	0.016	0.035
difteria	0.032	0.022	0.041
hiv_aids	-0.496	-0.530	-0.462
composicao_renda_recursos	7.431	6.206	8.655
escolaridade	0.925	0.840	1.010
magreza	-0.056	-0.099	-0.014

Diagnósticos do modelo

A análise diagnóstica é fundamental para verificar se os pressupostos da regressão linear múltipla são razoavelmente atendidos. Os gráficos de diagnóstico (resíduos vs ajustados, Q-Q plot, Scale-Location e alavancagem) fornecem uma visão ampla do comportamento dos resíduos.

Resíduos vs Valores Ajustados


- **Variância heterogênea** em diferentes níveis de valores ajustados;
- Leve padrão curvilíneo, sugerindo possibilidade de não linearidade residual.

Q-Q Plot dos resíduos

O Q-Q plot mostra leve desvio da normalidade nas extremidades (caudas), indicando a presença de outliers ou distribuições mais pesadas do que o normal.

Scale–Location (Resíduos Padronizados vs Ajustados)

O gráfico reforça a evidência de **heterocedasticidade**, com aumento da variância dos resíduos em valores ajustados mais altos.



Teste de heterocedasticidade (Breusch–Pagan)

O teste Breusch–Pagan resultou em:

- $BP = 329.97 \quad -p < 2.2e-16$

Há **heterocedasticidade significativa**.

Portanto, passamos a utilizar **erros-padrão robustos** é essencial para garantir validade da inferência.

Erros-padrão robustos (HC)

Para lidar com a heterocedasticidade, foram estimados erros-padrão robustos do tipo **HC1**.


Os coeficientes permaneceram praticamente iguais, mas os erros-padrão e valores t foram ajustados.

Distâncias de Cook (Influência)

A análise das **Distâncias de Cook** mostra diversos pontos com valores mais altos, indicando observações influentes.

Esses pontos correspondem a países com condições extremas, tais como:

- epidemias severas ; conflitos armados; crises humanitárias;
- variações abruptas na cobertura vacinal; valores populacionais atípicos.



Conclusão

O modelo final explica mais de **82%** da variação da expectativa de vida entre países, mostrando que fatores sociais, econômicos, nutricionais e epidemiológicos exercem papéis centrais na longevidade global. A seguir, apresentamos os efeitos estimados de cada variável de forma clara e visual:

- **Mortalidade_Adulto (-0,017)**
 - Cada **10 mortes adicionais por 1.000 adultos** reduzem a expectativa de vida em **~0,17 ano** (cerca de **2 meses**).
- **HIV_AIDS (-0,50)**
 - Cada **10 mortes a mais por 100.000 habitantes** por HIV/AIDS reduzem a expectativa de vida em aproximadamente **5 anos** — o efeito negativo mais forte do modelo.
- **Magreza Infantil (-0,056)**
 - Um aumento de **5 pontos percentuais** na prevalência de magreza implica redução de **~0,28 ano** (cerca de **3 meses**) na expectativa de vida.
- **Escolaridade (+0,93)**
 - Cada **1 ano adicional de escolaridade média** aumenta a expectativa de vida em **~0,93 ano** (quase **11 meses**).
 - É um dos determinantes positivos mais fortes.
- **Composicao_Renda_Recursos (+7,43)**
 - Um aumento de **0,1 ponto** no índice (IDH – renda) eleva a expectativa de vida em **~0,74 ano** (cerca de **9 meses**), refletindo melhores condições socioeconômicas.
- **Poliomielite (+0,026)**
 - Um aumento de **10 pontos percentuais** na cobertura vacinal gera um acréscimo de **~0,26 ano** (cerca de **3 meses**).
- **Difteria (+0,032)**
 - Um aumento de **10 pontos percentuais** na cobertura DTP3 eleva a expectativa em **~0,32 ano** (cerca de **4 meses**).
- **IMC (+0,036)**
 - Um aumento de **1 unidade** no IMC médio populacional está associado a **+0,04 ano** (~0,5 mês), indicando melhor nutrição geral.
- **Percentual_Despesa (+0,00036)**
 - Um aumento de **5 pontos percentuais** no gasto público em saúde adiciona cerca de **1 dia** à expectativa de vida — efeito pequeno isoladamente, mas relevante quando somado a outras políticas.